

Intelligenza Artificiale e Laboratorio

Planning, Sistemi a Regole e Incertezza

Roberto Micalizio

a.a. 2025/2026

Università degli Studi di Torino,
Dipartimento di Informatica



Ragionamento in Presenza di Incertezza

- Indichiamo con A_t il piano che ci fa partire per l'aeroporto t minuti prima del decollo
- Come stabilire se A_t ci porterà in aeroporto per tempo?

- Indichiamo con A_t il piano che ci fa partire per l'aeroporto t minuti prima del decollo
- Come stabilire se A_t ci porterà in aeroporto per tempo?

Problemi:

- Osservabilità parziale (stato delle strade, traffico, ecc.)
- Osservazioni imprecise (notizie traffico e meteo inesatte)
- Incertezza sul risultato delle azioni (la macchina non parte)
- Difficile modellare sistema nel suo complesso

- Indichiamo con A_t il piano che ci fa partire per l'aeroporto t minuti prima del decollo
- Come stabilire se A_t ci porterà in aeroporto per tempo?

Problemi:

- Osservabilità parziale (stato delle strade, traffico, ecc.)
- Osservazioni imprecise (notizie traffico e meteo inesatte)
- Incertezza sul risultato delle azioni (la macchina non parte)
- Difficile modellare sistema nel suo complesso

Un approccio puramente logico

- o 1) rischia di prendere **decisioni errate**: " A_{25} mi porta in aeroporto in tempo"
- o 2) porta a conclusioni che sono **troppo deboli** per il *decision making* " A_{25} arriverò in tempo, se il ponte non è bloccato, se non piove, se non ho lo pneumatico a terra, se ecc."

Incertezza

- Indichiamo con A_t il piano che ci fa partire per l'aeroporto t minuti prima del decollo
- Come stabilire se A_t ci porterà in aeroporto per tempo?

Problemi:

- Osservabilità parziale (stato delle strade, traffico, ecc.)
- Osservazioni imprecise (notizie traffico e meteo inesatte)
- Incertezza sul risultato delle azioni (la macchina non parte)
- Difficile modellare sistema nel suo complesso

Un approccio puramente logico

o 1) rischia di prendere **decisioni errate**: " A_{25} mi porta in aeroporto in tempo"

o 2) porta a conclusioni che sono **troppo deboli** per il *decision making* " A_{25} arriverò in tempo, se il ponte non è bloccato, se non piove, se non ho lo pneumatico a terra, se ecc."

(A_{1440} potrebbe dare sufficienti garanzie, ma dovrei dormire una notte in aeroporto!)

Perché l'approccio puramente logico non sempre funziona

- Consideriamo un semplice scenario medico:

$$\forall p. \text{Sintomo}(p, \text{MalDiDenti}) \Rightarrow \text{Malattia}(p, \text{Carie})$$

Perché l'approccio puramente logico non sempre funziona

- Consideriamo un semplice scenario medico:

$$\forall p. \text{Sintomo}(p, \text{MalDiDenti}) \Rightarrow \text{Malattia}(p, \text{Carie})$$

Errore: non sempre chi ha mal di denti ha la carie

- Correggiamo in:

$$\forall p. \text{Sintomo}(p, \text{MalDiDenti}) \Rightarrow \text{Malattia}(p, \text{Carie}) \vee \text{Malattia}(p, \text{Gengivite}) \vee \dots$$

Perché l'approccio puramente logico non sempre funziona

- Consideriamo un semplice scenario medico:

$$\forall p. \text{Sintomo}(p, \text{MalDiDenti}) \Rightarrow \text{Malattia}(p, \text{Carie})$$

Errore: non sempre chi ha mal di denti ha la carie

- Correggiamo in:

$$\forall p. \text{Sintomo}(p, \text{MalDiDenti}) \Rightarrow \text{Malattia}(p, \text{Carie}) \vee \text{Malattia}(p, \text{Gengivite}) \vee \dots$$

Problema: la lista di malattie che causano il mal di denti potrebbe essere lunga, magari non tutte note!

- Cambiamo punto di vista:

$$\forall p. \text{Malattia}(p, \text{Carie}) \Rightarrow \text{Sintomo}(p, \text{MalDiDenti})$$

Perché l'approccio puramente logico non sempre funziona

- Consideriamo un semplice scenario medico:

$$\forall p. \text{Sintomo}(p, \text{MalDiDenti}) \Rightarrow \text{Malattia}(p, \text{Carie})$$

Errore: non sempre chi ha mal di denti ha la carie

- Correggiamo in:

$$\forall p. \text{Sintomo}(p, \text{MalDiDenti}) \Rightarrow \text{Malattia}(p, \text{Carie}) \vee \text{Malattia}(p, \text{Gengivite}) \vee \dots$$

Problema: la lista di malattie che causano il mal di denti potrebbe essere lunga, magari non tutte note!

- Cambiamo punto di vista:

$$\forall p. \text{Malattia}(p, \text{Carie}) \Rightarrow \text{Sintomo}(p, \text{MalDiDenti})$$

Errore: non sempre chi ha la carie ha mal di denti

Perché l'approccio puramente logico non sempre funziona

- Consideriamo un semplice scenario medico:

$$\forall p. \text{Sintomo}(p, \text{MalDiDenti}) \Rightarrow \text{Malattia}(p, \text{Carie})$$

Errore: non sempre chi ha mal di denti ha la carie

- Correggiamo in:

$$\forall p. \text{Sintomo}(p, \text{MalDiDenti}) \Rightarrow \text{Malattia}(p, \text{Carie}) \vee \text{Malattia}(p, \text{Gengivite}) \vee \dots$$

Problema: la lista di malattie che causano il mal di denti potrebbe essere lunga, magari non tutte note!

- Cambiamo punto di vista:

$$\forall p. \text{Malattia}(p, \text{Carie}) \Rightarrow \text{Sintomo}(p, \text{MalDiDenti})$$

Errore: non sempre chi ha la carie ha mal di denti

Il problema è che **la relazione** tra Carie e MalDiDenti **non è conseguenza logica** in nessuna delle due direzioni

Conclusione: Può esserci una causalità, ma non è rigida e certa come quella assunta in una teoria logica!

Limiti della Logica del Primo Ordine

- **pigrizia**: elencare insieme completo di premesse/conseguenze richiede troppo lavoro; le regole diventano difficili da comprendere e utilizzare
- **ignoranza teorica**: non conosciamo tutto
- **ignoranza pratica**: anche se conosciamo tutto in generale, potremmo avere lacune sul caso specifico; es. per un paziente potremmo non aver fatto alcuni esami e quindi potremmo non essere in grado applicare le regole (*mancano sufficienti osservazioni*)

Soluzione: Probabilità

- La **probabilità** fornisce uno strumento per riassumere l'incertezza che deriva da pigrizia e ignoranza
- Assegnare una probabilità ad una formula corrisponde al **grado di credenza** nella verità della formula
 - NB. Probabilità dell'80% non vuol dire vera all'80%, *non è un grado associato alla verità (come in fuzzy logic), ma alla credenza*
- Credenze dipendono dalle **prove** (i.e., evidenze, osservazioni)
 - Tutti gli enunciati indicheranno sempre le prove alla base degli assegnamenti di probabilità
- Due casi:
 - **Probabilità a priori** : in assenza di prove
 - **Probabilità a posteriori (condizionata)**: dopo avere osservazioni

Come ci aiuta la probabilità: Decisioni Razionali

- Attribuiamo a A_{90} probabilità 95% di successo
- A_{120} e A_{1440} avranno probabilità anche maggiori ma sono necessariamente migliori?
- Per prendere **decisioni razionali** un agente deve avere **preferenze sugli esiti** delle sue azioni
- **Teoria dell'utilità** attribuisce ad ogni esito un grado di utilità per l'agente e permette all'agente di ragionare su esiti alternativi
- Agente razionale compie azioni che massimizzano l'utilità attesa:

Teoria delle decisioni =
Teoria delle Probabilità + Teoria dell'Utilità

Convenzioni sulla notazione

- *Variabile casuale* si riferisce a una parte del mondo il cui stato è inizialmente sconosciuto; può avere dominio continuo o discreto
- Probabilità saranno sempre associate a *proposizioni*. Nel nostro caso le proposizioni assumeranno la forma

$$X = val$$

Dove X è variabile casuale discreta e val è un valore del suo dominio

- con lettere minuscole a, b, c indicheremo variabili casuali generiche (astratte)
- con lettere maiuscole indicheremo variabili casuali di un dominio specifico

$$Range(Cavity) = \langle true, false \rangle$$

$$Range(Weather) = \langle sunny, rain, cloudy, snow \rangle$$

notare che il dominio è visto come una tupla ordinata

- Per semplificare la notazione quando la variabile è booleana:


$$cavity \equiv Cavity = true$$

$$\neg cavity \equiv Cavity = false$$

Assiomi delle Probabilità

- Per qualsiasi proposizione a e b
 1. $0 \leq P(a) \leq 1$
 2. $P(\text{true}) = 1$ and $P(\text{false}) = 0$
 3. $P(a \vee b) = P(a) + P(b) - P(a \wedge b)$

True



- (questi assiomi sono anche conosciuti come **Assiomi di Kolmogorov**)

- L'uso degli assiomi nella rappresentazione di “gradi di belief” come probabilità garantisce razionalità e consistenza delle decisioni
- De Finetti ha dimostrato che:
 - siano A_1 e A_2 due agenti che scommettono l'uno contro l'altro
 - se A_1 esprime un insieme di gradi di belief che violano gli assiomi della teoria delle probabilità, allora per A_2 , che rispetta gli assiomi della teoria delle probabilità, esiste una strategia (una combinazione di scommesse), che garantisce che A_1 perda ogni volta.
- I CF sono un esempio di gradi di belief che non soddisfano gli assiomi: trade-off tra poter ragionare con regole di buon senso (common-sense reasoning) e complessità computazionale

Evento Atomico

- **Evento Atomico**: specifica completa dello stato del mondo $\Rightarrow$ è un **assegnamento di valori a tutte le variabili casuali**
- *Proprietà*:
 - sono **mutuamente esclusivi**
 - *l'insieme di tutti gli eventi atomici descrive la verità o falsità di qualsiasi proposizione* (semplice o complessa); es.
 - dall'evento atomico $cavity \wedge \neg toothache$ segue
 - $cavity$ è vera ($Cavity = true$)
 - $cavity \Rightarrow toothache$ è falsa
 - **ogni proposizione è logicamente equivalente alla disgiunzione di tutti gli eventi atomici che ne implicano la verità**; es.
 - $cavity \equiv (cavity \wedge toothache) \vee (cavity \wedge \neg toothache)$
 - In generale

$$P(a) = \sum_{e_i \in e(a)} P(e_i)$$

dove $e(a)$ è l'insieme degli eventi atomici dove a è vera

Probabilità a priori

- **Probabilità a priori**: è il grado di credenza in una proposizione a in assenza di ogni altra informazione; es.

$$P(a); P(cavity) = 0.1; P(Weather = sunny) = 0.72$$

Probabilità a priori

- **Probabilità a priori**: è il grado di credenza in una proposizione a in assenza di ogni altra informazione; es.
 $P(a)$; $P(cavity) = 0.1$; $P(Weather = sunny) = 0.72$
- **Distribuzione di probabilità** (*a priori*) è un vettore di valori di probabilità: uno per ogni valore del dominio della variabile casuale considerata; es.
 $Range(Weather) = \langle sunny, rain, cloudy, snow \rangle$
 $P(Weather) = \langle 0.7, 0.02, 0.08, 0.2 \rangle$
NB: i valori sono *normalizzati* in modo tale che la loro somma sia 1

Probabilità a priori

- **Probabilità a priori**: è il grado di credenza in una proposizione *a* in assenza di ogni altra informazione; es.
 $P(a)$; $P(cavity) = 0.1$; $P(Weather = sunny) = 0.72$
- **Distribuzione di probabilità** (*a priori*) è un vettore di valori di probabilità: uno per ogni valore del dominio della variabile casuale considerata; es.
 $Range(Weather) = \langle sunny, rain, cloudy, snow \rangle$
 $P(Weather) = \langle 0.7, 0.02, 0.08, 0.2 \rangle$
NB: i valori sono *normalizzati* in modo tale che la loro somma sia 1
- **Distribuzione di probabilità congiunta**: è una matrice che assegna un valore di probabilità ad ogni possibile combinazione di valori delle variabili considerate; es.:
 $P(Weather, Cavity) =$

$Weather =$	$sunny$	$rain$	$cloudy$	$snow$
$Cavity = true$				
$Cavity = false$				

Probabilità a priori

- **Probabilità a priori**: è il grado di credenza in una proposizione *a* in assenza di ogni altra informazione; es.
 $P(a)$; $P(cavity) = 0.1$; $P(Weather = sunny) = 0.72$
- **Distribuzione di probabilità (a priori)** è un vettore di valori di probabilità: uno per ogni valore del dominio della variabile casuale considerata; es.
 $Range(Weather) = \langle sunny, rain, cloudy, snow \rangle$
 $P(Weather) = \langle 0.7, 0.02, 0.08, 0.2 \rangle$
NB: i valori sono *normalizzati* in modo tale che la loro somma sia 1
- **Distribuzione di probabilità congiunta**: è una matrice che assegna un valore di probabilità ad ogni possibile combinazione di valori delle variabili considerate; es.:
 $P(Weather, Cavity) =$

$Weather =$	$sunny$	$rain$	$cloudy$	$snow$
$Cavity = true$				
$Cavity = false$				

- **Distribuzione di probabilità congiunta COMPLETA** se costruita su tutte le variabili del dominio

Probabilità condizionate (a posteriori)

- Quando acquisiamo nuova conoscenza, non si possono più usare le probabilità a priori.
- **Probabilità condizionata:** $P(a|b)$ è la probabilità di a quando **tutto ciò che sappiamo è b**

$$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$

quando $P(b) \neq 0$

- **Regola del prodotto:**

$$P(a \wedge b) = P(a|b)P(b) = P(b|a)P(a)$$

- generalizzando **Distribuzione di Probabilità Condizionate:**

$$\mathbf{P}(X, Y) = \mathbf{P}(X|Y)\mathbf{P}(Y)$$

definita per ogni possibile coppia di valori $X = x_i$ e $Y = y_j$; non è un prodotto tra matrici, ma tra gli elementi.

Ad esempio:

$$\mathbf{P}(\text{Weather}, \text{Cavity}) = \mathbf{P}(\text{Weather}|\text{Cavity})\mathbf{P}(\text{Cavity})$$

Probabilità condizionate (a posteriori)

- **Osservazione:** probabilità condizionate **non sono** “implicazioni logiche con incertezza”
- $P(a|b) = .8$ non deve essere interpretata come $P(b \rightarrow a) = .8$
- perché:
 1. $P(b \rightarrow a)$ e $P(a)$ coincidono, ma $P(a)$ ha senso solo se non abbiamo altra conoscenza, se conosciamo b allora non possiamo parlare di probabilità a priori di a
 2. Le **probabilità condizionate non sono monotone** come le implicazioni logiche: se aggiungiamo altra informazione la probabilità condizionata di a può cambiare significativamente:
 $P(a|b \wedge c)$ può essere molto diversa (in positivo o negativo) rispetto a $P(a|b)$

Inferenze con Distribuzioni Congiunte Complete

Inferenza probabilistica

- **Inferenza probabilistica**: calcolo delle probabilità a posteriori di proposizioni poste come interrogazioni (query) partendo dalle prove osservate
- Abbiamo già osservato che:

$$P(a) = \sum_{e_i \in \mathbf{e}(a)} P(e_i)$$

dove $\mathbf{e}(a)$ è l'insieme degli eventi atomici dove a è vera

- Nel caso di variabili discrete a più valori:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

Inferenza per Enumerazione

- Abbiamo già osservato che:

$$P(a) = \sum_{e_i \in \mathbf{e}(a)} P(e_i)$$

dove $\mathbf{e}(a)$ è l'insieme degli eventi atomici dove a è vera

- Nel caso di variabili discrete a più valori:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

$$P(\text{cavity} \vee \text{toothache}) = 0.28$$

Inferenza per Enumerazione

- Abbiamo già osservato che:

$$P(a) = \sum_{e_i \in \mathbf{e}(a)} P(e_i)$$

dove $\mathbf{e}(a)$ è l'insieme degli eventi atomici dove a è vera

- Nel caso di variabili discrete a più valori:

	<i>toothache</i>		$\neg$ <i>toothache</i>		
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>	
<i>cavity</i>	0.108	0.012	0.072	0.008	0.2
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576	

$P(\text{cavity}) = 0.2 \Rightarrow$ **Probabilità Marginale** $\equiv$ Probabilità a priori

Inferenza per Enumerazione

- Abbiamo già osservato che:

$$P(a) = \sum_{e_i \in \mathbf{e}(a)} P(e_i)$$

dove $\mathbf{e}(a)$ è l'insieme degli eventi atomici dove a è vera

- Nel caso di variabili discrete a più valori:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

$$P(\text{catch}) = 0.34$$

- Abbiamo già osservato che:

$$P(a) = \sum_{e_i \in \mathbf{e}(a)} P(e_i)$$

dove $\mathbf{e}(a)$ è l'insieme degli eventi atomici dove a è vera

- Nel caso di variabili discrete a più valori:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

$$P(\neg \text{cavity} | \text{toothache}) = \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = 0.4$$

Regola del Condizionamento

- Generalizzando il principio della marginalizzazione

$$P(\mathbf{Y}) = \sum_{\mathbf{z}} P(\mathbf{Y}, \mathbf{z})$$

dove:

- $\mathbf{Y}$ e $\mathbf{Z}$ sono insiemi di variabili casuali
- $\mathbf{z}$ è un vettore di assegnazioni di valori alle variabili in $\mathbf{Z}$

è la distribuzione di probabilità a priori delle variabili in $\mathbf{Y}$

- **Regola di condizionamento:**

$$P(\mathbf{Y}) = \sum_{\mathbf{z}} P(\mathbf{Y}|\mathbf{z})P(\mathbf{z})$$

- Nella maggior parte dei casi ci interessa calcolare la probabilità condizionata di qualche variabile, avendo a disposizione altre variabili come prova.

Normalizzazione

- $P(\text{Carie}|\text{toothache}) = \langle P(\text{carie}|\text{toothache}), P(\neg\text{carie}|\text{toothache}) \rangle$

In entrambe le probabilità sono calcolate moltiplicando per $\frac{1}{P(\text{toothache})}$ che è una costante di normalizzazione: garantisce che la somma delle due probabilità sia 1

Allora posso riscrivere come:

- $P(\text{Carie}|\text{toothache}) = \alpha P(\text{Carie}, \text{toothache})$

dove $\alpha = \frac{1}{P(\text{toothache})}$

Normalizzazione

- $P(\text{Carie}|\text{toothache}) = \langle P(\text{carie}|\text{toothache}), P(\neg\text{carie}|\text{toothache}) \rangle$

In entrambe le probabilità sono calcolate moltiplicando per $\frac{1}{P(\text{toothache})}$ che è una costante di normalizzazione: garantisce che la somma delle due probabilità sia 1

Allora posso riscrivere come:

- $P(\text{Carie}|\text{toothache}) = \alpha P(\text{Carie}, \text{toothache})$

dove $\alpha = \frac{1}{P(\text{toothache})}$

- **Procedura di Inferenza Generale:**

$$P(X|e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

dove: **E** variabili di evidenza; **Y** variabili nascoste; **X** variabile di query

Normalizzazione

- $P(\text{Carie}|\text{toothache}) = \langle P(\text{carie}|\text{toothache}), P(\neg\text{carie}|\text{toothache}) \rangle$
In entrambe le probabilità sono calcolate moltiplicando per $\frac{1}{P(\text{toothache})}$ che è una costante di normalizzazione: garantisce che la somma delle due probabilità sia 1

Allora posso riscrivere come:

- $P(\text{Carie}|\text{toothache}) = \alpha P(\text{Carie}, \text{toothache})$
dove $\alpha = \frac{1}{P(\text{toothache})}$

- **Procedura di Inferenza Generale:**

$$P(X|e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

dove: **E** variabili di evidenza; **Y** variabili nascoste; **X** variabile di query

- Questa procedura ha due svantaggi:
 - è computazionalmente costosa: per n variabili booleane $O(2^n)$
 - costruire la distribuzione congiunta completa non è sempre possibile nei casi reali con centinaia (o migliaia) di variabili

Regola di Bayes

- Dalla regola del prodotto:

$$P(a \wedge b) = P(a|b)P(b) = P(b|a)P(a)$$

Regola di Bayes

- Dalla regola del prodotto:

$$P(a \wedge b) = P(a|b)P(b) = P(b|a)P(a)$$

- **Regola di Bayes**

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

Regola di Bayes

- Dalla regola del prodotto:

$$P(a \wedge b) = P(a|b)P(b) = P(b|a)P(a)$$

- **Regola di Bayes**

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

- generalizzando:

$$\mathbf{P}(Y|X) = \frac{\mathbf{P}(X|Y)\mathbf{P}(Y)}{\mathbf{P}(X)} = \alpha\mathbf{P}(X|Y)\mathbf{P}(Y)$$

NB: poiché X e Y sono variabili casuali a più valori con $\mathbf{P}$ indichiamo l'intero sistema di equazioni definite su ogni possibile coppia di valori per X e Y

Regola di Bayes

- Dalla regola del prodotto:

$$P(a \wedge b) = P(a|b)P(b) = P(b|a)P(a)$$

- **Regola di Bayes**

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

- generalizzando:

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)} = \alpha P(X|Y)P(Y)$$

NB: poiché X e Y sono variabili casuali a più valori con $\mathbf{P}$ indichiamo l'intero sistema di equazioni definite su ogni possibile coppia di valori per X e Y

- **Regola di Bayes e condizionamento all'evidenza $\mathbf{e}$**

$$P(Y|X, \mathbf{e}) = \frac{P(X|Y, \mathbf{e})P(Y|\mathbf{e})}{P(X|\mathbf{e})}$$

dove $\mathbf{e}$ è un vettore di valori alle variabili di prova (vedi regola della catena in seguito)

Uso della Regola di Bayes

- Per stabilire una probabilità necessitiamo di ben altre tre probabilità!
Sembra poco utile, **MA** nei casi reali abbiamo a disposizione informazione probabilistica nella forma

$$P(\text{effetto}|\text{causa})$$

e spesso vogliamo proprio calcolare quanto probabile sia una causa avendo osservato certi effetti cioè

$$P(\text{causa}|\text{effetto})$$

- es. diagnosi medica:
 - dal sintomo vogliamo risalire alla malattia
 - ma lo stesso sintomo potrebbe essere associato a più malattie
 - quello che ci permette di concludere Bayes è che se anche un sintomo è molto comune in una malattia, se la malattia è rara, la probabilità che un paziente abbia proprio quella malattia rimane bassa

Uso della Regola di Bayes

- Consideriamo il lo scenario del dentista e due evidenze: mal di denti e il fatto che lo strumento “prende”: c'è una carie?

Uso della Regola di Bayes

- Consideriamo il lo scenario del dentista e due evidenze: mal di denti e il fatto che lo strumento “prende”: c'è una carie?
- Inferenza per enumerazione (dalla distribuzione congiunta completa)

$$\mathbf{P}(\text{Cavity}|\text{toothache}, \text{catch}) = \alpha \langle 0.108, 0.016 \rangle = \langle 0.871, 0.129 \rangle$$

Ma scala male al crescere delle variabili: con 3 variabili booleane, la distribuzione congiunta completa ha $2^3 - 1 = 7$ *righe indipendenti*

Uso della Regola di Bayes

- Consideriamo il lo scenario del dentista e due evidenze: mal di denti e il fatto che lo strumento “prende”: c'è una carie?
- Inferenza per enumerazione (dalla distribuzione congiunta completa)

$$\mathbf{P}(\text{Cavity}|\text{toothache}, \text{catch}) = \alpha \langle 0.108, 0.016 \rangle = \langle 0.871, 0.129 \rangle$$

Ma scala male al crescere delle variabili: con 3 variabili booleane, la distribuzione congiunta completa ha $2^3 - 1 = 7$ *righe indipendenti*

- Sfruttando la regola di Bayes:

$$\mathbf{P}(\text{Cavity}|\text{toothache}, \text{catch}) = \alpha \mathbf{P}(\text{toothache}, \text{catch}|\text{Cavity}) \mathbf{P}(\text{Cavity})$$

Ma anche questa formulazione scala poco bene: con n variabili di prova ci sono 2^n combinazioni di valori per cui dobbiamo conoscere le probabilità condizionate $\sim$ distribuzione completa congiunta

Uso della Regola di Bayes

- Consideriamo il lo scenario del dentista e due evidenze: mal di denti e il fatto che lo strumento “prende”: c'è una carie?
- Inferenza per enumerazione (dalla distribuzione congiunta completa)

$$\mathbf{P}(Cavity|toothache, catch) = \alpha \langle 0.108, 0.016 \rangle = \langle 0.871, 0.129 \rangle$$

Ma scala male al crescere delle variabili: con 3 variabili booleane, la distribuzione congiunta completa ha $2^3 - 1 = 7$ *righe indipendenti*

- Sfruttando la regola di Bayes:

$$\mathbf{P}(Cavity|toothache, catch) = \alpha \mathbf{P}(toothache, catch|Cavity) \mathbf{P}(Cavity)$$

Ma anche questa formulazione scala poco bene: con n variabili di prova ci sono 2^n combinazioni di valori per cui dobbiamo conoscere le probabilità condizionate $\sim$ distribuzione completa congiunta

- Per poter sfruttare Bayes abbiamo bisogno di aggiungere delle asserzioni di **indipendenza**


Indipendenza (assoluta)

Indipendenza

a e b sono indipendenti se e solo se

$P(a|b) = P(a)$ oppure $P(b|a) = P(b)$ oppure $P(a \wedge b) = P(a)P(b)$

- Ad esempio:




Indipendenza

a e b sono indipendenti se e solo se

$P(a|b) = P(a)$ oppure $P(b|a) = P(b)$ oppure $P(a \wedge b) = P(a)P(b)$

- Ad esempio:



$$P(\textit{Toothache}, \textit{Catch}, \textit{Cavity}, \textit{Weather}) = \\ P(\textit{Toothache}, \textit{Catch}, \textit{Cavity})P(\textit{Weather})$$

- passiamo da 32 a 12 righe della distribuzione congiunta completa

Indipendenza

a e b sono indipendenti se e solo se

$P(a|b) = P(a)$ oppure $P(b|a) = P(b)$ oppure $P(a \wedge b) = P(a)P(b)$

- Altro esempio:
 - n lanci indipendenti di una moneta:

$$P(C_1, \dots, C_n) = \prod_i P(C_i)$$

- passiamo da $O(2^n)$ a $O(n)$

Indipendenza assoluta è però rara nei domini reali: abbiamo bisogno di un modo più generale “domain-independent” per sfruttare l'indipendenza

Indipendenza Condizionale

Indipendenza Condizionale

- **Osservazione** Se *Toothache* e *Catch* fossero indipendenti, avremmo un vantaggio dal punto di vista computazionale
- Ma non possiamo dire che lo siano, in generale:
se “*prende*” allora è probabile che ci sia una carie e che quindi il dente faccia male; ma vale anche il viceversa:
se *il dente fa male* è probabile che ci sia una carie e quindi l’attrezzo prende.
La relazione tra “prende” e “fa male” passa per “carie”!

Indipendenza Condizionale

- **Osservazione** Se *Toothache* e *Catch* fossero indipendenti, avremmo un vantaggio dal punto di vista computazionale
- Ma non possiamo dire che lo siano, in generale:
se “*prende*” allora è probabile che ci sia una carie e che quindi il dente faccia male; ma vale anche il viceversa:
se *il dente fa male* è probabile che ci sia una carie e quindi l’attrezzo prende.
La relazione tra “prende” e “fa male” passa per “carie”!
- **Allora:** *Toothache* e *Catch* sono indipendenti data la presenza/assenza di *Cavity*

Indipendenza Condizionale

- **Osservazione** Se *Toothache* e *Catch* fossero indipendenti, avremmo un vantaggio dal punto di vista computazionale
- Ma non possiamo dire che lo siano, in generale:
se “*prende*” allora è probabile che ci sia una carie e che quindi il dente faccia male; ma vale anche il viceversa:
se *il dente fa male* è probabile che ci sia una carie e quindi l’attrezzo prende.
La relazione tra “*prende*” e “*fa male*” passa per “*carie*”!
- **Allora:** *Toothache* e *Catch* sono indipendenti data la presenza/assenza di *Cavity*

Indipendenza condizionale

Toothache e *Catch* sono causate da *Cavity*, però nessuna ha effetto sull'altra, data *Cavity* si ha *Toothache* e *Catch* sono indipendenti

$$\mathbf{P}(\textit{toothache}, \textit{catch} | \textit{Cavity}) = \mathbf{P}(\textit{toothache} | \textit{Cavity}) \mathbf{P}(\textit{catch} | \textit{Cavity}) \quad (*)$$

In che modo l'indipendenza condizionale aiuta?

In che modo l'indipendenza condizionale aiuta?

- Sostituiamo (*) in

$$P(Cavity|toothache, catch) = \alpha P(toothache, catch|Cavity)P(Cavity)$$

Il risultato è:

$$P(Cavity|toothache, catch) = \alpha P(toothache|Cavity)P(catch|Cavity)P(Cavity)$$

- In questo caso, il numero di probabilità **indipendenti** da calcolare è 3.

In che modo l'indipendenza condizionale aiuta?

- Sostituiamo (*) in

$$P(Cavity|toothache, catch) = \alpha P(toothache, catch|Cavity)P(Cavity)$$

Il risultato è:

$$P(Cavity|toothache, catch) = \alpha P(toothache|Cavity)P(catch|Cavity)P(Cavity)$$

- In questo caso, il numero di probabilità **indipendenti** da calcolare è 3.

Risultato

Per n effetti condizionatamente indipendenti dato $Cavity$, la dimensione della rappresentazione cresce come $O(n)$ anziché $O(2^n)$

Modello di Bayes Ingenuo

- Generalizzando il risultato della slide precedente:

$$\mathbf{P}(Causa, Effetto_1, \dots, Effetto_n) = \mathbf{P}(Causa) \prod_i \mathbf{P}(Effetto_i | Causa)$$

- Modello anche noto come Classificatore Bayesiano naive
- “L’ingenuità” sta nel fatto che si assume che le n variabili di effetto siano tra loro indipendenti, anche quando nei casi reali non sempre questo è vero.

Generalizzazione delle relazioni di Indipendenza Condizionale

- L'indipendenza condizionale di X e Y data Z vale sse

$$\mathbf{P}(X, Y|Z) = \mathbf{P}(X|Z)\mathbf{P}(Y|Z)$$

- Se l'indipendenza condizionale vale, allora

$$\mathbf{P}(X|Y, Z) = \mathbf{P}(X|Z)$$

$$\mathbf{P}(Y|X, Z) = \mathbf{P}(Y|Z)$$

Un esempio (pseudo)-medico

Date le variabili booleane

- I : il paziente ha l'influenza?
- T : il paziente ha il mal di testa?
- F : il paziente ha la febbre?

Assumendo che valga $\mathbf{P}(T, F|I) = \mathbf{P}(T|I)\mathbf{P}(F|I)$ e che valgano le seguenti probabilità:

- $P(I = \text{true}) = .2$
- $P(T = \text{true}|I = \text{true}) = .5, P(T = \text{true}|I = \text{false}) = .2$
- $P(F = \text{true}|I = \text{true}) = .4, P(F = \text{true}|I = \text{false}) = .1$

Un esempio (pseudo)-medico

Date le variabili booleane

- I : il paziente ha l'influenza?
- T : il paziente ha il mal di testa?
- F : il paziente ha la febbre?

Assumendo che valga $\mathbf{P}(T, F|I) = \mathbf{P}(T|I)\mathbf{P}(F|I)$ e che valgano le seguenti probabilità:

- $P(I = \text{true}) = .2$
- $P(T = \text{true}|I = \text{true}) = .5, P(T = \text{true}|I = \text{false}) = .2$
- $P(F = \text{true}|I = \text{true}) = .4, P(F = \text{true}|I = \text{false}) = .1$

Qual è la probabilità $P(I = 1|T = 1, F = 1)$?

Reti Bayesiane: Sintassi e Semantica

Belief Networks


- E' una **rappresentazione grafica di asserzioni di indipendenze condizionali**
- Fornisce una **specifica concisa** di *qualsiasi distribuzione congiunta completa*
- E' un **grafo**:
 - un nodo per ogni variabile casuale (discreta o continua)
 - è un DAG: archi diretti e privo di cicli
 - un arco da X a Y implica che X è un genitore di Y e X ha una **influenza diretta** su Y
 - ogni nodo X_i è associata ad una *distribuzione condizionale di X_i dati i suoi genitori*:

$$P(X_i | \text{Parents}(X_i))$$

quantifica gli effetti dei genitori sul nodo; è espressa come *Tabella di Prob. Condizionali (CPT)*

- in generale la CPT di una variabile (booleana) con k genitori booleani contiene 2^k righe: una per ogni possibile combinazione di valori dei genitori


- la **topologia della rete** specifica le **condizioni di indipendenza** e definisce implicitamente la distribuzione congiunta completa di tutte le variabili casuali



- Weather* è indipendente dalle altre variabili
- Catch* e *Toothache* sono condizionalmente indipendenti dato *Cavity*

- **Scenario:** Siete al lavoro e il vostro vicino John vi chiama per dirvi che suona l'allarme di casa vostra. La vostra vicina Mary non ha però chiamato. Talvolta l'allarme suona per via di piccoli terremoti, abitate a San Francisco, quindi è normale. C'è stato un tentativo di furto?
- **Modellazione del problema:**
 - Variabili: *Burglar*, *Earthquake*, *Alarm*, *JohnCalls*, *MaryCalls*
 - Dipendenze dirette:
 - un ladro può far scattare l'allarme;
 - un terremoto può far scattare l'allarme;
 - Mary può chiamare per via dell'allarme;
 - John può chiamare per via dell'allarme

Esempio



- E' nostra ipotesi che i vicini non percepiscano direttamente terremoti o intrusioni, ma solo l'allarme
- Le probabilità catturano un'infinità di situazioni (non note) per cui i vicini possono non telefonare anche quando l'allarme suona (o viceversa)

Compattezza (Compactness)

- Una CPT per una variabile booleana X_i con k genitori booleani ha 2^k righe per tutte le possibili combinazioni di valori dei genitori
- Ogni riga contiene un valore p per $X_i = \text{true}$ (per $X_i = \text{false}$ il valore è semplicemente $1 - p$)
- Se ogni variabile ha non più di k genitori la rete completa richiede $O(n \cdot 2^k)$ valori
- Dato che in genere $k \ll n$, il numero di valori necessari cresce linearmente in n contro $O(2^n)$ della distribuzione completa congiunta
- ad esempio, nel caso precedente $1+1+4+2+2 = 10$ valori, rispetto a $2^5 - 1 = 31$

Semantica Globale delle BN

Semantica: stabilisce come la struttura (sintassi) della BN corrisponde ad una distribuzione congiunta delle variabili

- La “semantica globale” definisce la distribuzione completa congiunta come il prodotto delle distribuzioni condizionali locali:

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$$

- Ad esempio: la distribuzione congiunta completa dell'esempio dell'allarme è costruita come

$$\mathbf{P}(J, M, A, B, E) = \mathbf{P}(J|A)\mathbf{P}(M|A)\mathbf{P}(A|B, E)\mathbf{P}(B)\mathbf{P}(E)$$

- la distribuzione congiunta completa richiede 32 equazioni su combinazioni complete di valori (2^5)
- La BN specifica solo 10 valori

Esempio di uso della semantica globale.

- Stabiliamo la probabilità che sia John sia Mary telefonino quando non si sono verificate le cause Terremoto e Intrusione
- In quanto rappresentazione (compatta) della distribuzione congiunta completa, una BN risponde a qualsiasi query

Esempio di uso della semantica globale.

- Stabiliamo la probabilità che sia John sia Mary telefonino quando non si sono verificate le cause Terremoto e Intrusione
- $P(j, m, a, \neg b, \neg e) =$
- In quanto rappresentazione (compatta) della distribuzione congiunta completa, una BN risponde a qualsiasi query

Esempio di uso della semantica globale.


- Stabiliamo la probabilità che sia John sia Mary telefonino quando non si sono verificate le cause Terremoto e Intrusione
- $P(j, m, a, \neg b, \neg e) =$
 $= P(j|a)P(m|a)P(a|\neg b, \neg e)P(\neg b)P(\neg e) =$
- In quanto rappresentazione (compatta) della distribuzione congiunta completa, una BN risponde a qualsiasi query

Esempio di uso della semantica globale.

- Stabiliamo la probabilità che sia John sia Mary telefonino quando non si sono verificate le cause Terremoto e Intrusione
- $P(j, m, a, \neg b, \neg e) =$
 $= P(j|a)P(m|a)P(a|\neg b, \neg e)P(\neg b)P(\neg e) =$
 $= .9 \times .7 \times .001 \times .999 \times .998 = .00062$
- In quanto rappresentazione (compatta) della distribuzione congiunta completa, una BN risponde a qualsiasi query


Semantica Locale delle BN

- “Semantica locale”: ogni nodo è condizionalmente indipendente dai suoi **non**-discendenti dati i suoi genitori



- Teorema: semantica globale $\equiv$ semantica locale

- **Markov Blanket:** ogni nodo è condizionalmente indipendente da tutti gli altri nodi di una rete data la sua coperta di Markov: genitori, discendenti, e genitori dei discendenti



- Per costruire una rete dobbiamo fare attenzione all'ordine con cui i nodi sono aggiunti nella rete stessa
- Sarebbe utile un criterio per stabilire se un nodo deve essere un genitore di un altro nodo
- **Chain Rule** (regola della catena):

$$\begin{aligned}\mathbf{P}(X_1, \dots, X_n) &= \mathbf{P}(X_1|X_2, \dots, X_n)\mathbf{P}(X_2, \dots, X_n) \\ &= \mathbf{P}(X_1|X_2, \dots, X_n)\mathbf{P}(X_2|X_3, \dots, X_n)\mathbf{P}(X_3, \dots, X_n) \\ &= \dots \\ &= \prod_{i=1}^n \mathbf{P}(X_i|X_{i+1}, \dots, X_n)\end{aligned}$$

- Confrontando semantica globale e chain rule

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$$

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | X_{i+1}, \dots, X_n)$$

- Confrontando semantica globale e chain rule

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$$

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | X_{i+1}, \dots, X_n)$$

- Si osserva che la chain rule è equivalente alla semantica globale delle reti bayesiane purché

$$\text{Parents}(X_i) \subseteq \{X_{i+1}, \dots, X_n\}$$

cioé vale

$$\mathbf{P}(X_i | X_{i+1}, \dots, X_n) = \mathbf{P}(X_i | \text{Parents}(X_i))$$

Costruire una BN

- Confrontando semantica globale e chain rule

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$$

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | X_{i+1}, \dots, X_n)$$

- Si osserva che la chain rule è equivalente alla semantica globale delle reti bayesiane purché

$$\text{Parents}(X_i) \subseteq \{X_{i+1}, \dots, X_n\}$$

cioé vale

$$\mathbf{P}(X_i | X_{i+1}, \dots, X_n) = \mathbf{P}(X_i | \text{Parents}(X_i))$$

Una rete rispetta la semantica globale delle BN solo se per ogni nodo X_i esso è **condizionalmente indipendente da ogni altro suo predecessore nell'ordine dei nodi, dati i suoi genitori** [Semantica locale]

Strategia di costruzione

1. Choose an ordering of variables $X_n, \dots, X_1$
2. For $i = n$ to 1
 - add X_i to the network
 - select parents from $X_{i+1}, \dots, X_n$ such that
$$\mathbf{P}(X_i | \text{Parents}(X_i)) = \mathbf{P}(X_i | X_{i+1}, \dots, X_n)$$

Strategia di costruzione

1. Choose an ordering of variables $X_n, \dots, X_1$
2. For $i = n$ to 1
 - add X_i to the network
 - select parents from $X_{i+1}, \dots, X_n$ such that
$$\mathbf{P}(X_i | \text{Parents}(X_i)) = \mathbf{P}(X_i | X_{i+1}, \dots, X_n)$$


In questo modo garantiamo la semantica globale:

$$\begin{aligned}\mathbf{P}(X_1, \dots, X_n) &= \prod_{i=1}^n \mathbf{P}(X_i | X_{i+1}, \dots, X_n) \text{ (chain rule)} \\ &= \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i)) \text{ per costruzione, a patto che:}\end{aligned}$$

$$\text{Parents}(X_i) \subseteq \{X_{i+1}, \dots, X_n\}$$

Esempio


- Cosa succede se scegliamo un ordinamento che non segue le relazioni causali, ad esempio M, J, A, B, E ?



- $P(J|M) = P(J)$?

Esempio


- Cosa succede se scegliamo un ordinamento che non segue le relazioni causali, ad esempio M, J, A, B, E ?



- $P(J|M) = P(J)$? No!
 - sapere che Mary telefona fa crescere l'aspettativa che anche John telefoni

Esempio


- Cosa succede se scegliamo un ordinamento che non segue le relazioni causali, ad esempio M, J, A, B, E ?



- $P(A|J, M) = P(A|J)? P(A|J, M) = P(A)?$

Esempio


- Cosa succede se scegliamo un ordinamento che non segue le relazioni causali, ad esempio M, J, A, B, E ?



- $P(A|J, M) = P(A|J)? P(A|J, M) = P(A)?$ No!
 - sapere che John chiama fa aumentare l'aspettativa che l'allarme suoni;
 - se John chiama e Mary non chiama l'aspettativa su allarme è ridotta

Esempio


- Cosa succede se scegliamo un ordinamento che non segue le relazioni causali, ad esempio M, J, A, B, E ?



- $P(B|A, J, M) = P(B)$?
- $P(B|A, J, M) = P(B|A)$?

Esempio


- Cosa succede se scegliamo un ordinamento che non segue le relazioni causali, ad esempio M, J, A, B, E ?



- $P(B|A, J, M) = P(B)$? No!
- $P(B|A, J, M) = P(B|A)$? Sì!

Esempio


- Cosa succede se scegliamo un ordinamento che non segue le relazioni causali, ad esempio M, J, A, B, E ?



- $P(E|B, A, J, M) = P(E)$?
- $P(E|B, A, J, M) = P(E|B, A)$?
 - Sapere che l'allarme suona e che c'è stata intrusione influenza l'aspettativa su terremoto

Esempio


- Cosa succede se scegliamo un ordinamento che non segue le relazioni causali, ad esempio M, J, A, B, E ?




- $P(E|B, A, J, M) = P(E)$? No!
- $P(E|B, A, J, M) = P(E|B, A)$? Sì!
 - Sapere che l'allarme suona e che c'è stata intrusione influenza l'aspettativa su terremoto

Esempio

- Le due reti rispettano la semantica globale, per costruzione, ma differiscono nella semantica locale




- B e E sono indipendenti
- J e M sono cond. ind. dato A



- E dipende da B
- E è cond. ind. da M e J dati A e B

Esempio

- Cosa succede se scegliamo un ordinamento che non segue le relazioni causali, ad esempio M, J, A, B, E ?
- le relazioni causali tra le variabili non sono allineate con le dipendenze espresse dalla rete:



- la rete è più debole
- *Earthquake* è indipendente condizionalmente dato *Burglary* e *Alarm*, ma come stabilire la probabilità che si verifichi un terremoto dato che l'allarme suona e che ci sia stata un'intrusione?

Inferenze Esatte con le Reti Bayesiane

Data una rete definita su un insieme di variabili **U**, occorre distinguere tra

- Variabili di **evidenza E**
- Variabili di **query X**
- Variabili **nascoste** $\mathbf{Y} = \mathbf{U} - \mathbf{E} - \mathbf{X}$

Data una rete definita su un insieme di variabili **U**, occorre distinguere tra

- Variabili di **evidenza E**
- Variabili di **query X**
- Variabili **nascoste Y = U - E - X**

Abbiamo già visto che dalla distribuzione congiunta completa possiamo rispondere a qualsiasi query

- **Procedura di Inferenza Generale:**

$$P(X|e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

Inferenze con le Reti Bayesiane

Data una rete definita su un insieme di variabili **U**, occorre distinguere tra

- Variabili di **evidenza E**
- Variabili di **query X**
- Variabili **nascoste** $\mathbf{Y} = \mathbf{U} - \mathbf{E} - \mathbf{X}$

Abbiamo già visto che dalla distribuzione congiunta completa possiamo rispondere a qualsiasi query

- **Procedura di Inferenza Generale:**

$$\mathbf{P}(X|\mathbf{e}) = \alpha \mathbf{P}(X, \mathbf{e}) = \alpha \sum_{\mathbf{y}} \mathbf{P}(X, \mathbf{e}, \mathbf{y})$$

Poiché una BN non è altro che una rappresentazione compatta di una dist. cong. compl. non ci resta che “navigare” lungo la rete

- Calcoliamo $P(\textit{Burglary} | \textit{JohnCall} = \textit{true}, \textit{MaryCall} = \textit{true})$

Inferenze con le Reti Bayesiane: Esempio

- Calcoliamo $P(\text{Burglary} | \text{JohnCall} = \text{true}, \text{MaryCall} = \text{true})$
- **Evidenze:** j, m ; **Query:** B ; **Nascoste:** A, E

Inferenze con le Reti Bayesiane: Esempio

- Calcoliamo $\mathbf{P}(\textit{Burglary} | \textit{JohnCall} = \textit{true}, \textit{MaryCall} = \textit{true})$
- **Evidenze:** j, m ; **Query:** B ; **Nascoste:** A, E
- $\mathbf{P}(B | j, m) = \alpha \mathbf{P}(B, j, m) = \alpha \sum_{e \in E} \sum_{a \in A} \mathbf{P}(B, j, m, a, e)$

Inferenze con le Reti Bayesiane: Esempio

- Calcoliamo $\mathbf{P}(\text{Burglary} | \text{JohnCall} = \text{true}, \text{MaryCall} = \text{true})$
- **Evidenze:** j, m ; **Query:** B ; **Nascoste:** A, E
- $\mathbf{P}(B | j, m) = \alpha \mathbf{P}(B, j, m) = \alpha \sum_{e \in E} \sum_{a \in A} \mathbf{P}(B, j, m, a, e)$
- Ricorrendo alla semantica globale delle BN
$$\mathbf{P}(B | j, m) = \alpha \sum_{e \in E} \sum_{a \in A} \mathbf{P}(B) P(e) \mathbf{P}(a | B, e) P(j | a) P(m | a)$$

Inferenze con le Reti Bayesiane: Esempio

- Calcoliamo $\mathbf{P}(\text{Burglary} | \text{JohnCall} = \text{true}, \text{MaryCall} = \text{true})$
- **Evidenze:** j, m ; **Query:** B ; **Nascoste:** A, E
- $\mathbf{P}(B | j, m) = \alpha \mathbf{P}(B, j, m) = \alpha \sum_{e \in E} \sum_{a \in A} \mathbf{P}(B, j, m, a, e)$
- Ricorrendo alla semantica globale delle BN
$$\mathbf{P}(B | j, m) = \alpha \sum_{e \in E} \sum_{a \in A} \mathbf{P}(B)P(e)\mathbf{P}(a | B, e)P(j | a)P(m | a)$$

Osservazione

- il numero di fattori nel prodotto cresce linearmente nel numero n di variabili (indipendenza condizionale)
- nel caso peggiore dovremo considerare quasi tutte le variabili (es. poche evidenze disponibili), quindi il numero di somme è esponenziale in n
- La complessità è $O(n2^n)$

Inferenze con le Reti Bayesiane: Esempio

- Si può fare un po' meglio portando fuori dalle sommatorie i fattori che non sono indicizzati

$$P(B|j, m) = \alpha P(B) \sum_{e \in E} P(e) \sum_{a \in A} P(a|b, e) P(j|a) P(m|a)$$




Figure 13.10 The structure of the expression shown in Equation (13.5). The evaluation proceeds top down, multiplying values along each path and summing at the “+” nodes. Notice the repetition of the paths for j and m .

- la complessità in spazio è lineare, ma in tempo rimane $O(2^n)$
- inoltre molti calcoli sono ripetuti più volte

Algoritmo di Eliminazione delle variabili

- La procedura di calcolo può essere migliorata evitando di ripetere più volte gli stessi calcoli
- Programmazione dinamica: svolto un calcolo ne ricordo il risultato per uso futuro
- l'**algoritmo di eliminazione delle variabili** è una possibile soluzione al problema della ripetizione dei calcoli

Algoritmo di Eliminazione delle variabili

- Intuizione: partendo dalla formulazione di una query che esplicita tutte le sommatorie nascoste
- individua i fattori della formula
- valuta la formula da destra verso sinistra svolgendo due operazioni fondamentali sui fattori:
 - **prodotto puntuale tra fattori**
 - **eliminazione di una variabile per summing out**

Algoritmo di Eliminazione delle variabili

Esempio

- Data la query:

$$\mathbf{P}(B|j, m)$$

- Si esplicitano le sommatorie nascoste (*marginalizzazione*)

$$\mathbf{P}(B|j, m) = \alpha \mathbf{P}(B) \sum_e P(e) \sum_a \mathbf{P}(a|B, e) P(j|a) P(m|a)$$

- Si individuano i **fattori**

$$\mathbf{P}(B|j, m) = \alpha \mathbf{f}_1(B) \times \sum_e \mathbf{f}_2(E) \times \sum_a \mathbf{f}_3(A|B, E) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A)$$

- Ogni fattore è una matrice i cui indici sono costruiti sulle variabili indicate come argomenti
- Queste variabili possono essere solo variabili "libere": non vincolate dalla query, cioè tutte le **variabili non di evidenza**

Algoritmo di Eliminazione delle variabili

Spiegazione dei fattori

- $\mathbf{f}_4(A)$ e $\mathbf{f}_5(A)$ sono indicizzati su A perché j e m sono fissate come evidenze nella query
- sono allora due vettori come segue

$$\mathbf{f}_4(A) = \begin{pmatrix} P(j|a) \\ P(j|\neg a) \end{pmatrix} = \begin{pmatrix} .9 \\ .05 \end{pmatrix} \quad \mathbf{f}_5(A) = \begin{pmatrix} P(m|a) \\ P(m|\neg a) \end{pmatrix} = \begin{pmatrix} .7 \\ .01 \end{pmatrix}$$

- il fattore $\mathbf{f}_3(ABE)$ è una matrice $2 \times 2 \times 2$
Il primo elemento è $P(a|b, e)$ l'ultimo $P(\neg a|\neg b, \neg e)$
- Intuitivamente, ogni fattore cattura una sorta di CPT: viene attribuita una probabilità ad ogni combinazione di valori delle variabili libere

Algoritmo di Eliminazione delle variabili

Determinati i fattori si procede da destra verso sinistra e si eliminano le variabili dai prodotti puntuali per **summing out** (vedi seguito)

$$\mathbf{P}(B|j, m) = \alpha \mathbf{f}_1(B) \times \sum_e \mathbf{f}_2(E) \times \sum_a \mathbf{f}_3(ABE) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A)$$

- Eliminando la variabile A dal prodotto $\mathbf{f}_3(ABE) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A)$ otteniamo un nuovo fattore 2×2 $\mathbf{f}_6(BE)$ definito come

$$\begin{aligned} \mathbf{f}_6(BE) &= \sum_a \mathbf{f}_3(ABE) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A) = \\ &= \mathbf{f}_3(aBE) \times \mathbf{f}_4(a) \times \mathbf{f}_5(a) + \mathbf{f}_3(\neg aBE) \times \mathbf{f}_4(\neg a) \times \mathbf{f}_5(\neg a) \end{aligned}$$

La query diventa

$$\mathbf{P}(B|j, m) = \alpha \mathbf{f}_1(B) \times \sum_e \mathbf{f}_2(E) \times \mathbf{f}_6(BE)$$

- si può adesso eliminare la variabile E dal prodotto di $\mathbf{f}_2$ e $\mathbf{f}_6$
- otteniamo un nuovo fattore $\mathbf{f}_7(B)$:

$$\begin{aligned}\mathbf{f}_7(B) &= \sum_e \mathbf{f}_2(E) \times \mathbf{f}_6(BE) = \\ &= \mathbf{f}_2(e) \times \mathbf{f}_6(Be) + \mathbf{f}_2(\neg e) \times \mathbf{f}_6(B\neg e)\end{aligned}$$

La query diventa

$$\mathbf{P}(B|j, m) = \alpha \mathbf{f}_1(B) \times \mathbf{f}_7(B)$$

- questo può essere risolto con il prodotto puntuale e poi con la normalizzazione

Algoritmo di Eliminazione delle variabili

Prodotto puntuale

- dati due fattori **f** e **g** il loro prodotto produce un nuovo fattore **h** le cui variabili sono date dall'unione delle variabili dei fattori di partenza
- Esempio:

$$\mathbf{f}(X_1, \dots, X_j, Y_1, \dots, Y_k) \times \mathbf{g}(Y_1, \dots, Y_k, Z_1, \dots, Z_l) = \\ \mathbf{h}(X_1, \dots, X_j, Y_1, \dots, Y_k, Z_1, \dots, Z_l)$$

- se tutte le variabili sono booleane, **f** ha 2^{j+k} elementi, **g** ha 2^{l+k} elementi e **h** ha 2^{j+k+l} elementi
 - **la dimensione di un fattore è esponenziale nel numero di variabili**
- ⇒ La complessità spaziale e temporale dell'algoritmo di eliminazione nasce proprio da questa caratteristica

Algoritmo di Eliminazione delle variabili

Prodotto puntuale

- Esempio

$f(X, Y)$:

	x	$\neg x$
y	.3	.9
$\neg y$	.7	.1

$g(Y, Z)$:

	y	$\neg y$
z	.2	.6
$\neg z$	.8	.4

$h(X, Y, Z)$:

x, y, z	$.3 \times .2$	.6
$x, y, \neg z$	$.3 \times .8$	.24
$x, \neg y, z$	$.7 \times .6$	.42
$x, \neg y, \neg z$	$.7 \times .4$	.28
$\neg x, y, z$	$.9 \times .2$	.18
...	...	...

Eliminazione per Summing out

- Si elimina una variabile da un prodotto di fattori sommando le sottomatrici ottenute fissando la variabile a ognuno dei suoi valori
- Eliminare X da $\mathbf{h}(X, Y, Z)$ per summing out:

$$\begin{aligned}\mathbf{h}_2(Y, Z) &= \sum_x \mathbf{h}(X, Y, Z) = \mathbf{h}(x, Y, Z) + \mathbf{h}(\neg x, Y, Z) \\ &= \begin{pmatrix} .6 & .24 \\ .42 & .28 \end{pmatrix} + \begin{pmatrix} .18 & .72 \\ .06 & .04 \end{pmatrix} = \begin{pmatrix} .24 & .96 \\ .48 & .32 \end{pmatrix}\end{aligned}$$

Possibili ottimizzazioni – Safe pruning

- Ogni fattore che non dipende dalla variabile da eliminare con summing out può essere portato fuori dalle sommatorie
- Esempio: vogliamo eliminare X

$$\sum_x \mathbf{f}(X, Y) \times \mathbf{g}(Y, Z) = \mathbf{g}(Y, Z) \times \sum_x \mathbf{f}(X, Y)$$

- Le matrici non sono moltiplicate fino a quando non dobbiamo eliminare una variabile di conseguenza si moltiplicano solo le matrici che contengono la variabile da eliminare
- *si può fare ancora meglio osservando che qualsiasi nodo foglia che non è né variabile di query né di evidenza può essere ignorata $\Rightarrow$*

Possibili ottimizzazioni – Safe pruning

- Esempio: vogliamo calcolare $\mathbf{P}(\text{JohnCalls} | \text{Burglary} = \text{true})$
- Esplicitiamo le sommatorie nascoste

$$\mathbf{P}(J|b) = \alpha P(b) \times \sum_e P(e) \times \sum_a P(a|b, e) \times \mathbf{P}(J|a) \times \sum_m P(m|a)$$

- Si può vedere come $\sum_m P(m|a)$ è per definizione 1, e non serve portare la variabile M nel calcolo
- Del resto sappiamo che J e M sono indipendenti dato A , ed è proprio questo il caso.
- ricordando la topologia della rete, M è proprio un nodo foglia che non è né variabile di query né di evidenza e può quindi essere eliminata.

Possibili ottimizzazioni – Safe pruning

- Osservazione: la rimozione di un nodo foglia può dare origine ad un altro nodo foglia a sua volta eliminabile
- eliminazione è potenzialmente ricorsiva
- In generale: **ogni variabile che non è un progenitore di una variabile di query o di evidenza è irrilevante per risolvere l'interrogazione** [*Semantica locale*]

Possibili ottimizzazioni – Ordinamento delle variabili

- L'ordinamento delle variabili ha un impatto sull'albero di parsificazione della formula, e quindi sui fattori che vengono prodotti
- Il risultato finale non dipende dall'ordinamento scelto
- **MA**: ordinamenti diversi producono fattori intermedi diversi
- più grandi sono i fattori intermedi peggio è perché crescono esponenzialmente
- trovare ordinamento ottimale – che minimizza la dimensione dei fattori intermedi – è un problema intrattabile
- una possibile soluzione greedy è quella di eliminare prima la variabile che minimizza la dimensione del prossimo fattore da costruire

Most Probable Explanation (MPE)

Qual è l'istanza più probabile di tutte le variabili di dominio $\mathbf{X}$ data l'evidenza $\mathbf{e}$?

$$MPE(\mathbf{e}) = \operatorname{argmax}_{\mathbf{x}} \mathbf{P}(\mathbf{x}, \mathbf{e})$$

Maximum a Posteriori Probability (MAP)

Qual è l'istanza $\mathbf{m}$ più probabile per un sottoinsieme $\mathbf{M} \subseteq \mathbf{X}$ di variabili di query, data l'evidenza $\mathbf{e}$?

$$MAP(\mathbf{e}) = \operatorname{argmax}_{\mathbf{m}} \mathbf{P}(\mathbf{m}, \mathbf{e})$$