

Strategie di ricerca informate

In cui si superano le inefficienze delle strategie di ricerca blind utilizzando opportune funzioni di valutazione della bontà (o utilità) degli stati

Domanda

Le strategie di ricerca blind non sono efficienti. E' possibile rendere la ricerca più efficiente utilizzando della conoscenza sul problema? La conoscenza permette di focalizzare la ricerca verso le direzioni più promettenti?




Fig. 1.4 A search tree for the 8-puzzle.

Domanda

E' possibile utilizzare conoscenza sugli stati per focalizzare la ricerca dell'obiettivo?





Fig. 1.4 A search tree for the 8-puzzle.

Esempio: numero di tessere al loro posto

Il contesto: grafi di ricerca

- Un grafo di ricerca è una coppia costituita da due insiemi, un insieme di nodi e un insieme di archi: $G = (\{n_i\}, \{e_{ij}\})$
- n_i : nodo
- e_{ij} : arco da n_i a n_j , la sua esistenza non implica che esista anche e_{ji}
- Ogni arco e_{ij} ha un costo c_{ij}
- Grafo dato implicitamente tramite un operatore successore gamma Γ , che restituisce i nodi successore di quello dato con i costi dei relativi archi: $\Gamma(n_i) = \{(n_i, c_{i1}), \dots, (n_i, c_{ik})\}$
- G_s indica il grafo sviluppato applicando ricorsivamente Γ a partire dal nodo iniziale s
- Cammino $(n_1, n_2, \dots, n_k)$ insieme ordinato di nodi in cui n_{i+1} è un successore di n_i
- Costo di un cammino: somma dei costi degli archi che lo compongono

Il problema



Si vuole determinare una soluzione che permetta di raggiungere, da un nodo iniziale dato, uno fra un insieme di nodi obiettivo

I passi, e quindi i percorsi, hanno un costo

Si vuole determinare un percorso di costo minimo in modo efficiente, cioè evitando per quanto possibile di espandere nodi che non portano a questo risultato

Se esiste almeno un cammino che collega il nodo iniziale a un nodo goal allora l'algoritmo deve restituire una soluzione

Per **soluzione** si intende il percorso che collega i due nodi

Frontiera: insieme dei nodi generati ma non ancora espansi

Funzioni di valutazione e funzioni euristiche


- Una strategia di ricerca informata ordina la frontiera sulla base di una funzione di valutazione $f(n)$ applicata ai nodi:
 - A seconda di come è definito $f(n)$ si ottengono strategie differenti
 - Spesso $f(n)$ comprende una componente $h(n)$ che restituisce una *stima del minimo fra i costi dei percorsi che congiungono lo stato corrispondente al nodo n a uno stato goal*
 - $h(n)$ è detta euristica
- La strategia generale è detta best-first search in quanto verrà espanso per primo lo stato “più promettente”
- Si tratta di una famiglia di strategie che comprende tutte quelle che studieremo (greedy, A^* , RBFS)

1. Ricerca greedy (avida)


- $f(n) = h(n)$
- Viene scelto il nodo stimato più vicino a quello obiettivo
 - Esempio: se gli stati sono località delle quali si hanno le coordinate, è possibile calcolare la distanza in linea d'aria tra due stati e usarla come stima della vicinanza (su strada) fra due località
- Problemi?

1. Ricerca greedy (avida)

- **Problemi?**
- In linea d'aria:
 - $(B, G) = 5$
 - $(C, G) = 7$
 - quindi $(B, G) < (C, G)$
- ma seguendo le strade:
 - $(B, G) = 10$
 - $(C, G) = 7$
 - Quindi $(B, G) > (C, G)$
- Inoltre: Rischio di loop per vicoli ciechi
- Difetti della ricerca in profondità



1. Ricerca greedy esempio



1. Ricerca greedy ancora peggio


Balme – Noasca:
linea d'aria: 18Km
Su strada: 91Km



- Combinare la ricerca a costo uniforme con la ricerca greedy:
 - **Costo uniforme**: espande per primi i nodi il cui raggiungimento dalla radice costa meno (guarda al passato)
 - **Ricerca greedy**: espande per primi i nodi che promettono di raggiungere l'obiettivo spendendo meno (guarda al futuro)

A* e obiettivi preferiti

- A* considera grafi, generati a partire da un singolo nodo iniziale, in cui un sottoinsieme **T** di nodi è costituito da **nodi obiettivo** (T sta per target).
- Dato un qualsiasi nodo n del grafo, un obiettivo t è detto **preferito per n** se e solo se il costo del cammino ottimo $h(n, t) \leq$ costo di qualsiasi altro cammino da n verso qualsiasi altro nodo di T .
- Si indica con $h(n)$ il costo di questo cammino ottimo quindi $h(n) = \min_t (h(n, t))$.



- Tutti i nodi $t_j \in T$
- $\forall t_j \neq t_i \ h(n, t_j) \geq h(n, t_i)$
- $h(n, t_i)$ è indicato con $h(n)$

A* e obiettivi preferiti


- A* considera grafi, generati a partire da un singolo nodo iniziale, in cui un sottoinsieme **T** di nodi è costituito da **nodi obiettivo** (T sta per target).
- Dato un qualsiasi nodo n del grafo, un obiettivo t è detto **preferito per n** se e solo se il costo del cammino ottimo $h(n, t) \leq$ costo di qualsiasi altro cammino da n a qualsiasi altro nodo di T .
- Si indica con $h(n)$ il costo di questo cammino ottimo quindi $h(n) = \min_t (h(n, t))$.
- In altri termini un nodo obiettivo è **preferito per n quando è uno dei nodi obiettivo più economici da raggiungere da n** .
- Prima vediamo lo pseudocodice di A* poi vediamo com'è fatta la funzione di valutazione

A* pseudocodice

- Sia s il nodo iniziale
- Sia T l'insieme dei nodi obiettivo (target)
- segna s come **APERTO** e calcola $f(s)$;
- seleziona il nodo **APERTO** n avente valutazione minima (i pari merito dovrebbero essere risolti a vantaggio degli eventuali $t \in T$);
- se n appartiene a T , marca n **CHIUSO** e termina;
- altrimenti marca n **CHIUSO** e applica l'operatore successore Γ a n e:
 - calcola il valore di f per tutti i successori n' ;
 - marca come **APERTI** quei successori n' che non risultano già **CHIUSI**;
 - rimarca come **APERTI** quei successori n' che erano **CHIUSI** ma per cui è stato calcolato un valore f più basso di quello calcolato in precedenza (cioè sono stati raggiunti tramite un percorso migliore)


2. Ricerca A* (a star)

- $f(n) = g(n) + h(n)$
 - $g(n)$ = costo minimo di tutti i percorsi, visti fino ad ora, che consentono di raggiungere il nodo n a partire dallo stato iniziale s
 - $h(n)$ = stima del costo minimo del proseguimento di percorso che consente di raggiungere un goal preferito di n
 - $f(n)$ = stima del costo minimo per raggiungere un goal preferito di n partendo da s




f come stima di f^*

- $f^*(n) = g^*(n) + h^*(n)$
 - costo vero del cammino risolutore ottimo (nel caso esista)
 - $g^*(n)$ = costo minimo per raggiungere il nodo n a partire dallo stato iniziale s (calcolato considerando tutti i cammini possibili)
 - $h^*(n)$ = costo minimo reale del proseguimento di percorso che consente di raggiungere un goal preferito a partire dal nodo n
 - $f^*(n)$ = costo minimo per raggiungere un goal preferito di n da s



A*: esempio della Romania

- Si consideri la seguente mappa semplificata della Romania e si supponga di dover andare da Arad a Bucharest
- La mappa contiene le distanze fra le varie città collegate direttamente da strade (esempio: distanza fra Sibiu e Fagaras è 99Km)
- È possibile spostarsi da una città a una vicina e il costo è dato dai Km percorsi



Esempio della Romania: euristica

- Sia l'euristica la distanza in linea d'aria fra ciascuna città e la destinazione Bucharest (misure riportate in tabella)
- Si noti che la distanza in linea d'aria è una stima ottimistica


Arad	366	Mehadia	241
Bucharest	0	Neant	234
Craiova	160	Oradea	380
Drobeta	242	Pitesti	100
Eforie	161	Rimnicu Vilcea	193
Fagaras	176	Sibiu	253
Giurgiu	77	Timisoara	329
Hirsova	151	Urziceni	80
Iasi	226	Vaslui	199
Lugoj	244	Zerind	374

Uso di A* 1/3

(a) The initial state




(b) After expanding Arad



Distanza su strada fra Arad e Sibiu


Distanza linea d'aria fra Sibiu e Bucharest

(c) After expanding Sibiu




Uso di A* 2/3

(d) After expanding Rimnicu Vilcea




(e) After expanding Fagaras



Uso di A* 3/3

(f) After expanding Pitesti

(f) After expanding Pitesti



Euristiche ammissibili

Una funzione euristica h è detta **ammissibile** quando $\forall n$, $h(n) \leq h^*(n)$ dove $h^*(n)$ è il costo minimo reale per raggiungere il nodo goal a partire dal nodo n

- Intuitivamente un'euristica è ammissibile quando non fa mai stime per eccesso, è ottimistica
- **Esempio:** la distanza in linea d'aria è un'euristica ammissibile rispetto alla distanza su strada

Ottimalità dell'algoritmo A^*

- Si dimostra che quando:

- 1) l'euristica h è ammissibile
- 2) e tutti i passi hanno un costo maggiore di una costante positiva piccola a piacere


- Allora:

- **A^* termina e trova una soluzione ottima** (di costo minimo)
- In altri termini in questo caso **A^* è completo e ottimale**

A* ottimale per alberi di ricerca

- **Nota:** in un albero di ricerca ogni nodo ha un solo cammino assoluto
- Perché manchi l'ottimalità deve accadere che durante la ricerca l'algoritmo:
 - scelga un nodo obiettivo sub-ottimo (G2)
 - al posto di un nodo (n)
 - che si trova su un cammino ottimo (che porta al goal G)
- Dimostriamo che in un albero di ricerca ciò non può capitare laddove l'euristica è ammissibile e i passi hanno costo non nullo

A* ottimale per alberi di ricerca




$$f^*(G) = g^*(G) + h^*(G) = C^*$$

G

G2

- Chiamiamo:
 - **G2** = obiettivo subottimo
 - **C*** il costo reale della soluzione ottima

A* ottimale per alberi di ricerca



Consideriamo G2:

$$f(G2) = g(G2) + h(G2) > C^*$$


1) $h(G2) = 0$ perché G2 è un nodo obiettivo

2) $f(G2) = g(G2) + h(G2) = \mathbf{g(G2) + 0 = g(G2)}$

3) Poiché per assunto G2 è subottimo, si ha che:

$$\mathbf{f(G2) = g(G2) > C^*}$$


A* ottimale per alberi di ricerca



Sia **n** un **generico nodo** appartenente a un **cammino ottimo**:


- **$g^*(n) = g(n)$** perché lavoriamo su di un albero e ogni nodo è raggiungibile dalla radice lungo un solo percorso

A* ottimale per alberi di ricerca



- **h** è **ammissibile** per ipotesi, quindi **$h(n) \leq h^*(n)$**
- Quindi: **$f(n) = g(n) + h(n) \leq g^*(n) + h^*(n) = C^*$**
- Quindi **$f(n) \leq C^* < f(G2)$**


A* ottimale per alberi di ricerca



- Quindi:
 - 1) $f(n) < f(G2)$
 - 2) **A* sceglie il nodo aperto con $f(.)$ minima,**
- Di conseguenza fra n e G2 verrà scelto n (q.e.d.)

A* ottimale per grafi di ricerca

- **Nei grafi vi è molteplicità di cammino:**
il primo cammino trovato durante la ricerca che porta a un certo stato non è necessariamente quello ottimo (nota: nell'esempio della Romania A* non si ferma quando incontra Bucarest la prima volta)
- **Questa proprietà invalida la precedente dimostrazione!**
- La dimostrazione generale è piuttosto complessa, occorre aggiungere l'ipotesi che **h** sia **monotona** (o consistente), cioè che dati un qualsiasi nodo n e un qualsiasi suo successore n' prodotto eseguendo l'azione a in n vale che **$h(n) \leq c(n, a, n') + h(n')$**
- Tale disuguaglianza è una disuguaglianza triangolare



A* ottimale per grafi di ricerca

- Si dimostra che quando l'**euristica è monotona**, per la disuguaglianza triangolare i **costi $f(n)$** lungo un cammino **sono non decrescenti**
- **A* espande i nodi in ordine non decrescente di f :**
 - se un nodo CHIUSO viene incontrato più volte lungo un percorso, i nuovi valori di f saranno superiori a quello calcolato la prima volta (cfr. Arad nell'esempio della Romania)
 - Di conseguenza sono i primi incontri con i nodi obiettivo che permettono di individuare una soluzione ottima
- Su questo assunto si dimostra l'ottimalità

A* ottimale per grafi di ricerca

- Dimostriamo che se l'euristica è monotona, i costi di $f(n)$ lungo un cammino sono non decrescenti:

1) Sia n' un nodo successore di n , per definizione:

$$g(n') = g(n) + c(n, a, n')$$

2) Sempre per definizione:

$$f(n') = g(n') + h(n')$$

3) E sostituendo $g(n')$:

$$f(n') = g(n) + c(n, a, n') + h(n')$$

A* ottimale per grafi di ricerca

4) Applichiamo ora la disuguaglianza triangolare:

$$f(n') = g(n) + c(n, a, n') + h(n') \geq g(n) + h(n)$$


5) Sappiamo però che, per definizione: $g(n) + h(n) = f(n)$

6) Di conseguenza: $f(n') \geq f(n)$ (q.e.d.)

Euristiche e impatto sulla ricerca

Euristiche monotone e ammissibili

- La **monotonicità** è una proprietà più stringente dell'**ammissibilità**
 - Si dimostra che **un'euristica monotona è anche ammissibile**
 - Spesso ma non sempre le euristiche ammissibili sono anche monotone



Esempio di euristica monotona

- La **distanza in linea d'aria** è un'euristica:
 - **ammissibile** e **monotona** per il problema della Romania, infatti data una città (genericamente indicata da luogo) e un suo possibile successore (indicato da luogo1) avremo sempre che:

$$h(\text{luogo}) < c(\text{luogo}, \text{vai}, \text{luogo1}) + h(\text{luogo1})$$

- Cioè la distanza in linea d'aria da luogo a Bucharest è minore della distanza via terra fra luogo e il confinante luogo1 più la distanza in linea d'aria da luogo1 a Bucharest

Ammissibile non vuol dire informativo !!

- $h(n) = 0$ è un'euristica sempre ammissibile ma non è informativa della desiderabilità degli stati
 - Permette di valutare solo il costo del percorso fatto per raggiungere un nodo
 - La ricerca **diventa cieca** e richiede l'**espansione di un maggiore numero di nodi** rispetto a usare un'euristica ammissibile e informativa
- In particolare se abbiamo inoltre che tutte le operazioni che permettono di passare da un nodo a un successore hanno costo uniforme pari a 1, **A*** diventa una ricerca in ampiezza