

Classificazione

Materiale parzialmente tratto dalle slide associate al libro: Introduction to Data Mining di Tan, Steinbach, e Kumar

Il problema




Il problema

- Le classi non esistono
- Non sono insite negli esempi (o istanze)
- Non si tratta di raggruppamenti naturali inequivocabili
- Sono definite a tavolino e **dipendono dal fine** per il quale si vuole costruire il predittore


Raggruppamento per colore



Raggruppamento per forma




Fiori finti e fiori veri




Il problema

- **Dati:**
 - **Esempi** (fiori)
 - Categorie o classi (fiori finti/fiori veri, fiori rosa/gialli/bianchi/rossi, ...)
 - **Costruire:**
 - Una rappresentazione astratta (**modello**) che permetta di associare in modo corretto nuove istanze alla classe (o alle classi) di appartenenza
- **Apprendimento supervisionato:** gli esempi dal quale astrarre le definizioni delle classi hanno associata la classe a cui appartengono
 - 1) Problema di rappresentazione dei dati
 - 2) Problema di analisi dei dati e costruzione delle definizioni
 - 3) Problema di utilizzo della conoscenza acquisita


Schema generale




Schema generale



Schema generale




Schema generale




Learning (o training) set

Per **learning** (o training) **set** si intende la collezione di dati usati per svolgere il compito di apprendimento. I dati sono divisi in **istanze** (o record o esempi). Ogni esempio è rappresentato da una **tupla** ($\bar{x}$, y) dove $\bar{x}$ è a sua volta una tupla di valori di **attributi descrittivi** e y è la **classe** di appartenenza dell'istanza



nome	temperatura	Copertura pelle	viviparo	Creatura acquatica	Creatura volatile	zampe	letargo	CLASSE
uomo	Sangue caldo	peluria	sì	no	no	sì	no	mammifero
pitone	Sangue freddo	squame	no	no	no	no	sì	rettile
salmone	Sangue freddo	squame	no	sì	no	no	no	pesce
balena	Sangue caldo	peluria(?)	sì	sì	no	no	no	mammifero
rana	Sangue freddo	nessuna	no	semi	no	sì	sì	anfibia
pinguino	Sangue caldo	piumaggio	no	semi	no	sì	no	uccello
piccione	Sangue caldo	piumaggio	no	no	sì	sì	no	uccello



Nota:

Come classe si usano attributi binari o categorie nominali

Sì no
1 0
Vero falso

Etichette:
es. Mammifero, pesce, ...

Usi dei Modelli appresi

Modello predittivo

Viene usato per predire la classe di appartenenza di istanze ignote in fase di apprendimento

Es. data la descrizione di una salamandra (sangue freddo, nessuna, no, semi, no, sì, sì) si usano le regole apprese per decidere a quale classe appartiene

Modello descrittivo

Viene usato come strumento esplicativo che permette di evidenziare quali caratteristiche distinguono le diverse categorie

Esprime in maniera sintetica delle descrizioni evitando di ragionare direttamente sugli esempi

Es. i mammiferi hanno il sangue caldo e solitamente non sono esseri acquatici

Test set

Qual è la bontà dei modelli appresi?

Valutazione sperimentale: il modello viene usato per classificare le istanze di un *test set*. La valutazione della bontà è fatta sulla base del comportamento di classificazione corretto/sbagliato su questi dati

Matrice di confusione:

		<i>classe predetta</i>	
		Classe 1	Classe 2
<i>classe reale</i>	Classe 1	f11	f12
	Classe 2	f21	f22

Errori !!

Predizioni corrette

Accuratezza ed error rate

$$\text{Accuratezza} = \frac{f_{11} + f_{22}}{f_{11} + f_{22} + f_{12} + f_{21}}$$

Predizioni
correttePredizioni
totali

$$\text{Error rate} = \frac{f_{12} + f_{21}}{f_{11} + f_{22} + f_{12} + f_{21}}$$

Predizioni
sbagliatePredizioni
totali

Matrice di confusione: esempio

	<i>classe predetta</i>	
	<i>lattina</i>	<i>altro ogg.</i>
<i>lattina</i>	18	2
<i>altro ogg.</i>	1	19

Accuratezza: $(18 + 19) / 40 = 92.5\%$

Error rate: $3 / 40 = 7.5\%$

Matrice dei costi

		<i>classe predetta</i>	
		Classe 1	Classe 2
<i>classe reale</i>	Classe 1	c1	c2
	Classe 2	c3	c4

Costi degli errori !!

Costi delle valutazioni corrette

Matrice dei costi: esempio

		<i>classe predetta</i>	
		Classe 1	Classe 2
<i>classe reale</i>	Classe 1	-1	50
	Classe 2	10	0

Ogni istanza di classe 1 correttamente classificata riduce il costo complessivo; sbagliare a classificare gli oggetti di classe 1 è molto costoso; sbagliare a classificare gli oggetti di classe 2 è meno grave

Esempio: è più grave dire a un malato che è sano o dire a una persona sana che è malata?



Matrice dei costi: esempio d'uso

COSTI		classe predetta	
		Classe 1	Classe 2
classe reale	Classe 1	-1	50
	Classe 2	10	0

Mat. Conf.		classe predetta	
		lattina	altro ogg.
classe reale	lattina	18	2
	altro ogg.	1	19


$$\text{Costo} = -1 \times 18 + 50 \times 2 + 1 \times 10 + 0 \times 19 = 92$$

Usi della classificazione (esempio)



Identificazione degli stati meteorologici

Usi della classificazione (esempio)



Classificazione della struttura
secondaria delle proteine
(alpha-helix, beta sheet, random
coil)

Usi della classificazione (esempio)




Uso lecito o fraudolento
in transazioni on-line con
carta di credito



Apprendimento

Rote learning (apprendimento meccanico)

Strategia: memorizzare le istanze




att1	att2	att3	att4	classe
a	b	b	d	A
a	f	b	b	B
b	b	c	d	A
c	c	d	f	C

MODELLO: non esiste in senso proprio
Il sistema ricorda dei “casi”, non generalizza

att1	att2	att3	att4	classe
a	b	b	d	A
a	f	b	b	B
b	b	c	d	A
c	c	d	f	C

MEMORIA




< a, f, b, b >

ISTANZA

Tramite confronti cerca un'istanza identica, se la trova restituisce la classe corrispondente

att1	att2	att3	att4	classe
a	b	b	d	A
a	f	b	b	B
b	b	c	d	A
c	c	d	f	C

MEMORIA



< a, f, b, d >

ISTANZA


Se non la trova prova a indovinare:

Cerca istanze simili

Misura di distanza come misura di similitudine
(vicino = simile)

att1	att2	att3	att4	classe
a	b	b	d	A
a	f	b	b	B
b	b	c	d	A
c	c	d	f	C

MEMORIA



< a, f, b, d >

ISTANZA


Se non la trova prova a indovinare:

Cerca istanze **simili** ...:

se le loro classi sono identiche, quello è l'output

att1	att2	att3	att4	classe
a	b	b	d	A
a	f	b	b	B
b	b	c	d	A
c	c	d	f	C

MEMORIA



< a, f, b, d >

ISTANZA

Se non la trova prova a indovinare:

Se **sono diverse** occorre attuare una strategia per comporre il risultato, es.

- **Votazione a maggioranza:**
corrispondenza = voto, la classe più votata vince
- **Votazione pesata:**
ogni voto ha un peso maggiore/minore a seconda della “distanza” fra le istanze considerate

- In caso di votazione pesata, i pesi vengono calcolati, usati e poi dimenticati

Generalizzazione di un modello

- Algoritmi di apprendimento diversi producono **modelli di tipo diverso**:
 - Alberi di decisione: albero
 - Sistemi a regole: insiemi di regole if-then
 - Reti neurali: matrici di numeri
 - Apprendimento per rinforzo: distribuzioni di probabilità e matrici di numeri
 - ...

Avvertenze prima dell'uso

- Un algoritmo di apprendimento impara **quello che c'è nei dati per come sono etichettati**, non quello che chi ha costruito i dati immagina ci sia
- **RICORDARE SEMPRE** che le classi **esistono solo nella mente** di chi usa il sistema
- Il sistema non ha altra conoscenza oltre ai dati
- Attenzione ai numeri! Richiedono competenza

Il mio classificatore è fantastico!!!!

Ha un'accuratezza del 99.9% !!!
(error rate pari a 0.1%)



WOW?

Attenti al LS e ai numeri ...

LEARNING SET

Istanze di classe A: 9990

Istanze di classe B: 10

Il classificatore ha costruito la regola “**if (TRUE) then classe A**” quindi restituisce sempre: *l'istanza è di classe A*

Accuratezza: $9990/10000 = 0.999$!!
(su LS)

Error rate: $10 / 10000 = 0.001$
(su LS)



Non ha
imparato
nulla

- **Esempio:** riconoscere “frutta” da altre cose

Esempio

- Servono dei dati

Esempio

- Servono dei dati



Eccoli !

Esempio

- Servono dei dati



Esempio


- Servono dei dati



Modello di frutta (?)

Esempio

- Modello troppo povero
- Insufficiente, riconosce solo le mele



Perché si fanno questi errori?

- I dati sono difficili da reperire
- Risorse disponibili + fretta (es. archivio fotografico coldiretti di una certa area, es. Trentino Alto Adige)
- Bias mentale (se vivo circondato dai meleti non mi sembra strano usare foto di mele, non mi vengono in mente uva o ciliegie)
- Attribuire all'algoritmo i meccanismi umani: noi siamo bravi a generalizzare, più di un software, e usiamo moltissima conoscenza senza rendercene conto (es. è prodotto da una pianta dall'impollinazione di un fiore, allora è un frutto)

Un passo oltre la frutta ...

- Fotografia: riconoscere i **volti delle persone**
- Decidere se **concedere un mutuo** (un rischio per la banca)
- Decidere se **concedere un'assicurazione sanitaria**
- **Applicazioni militari** (es. riconoscimento automatico di un obiettivo)
- Applicazioni civili, **tecnologie see and spray**: identificare le piante con parassiti per limitare irrorazione di insetticidi

... applicazioni reali (esempi)

- Volti: <https://www.luxand.com/facesdk/>
- Mutui: <https://www.app0.io/blog/ai-in-lending>
- Salute: <https://research.aimultiple.com/ai-health-insurance/>
- Militari: https://en.wikipedia.org/wiki/Automatic_target_recognition
- Agricoltura: <https://www.deere.com/en/sprayers/see-spray-ultimate/>

(aggiornati maggio 2024)

Responsabilità? Esempio


- **Trolley problem** adattato alla guida autonoma
 - Un bambino attraversa la strada all'improvviso
 - Se l'auto non frena lo investe
 - Se frena, data la velocità, l'incidente può mettere a rischio l'incolumità dei viaggiatori
 - Se sterza finisce sul marciapiede di cui non ha percezione (c'è qualcuno?)
- **Di chi è la responsabilità della decisione** di un agente autonomo?
- Problem of the many hands

Esempio

<https://ndpr.nd.edu/reviews/moral-responsibility-and-the-problem-of-many-hands/>

Induzione di alberi di decisione

Alberi di decisione




Sono strumenti di supporto alle decisioni che usano modelli strutturati ad albero, comunemente utilizzati per esempio per la definizione di strategie mirate al conseguimento di un goal

Esistono da tempi immemorabili

Hanno moltissime applicazioni. Per esempio la struttura di navigazione di molti negozi on-line implementa un albero di decisione (ti interessa un libro, un film o un gioco?)

Fonte: wikipedia

Alberi di decisione




Noi studieremo un metodo che consente di indurre da esempi degli alberi di decisione da utilizzare in compiti di classificazione

MODELLO = albero

Fonte: wikipedia



Struttura degli alberi di decisione



NODI INTERNI: test

FOGLIE: decisioni

Struttura degli alberi di decisione



Iris: 3 classi



Iris virginica (1)



Iris setosa (2)



Iris versicolor (3)

ATTRIBUTI: petal width, petal length, sepal width, sepal length (di tipo continuo)

Dataset: <https://archive.ics.uci.edu/dataset/53/iris>

(1) By Eric Hunt - Own work, CC BY-SA 4.0, <https://commons.wikimedia.org/w/index.php?curid=72555262>

(2) By w:ru:Денис Анисимов (talk | contribs) - Own work by the original uploader, Public Domain, <https://commons.wikimedia.org/w/index.php?curid=57593826>

(3) By D. Gordon E. Robertson - Own work, CC BY-SA 3.0, <https://commons.wikimedia.org/w/index.php?curid=10227368>

Esempio albero di decisione

