

Algoritmi di apprendimento

- Alcuni algoritmi per l'apprendimento di alberi di decisione:
 - **Algoritmo di Hunt**
 - ID3, C4.5
 - CART
 - ...

Algoritmo di Hunt

L'albero viene costruito procedendo *ricorsivamente* e suddividendo il learning set in sottoinsiemi *via via più "puri"*. Il generico passo di suddivisione di un nodo dell'albero esegue questi passi:

Dati:

D_t = sottoinsieme del learning set associato al nodo t

$y = \{y_1, y_2, \dots, y_c\}$ = insieme delle etichette che identificano le classi

passo 1: se tutte le istanze in D_t appartengono alla stessa classe y_t allora il nodo è una foglia etichettata dalla classe y_t delle sue istanze

passo 2: si sceglie un attributo fra quelli che descrivono le istanze, si produce un nodo figlio per ogni possibile valore dell'attributo (il range è dato dal learning set?).

A ciascun nodo figlio si associa uno specifico valore e si associano ad esso anche quelle istanze, già associate al padre, per le quali l'attributo assume il valore corrispondente al nodo

Algoritmo di Hunt

nota 1: se una certa combinazione di valori non è rappresentata da nessuna istanza, questa sarà associata alla classe di default (se esiste)


nota 2: se tutte le istanze associate a un nodo sono identiche come tuple ma corrispondono a classi differenti (non-determinismo), il nodo non può essere scisso.

Diventa una foglia che ha associata la classe più rappresentata

nota 3: quando si termina la costruzione dell'albero?

nota 4: come si sceglie l'attributo di split?


Split = suddividere il learning set



In generale ...

- **Strategia greedy**
 - Gli attributi su cui effettuare gli split sono selezionati in modo da massimizzare una qualche misura di riferimento
- **Problemi:**
 - Come **specificare la condizione di test** sugli attributi scelti?
 - *Attributi binari*
 - *Attributi nominali*
 - *Attributi ordinali*
 - *Attributi continui*
 - Come **determinare lo split migliore?**
 - **Quando fermarsi** nella costruzione dell'albero?

Split su attributi binari



La risposta non può che essere sì oppure no

Il nodo corrente avrà due figli a seconda del valore rappresentato. Gli esempi associati al nodo radice verranno suddivisi fra i due figli a seconda del valore riportato in corrispondenza dell'attributo

Altri esempi: animale acquatico, volatile, a sangue caldo, ...


Split su attributi nominali

L'attributo assume valori su un insieme (finito) di etichette $\{L1, L2, \dots, Ln\}$

Gli split possono essere **binari** oppure **multivalore**


Split su attributi nominali

Split multivalore: il nodo avrà tanti figli quanti sono i possibili valori dell'attributo



Split su attributi nominali

Split binari: il nodo avrà due figli, uno corrisponde a un valore, l'altro all'insieme dei rimanenti valori




Ci sono $2^{k-1} - 1$ possibili alternative se l'attributo ha k valori alternativi possibili


Split su attributi ordinali

Anche in questo caso si possono avere split binari o multivalore con un vincolo: il raggruppamento dei valori deve rispettare l'ordinamento

Esempio: supponiamo di avere le misure $small < medium < large < extralarge$




Corretto!! $A < B$



Errato!! $C ?? D$


Split binari di attributi continui

In questo caso il test prevedono l'identificazione di un valore possibile v per l'attributo A in questione




Split multivalore di attributi continui

In questo caso il test prevedono l'identificazione di un insieme di valori v_i per l'attributo A in questione e la produzione di una serie di test $v_i \leq A < v_{i+1}$



Occorre **discretizzare** la variabile continua identificando un numero finito di intervalli significativi di valori

Quale split?



Supponiamo di dover costruire un DT che consenta di distinguere sedie da tavoli.
È indifferente l'ordine con il quale scegliamo di effettuare gli split?

Partire da *materiale* da *ruote* oppure da *schienale* fa qualche differenza?

Bontà degli split


Criterio generale: alberi compatti sono preferiti ad alberi che consentono di raggiungere lo stesso grado di accuratezza (e di error rate) usando un maggior numero di test

Rasoio di Occam: a parità di assunzioni, la spiegazione più semplice è da preferire

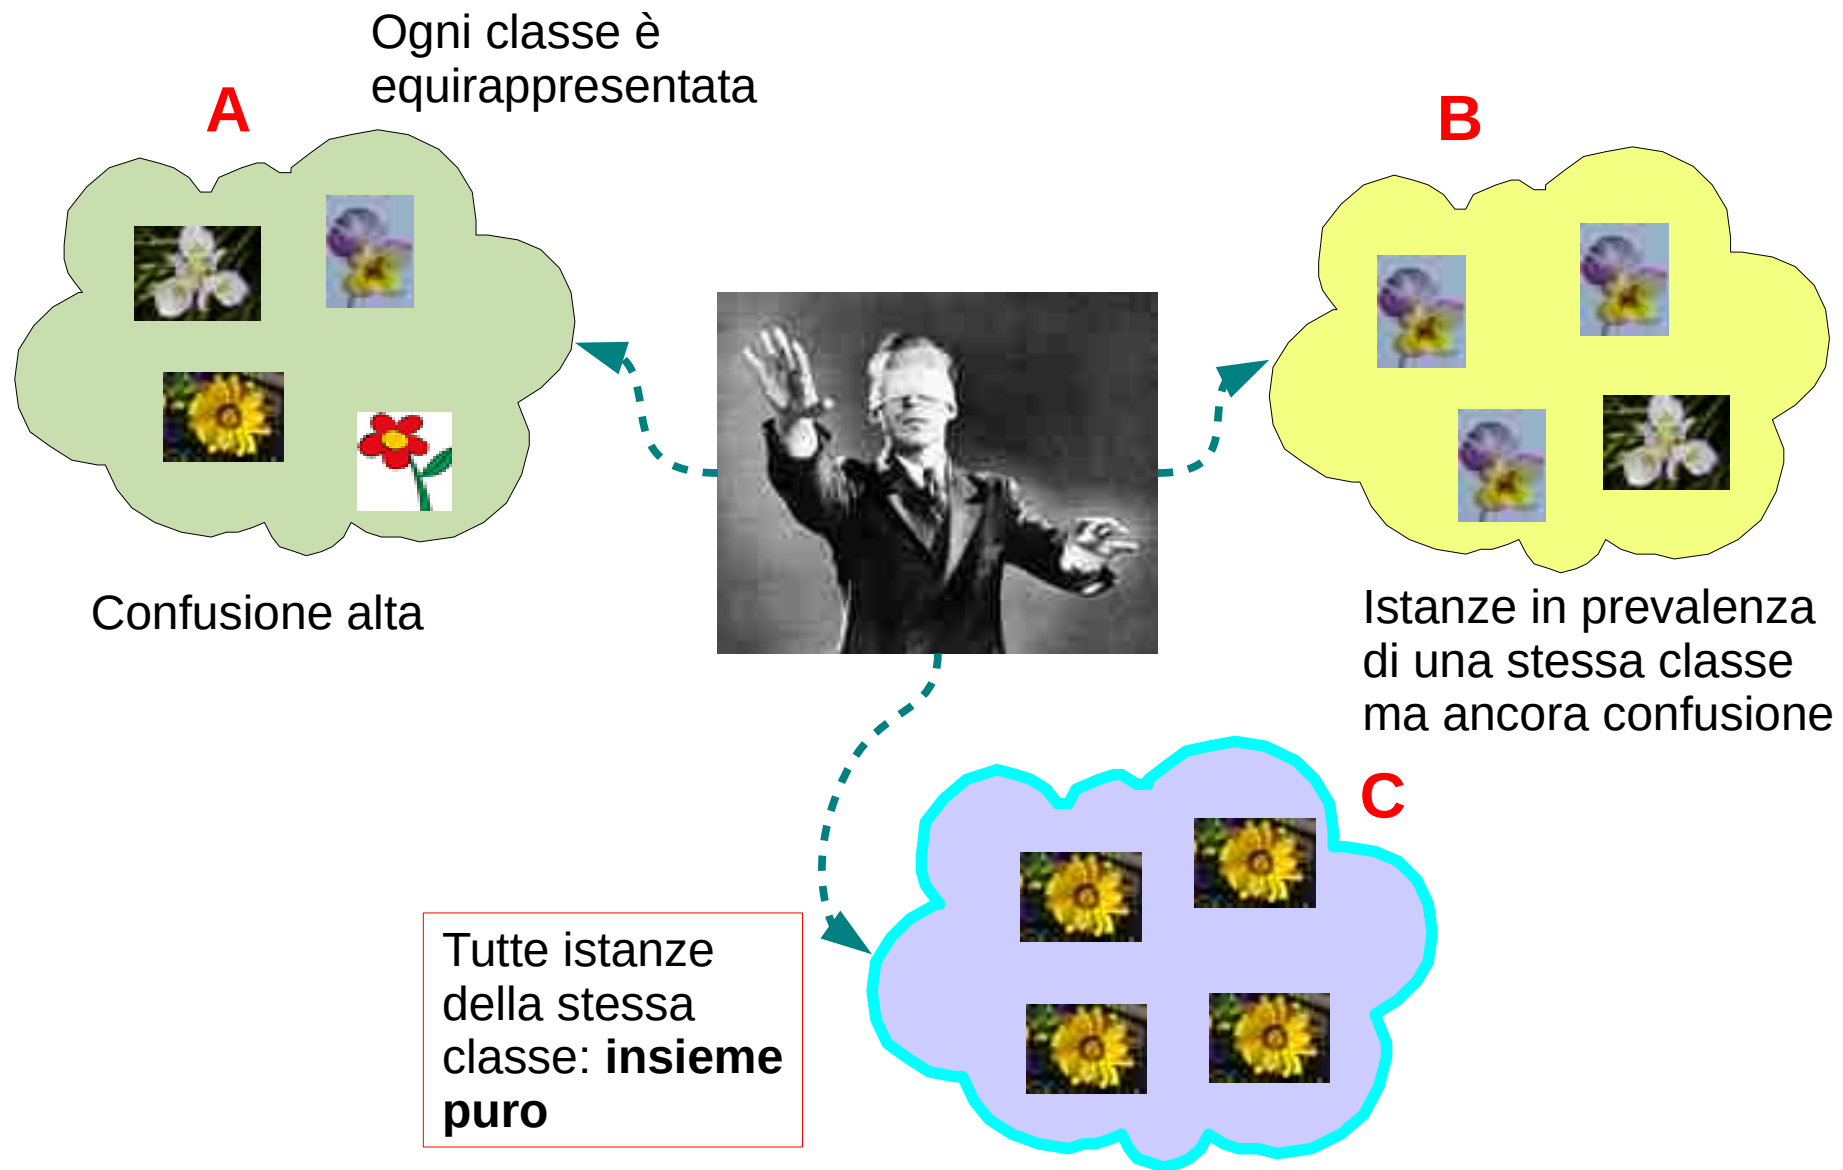


William of Ockham


Misure per determinare la bontà di uno split




Misure per determinare la bontà di uno split



È meglio questo split ...



... o questo split?



Criterio generale

- Sono preferiti gli split che producono nodi figli la cui estensione prevede minore confusione (il cui grado di purezza è maggiore)
- Misure alternative:
 - *Entropia*
 - *Gini*
 - *Errore di classificazione*

Base delle misure di selezione


Dato un nodo t , sia $p(i | t)$ la probabilità che un elemento estratto casualmente dall'insieme sia di classe i

$$p(\text{viola} | t) = 0.5 \quad (2 \text{ su } 4)$$

$$p(\text{iris} | t) = 0.25 \quad (1 \text{ su } 4)$$


$$p(\text{finto} | t) = 0.25 \quad (1 \text{ su } 4)$$

$(0.5, 0.25, 0.25)$ è la **distribuzione di probabilità** di appartenenza di un record estratto a caso dall'estensione associata al nodo t a una delle classi in questione



Entropia

$$Entropia(t) = - \sum_{i=0}^{c-1} p(i|t) \log_2 p(i|t)$$



Per ogni classe

Probabilità che l'elemento appartenga alla classe i-ma

Assunto nel calcolo dell'entropia: $0 \log_2 0 = 0$

Entropia

$$Entropia(t) = - \sum_{i=0}^{c-1} p(i|t) \log_2 p(i|t)$$

Assunto nel calcolo dell'entropia: $0 \log_2 0 = 0$

Supponiamo di avere due sole classi:


le distribuzioni (0, 1) e (1, 0) sono le migliori, purezza massima dell'insieme, nessuna confusione. Calcoliamo per il caso **(0, 1)**

Entropia: $-0 \log_2 0 - 1 \log_2 1 = 0$

La distribuzione **(0.5, 0.5)** è la peggiore, massimo grado di confusione:

Entropia: $-0.5 \log_2 0.5 - 0.5 \log_2 0.5 = -\log_2 2^{-1} = 1$

Misure: confronto




Valore dell'entropia per una sorgente binaria

Calcolo del guadagno

Problema della scelta dello split: valuto i diversi split che posso fare, usando attributi diversi, tramite una delle misure viste e scelgo quello che mi restituisce il risultato col minor grado di confusione


Misura del risultato di uno split:



Dall'impurità del nodo genitore viene sottratta la media pesata delle impurità dei nodi figli. Di solito la misura dell'impurità è scelta in modo tale da minimizzare l'impurità / massimizzare il guadagno

Spiegazione della formula


$$\Delta = I(\text{parent}) - \sum_{j=1}^k \frac{N(v_j)}{N} I(v_j)$$




NODI FIGLI, IMMAGINANDO DI FARE LO SPLIT SU A

Spiegazione della formula


$$\Delta = I(\text{parent}) - \sum_{j=1}^k \frac{N(v_j)}{N} I(v_j)$$



$N(v_j)$:
cardinalità
di questo
insieme



La porzione di D_t associata al generico nodo figlio j -mo avrà in A valori tutti uguali fra di loro (indichiamo tale valore con v_j)



N : numero istanze
in D_t

NB: la colonna A contiene valori diversi, alcuni sono uguali a v_j altri no. Questi dati vengono distribuiti fra i figli quando si fa lo split

Information gain

Per **information gain** si intende una misura del guadagno ottenuta usando l'**entropia** come valore dell'impurità dei nodi:

$$\Delta = \text{entropia}(\text{parent}) - \sum_{j=1}^k \frac{N(v_j)}{N} \text{entropia}(v_j)$$

Information gain

Per **information gain** si intende una misura del guadagno ottenuta usando l'**entropia** come valore dell'impurità dei nodi:

$$\Delta = \text{entropia}(\text{parent}) - \sum_{j=1}^k \frac{N(v_j)}{N} \text{entropia}(v_j)$$

Nota: le misure del grado di confusione, come Gini ed entropia tendono a favorire attributi che hanno *molti valori diversi* rispetto ad attributi con *pochi valori* alternativi

Osservazione: un *identificatore univoco* (es. un numero di matricola) annulla l'entropia (ogni nodo figlio conterrà una sola istanza) ma non è un attributo significativo!

Possibile soluzione: usare solo split binari