Tecnologie del Linguaggio Naturale

Parte Prima

A.A. 2025/2026

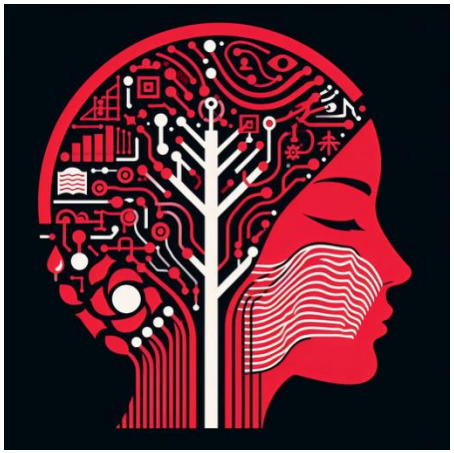

> Esercizi d'esame

9 Marzo, 2026

Scegliere un esercizio tra 1, 2 o 3

1. PoS Tagger per lingue morte

2. Convertitore sintattico IT -> IT-YO

3. DS: We are hiring Padawan!

1 PoS Tagger

Costruire un PoS tagger statistico basato su HMM per il Greco antico e il Latino

A. Implementare Learning (contare) e Decoding (Viterbi)
B. Addestrare il sistema su Greco e Latino (separatamente) usando 2 Treebank del progetto UD
C. Valutare il sistema, usando diverse strategie di smoothing
D. Valutare rispetto ad una baseline facile e ad una difficile

1.A algoritmo per il learning

- Elenchi di parole e di PoS TAG
- Probabilità PoS->PoS: **$P(t_i|t_{i-1})$** $$P(t_i|t_{i-1}) = \frac{C(t_{i-1}, t_i)}{C(t_{i-1})}$$
- Probabilità PoS->Word: **$P(w_i|t_i)$** $$P(w_i|t_i) = \frac{C(t_i, w_i)}{C(t_i)}$$
- Viterbi
- **HINT**: usare i logaritmi per le probabilità!

1.A algoritmo per il learning

- Elenchi di parole e di PoS TAG

```
# sent_id = test-s1
# text = + In Dei omnipotentis nomine, regnante domno nostro Karolus divina faventem clementia imperatore augu
quinta.
# reference = document_id='85:47'-span='146'
1       +          +       PUNCT   SYM        _          5        punct    _        _
2       In         in      ADP     r|r|-|-|-|-|-|-|-|-  _          5        case     _        _
3       Dei        Deus    PROPN   Propn|n|-|s|-|-|-|m|g|- Case=Gen|Gender=Masc|Number=Sing        5        nmod
4       omnipotentis       omnipotens      ADJ     a|a|-|s|-|-|-|m|g|-     Case=Gen|Gender=Masc|Number=Sing
5       nomine     nomen   NOUN    n|n|-|s|-|-|-|n|b|-     Case=Abl|Gender=Neut|Number=Sing        7        obl
...        ...                    ...
```

```
# newdoc id = tlg0003.tlg001.perseus-grc1.1.tb.xml
# sent_id = tlg0003.tlg001.perseus-grc1.1.tb.xml@3
# text = τὰ γὰρ πρὸ αὐτῶν καὶ τὰ ἔτι παλαίτερα σαφῶς μὲν εὑρεῖν διὰ χρόνου πλῆθος ἀδύνατα ἦν, ἐκ δὲ τεκμηρίων ὧν ἐπὶ
νομίζω γενέσθαι οὔτε κατὰ τοὺς πολέμους οὔτε ἐς τὰ ἄλλα.
1       τὰ         ὁ       DET     l-p---na-       Case=Acc|Gender=Neut|Number=Plur        11       det      _        _
2       γὰρ        γάρ     ADV     d--------       _        15       advmod   _        _
3       πρὸ        πρό     ADP     r--------       _        4        case     _        _
4       αὐτῶν      αὐτός   PRON    p-p---ng-       Case=Gen|Gender=Neut|Number=Plur        1        nmod     _        _
5       καὶ        καί     CCONJ   c--------       _        1        cc       _        _
6       τὰ         ὁ       DET     l-p---na-       Case=Acc|Gender=Neut|Number=Plur        8        det      _        _
7       ἔτι        ἔτι     ADV     d--------       _        8        advmod   _        _
...        ...                    ...
```

1.B data: training-dev-test

- Greco antico -> Perseus
  - INFO: https://universaldependencies.org/treebanks/grc_perseus/index.html
  - DATA: https://github.com/UniversalDependencies/UD_Ancient_Greek-Perseus
- Latino -> LLCT
  - INFO: https://universaldependencies.org/treebanks/la_llct/index.html
  - DATA: https://github.com/UniversalDependencies/UD_Latin-LLCT

1.C smoothing

Ipotesi di smoothing per le parole sconosciute:

- Sempre nomi P(unk|NOUN) = 1
- Sempre nomi/verbi P(unk|NOUN)=P(unk|VERB)=0.5
- $P(unk|t_i) = 1/\#(PoS_TAGs)$
- Statistica PoS sul development set: parole che compaiono 1 sola volta
- Approcci Syntax-based? Suffissi? (opzionale)

1.D Valutare

Calcolare la precisione sul test set.

Implementare 2 baselines:

- Facile: assegnare il tag più frequente se c'è nel training, altrimenti nome.
- Difficile (opzionale): MEMM https://github.com/Michael-Tu/ML-DL-NLP/tree/master/MEMM-POS-Tagger

Quali sono gli errori più comuni?

Esercizio 2: convertitore IT -> IT-YO

1. Yoddish language
   - http://www.yodaspeak.co.uk/index.php
2. Lingua XSV
   - http://itre.cis.upenn.edu/%7Emyl/languagelog/archives/002173.html
   - http://articles.chicagotribune.com/2005-05-17/features/0505170253_1_yoda-languages-word-order
3. Anche Shakespeare parlava come Yoda
   - http://prestwickhouse.blogspot.it/2009/12/plain-english-how-yoda-helps-students.html

Esercizio 2: convertitore IT -> IT-YO

SVX -> XSV

- Scrivere a una CFG per l'italiano (G1) che parsifchi (almeno) le frasi di esempio.
- **HINT:** ispirarsi alla grammatica “simple-sem.fcfg” e costruirla *direttamente* in CNF
- https://github.com/nltk/nltk_teach/blob/master/examples/grammars/book_grammars/simple-sem.fcfg

Esercizio 2: convertitore IT -> IT-YO

SVX -> XSV

- Implementare l'algoritmo CKY e provare la grammatica G1 su questo programma per le frasi di esempio.
- Costruire un algoritmo di traduzione che riscriva l'abero di derivazione per Italiano in un albero Italiano-Yodish e stamparne le foglie.
- **Attenzione**: ignorare l'ambiguità e prendere il primo albero ottenuto

Frasi di esempio esercizio 2

- Tu avrai novecento anni di età -> *Novecento anni di età tu avrai*
- Tu hai amici lì-> *Amici tu hai lì*
- Noi siamo illuminati-> *Illuminati noi siamo*

3. DS: We are hiring Padawan!

Il DS (ITA o ENG) deve impersonare il personaggio Darth Vader o Obi-Wan_kenobi. Il DS è **task-based**: deve interrogare l'utente sulla conoscenza della cultura Jedi per decidere se l'utente può diventare un Padawan.

https://it.wikipedia.org/wiki/Dart_Fener

https://it.wikipedia.org/wiki/Obi-Wan_Kenobi

3. DS: We are hiring Padawan!

Cultura Jedi:

1. https://it.wikipedia.org/wiki/Jedi
2. The Jedi Path
   - https://books.google.it/books?id=vDaqCwAAQBAJ&printsec=frontcover&redir_esc=y#v=onepage&q&f=false

Esempi:

- Dove si trova la sede principale dell'Ordine?
- Quanti figli può avere un Jedi?
- Quali sono i tre pilastri della cultura Jedi?

3.A ANALISI

Algoritmo: ANALISI-DM-GENERAZIONE

2 possibili approcci:

- Come Eliza: espressioni regolari su stringhe
- Con le dipendenze: si usi un parser a dipendenza (es. udpipe, Spacy, Stanza, Tint) si cerchino le regolarità nell'albero. Es: ***I Jedi non possono avere figli.***
  - ***avere–nsubj-> Jedi***
  - ***Jedi –det-> I***
  - ***avere–obj-> figli***

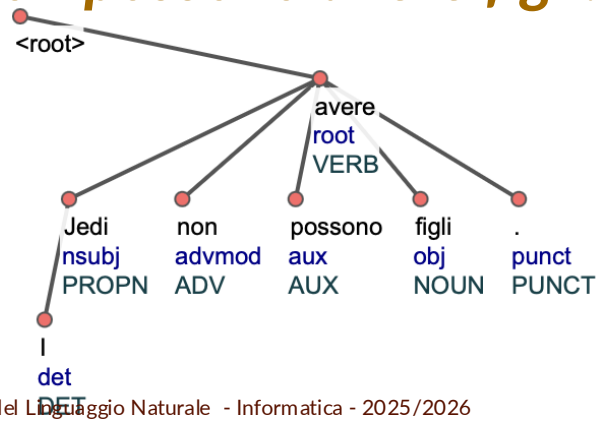

3.B DM

- **L'iniziativa è del sistema** che deve interrogare
- **Frame-Based:** ogni pozione viene rappresentata come un frame da riempire i cui slot sono gli ingredienti -> **Common-ground**
- Il DM deve interrogare eventualmente proponendo risposte vere o false
- Dovrebbe dare un giudizio, un commento (sagace) e decidere se l'utente è adatto a diventare Padawan alla fine dell'interazione
- Backup-strategy
- Memory

3.C Generazione

- Quello che volete:
  - Template statici
  - Parafrasi con llm

3.D Valutare

- Analizzare almeno 3 dialoghi (-> relazione)
- Quali sono gli errori più comuni?
- Quali fenomeni linguistici si riescono a gestire?

Trindi Tick List

3.E Bonus Tracks

- SpeechRecognition e Text2Speech: cosa cambia negli errori?

Consegna

Bisogna consegnare il codice e una breve relazione (5-10 pagine) almeno due giorni prima della data dell'esame dell'orale concordata.

Attenzione: gli esercizi si possono fare in gruppi formati da 1, 2 o 3 persone (dello stesso A.A.)
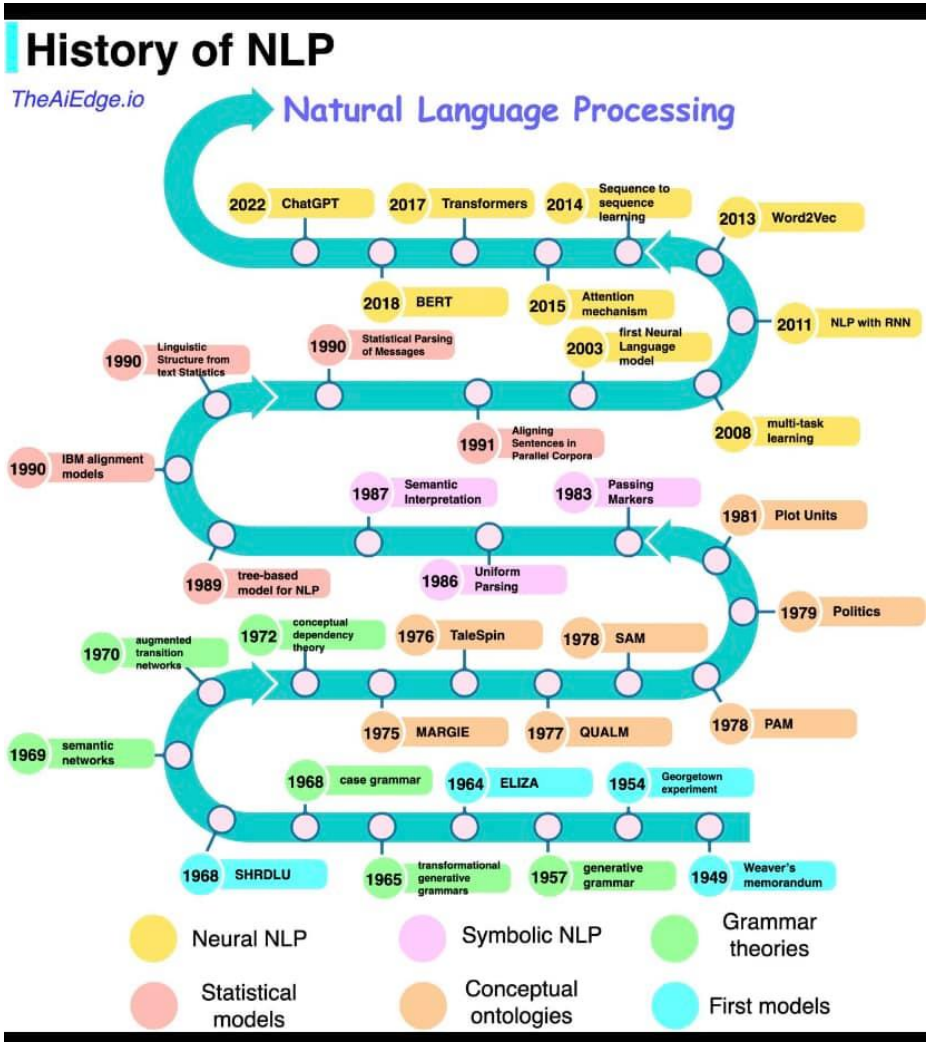
TLN - Fine Parte 1