


IA, Etica ed Equità

Equità
nella classificazione



Welcome to the First International Beauty Contest
Judged by Artificial Intelligence
Beauty.AI 2.0

Be the First Beauty Queen or King
Judged by Robots

Watch our video



Alcuni esempi di successo del ML

Un "algoritmo per
concorsi di bellezza"

🕒 This article is more than 4 years old

A beauty contest was judged by AI and the robots didn't like dark skin


The first international beauty contest decided by an algorithm has sparked controversy after the results revealed one glaring factor linking the winners

Alcuni esempi di successo del ML


Guardian, vincitrici per lo più bianche nel concorso di bellezza AI

GLOBAL HEADCOUNT

■ Male ■ Female



EMPLOYEES IN TECHNICAL ROLES




Alcuni esempi di successo del ML


Reuters: Amazon abbandona lo strumento segreto di reclutamento basato sull'AI che mostrava pregiudizi nei confronti delle donne

GLOBAL HEADCOUNT

■ Male ■ Female



EMPLOYEES IN TECHNICAL ROLES



Alcuni esempi di successo del ML


//

"Tutti volevano questo Santo Graal", ha detto una delle persone coinvolte.


"Volevano letteralmente che fosse un motore in cui io inserisco 100 curriculum, lui mi restituisce i cinque migliori e noi assumiamo quelli".

GLOBAL HEADCOUNT

■ Male ■ Female



EMPLOYEES IN TECHNICAL ROLES




Alcuni esempi di successo del ML

//


[...] I modelli informatici di Amazon sono stati addestrati a vagliare i candidati osservando i modelli dei curriculum inviati all'azienda in un periodo di 10 anni. La maggior parte proveniva da uomini, a riflettere il predominio maschile nel settore tecnologico.

GLOBAL HEADCOUNT

■ Male ■ Female



EMPLOYEES IN TECHNICAL ROLES



Alcuni esempi di successo del ML


//

[...] Penalizzava i curriculum che includevano la parola "donne", come in "capitano del club di scacchi femminile". E declassava i laureati di due college femminili, secondo persone informate sulla questione.


COMPAS

	
VERNON PRATER	BRISHA BORDEN
LOW RISK	HIGH RISK
3	8

COMPAS

 VERNON PRATER Prior Offenses 2 armed robberies, 1 attempted armed robbery Subsequent Offenses 1 grand theft LOW RISK 3	 BRISHA BORDEN Prior Offenses 4 juvenile misdemeanors Subsequent Offenses None HIGH RISK 8
---	---

COMPAS



Come avviene

I modelli/sistemi di IA commettono sempre **errori**, ma la **distribuzione di tali errori** può influenzare in modo diverso gruppi di persone diversi.

Poiché solitamente non è disponibile un modello perfetto, lo studio della **equità** nell'apprendimento automatico cerca di evitare situazioni in cui determinati gruppi siano discriminati.

Classificazione - Introduzione

X : **dati**, covariate

Y : ground truth, etichette, **variabile target**

La classificazione è il processo che determina un valore plausibile per Y dato X .

Più tecnicamente, si cerca di apprendere i parametri θ di una funzione f_θ che mappa la **variabile aleatoria** X su una stima $\hat{Y}$ di Y :

$$\hat{Y} = f_\theta(X)$$


Classificazione - Introduzione

		qualification score		positive outcomes
		high	low	
race	Black	⊕	⊖ ⊖ ⊖ ⊖	20% of Black
	White	⊕ ⊕ ⊕	⊖ ⊖	60% of White

X : punteggio di qualificazione

Y : la persona ha ricevuto una valutazione positiva dal proprio responsabile dopo 12 mesi di lavoro (+) o no (-)

Il ciclo ML



Misurazione: il processo in cui lo stato del mondo viene ridotto a tabelle di dati.

Misurazione

//

Il "pregiudizio di valutazione a favore degli uomini", come alcuni lo chiamano, porta generalmente le donne ad essere valutate meno degli uomini, anche in situazioni in cui le loro prestazioni sono state dimostrate pari a quelle degli uomini. Uno studio sulla qualità della scrittura nei saggi (i ricercatori hanno "variato" il sesso dell'autore) ha mostrato un pregiudizio simile, con lettori sia maschi che femmine che hanno valutato i saggi come di qualità inferiore se credevano che l'autore fosse una donna.

Snipes, Thomson e Oswald. *Pregiudizio di genere nelle valutazioni dei clienti sulla qualità del servizio*. Journal of Services Marketing, 2006.

Discriminazione?

Finora ci siamo basati su una comprensione intuitiva dei concetti di **discriminazione** e **pregiudizio**, principalmente attraverso l'analisi di casi di studio.

Sebbene sia difficile dare una definizione onnicomprensiva di discriminazione, fornirò una breve sintesi di ciò che filosofi politici, scienziati sociali e legislatori hanno detto al riguardo.

Trattare questo argomento durante una lezione di informatica è difficile sia per voi che per me!

Questa non sarà **affatto** esaustiva.

Discriminazione

Fonti per questa lezione:

- Reuben Binns. "Fairness in Machine Learning: Lessons from Political Philosophy". Atti della conferenza Machine Learning Research. 2018.
- Lippert-Ramussen. 'Born Free and Equal?'. Oxford University Press. 2014.
- Corte europea dei diritti dell'uomo. Handbook on EU Anti-discrimination law. 2010.

Discriminazione?

Alcune domande rilevanti:

- Che cos'è esattamente la discriminazione?
- Perché è sbagliata?
- La "discriminazione algoritmica" è diversa dalla discriminazione prodotta dall'uomo?

Che cos'è la discriminazione?

La discriminazione diretta è la pratica di **trattare in modo diverso** le persone in base alla loro appartenenza a un gruppo sociale rilevante.

Esempi:

- Preferire un candidato maschio a una candidata femmina con le stesse qualifiche
- Imporre condizioni più severe per la libertà vigilata ai candidati appartenenti a un gruppo minoritario

Nell'UE, questo è disciplinato dall'articolo 21 della Carta dei diritti fondamentali.

Negli Stati Uniti e nella letteratura sull'equità ML, questo concetto è solitamente indicato come disparate treatment.

Discriminazione indiretta

La discriminazione indiretta è la pratica di offrire **lo stesso trattamento** a persone appartenenti a **gruppi sociali distinti** se ciò comporta che un gruppo di persone **sia posto in una situazione di particolare svantaggio**.

Negli Stati Uniti e nella letteratura sull'equità ML, questo concetto è solitamente denominato "impatto disparato".

Discriminazione indiretta

Esempi (EU Handbook on Anti-discrimination law):

- *Hilde Schönheit contro Stadt Frankfurt am Main*. Le pensioni dei dipendenti a tempo parziale erano calcolate utilizzando un tasso diverso da quello dei dipendenti a tempo pieno. Questo tasso diverso non era basato sulle differenze di tempo trascorso al lavoro. Pertanto, i dipendenti a tempo parziale ricevevano una pensione inferiore a quella dei dipendenti a tempo pieno, anche tenendo conto della diversa anzianità di servizio, il che significava, in pratica, che i lavoratori a tempo parziale erano retribuiti in misura inferiore. Questa norma neutra sul calcolo delle pensioni si applicava in modo uguale a tutti i lavoratori a tempo parziale. Tuttavia, poiché circa l'88 % dei lavoratori a tempo parziale erano donne, **l'effetto della norma era sproporzionatamente negativo per le donne rispetto agli uomini.**

Discriminazione indiretta

Esempi:

- *D.H. e altri contro Repubblica Ceca*. Una serie di test era stata utilizzata per valutare l'intelligenza e l'idoneità degli alunni al fine di determinare se dovessero essere trasferiti dall'istruzione ordinaria a scuole speciali. Queste scuole speciali erano destinate a persone con disabilità intellettive e altre difficoltà di apprendimento. Lo stesso test è stato applicato a tutti gli alunni che erano stati presi in considerazione per l'inserimento in scuole speciali. Tuttavia, nella pratica il test era stato concepito per la popolazione ceca generale, con la conseguenza che gli studenti rom erano intrinsecamente più inclini a ottenere risultati scarsi, cosa che effettivamente è avvenuta, **con la conseguenza che tra il 50% e il 90% dei bambini rom sono stati istruiti al di fuori del sistema scolastico tradizionale.**

Discriminazione indiretta?

A un certo livello, potremmo non essere d'accordo sul fatto che i casi sopra citati costituiscano discriminazione, e alcuni sicuramente non saranno d'accordo.

Una possibile argomentazione, etica e non legale: nessuno **aveva intenzione** danneggiare determinati gruppi, e i test/i tassi pensionistici non sono stati creati/calcolati tenendo conto di questi aspetti.

Pertanto, non si è verificata alcuna discriminazione.

Cosa rende sbagliata la discriminazione?

Nella filosofia morale e politica, l'esistenza di una **systematic animosity** (ostilità sistematica) a favore o contro determinati gruppi sociali rilevanti da parte di chi prende le decisioni è stata tradizionalmente la base per definire la discriminazione come sbagliata.

Se chi prende le decisioni ha anche un intento esplicitamente negativo o una mancanza di rispetto nei confronti di un individuo, allora sta commettendo **discriminazione**.

Pertanto, un possibile motivo che possiamo analizzare è l'**intento**.

Ma questo funziona per gli algoritmi?

Intenzione e discriminazione

Se il possesso di determinati stati mentali "ostili" è necessario per la definizione di discriminazione, allora i casi di studio che abbiamo visto finora **non costituiscono discriminazione**.

Naturalmente, gli algoritmi non possiedono stati mentali.

I data scientist che stanno dietro ai sistemi di IA possono facilmente affermare di non avere avuto intenzioni ostili nei confronti di determinati gruppi.

Notiamo anche una questione centrale: la spiegazione basata sugli stati mentali **non copre necessariamente la discriminazione indiretta**.

Individui e discriminazione

Un altro possibile motivo: basarsi su inferenze sugli individui che sono **fondate su generalizzazioni** sui gruppi di cui fanno parte.

In altre parole: **non trattare le persone come individui.**

Supponiamo che un datore di lavoro legga che i fumatori sono in media meno produttivi dei non fumatori. Quindi, i candidati che fumano vengono respinti senza eccezioni.

Individui e discriminazione

Qui ci imbattiamo in diversi problemi:

- La definizione di **generalizzazione**. Supponiamo che lo stesso datore di lavoro utilizzi invece un lungo test di produttività per decidere se assumere un candidato. Si tratta sempre di generalizzazione, ma la linea di condotta sembra ora meno discriminatoria.
- Il punto è forse che i mezzi di generalizzazione sono **insufficientemente precisi**? Ciò sembra insoddisfacente. Quanto dovrebbero essere precisi, esattamente?
- Il **processo decisionale algoritmico** è mai ammissibile in queste condizioni? Un sistema di apprendimento automatico di solito esegue un'**induzione**, che è di per sé una forma di **generalizzazione**.

Egalitarismo

Un'altra proposta è quella di esaminare le questioni sollevate dagli algoritmi presentati finora attraverso la lente dell'egualitarismo.

In linea di massima, l'egualitarismo è l'idea che le persone debbano essere trattate in modo uguale e che, a volte, alcune cose di valore debbano essere distribuite equamente.

Pertanto, possiamo dire che i sistemi che abbiamo osservato finora **non sono egualitari**.

Uguaglianza di cosa?

Non tutte le posizioni egualitarie concordano su **cosa** debba essere distribuito equamente.

Opinioni contrastanti: piacere o soddisfazione delle preferenze (Cohen), risorse come reddito e beni (Rawls e Dworkin), capacità e risorse necessarie per fare determinate cose (Sen).

Gli algoritmi che non riescono a distribuire equamente questi beni possono causare **danni** alle persone in modo disparato a seconda del gruppo a cui appartengono.

Cosa dice la filosofia politica a riguardo della giustizia distributiva

- **Benessere**, piacere o soddisfazione delle preferenze (*Welfarismo*), rappresentato da autori come Gerald A. Cohen):
sostiene che l'oggetto della giustizia sia il **benessere individuale o la felicità**.
Secondo questa visione, una distribuzione è equa quando tutti gli individui raggiungono lo stesso livello di soddisfazione o di piacere.
- **Risorse materiali** e beni primari (*Egualitarismo delle risorse*, sostenuto da John Rawls con la sua Teoria della giustizia e Ronald Dworkin):
afferma che lo stato non deve eguagliare il benessere (poiché le persone hanno desideri e costi di felicità diversi), ma deve *distribuire equamente le risorse materiali*, il reddito, le *opportunità e i diritti fondamentali*, affinché *tutti abbiano gli stessi mezzi* per perseguire i propri progetti di vita.
- **Capacità e opportunità** (*Approccio delle capacità*, proposto da Amartya Sen):
sostiene che le persone hanno capacità diverse di convertire le risorse in benessere (ad esempio, una persona con disabilità ha bisogno di più risorse per raggiungere la stessa mobilità di una persona sana). *L'eguaglianza deve riguardare l'effettiva libertà e le capacità* (capabilities) di fare o essere ciò che si ha motivo di valorizzare (il proprio potenziale).

Danni

Un algoritmo discriminatorio (non egualitario) può causare due diversi tipi di danni:

- **Allocativi**. A determinati gruppi vengono negate risorse in modo disparato. Esempi: COMPAS, sistema di assunzione di Amazon.
- **Rappresentativi**. Il sistema di IA rafforza la subordinazione di alcuni gruppi. Esempio: beauty.ai, traduzione automatica

Fortuna e merito

Un aspetto che non abbiamo ancora discusso è il **merito**, ovvero la condizione di essere meritevoli di una risorsa grazie a scelte, talento, duro lavoro, ecc.

La posizione egualitaria (fortuna) sostiene che le disuguaglianze dovute alla **fortuna**, ovvero circostanze al di fuori del nostro controllo, dovrebbero essere corrette.

Naturalmente, tracciare una linea di demarcazione tra le caratteristiche di un vettore che sono dovute alla pura fortuna e quelle che sono anche dovute alle **scelte** di un individuo è tutt'altro che semplice.

Misurare la fortuna e il merito può anche essere estremamente difficile e costoso.

Egalitarismo e discriminazione indiretta

Ciononostante, si potrebbe sostenere che l'egalitarismo fornisce una base etica ragionevole per l'erroneità **sia** della discriminazione diretta che di quella indiretta.

Con questo, si intende che spiega le basi etiche per cui si potrebbe ritenere che questi algoritmi sono eticamente sbagliati; **non si intende** che la posizione è da condividere necessariamente.

Ad esempio, chi non avesse una posizione egualitaria in generale potrebbe piuttosto serenamente non concordare nel definire questi algoritmi e i loro effetti come sbagliati.

Discriminazione?

Alcune domande rilevanti:

- Che cos'è esattamente la discriminazione?
- Che cosa la rende sbagliata?
- **La "discriminazione algoritmica" è diversa dalla discriminazione prodotta dall'uomo?**


Discutiamone!

Equità per inconsapevolezza

Una cosa di cui dobbiamo essere consapevoli è che **gli algoritmi basati sui dati sono in grado di recuperare informazioni sensibili.**

Ad esempio, il tuo codice postale rivela alcune informazioni sulla tua ascendenza/etnia, poiché le statistiche sulla popolazione sono solitamente disponibili al pubblico.

Equità per inconsapevolezza



Sinistra: una particolare caratteristica ha la stessa distribuzione ma una differenza media di 0,5 tra i gruppi. **Destra:** quanto bene possiamo prevedere se un individuo appartiene a un gruppo o all'altro man mano che il numero di queste caratteristiche aumenta.

Equità per inconsapevolezza

L'inconsapevolezza di solito non esiste nei dati del mondo reale ed è difficile da sostenere se si osservano le correlazioni, o se le osservano gli algoritmi

Criteri statistici di non discriminazione

Quando si ha a che fare con un algoritmo di classificazione, può essere interessante **quantificare** lo squilibrio nelle sue decisioni **tra diversi gruppi**.

La nostra impostazione è simile a quella discussa nella lezione precedente:

X covariate; Y variabile target; $\hat{Y}$ la nostra stima del target tramite il classificatore f_θ ; il punteggio di rischio R .

Aggiungiamo: A l'attributo sensibile, una caratteristica discreta che rappresenta il gruppo a cui appartiene un individuo. Esempi: 1 uomo, 0 donna; 2 asiatici, 1 nero, 0 bianco...

Criteri statistici di non discriminazione



Potremmo essere interessati a bilanciare il **tasso di accettazione** del nostro classificatore, ovvero $P(\hat{Y} = 1)$.

Criteri statistici di non discriminazione

Si noti che qui stiamo ipotizzando che un particolare valore di Y - e quindi di $\hat{Y}$ - rappresenti un risultato più desiderabile - ottenere un colloquio, ottenere un prestito, essere rilasciato sotto cauzione...

Indipendenza

Le variabili casuali $(A, \hat{Y})$ soddisfano l'indipendenza se $\hat{Y} \perp A$.

Se $\hat{Y}$ è binario, l'indipendenza si semplifica nella seguente condizione:

$$\mathbb{P}(\hat{Y} = 1 \mid A = a) = \mathbb{P}(\hat{Y} = 1 \mid A = b)$$

Se A può assumere più valori di $\{a, b\}$, allora la condizione deve essere soddisfatta per tutte le coppie di gruppi, ad esempio (a, b) , (a, c) , (b, c) .

Indipendenza

Possiamo anche rilassare l'indipendenza come segue:

$$\mathbb{P}(\hat{Y} = 1 \mid A = a) \geq \mathbb{P}(\hat{Y} = 1 \mid A = b) - \epsilon$$

Oppure riscriverla come rapporto:

$$\frac{\mathbb{P}(\hat{Y} = 1 \mid A = a)}{\mathbb{P}(\hat{Y} = 1 \mid A = b)} \geq 1 - \epsilon$$

In entrambi i casi $\epsilon \geq 0$. Aggiungere alla differenza un valore assoluto sono e' ammesso e incoraggiato.

Indipendenza

- L'indipendenza può riflettere la convinzione che **tutti i gruppi abbiano pari diritto all'accettazione**.
- È stata studiata in modo piuttosto approfondito nella letteratura sul ML.
- Si noti che l'indipendenza non richiede affatto di prendere in considerazione Y . Ciò può andare bene se si ritiene che vi sia un bias sistematico nella misurazione di Y , ad esempio nelle domande di assunzione.


Indipendenza

C'è una questione più importante relativa all'indipendenza: immaginate un decisore malintenzionato che assume persone del gruppo a con un processo rigoroso e una probabilità $p > 0$.

Le persone del gruppo b vengono assunte in modo casuale con la stessa probabilità p .

Questa metodologia soddisfa perfettamente l'indipendenza. Tuttavia, considerate il ciclo ML...

Indipendenza



Le azioni hanno conseguenze sullo stato del mondo e quindi sui dati: se l'azienda avvia un processo di assunzione basato sui dati dopo aver raccolto questo tipo di dati, vedrà che i dipendenti del gruppo b stanno ottenendo risultati scadenti.

Indipendenza

//

Utilizzando un set di dati relativo a tutti i cambiamenti di CEO nelle aziende Fortune 500 in un periodo di 15 anni, analizziamo i meccanismi che determinano le probabilità di promozione e la durata della leadership delle donne e dei CEO appartenenti a minoranze razziali/etniche. In linea con la teoria del glass cliff, abbiamo riscontrato che **le minoranze occupazionali**, definite come donne bianche e uomini e donne di colore, **hanno maggiori probabilità rispetto agli uomini bianchi di essere promossi CEO di aziende con performance deboli**. Sebbene non riscontriamo differenze significative nella durata della permanenza in carica tra le minoranze occupazionali e gli uomini bianchi, abbiamo osservato che quando le prestazioni dell'azienda diminuiscono durante il mandato dei CEO appartenenti a minoranze occupazionali, questi leader tendono ad essere sostituiti da uomini bianchi. Abbiamo definito questo fenomeno "effetto salvatore".

Cook e Glass. "Above the glass ceiling: When are women and racial/ethnic minorities promoted to CEO?". Strategic Management Journal 35, 2014.

Separazione

Come discusso in precedenza, l'indipendenza non tiene affatto conto di Y .

Tuttavia, se riteniamo che la nostra verità di base Y sia stata raccolta con attenzione e non contenga molti pregiudizi, essa può rappresentare una **suddivisione della popolazione** in gruppi con **uguale diritto all'accettazione**.

Naturalmente, alcuni gruppi demografici $A = a$ potrebbero essere meno rappresentati nel gruppo di etichette $Y = 1$. Si potrebbe sostenere che in questi casi è giustificato accettare un numero inferiore di individui dal gruppo a .

Separazione

- Le variabili casuali $(Y, A, \hat{Y})$ soddisfano la **separazione** se $\hat{Y} \perp A|Y$.
- Nel caso della classificazione binaria e di A binario:

$$\begin{aligned}\mathbb{P}(\hat{Y} = 1|Y = 1, A = a) &= \mathbb{P}(\hat{Y} = 1|Y = 1, A = b) \\ \mathbb{P}(\hat{Y} = 1|Y = 0, A = a) &= \mathbb{P}(\hat{Y} = 1|Y = 0, A = b)\end{aligned}$$

Intuitivamente: una volta scelto il valore per Y , il valore di A non ha importanza per il classificatore.

Separazione

$$\mathbb{P}(\hat{Y} = 1 \mid Y = 1, A = a) = \mathbb{P}(\hat{Y} = 1 \mid Y = 1, A = b)$$

$$\mathbb{P}(\hat{Y} = 1 \mid Y = 0, A = a) = \mathbb{P}(\hat{Y} = 1 \mid Y = 0, A = b)$$

Si noti che $\mathbb{P}(\hat{Y} = 1 \mid Y = 1)$ è il **tasso di veri positivi**.

Ricordiamo che $1 - \text{tasso di veri positivi} = \text{tasso di falsi negativi}$.

Si noti che $\mathbb{P}(\hat{Y} = 1 \mid Y = 0)$ è il **tasso di falsi positivi**.

Pertanto, la separazione richiede che tutti i gruppi abbiano **lo stesso tasso di falsi negativi** e **lo stesso tasso di falsi positivi**.

La separazione può essere intesa come **parità del tasso di errore** tra i gruppi.

Sufficienza

Le variabili casuali $(\hat{Y}, A, Y)$ soddisfano la sufficienza** se $Y \perp A \mid \hat{Y}$.

Nella classificazione binaria e nel caso binario A :

$$\mathbb{P}(Y = 1 \mid \hat{Y} = 1, A = a) = \mathbb{P}(Y = 1 \mid \hat{Y} = 1, A = b)$$

$$\mathbb{P}(Y = 1 \mid \hat{Y} = 0, A = a) = \mathbb{P}(Y = 1 \mid \hat{Y} = 0, A = b)$$

Intuitivamente: parità dei valori positivi/negativi previsti tra i gruppi.

Teoremi di incompatibilità

Questi criteri vincolano la joint distribution di $(Y, A, \hat{Y})$ in modi non banali.

Esistono diversi **teoremi di incompatibilità** che ci mostrano come questi criteri non possano essere soddisfatti contemporaneamente da alcun classificatore f .

Indipendenza vs. Sufficienza

Indipendenza: $A \perp \hat{Y}$.

Sufficienza: $Y \perp A \mid \hat{Y}$.

Teorema 1. Supponiamo che A e Y non siano indipendenti. Allora, la sufficienza e l'indipendenza non possono essere entrambe vere.

Dimostrazione per contraddizione. (vedi slide successiva)

Dimostrazione:

1. Per la regola della catena: $\mathbb{P}(A, Y) = \mathbb{P}(Y|A)\mathbb{P}(A)$
2. Per la sufficienza: $\mathbb{P}(Y, A|\hat{Y}) = \mathbb{P}(Y|\hat{Y}) \cdot \mathbb{P}(A|\hat{Y})$ che si può anche scrivere come $\mathbb{P}(Y|A, \hat{Y}) = \mathbb{P}(Y|\hat{Y})$
3. Per l'indipendenza tra A e $\hat{Y}$: $\mathbb{P}(A|\hat{Y}) = \mathbb{P}(A)$
4. Per il teorema di scomposizione: $\mathbb{P}(Y|A) = \sum_r \mathbb{P}(Y|A, R = r) \cdot \mathbb{P}(R = r|A)$
5. Sostituendo l'equazione al punto 2) e al punto 3) nell'equazione al punto 4):
$$\mathbb{P}(Y|A) = \sum_r \mathbb{P}(Y|R = r) \cdot \mathbb{P}(R = r) = \mathbb{P}(Y)$$

che dimostra l'indipendenza tra A e Y , il che contraddice l'assunzione iniziale.