

Modeling social media and literary language with N-grams

applicazione didattica dei Modelli di Linguaggio Probabilistici (N-grammi), L'obiettivo è confrontare due domini linguistici radicalmente opposti: il **linguaggio dei social media** e il **linguaggio letterario dell'800**.

Il codice pulisce i testi, estrae le sequenze di parole, addestra modelli statistici per calcolare le probabilità delle frasi, genera nuovo testo artificiale nello stile dei due domini e implementa un classificatore testuale.

1. Importazioni e Setup del Dataset (STEP 1)

Vengono scaricati e importati i componenti della libreria **NLTK**:

- *twitter_samples*: Un corpus di 10.000 tweet (5.000 positivi e 5.000 negativi)
- *gutenberg*: Una raccolta di classici della letteratura (da cui viene estratto *Emma*).
- *nltk.lm* (Language Modeling): Sotto-modulo che contiene gli stimatori statistici come MLE, Laplace e le funzioni di pipeline.

2. Text Preprocessing e Pulizia (STEP 2)

Il testo grezzo non può essere passato direttamente al modello statistico. Due funzioni di pulizia applicano strategie differenziate:

- **pulisci_tweet(testo)**: Usa le espressioni regolari (*re.sub*) per eliminare gli elementi di disturbo tipici di internet: URL (*http\S+*), menzioni (*@\w+*) e il simbolo dei tag (*#*). Rimuove tutto ciò che non è una lettera ed esegue il *lowercasing* (tutto in minuscolo).
- **pulisci_letterario(testo)**: Si limita a rimuovere la punteggiatura e i numeri, convertendo in minuscolo.

STEP 3, le stringhe pulite vengono unite e convertite in liste di singole parole tramite *word_tokenize()*.

3. Rimozione delle Stopwords e Analisi Frequenze

Il codice estrae gli **N-grammi**, ovvero sequenze continue di N-parole adiacenti.

- **Unigrammi (N=1)**: Singole parole (*['i', 'love', 'you']*).
- **Bigrammi (N=2)**: Coppie di parole (*[(('i', 'love'), ('love', 'you'))]*).
- **Trigrammi (N=3)**: Triplette di parole (*[(('i', 'love', 'you'))]*).

STEP 4 – rimozione stopwords: parole vuote come *the, is, of, at*), per estrarre il contenuto semantico puro. I risultati mostrano che su Twitter i bigrammi più frequenti sono formule emotive o ringraziamenti (*('thank', 'you'), ('love', 'you')*), mentre nel testo letterario emergono combinazioni formali e narrative (*('mr', 'knightley'), ('could', 'not')*).

STEP 5, estrazione dei bigrammi e trigrammi **mantenendo** le stopwords per l'addestramento dei modelli probabilistici (le parole funzionali sono essenziali per la struttura grammaticale).

5. Generazione Automatica del Testo (STEP 7)

I modelli MLE possono essere usati come generatori di testo pseudo-casuali (generazione autoregressiva). Il metodo `modello.generate(n_parole)` campiona una parola alla volta in base alla distribuzione di probabilità appresa.

- Il modello Twitter genera stringhe informali e sconnesse basate su schemi ripetitivi di messaggi social.
- Il modello letterario produce strutture sintattiche che ricordano la prosa classica inglese.

Il codice applica un filtro custom per rimuovere i token di padding [marcatori artificiali posti all'inizio e alla fine delle frasi, servono a delimitare i confini della frase e gestire le probabilità di inizio e fine periodo(<s>, </s>)] e le lettere singole isolate che rappresentano rumore generato dalle troncature.

6. Perplexity e Classificazione Cross-Domain (STEP 8, 9 & 10)

La **Perplexity (PP)** è la metrica principale per valutare un modello di linguaggio.

Geometricamente rappresenta il fattore di ramificazione (il grado di incertezza del modello nel predire la parola successiva).

$$PP(W) = P(w_1 w_2 \dots w_N)^{-\frac{1}{N}}$$

- **Bassa Perplexity:** Il modello è sicuro di sé, comprende bene la frase.
- **Alta Perplexity:** Il modello è sorpreso dalla frase, non la riconosce.

Nello **STEP 8**, si nota che se passiamo una frase di Twitter al modello Letterario, la sua Perplexity schizza a valori altissimi (e viceversa).

Nello **STEP 9**, per superare i limiti di scala della perplessità, viene implementato un classificatore basato sulla **Log-Likelihood** (somma dei logaritmi delle probabilità). La regola di decisione è semplice:

$$\text{Verdetto} = \arg \max_{M \in \{\text{Twitter}, \text{Letterario}\}} \sum \log P_M(w_i | w_{i-1})$$

La frase viene assegnata al modello che ottiene il punteggio più alto (meno negativo).

Nello **STEP 10**, viene dimostrata visivamente l'importanza dello smoothing di Laplace: davanti a una parola inventata ("xyzword"), il modello MLE fallisce restituendo probabilità zero e mandando la perplexity a infinito. Il modello Laplace assegna invece una piccolissima frazione di probabilità residua, permettendo al sistema di calcolare un punteggio numerico stabile.

7. Analisi Linguistica Quantitativa (STEP 12)

Vengono calcolati due indici linguistici fondamentali per descrivere la natura dei dati:

Type-Token Ratio (TTR)

Misura la ricchezza del vocabolario. È il rapporto tra il numero di parole uniche (*Types*, cioè la dimensione del set) e il numero totale di parole scritte (*Tokens*).

$$\text{TTR} = \frac{\text{Numero di parole uniche}}{\text{Numero totale di token}}$$

I tweet presentano un TTR più elevato rispetto al testo letterario perché, pur essendo testi brevi, contengono un ammontare massiccio di forme gergali diverse, errori di battitura intenzionali, abbreviazioni e slang che gonfiano artificialmente il numero di parole uniche.

Lunghezza media delle frasi: Un tweet ha una lunghezza vincolata dal mezzo di comunicazione stesso (poche parole per post). Al contrario, la prosa letteraria dell'Ottocento fa ampio uso di strutture subordinate complesse (ipotassi), risultando in frasi mediamente molto più lunghe e articolate.

Concetti chiave per lo studio del laboratorio

Se ti vengono fatte domande su questo specifico script all'esame, focalizzati su questi punti:

1. A cosa serve il Padding? Consente al modello di calcolare correttamente la

probabilità che una parola si trovi all'inizio di una frase $(P(w_1 | \langle s \rangle))$ o che chiuda il periodo $P(\langle /s \rangle | w_n)$.

2. Perché la Log-Likelihood è preferibile alla Likelihood standard? Moltiplicare tra loro molte probabilità (che sono numeri compresi tra 0 e 1) porta rapidamente ad un fenomeno informatico chiamato *underflow numerico* (il numero diventa così piccolo da essere approssimato a zero dalla CPU). Trasformando le probabilità in logaritmi, le moltiplicazioni diventano somme, stabilizzando il calcolo computazionale.

3. Che differenza c'è tra un modello Bigram ($n=2$) e un Trigram ($n=3$)? Il bigramma guarda solo la parola immediatamente precedente (memoria a breve termine). Il trigramma cattura un contesto più ampio (due parole precedenti), riducendo la perplexità e generando testi più coerenti, ma soffre maggiormente del problema della sfoltimento dei dati (*data sparsity*), poiché è molto più difficile trovare triplette esatte identiche nel testo di addestramento.