

Università degli Studi di Torino
Corso di Laurea Magistrale in Informatica

Tecnologie del Linguaggio Naturale

Parte 2 – Prof. Daniele Radicioni

Lab 8

Word Clustering con Word2Vec

Confronto tra testi musicali: anni 70 vs anni 2000

Gruppo di lavoro:

Studente	Matricola
Alessandro Olivero	915069
Samuele Iudice	1235245
Andrea Franco	1226739

Docente: Prof. Daniele Radicioni

Anno Accademico: 2025/2026

Indice

1	Introduzione	2
2	Background Teorico	2
3	Dataset e Pre-elaborazione	2
3.1	Dataset e selezione degli artisti	2
3.2	Pipeline di pulizia	3
4	Addestramento dei Modelli Word2Vec	4
5	Analisi delle Parole Simili	4
6	Similarità Coseno tra Coppie di Parole	5
7	Analisi del Vocabolario	6
8	Analisi Sistemica del Semantic Shift	6
8.1	Coppie con maggiore variazione di similarità	6
8.2	Parole con maggiore cambiamento di contesto	7
9	Clustering K-Means	8
10	Visualizzazione t-SNE	9
11	Sintesi, Limiti e Osservazioni Principali	10
12	Conclusioni	10
13	Dichiarazione sui Contributi di IA	11

1 Introduzione

Questo laboratorio esplora le **rappresentazioni distribuzionali del lessico** tramite Word2Vec, applicato a un dominio ricco di variazione temporale: i **testi delle canzoni**. Si confronta il linguaggio della musica degli **anni 70** (rock, pop, soul) con quello degli **anni 2000** (pop moderno, rap, alternative rock), analizzando come le rappresentazioni vettoriali differiscono tra le due ere, quali parole hanno cambiato contesto semantico, e se i cluster lessicali riflettono temi culturali diversi.

Il dataset è lo *Spotify Million Song Dataset*. Si selezionano manualmente artisti rappresentativi per ciascuna era, si addestrano due modelli Word2Vec Skip-gram indipendenti (Sezione 4), e da questi partono quattro analisi: parole simili, similarità coseno tra coppie, deriva semantica sistematica (semantic shift) e clustering con visualizzazione t-SNE.

2 Background Teorico

L'**ipotesi distribuzionale** (Firth, 1957: “*you shall know a word by the company it keeps*”) afferma che il significato di una parola emerge dal contesto in cui appare. **Word2Vec** (Mikolov et al., 2013) mette in pratica questa idea rappresentando ogni parola con un vettore denso $\mathbb{R}^d$, in modo che parole con contesti simili abbiano vettori vicini, tramite due architetture: **CBOW** (predice la parola target dal contesto, il default di Gensim) e **Skip-gram** (predice il contesto data la parola target, più efficace su corpus piccoli e parole rare). Qui si usa Skip-gram, impostato esplicitamente con $sg=1$, finestra $w=5$, dimensione $d=100$.

La similarità tra due vettori si misura con la **similarità coseno**:

$$\text{sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \in [-1, 1]$$

Confrontando i k vicini più prossimi di una parola nei due modelli si ottiene una misura di **semantic shift**, l'**overlap dei vicini**:

$$\text{overlap}(p) = \frac{|N_{70}(p) \cap N_{2000}(p)|}{k}$$

un valore basso indica contesto cambiato, un valore alto indica stabilità.

Il **K-Means** partiziona i vettori in k cluster minimizzando la varianza intra-cluster:

$$\arg \min_{\{C_j\}} \sum_j \sum_{\mathbf{x} \in C_j} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2$$

raggruppando le parole per similarità semantica. Il **t-SNE** riduce i vettori a 100D in 2D preservando la struttura locale, per visualizzare i cluster.

3 Dataset e Pre-elaborazione

3.1 Dataset e selezione degli artisti

Il dataset è lo **Spotify Million Song Dataset** (`spotify_millsongdata.csv`: `artist`, `song`, `text`), 57650 canzoni, 643 artisti.

Selezione artisti per era

```
1 artisti_70s = [  
2     'Black Sabbath', 'Pink Floyd', 'Queen',  
3     'Eagles', 'Fleetwood Mac', 'Bee Gees',  
4     'David Bowie', 'Elton John', 'ABBA',  
5     'Doors', 'Rolling Stones', 'Deep Purple'  
6 ]  
7 artisti_2000s = [  
8     'Eminem', 'Coldplay', 'Linkin Park',  
9     'Christina Aguilera', 'Radiohead', 'Foo Fighters',  
10    'Lady Gaga', 'Taylor Swift', 'The Killers',  
11    'Green Day', 'Nickelback'  
12 ]  
13 df_70s = df[df['artist'].isin(artisti_70s)].copy()  
14 df_2000s = df[df['artist'].isin(artisti_2000s)].copy()
```

La selezione copre i generi dominanti di ciascuna era. Risultato: **1729 canzoni** per gli anni 70 (12 artisti), **1312** per gli anni 2000 (11 artisti).

3.2 Pipeline di pulizia

Pulizia e tokenizzazione dei testi

```
1 def pulisci_testo(testo):  
2     if not isinstance(testo, str):  
3         return []  
4     testo = re.sub(r'\[.*?\]', '', testo)      # rimuove [Chorus], [Verse]...  
5     testo = re.sub(r'^a-zA-Z\s', '', testo)    # solo lettere  
6     testo = testo.lower()  
7     tokens = testo.split()  
8     tokens = [t for t in tokens if t not in stop and len(t) >= 3]  
9     return tokens  
10  
11 df_70s['tokens'] = df_70s['text'].apply(pulisci_testo)  
12 df_2000s['tokens'] = df_2000s['text'].apply(pulisci_testo)  
13 df_70s = df_70s[df_70s['tokens'].map(len) > 5]  
14 df_2000s = df_2000s[df_2000s['tokens'].map(len) > 5]
```

Pipeline: rimozione annotazioni strutturali, rimozione caratteri non alfabetici, lowercasing, stopword NLTK (incluse le forme contratte come *dont*, *cant*, *youre*) + token < 3 caratteri, filtraggio canzoni con ≤ 5 token.

Dopo la pulizia: corpus anni 70 **163 180 token** (11 174 unici), corpus anni 2000 **149 820 token** (11 551 unici).

4 Addestramento dei Modelli Word2Vec

Addestramento Word2Vec con Gensim

```
1 params = dict(  
2     sg          = 1,      # Skip-gram (il default di Gensim sarebbe CBOW)  
3     vector_size = 100, window = 5, min_count = 3,  
4     workers     = 1,      # riproducibilit  bit-esatta a parita' di seed  
5     epochs      = 20, seed = 42  
6 )  
7 model_70s      = Word2Vec(sentences=df_70s['tokens'].tolist(), **params)  
8 model_2000s    = Word2Vec(sentences=df_2000s['tokens'].tolist(), **params)
```

Due modelli **completamente indipendenti**, stessa architettura, corpus distinti:

Tabella 1: Iperparametri del modello Word2Vec

Parametro	Valore	Significato
sg	1	Skip-gram (0 = CBOW, default Gensim)
vector_size	100	Dimensione dello spazio vettoriale
window	5	Parole di contesto a sinistra/destra
min_count	3	Frequenza minima per il vocabolario
epochs	20	Passaggi sul corpus

Vocabolario risultante: **4752 parole** (anni 70), **4800** (anni 2000), di cui **2973 in comune**, 1779 esclusive anni 70, 1827 esclusive anni 2000.

5 Analisi delle Parole Simili

Tabella 2: Top-3 vicini pi  prossimi per parola chiave (risultati reali)

Parola	Top 3 Anni 70	Top 3 Anni 2000
love	forsake, harmony, tender	everlastic, lusting, elastic
night	tonights, starry, gloria	mmmarry, friday, mmmmarry
heart	hijack, indecision, steals	aaate, amaze, belongs
world	battleground, smash, upside	slips, rule, seas
time	rages, rediscover, enemies	thanks, wasting, replaced
life	lalala, earn, lalena	intoxicated, overdrive, kandy
feel	sheer, cardiac, tense	careen, garner, alienated

I vicini estratti **non formano quasi mai associazioni tematicamente pulite**: parole come *forsake* o *everlastic* non sono metafore coerenti, e in alcuni casi sembrano errori dovuti a parole rare o mal tagliate nel testo originale.   un limite atteso su corpus di poche migliaia di canzoni: per parole molto frequenti come *love*, il vicinato immediato   dominato da co-occorrenze casuali e specifiche di poche canzoni, pi  che da relazioni semantiche stabili. Le analisi aggregate delle Sezioni 8.1–8.2, su centinaia di parole invece che su singoli esempi, sono pi  robuste di questa ispezione qualitativa.

6 Similarità Coseno tra Coppie di Parole

Tabella 3: Similarità coseno tra coppie di parole (risultati reali)

Coppia	Anni 70	Anni 2000
(love, heart)	0.326	0.262
(love, money)	0.158	0.320
(night, dark)	0.286	0.330
(god, heaven)	0.281	0.202
(war, peace)	0.398	0.377
(free, soul)	0.268	0.134

(**free, soul**) mostra il calo più netto (0.27→0.13), la coppia più significativa del gruppo; (**god, heaven**) cala da 0.28 a 0.20 (indicativo, non conclusivo su soli 6 esempi); (**war, peace**) resta alta e stabile (0.40 vs 0.38); (**love, heart**) moderata in entrambe le ere, più alta negli anni 70.

La Figura 1 estende il confronto a 12 parole chiave.




Figura 1: Similarità coseno tra 12 parole chiave: anni 70 (sinistra), anni 2000 (centro), differenza diretta 2000s–70s (destra).

Il pannello di destra mostra dove il confronto a coppie isolate vale anche su scala più ampia: *life–love* cala di -0.36 (il calo più marcato), *night–god* e *heart–god* salgono di $+0.14/+0.13$. Il quadro è di piccoli spostamenti diffusi in entrambe le direzioni, non un'unica tendenza dominante.

7 Analisi del Vocabolario

Confronto dei vocabolari e parole caratteristiche

```
1 vocab_70s = set(model_70s.wv.index_to_key)
2 vocab_2000s = set(model_2000s.wv.index_to_key)
3 solo_70s = vocab_70s - vocab_2000s
4 solo_2000s = vocab_2000s - vocab_70s
5 comuni = vocab_70s & vocab_2000s
6
7 interessanti_70s = sorted(
8     [p for p in solo_70s if freq_70s[p] > 20], key=lambda x: -freq_70s[x])
9 interessanti_2000s = sorted(
10    [p for p in solo_2000s if freq_2000s[p] > 20], key=lambda x: -freq_2000s[x])
```

Esclusive anni 70 (freq > 20): *boogie, diddley, whop, aaaahh, mustapha, ahha, gentle, zane, bicycle, pity, lucy...* **Esclusive anni 2000**: *superstar, hooker, gangsta, yall, rap, retro, muh, ayo, chocolate, freezer, mom...*

Confrontando con il dataset originale: molte parole “caratteristiche di un’era” sono in realtà caratteristiche di un **singolo artista**. *Mustapha* e *bicycle* vengono dai Queen (*Mustapha, Bicycle Race*); *diddley* dai Rolling Stones (cover di Bo Diddley); *gaga, artpop, retro* sono quasi interamente di Lady Gaga; *gangsta* è esclusivamente di Eminem. Il “vocabolario esclusivo” misura quindi in parte lo stile di un singolo artista molto presente nel campione, non un tratto condiviso del periodo (si veda il limite discusso in Sezione 11).

8 Analisi Sistemática del Semantic Shift

8.1 Coppie con maggiore variazione di similarità

Analisi sistematica delle coppie di parole (versione vettorizzata)

```
1 FREQ_COPPIE = 100
2 candidati = [p for p in (vocab_70s & vocab_2000s)
3               if freq_70s[p] >= FREQ_COPPIE and freq_2000s[p] >= FREQ_COPPIE]
4
5 def matrice_coseno(model, parole):    # N x N invece di N^2/2 chiamate a .similarity
6     ()
7     vettori = np.array([model.wv[p] for p in parole])
8     norme = vettori / np.linalg.norm(vettori, axis=1, keepdims=True)
9     return norme @ norme.T
10
11 sim70, sim2000 = matrice_coseno(model_70s, candidati), matrice_coseno(model_2000s,
12                                candidati)
13 coppie_sist = [{'w1': candidati[i], 'w2': candidati[j],
14                 'delta': abs(float(sim70[i,j] - sim2000[i,j]))}
15                for i in range(len(candidati)) for j in range(i+1, len(candidati))]
16 coppie_sist.sort(key=lambda x: -x['delta'])
```

Per ogni coppia con frequenza sufficiente in entrambi i corpus si calcola il delta di similarità:

$$\Delta(w_1, w_2) = | \text{sim}_{70}(w_1, w_2) - \text{sim}_{2000}(w_1, w_2) |$$

Con soglia FREQ_COPPIE=100: **245 parole candidate, 29 890 coppie.**

Tabella 4: Top 5 coppie con maggiore variazione di similarità (risultati reali)

Coppia	Anni 70	Anni 2000	Δ	Trend
(tell, world)	0.447	0.000	0.447	più lontane
(fight, two)	-0.078	0.332	0.409	più vicine
(remember, lies)	0.424	0.016	0.408	più lontane
(happy, show)	0.428	0.022	0.406	più lontane
(old, city)	-0.094	0.305	0.399	più vicine

Le 5 coppie a Δ più basso sono identiche fino alla quarta cifra decimale (es. (round, last) 0.1493/0.1493): con 29 890 coppie confrontate, è normale che qualcuna abbia per puro caso un delta quasi zero, senza che questo dimostri una vera stabilità semantica – a differenza delle coppie in Tabella 4, il cui Δ è troppo grande per essere spiegato dal solo caso.

8.2 Parole con maggiore cambiamento di contesto

Overlap dei vicini per misurare il semantic shift

```

1  FREQ_MINIMA, TOP_N_VICINI = 30, 10
2  parole_frequenti_comuni = [p for p in comuni
3      if freq_70s[p] >= FREQ_MINIMA and freq_2000s[p] >= FREQ_MINIMA]
4
5  risultati = []
6  for parola in parole_frequenti_comuni:
7      vicini_70s = set(w for w, _ in model_70s.wv.most_similar(parola, topn=
8          TOP_N_VICINI))
9      vicini_2000s = set(w for w, _ in model_2000s.wv.most_similar(parola, topn=
10         TOP_N_VICINI))
11     overlap = len(vicini_70s & vicini_2000s) / TOP_N_VICINI
12     risultati.append({'parola': parola, 'cambiamento': 1 - overlap, 'overlap':
13         overlap})
14 risultati.sort(key=lambda x: -x['cambiamento'])

```

Con soglia `FREQ_MINIMA=30`: **648 parole comuni**. Per la maggior parte del top-30 l'overlap è **0%** – dominato dalle parole più **frequenti in assoluto** (*love, know, like, got, yeah, get, one, baby, time...*, le stesse di Sezione 5): conferma che con corpus di poche migliaia di canzoni il vicinato immediato è dominato da rumore statistico tanto più quanto più la parola è frequente, perché attraversa più contesti diversi.

Le parole più **stabili** (overlap 10–30%) sono *new* (*brand, orleans, york*), *rest* (*test, vagabonds*), *single* (*every*), *fate* (*sealed*), *snow* (*covered*), *rich* (*poor*), *bone* (*flesh*). Ciò che sopravvive intatto per 30 anni non sono temi, ma **espressioni fisse della lingua** (dette anche *collocazioni*: coppie di parole che si usano quasi sempre insieme) – *brand new, every single, sealed fate, snow covered, rich or poor, flesh and bone*: il nucleo lessicale invariato è fatto soprattutto di queste frasi fisse, non di significati condivisi.




Figura 2: Deriva semantica: (sinistra) top-20 parole per grado di cambiamento di contesto; (destra) similarità coseno delle coppie di parole comuni, anni 70 vs anni 2000 – sopra la diagonale indica coppie più simili nei 2000s, sotto indica coppie più distanti.

Lo scatter mostra la nuvola di punti nettamente sbilanciata **sotto** la diagonale: la maggioranza delle coppie comuni risulta meno simile nel 2000 che negli anni 70. Il vocabolario condiviso viene quindi usato in modi più vari negli anni 2000 (si veda anche Sezione 9), piuttosto che restare stabile nel tempo.

9 Clustering K-Means

Clustering K-Means sulle top 200 parole

```

1 def fai_clustering(model, n_clusters=6, top_words=200):
2     parole = model.wv.index_to_key[:top_words]
3     vettori = np.array([model.wv[w] for w in parole])
4     # norma unitaria: coerente con la cosine similarity usata nel resto dell'
    analisi
5     vettori_norm = vettori / np.linalg.norm(vettori, axis=1, keepdims=True)
6     km = KMeans(n_clusters=n_clusters, random_state=42, n_init=10)
7     labels = km.fit_predict(vettori_norm)
8     return labels, list(parole), vettori

```

Clustering sulle **200 parole più frequenti** di ciascun modello, $k = 6$:

Tabella 5: Cluster K-Means, anni 70 (prime 12 parole per cluster)

Cluster	Parole
0	love, got, baby, yeah, want, well, take, gonna, away, let, make, right
1	get, come, man, back, tell, home, find, woman, better, people, dance, old
2	feel, heart, world, long, good, still, said, ooh, keep, gone, hey, alone
3	say, would, going, always, turn, nothing, end, dream, everything, must, call, someone
4	know, see, little, look, think, girl, light, please, bad, thing, put, blue
5	like, time, one, never, way, life, night, could, day, eyes, give, every

Tabella 6: Cluster K-Means, anni 2000 (prime 12 parole per cluster)

Cluster	Parole
0	got, time, away, around, need, life, night, day, mind, gone, thing, face
1	love, one, want, never, way, take, feel, right, little, every, everything, always
2	like, know, get, yeah, come, cause, baby, make, give, think, eyes, ooh
3	let, world, girl, hold, stop, going, show, wrong, live, dance, beautiful, far
4	back, well, heart, look, find, nothing, tonight, last, put, head, better, turn
5	see, say, gonna, could, wanna, said, home, man, still, would, even, alone

I vettori sono normalizzati a norma unitaria prima del clustering (senza, un vettore con lunghezza fuori norma in K-Means con distanza euclidea finiva isolato in un cluster tutto suo). Lavorando sulle parole più **frequenti** (non un campione casuale), i cluster restano dominati da parole funzionali e verbi comuni piuttosto che da lessico raro legato a un tema: un raggruppamento più **grammaticale** che tematico. Alcuni cluster ricorrono comunque in entrambe le ere con lo stesso tema di fondo: cluster 0 anni 70 (*love, baby, want, gonna*) e cluster 1 anni 2000 (*love, want, feel, right*) parlano entrambi di amore e desiderio; cluster 5 anni 70 e cluster 0 anni 2000 parlano entrambi di tempo che passa (*time, life, night, day*).

10 Visualizzazione t-SNE

Il grafico t-SNE proietta le 200 parole più frequenti (100D→2D) colorate per cluster, con le parole tematicamente rilevanti (*love, night, heart, soul, free, dark...*) annotate direttamente.




Figura 3: Proiezione t-SNE dei 6 cluster K-Means, anni 70 (sinistra) vs anni 2000 (destra).

In entrambe le proiezioni i cluster appaiono visivamente **sovrapposti**, senza separazione netta in regioni distinte – coerente con Sezione 9: sulle parole più frequenti il segnale dominante è grammaticale, non tematico.

11 Sintesi, Limiti e Osservazioni Principali

Interrogando lo spazio vettoriale su **single parole isolate** (Sezioni 5, 8.2) il segnale è quasi sempre dominato dal rumore. Passando ad **analisi aggregate su centinaia di coppie** (Sezione 8.1) i risultati diventano più affidabili, a patto di scartare i delta quasi nulli (che sono per lo più effetto del caso). Il risultato più solido resta il confronto sui vicini più stabili: non temi condivisi, ma **espressioni fisse della lingua** (Sezione 8.2).

Tabella 7: Riepilogo comparativo delle caratteristiche dei due corpus

Caratteristica	Anni 70	Anni 2000
Artisti rappresentativi	12	11
Canzoni (post-pulizia)	1 729	1 312
Token totali	163 180	149 820
Token unici (post-pulizia)	11 174	11 551
Vocabolario Word2Vec	4 752	4 800
Parole esclusive	1 779	1 827

Parole comuni ai due vocabolari: 2 973.

Osservazioni principali:

1. Le rappresentazioni riflettono differenze di dominio a livello **aggregato**, non su singole parole isolate.
2. Il vocabolario esclusivo rivela più il **bias di selezione degli artisti** che il periodo storico (*mustapha, bicycle*→Queen; *gaga, artpop*→Lady Gaga).
3. I cluster K-Means sono **legati alla grammatica più che al tema**; t-SNE conferma che i cluster si sovrappongono visivamente.
4. Il nucleo lessicale più stabile nel tempo è fatto di **frasi fisse**: ciò che 30 anni di musica non cambiano sono le formule linguistiche, non i significati.

Limiti: bias nella selezione manuale degli artisti (dimostrato, non ipotizzato, in Sezione 7); corpus di dimensioni non identiche fra le due ere; spazi vettoriali dei due modelli non allineati (solo la similarità coseno *interna* a ciascun modello è robusta); rimozione di stopword/token corti che può eliminare parole grammaticalmente significative. Nel complesso i risultati sostengono bene un’osservazione **qualitativa** (i due corpus usano in parte le stesse parole e in parte parole diverse), ma non bastano per affermazioni **numeriche** forti sul cambiamento di significato di una singola parola: servirebbero corpus più grandi, più artisti per era e un vero test statistico, che qui non sono stati fatti.

12 Conclusioni

Il laboratorio ha mostrato come Word2Vec, su testi musicali, catturi differenze semantiche e culturali tra due ere, con affidabilità maggiore su statistiche aggregate che su singole parole

isolate. I cluster K-Means e t-SNE completano l'analisi mostrando una struttura legata soprattutto alla grammatica, non ai temi. Il risultato più solido – e più sorprendente – è che ciò che resta stabile nel lessico musicale a 30 anni di distanza non sono i temi, ma le **frasi fisse** della lingua (*brand new, every single, sealed fate*). Questo tipo di analisi, applicabile a qualsiasi corpus che si estende nel tempo, mostra il potenziale delle rappresentazioni distribuzionali per lo studio dell'evoluzione del linguaggio nel tempo.

13 Dichiarazione sui Contributi di IA

Per questo laboratorio ci siamo appoggiati anche a uno strumento di intelligenza artificiale generativa (Claude, Anthropic), come supporto puntuale durante lo sviluppo:

- **Bug Skip-gram vs. CBOW**: mancava `sg=1` esplicito, Gensim addestrava silenziosamente CBOW nonostante testo e relazione dichiarassero Skip-gram; corretto.
- **Riproducibilità**: con `workers=4` il training non era bit-esatto a parità di seed; corretto con `workers=1`. K-Means produceva occasionalmente un cluster singoletto; risolto normalizzando i vettori a norma unitaria.
- **Secondo bug di riproducibilità**: la top-30 di Sezione 8.2 aveva un ordine dipendente da `PYTHONHASHSEED`, quindi cambiava a ogni esecuzione pur restando identico il modello; corretto ordinando esplicitamente le liste derivate da insiemi.
- **Lettura dei risultati**: dopo il fix, il top-30 per cambiamento di contesto è risultato dominato dalle parole più frequenti del corpus, le stesse ispezionate in Sezione 5 – un collegamento tra le due sezioni non ovvio a prima vista, che rafforza invece di contraddire l'argomento centrale sul rumore statistico.