

Università degli Studi di Torino
Corso di Laurea Magistrale in Informatica

Tecnologie del Linguaggio Naturale
Parte 3 – Prof. Luigi Di Caro

Lab 5
Hybrid Search RAG
Retrieval-Augmented Generation con ricerca ibrida semantica e lessicale

Gruppo di lavoro:

Studente	Matricola
Alessandro Olivero	915069
Samuele Iudice	1235245
Andrea Franco	1226739

Docente: Prof. Luigi Di Caro
Anno Accademico: 2025/2026

Indice

1	Introduzione	2
2	Cosa abbiamo usato	2
3	Risultati e Analisi	3
3.1	Precision@5 al variare di N_DOCS	3
3.2	Context Relevance e Answer Relevance: differenze minime	4
3.3	Faithfulness: vantaggio sistematico dell'ibrido	4
3.4	Robustezza: non è una vittoria automatica dell'ibrido	4
3.5	Un esempio qualitativo	5
3.6	Le conclusioni non dipendono da $k = 5$	5
4	Limiti	6
5	Conclusioni	6

1 Introduzione

Un sistema **Retrieval-Augmented Generation (RAG)** risponde a domande recuperando documenti rilevanti da una knowledge base e condizionando su di essi la generazione di un LLM, riducendo le allucinazioni rispetto a un LLM stand-alone. Questo lavoro confronta due strategie di retrieval su un corpus di paper NLP da arXiv:

- **RAG base:** retrieval puramente semantico (embeddings + FAISS).
- **RAG ibrido:** fusione del retrieval semantico con BM25 lessicale tramite Reciprocal Rank Fusion (RRF).

L'obiettivo è capire se e quanto l'aggiunta di BM25 migliori il sistema, e se le conclusioni reggono al variare della dimensione del corpus (1 000–44 949 documenti) e del numero di documenti recuperati (k). Nelle pagine seguenti ci concentriamo soprattutto sui risultati e su cosa ci dicono; il codice completo, commentato, si trova nei file `lab5_hybrid.py` (l'esperimento) e `lab5_hybrid_consegna.py` (una pipeline dimostrativa che risponde citando le fonti).

2 Cosa abbiamo usato

Tabella 1: Componenti del sistema

Componente	Scelta	Ruolo
Dataset	MaartenGr/arxiv_nlp (44 949 paper)	Corpus (titolo + abstract)
Embedding	SciBERT (allenai/scibert_scivocab_uncased)	Retrieval semantico
Indice vettoriale	FAISS IndexFlatIP	ANN search (coseno)
Retrieval lessicale	BM25Okapi (rank_bm25)	Keyword search
Fusione	Reciprocal Rank Fusion ($k = 60$)	Re-ranking ibrido
Generazione	Phi-3.5-mini-instruct (3.8B, greedy)	Risposta con citazioni

Il dataset `arxiv_nlp` è stato scelto perché offre un corpus di dimensioni realistiche e testi già puliti (titolo e abstract), utile per isolare l'effetto della dimensione del corpus senza doversi preoccupare di rumore nei dati. SciBERT è scelto per il vocabolario specializzato sul dominio scientifico; non essendo però un modello fine-tuned per sentence similarity, le sue similarità coseno restano compresse verso l'alto – un limite di cui si tiene conto nell'interpretare Context/Answer Relevance. BM25 recupera invece per corrispondenza esatta dei termini: complementare a SciBERT sui termini tecnici (“NER”, “LDA”, acronimi) che il retrieval denso tende a generalizzare. Per fondere i due ranking si è scelto RRF invece di sommare direttamente gli score di FAISS (similarità coseno) e BM25 (punteggio TF-IDF-like), che vivono su scale non comparabili: RRF aggira il problema usando solo la posizione di ciascun documento nelle due liste, con $k = 60$ (valore standard in letteratura, che pesa in modo simile i primi risultati anche quando le due liste hanno scale di punteggio molto diverse). Phi-3.5-mini-instruct è stato scelto come compromesso fra capacità di seguire istruzioni (citare le fonti, dichiarare quando il contesto è insufficiente) e costo computazionale: gira interamente su CPU, a differenza di modelli più grandi che avrebbero richiesto una GPU non disponibile.

Fusione ibrida: retrieval semantico + BM25 via RRF

```
1 def retrieve_hybrid(query, k=5):
2     sem = retrieve_semantic(query, k=20)    # top-20 per retriever prima
3     bm = retrieve_bm25(query, k=20)         # della fusione: pool ampio per RRF
4     return reciprocal_rank_fusion([sem, bm][:k])
5
6 def reciprocal_rank_fusion(results_list, k=60):
7     rrf_scores, doc_map = {}, {}
8     for results in results_list:
9         for item in results:
10             ix = item['idx']
11             rrf_scores[ix] = rrf_scores.get(ix, 0) + 1 / (k + item['rank'])
12             doc_map[ix] = item
13     ranked = sorted(rrf_scores.items(), key=lambda x: x[1], reverse=True)
14     return [{'rank': i+1, 'idx': ix, **doc_map[ix]}
15             for i, (ix, _) in enumerate(ranked)]
```

Metriche (ispirate a RAGAS): *Precision@k* (frazione dei top- k che contiene una keyword del gold standard), *Context Relevance* (coseno query–snippet recuperati), *Answer Relevance* (coseno query–risposta), *Faithfulness proxy* (frazione di parole di contenuto della risposta che compaiono nel contesto recuperato) e *Robustezza* (overlap@5 fra una query e le sue parafrasi). Tutte lessicali o basate su embedding – nessuna richiede giudizio umano, il che le rende economiche ma approssimate.

Esperimento: corpus annidati a $N_{\text{DOCS}} \in \{1\,000, 5\,000, 15\,000, 25\,000, 44\,949\}$ (mischianti una sola volta, così che i corpus piccoli siano sottoinsiemi di quelli grandi e un calo di prestazioni non dipenda dal campionamento casuale), scelti per coprire un ordine di grandezza dal corpus più piccolo a quello completo; gold standard di 5 query NLP eterogenee; confronto su $k \in \{3, 5, 10, 15\}$, con valori sia sotto sia sopra 5, per verificare che le conclusioni non dipendano dalla scelta $k = 5$ in particolare.

3 Risultati e Analisi

3.1 Precision@5 al variare di N_DOCS

Tabella 2: Precision@5, base vs. ibrido

N_DOCS	Base	Ibrido	Delta	Miglioramento
1 000	0.160	0.480	+0.320	+200.0%
5 000	0.280	0.680	+0.400	+142.9%
15 000	0.200	0.560	+0.360	+180.0%
25 000	0.200	0.560	+0.360	+180.0%
44 949	0.040	0.480	+0.440	+1100.0%

Delta indica la differenza Ibrido – Base: un valore positivo significa che l’ibrido fa meglio del base su quella metrica. L’ibrido supera il base in **tutte** le configurazioni (delta medio +0.376). Il dato più rilevante è il crollo del base a **0.040** sull’intero corpus: guardando il dettaglio per query, il retrieval solo-semantico non trova alcun documento rilevante nei top-5 per 4 query su 5 (BERT/self-attention, word2vec, machine translation, topic

modeling), recuperando qualcosa solo per “named entity recognition”. L’ibrido, sullo stesso identico corpus, resta a 0.480 – una differenza di 12 volte a parità di dati, imputabile solo alla presenza di BM25. Su un corpus ampio e con query brevi e generiche, il retrieval solo-embedding perde la capacità di isolare i pochi documenti pertinenti fra decine di migliaia; BM25 mantiene il segnale sulle parole chiave indipendentemente da quanti documenti competono nell’indice. Entrambe le curve hanno inoltre un picco a N=5 000, con un calo più marcato per il base che per l’ibrido dopo quel punto.

Tabella 3: Metriche complete per N_DOCS (base / ibrido)

N_DOCS	CR		AR		FF		Robustezza	
	Base	Ibr.	Base	Ibr.	Base	Ibr.	Base	Ibr.
1 000	0.716	0.715	0.676	0.657	0.503	0.740	0.233	0.267
5 000	0.724	0.722	0.676	0.659	0.571	0.693	0.167	0.100
15 000	0.713	0.731	0.683	0.675	0.604	0.727	0.100	0.067
25 000	0.720	0.728	0.692	0.667	0.599	0.702	0.067	0.000
44 949	0.719	0.724	0.687	0.680	0.438	0.635	0.033	0.033

3.2 Context Relevance e Answer Relevance: differenze minime

CR e AR differiscono poco fra base e ibrido ($|\Delta| < 0.02$ quasi ovunque): sono calcolate con gli stessi embedding SciBERT usati dal retrieval semantico, quindi non sono una misura indipendente della qualità del sistema – un limite già atteso, non un risultato. L’AR ibrida è quasi sempre leggermente inferiore alla base: i documenti trovati da BM25 sono più lontani dalla query nello spazio degli embedding (li trova per parola chiave, non per significato), e questo si riflette leggermente anche sulla risposta generata.

3.3 Faithfulness: vantaggio sistematico dell’ibrido

La Faithfulness è più alta per l’ibrido in **tutte** le configurazioni, con margini fra +0.103 e +0.237 (il salto più grande a N=1000 e sul corpus completo). I documenti trovati dall’ibrido restano più legati al vocabolario tecnico della domanda: l’LLM usa quindi più parole realmente presenti nei testi forniti, invece di “riempire i vuoti” con parole plausibili ma non presenti nel contesto.

3.4 Robustezza: non è una vittoria automatica dell’ibrido

Tabella 4: Robustezza (overlap@5 su query parafrasate)

N_DOCS	Base	Ibrido
1 000	0.233	0.267
5 000	0.167	0.100
15 000	0.100	0.067
25 000	0.067	0.000
44 949	0.033	0.033

L'ibrido è più robusto solo a $N=1\,000$; a $N=5\,000$ – $25\,000$ è il **base** a essere più stabile alle parafrasi. Aggiungere BM25 aiuta la precisione ma non garantisce automaticamente più stabilità: un secondo canale basato su corrispondenza esatta delle parole può essere più sensibile a un sinonimo diverso nella parafrasi, che BM25 non riconosce come la stessa keyword. In entrambi i sistemi la robustezza cala comunque con corpus più grandi (più documenti candidati, più facile che piccole variazioni lessicali spostino i top-5).

3.5 Un esempio qualitativo

Tabella 5: Esempio di risposta – query BERT, corpus completo (44 949 doc.)

Base: “...there is no direct information or discussion about BERT ...or self-attention mechanisms. The papers focus on various aspects of Natural Language Processing (NLP)....”
Ibrido: “...there is no direct explanation of BERT or self-attention mechanisms. The papers discuss ...attention in neural machine translation (Paper 2), cross-lingual syntactic ability of multilingual BERT (Paper 4)....”

Entrambi i sistemi dichiarano correttamente l'assenza di un paper specificamente dedicato a BERT, invece di inventare una risposta – comportamento corretto, ma che conferma il limite: nemmeno l'ibrido recupera un paper che spieghi BERT direttamente su questo corpus/gold standard. L'ibrido arriva però più vicino al tema, citando esplicitamente un paper su BERT multilingue.

3.6 Le conclusioni non dipendono da $k = 5$

Ripetendo il confronto Precision@ k /Context Relevance per *tutte* le configurazioni di N_DOCS a $k \in \{3, 10, 15\}$ (oltre al $k = 5$ già discusso), e Answer Relevance/Faithfulness a $k \in \{3, 5, 10, 15\}$ sul corpus più piccolo ($N=1\,000$, per contenere i tempi di generazione su CPU):

Tabella 6: Answer Relevance e Faithfulness al variare di k (N_DOCS=1 000)

k	AR Base	AR Ibrido	FF Base	FF Ibrido
3	0.683	0.663	0.414	0.627
5	0.676	0.657	0.503	0.740
10	0.695	0.653	0.613	0.789
15	0.669	0.661	0.608	0.819

L'ibrido supera il base in Precision@ k in **tutte le 20 combinazioni** di N_DOCS e k testate (margini da $\sim 2\times$ a $\sim 8\times$), e resta più fedele al contesto a ogni k (delta di Faithfulness $+0.176$ a $+0.237$, in linea o superiore al delta medio già visto a $k = 5$). L'unico effetto negativo dell'ibrido – Answer Relevance leggermente più bassa – è anch'esso presente a ogni k . Le conclusioni non sono quindi un artefatto della scelta $k = 5$, ma una caratteristica sistematica della fusione RRF.

4 Limiti

- **Gold standard lessicale:** la rilevanza è definita da parole chiave, non da giudizio umano; alcune keyword sono ampie (“topic”, “clustering”), il che favorisce strutturalmente un sistema che usa anche il matching lessicale (l’ibrido).
- **Faithfulness proxy:** stima lessicale (parole di contenuto della risposta presenti nel contesto), non verifica la correttezza logica delle affermazioni.
- **Context/Answer Relevance non indipendenti dal retrieval:** condividono l’embedding SciBERT usato per il retrieval semantico.
- **Costo computazionale:** intera pipeline eseguita su CPU (Phi-3.5-mini in float32, ~ 1.5 token/s); l’esperimento completo su 5 configurazioni di N_DOCS e 4 valori di k richiede diverse ore.
- **Campione ridotto:** 5 query per il gold standard e 3 per la robustezza; conclusioni da leggere come tendenze, non differenze puntualmente significative.

5 Conclusioni

1. Il retrieval ibrido migliora la Precision@5 in modo sistematico su tutte le dimensioni di corpus testate (delta medio +0.376), e questo si conferma per ogni valore di k testato ($k = 3, 5, 10, 15$), non solo per $k = 5$.
2. Il sistema base **crolla** su corpus grandi (P@5 0.040 a 44 949 documenti), mentre l’ibrido resta stabile (0.480): la ragione pratica per cui BM25 non è opzionale su corpus di queste dimensioni.
3. La Faithfulness beneficia chiaramente e sistematicamente del retrieval ibrido (margini +0.103 a +0.237), il risultato più stabile di tutto l’esperimento.
4. La robustezza alle parafrasi *non* premia sempre l’ibrido: aggiungere BM25 migliora la precisione ma non garantisce automaticamente più stabilità a piccole variazioni della query.
5. Context Relevance e Answer Relevance mostrano differenze minime fra i due sistemi, per un limite noto della metrica (stesso embedding del retrieval), non per assenza di differenze reali fra base e ibrido.