

Relazione LAB-1: Complessità Definizione e Sovrapposizione Semantica

Alessandro Olivero

Samele Iudice

Andrea Franco

13 maggio 2026

1 Fase 1: Creazione condivisa di definizioni

In questa prima fase, l'obiettivo è stato esplorare la complessità insita nella formulazione di definizioni per quattro concetti distinti, bilanciati lungo due dimensioni (concretezza e specificità):

- **Tree (Albero):** Concetto concreto e generico.
- **Teapot (Teiera):** Concetto concreto e specifico.
- **Music (Musica):** Concetto astratto e generico.
- **Ethics (Etica):** Concetto astratto e specifico.

Per lo svolgimento dell'esercizio, ci si è avvalsi di un dataset testuale ("Dataset definizioni-spurio.csv") contenente molteplici definizioni redatte in linguaggio naturale da diversi utenti. Il vincolo di partenza era che ciascuna definizione dovesse risultare comprensibile a un lettore generico. Di seguito alcuni esempi estratti dal dataset:

- **Tree (CG):** *"A plant with roots, trunk, branches and foliage used to obtain timber and produce paper."*
- **Ethics (AS):** *"Philosophical thought aimed at explaining ideal human behavior, attempting to demonstrate what is right and what is wrong."*

2 Fase 2: Analisi collettiva

Dall'analisi qualitativa delle definizioni raccolte sono emerse dinamiche linguistiche rilevanti:

1. **Scelte linguistiche e specificità:** Per i concetti concreti (*Tree*, *Teapot*), il lessico si concentra su componenti fisiche e funzionali (es. *"roots"*, *"metal container"*). Per *Teapot*, in particolare, emerge un altissimo grado di specificità legata al suo scopo primario (l'infusione del tè). Al contrario, per i concetti astratti (*Music*, *Ethics*), il vocabolario si sposta sulla sfera cognitiva e sensoriale (*"sentiment"*, *"behavior"*, *"melodious sounds"*).
2. **Difficoltà concettuali:** Si è riscontrata una maggiore difficoltà nel definire i concetti astratti. Mentre per l'albero e la teiera il referente fisico nel mondo reale guida uniformemente la descrizione, concetti come l'etica hanno generato definizioni eterogenee, sfumate e fortemente dipendenti dal contesto socio-culturale.
3. **Strategie definitorie:** L'approccio classico aristotelico del *genus-differentia* è stato adottato spontaneamente per i concetti concreti (*Tree* = *Kind of plant* [genus] + *composed by a trunk* [differentia]). Per i concetti astratti come la musica, invece, gli utenti hanno spesso preferito descrizioni operative o parafrasi basate sull'effetto prodotto.

3 Fase 3 e 4: Confronto lessicale (Simlex) e semantico (Simsem)

Al fine di quantificare la sovrapposizione tra le definizioni di uno stesso concetto, sono state applicate metriche computazionali (tramite script esterno in Python).

- **Metodologia Simlex:** Il testo è stato normalizzato (conversione in minuscolo, rimozione di punteggiatura e *stopword*, lemmatizzazione). È stato poi calcolato l'**Indice di Jaccard** sulle definizioni accoppiate a due a due per misurare l'esatta sovrapposizione lessicale.
- **Metodologia Simsem:** Le definizioni sono state vettorializzate tramite approccio **TF-IDF** ed è stata calcolata la **Cosine Similarity** media per catturare la vicinanza concettuale.

Tabella 1: Risultati medi aggregati della sovrapposizione lessicale e semantica.

Concetto	Tipo	Specificità	Simlex (Jaccard)	Simsem (Cosine)
Tree	Concreto	Generico	0.084	0.077
Teapot	Concreto	Specifico	0.057	0.062
Ethics	Astratto	Specifico	0.034	0.041
Music	Astratto	Generico	0.034	0.036

4 Fase 5: Analisi e riflessione finale

L'aggregazione quantitativa dei risultati ci permette di trarre le seguenti conclusioni:

- **Variabilità Lessicale (Simlex):** I valori di Jaccard sono risultati estremamente bassi per tutti i concetti (con un picco massimo di appena l'8.4% per l'albero). Ciò dimostra un'altissima variabilità del linguaggio naturale: i parlanti scelgono vocaboli molto diversi anche quando descrivono lo stesso referente.
- **Somiglianza Semantica (Simsem):** La metrica del coseno si è rivelata preziosa per i concetti astratti. Per l'Etica (0.041) e la Musica (0.036), la similarità semantica supera quella lessicale (0.034). I modelli vettoriali riescono infatti ad allineare sinonimi e concetti affini, riflettendo l'intuizione umana che riconosce definizioni concettualmente vicine pur se lessicalmente distanti.
- **Il ruolo di Concretezza e Astrazione:** Emerge un pattern inequivocabile: i concetti concreti ottengono punteggi di similarità nettamente superiori rispetto a quelli astratti. Il referente fisico restringe il campo semantico "costringendo" i parlanti a un lessico condiviso, mentre l'astrazione concettuale amplifica drasticamente le divergenze interpretative e formali.