

LAB-2: Valutazione Content-to-Form

Ricerca Onomasiologica con WordNet

TLN 2025/2026 – Prof. Luigi Di Caro

Alessandro Olivero

Samele Iudice

Andrea Franco

1 Obiettivo

Il Lab-2 esplora la **ricerca onomasiologica**: dato un contenuto (una definizione scritta in linguaggio naturale), si cerca di risalire alla **forma lessicale** codificata in WordNet, ovvero al synset corretto.

Questo inverte la direzione tipica di un dizionario (*forma* $\rightarrow$ *contenuto*) e pone la domanda: *quanto deve essere “buona” una definizione affinché permetta il recupero automatico del concetto giusto?*

2 Materiale e metodo

Dataset

Si è utilizzato il dataset `Dataset_definizioni-spurio.csv`, contenente 28 definizioni raccolte durante la lezione per quattro concetti:

Colonna	Concetto	Tipo	Specificità
AG	Music	Astratto	Generico
AS	Ethics	Astratto	Specifico
CG	Tree	Concreto	Generico
CS	Teapot	Concreto	Specifico

Procedura

Per ciascuna definizione è stato applicato il seguente procedimento:

1. **Pulizia del testo**: conversione in minuscolo, rimozione della punteggiatura, filtraggio delle stopwords.
2. **Selezione dei synset candidati**: per ogni concetto sono stati scelti i 5 synset più plausibili da WordNet 3.1 (inclusi sensi alternativi e iperonimi).
3. **Vettorizzazione TF-IDF**: la definizione e le glosse dei synset candidati vengono rappresentate come vettori TF-IDF.
4. **Cosine similarity**: si confronta la definizione con ogni glossa e si seleziona il synset con punteggio più alto.

5. **Valutazione:** il synset recuperato viene confrontato con il synset target (quello semanticamente corretto).

3 Risultati

3.1 Risultati per concetto

Tabella 1: Accuratezza e score di similarità per concetto

Concetto	Tipo	Spec.	Synset target	Corretto	Score medio	Score max
Music	Astratto	Generico	<code>music.n.01</code>	9/28 (32.1%)	0.1298	0.3981
Ethics	Astratto	Specifico	<code>ethics.n.01</code>	12/28 (42.9%)	0.1524	0.6295
Tree	Concreto	Generico	<code>tree.n.01</code>	25/28 (89.3%)	0.1025	0.2919
Teapot	Concreto	Specifico	<code>teapot.n.01</code>	20/28 (71.4%)	0.1272	0.3063

3.2 Aggregazione per tipo e specificità

Tabella 2: Score medio e accuratezza aggregati

Dimensione	Gruppo	Score medio	Accuratezza
Tipo	Astratto	0.1411	37.5%
	Concreto	0.1149	80.4%
Specificità	Generico	0.1162	60.7%
	Specifico	0.1398	57.1%

3.3 Esempi rappresentativi

Definizione con score più alto – Ethics (0.63):

“Branch of philosophy that studies human behavior by trying to define what is right and what is wrong, often influenced by historical and sociocultural context.”

Questa definizione segue esplicitamente lo schema *genus-differentia*: il genus “*branch of philosophy*” corrisponde quasi letteralmente alla glossa di `ethics.n.01` (“*the philosophical study of moral values and rules*”), garantendo un’alta sovrapposizione lessicale.

Definizione con score più alto – Music (0.40):

“A set of sounds made simultaneously by people and/or musical instruments.”

Cattura bene gli elementi chiave (*sounds, instruments*) ma non include il riferimento alla struttura artistica presente nella glossa target.

Definizione con score più alto – Tree (0.29):

“Woody plant with branches and leaves.”

Brevissima ma efficace: i termini *plant*, *branches* coincidono con la glossa **tree.n.01**.

Definizioni a score zero: Diverse definizioni mostrano score pari a 0. In molti casi si tratta di risposte compilate in modo generico o errato dagli studenti (es. una definizione di teapot inserita nella colonna di Ethics), confermando che la qualità della definizione ha un impatto diretto sul recupero.

4 Analisi e discussione

4.1 Concetti concreti vs astratti

Il risultato più significativo è la netta differenza di accuratezza tra concetti **concreti** (80.4%) e **astratti** (37.5%).

I concetti concreti come *Tree* e *Teapot* hanno proprietà fisiche ben definite (tronco, rami, foglie; beccuccio, manico, ceramica) che si traducono in un vocabolario condiviso e prevedibile. Le definizioni degli studenti convergono sugli stessi termini chiave, facilitando il matching con le glosse WordNet.

I concetti astratti come *Music* ed *Ethics* ammettono invece descrizioni molto diverse: chi si concentra sull'aspetto emotivo, chi su quello filosofico, chi su quello strutturale. La variabilità lessicale è alta, e il TF-IDF non riesce a catturare la somiglianza concettuale quando le parole usate divergono.

4.2 L'efficacia del genus-differentia

Le definizioni che seguono lo schema *genus-differentia* ottengono sistematicamente score più alti. Il *genus* (categoria generale) corrisponde spesso all'iperonimo del synset target in WordNet, mentre la *differentia* (proprietà distintiva) permette di discriminare tra synset dello stesso campo semantico.

Esempio: “*branch of philosophy [genus] that studies moral values [differentia]*” si allinea con **ethics.n.01** (“*the philosophical study of moral values and rules*”).

4.3 Limiti del metodo TF-IDF

Il metodo TF-IDF presenta alcune limitazioni rilevanti:

- **Opacità semantica:** due parole sinonime (es. *container* e *vessel*) ricevono score zero nonostante la somiglianza concettuale.
- **Sensibilità alla lunghezza:** definizioni molto brevi producono vettori sparsi con bassa copertura.
- **Assenza di struttura:** il TF-IDF tratta la definizione come bag-of-words, perdendo la struttura sintattica che in uno schema genus-differentia è semanticamente significativa.

Un approccio con embeddings contestuali (es. Sentence-BERT) cattura meglio la similarità semantica, superando il limite della dipendenza lessicale esatta.

4.4 Qualità delle definizioni e recupero del synset

L'esercizio mette in luce che la qualità di una definizione non è solo una questione stilistica, ma ha un impatto misurabile sulla ricercabilità del concetto:

- Definizioni con genus esplicito → recupero più facile.
- Definizioni per esempi o per riferimento → recupero più difficile (mancano i termini tecnici della glossa).
- Definizioni vaghe o generiche → score prossimo a zero.

5 Conclusioni

Il Lab-2 ha mostrato empiricamente che la ricerca onomasiologica automatica è significativamente più efficace per concetti concreti rispetto a concetti astratti. La struttura genus-differentia risulta la strategia definitoria più utile per il recupero automatico in WordNet, poiché allinea il vocabolario della definizione con quello delle glosse lessicografiche.

Dal punto di vista computazionale, il metodo TF-IDF è un baseline ragionevole ma insufficiente per catturare la ricchezza semantica di concetti astratti; approcci basati su embeddings contestuali rappresentano il naturale passo successivo.