

Università degli Studi di Torino
Corso di Laurea Magistrale in Informatica

Tecnologie del Linguaggio Naturale

Parte 3 – Prof. Luigi Di Caro

Lab 3

Complessità Polisemica Cross-Linguistica

Confronto della polisemia tra Inglese, Italiano e Spagnolo tramite Open
Multilingual WordNet

Gruppo di lavoro:

Studente	Matricola
Alessandro Olivero	915069
Samuele Iudice	1235245
Andrea Franco	1226739

Docente: Prof. Luigi Di Caro

Anno Accademico: 2025/2026

Indice

1	Introduzione	2
2	Background Teorico	2
2.1	Le tre dimensioni della polisemia	2
2.2	Il limite del dataset multilingue: distribuzione uniforme	2
2.3	Open Multilingual WordNet (OMW)	3
3	Metodologia	3
3.1	Selezione dei lemmi	3
3.2	Calcolo delle metriche	4
3.3	Misura dell’asimmetria cross-linguistica	4
4	Risultati	4
4.1	Statistiche descrittive per lingua	4
4.2	Heatmap: numero di sensi per lemma e lingua	5
4.3	Entropia polisemica per lemma e lingua	6
4.4	Asimmetria EN vs. lingue romanze	6
4.5	Distribuzione per lingua e categoria grammaticale	7
4.6	Rapporti di polisemia	8
5	Discussione	8
5.1	La gerarchia $EN \gg ES > IT$ non è (solo) linguistica	8
5.2	Il caso <i>bank</i> : asimmetria semantica, non solo quantitativa	8
5.3	<i>run</i> e <i>break</i> : i casi di massima asimmetria	9
5.4	I lemmi più stabili cross-linguisticamente	9
5.5	Implicazioni per il NLP multilingue	9
6	Conclusioni	9

1 Introduzione

Questo laboratorio affronta il **Progetto 3: Confronto cross-linguistico** proposto nelle dispense del corso (Capitolo 4, “Polisemia: complessità, struttura e variazioni multilingue”). L’obiettivo è verificare empiricamente una delle tesi centrali del capitolo: *la polisemia non è una proprietà universale della parola, ma del modo in cui una lingua organizza il proprio lessico*. Non esiste cioè una “polisemia assoluta” indipendente dalla lingua – la stessa area concettuale può essere lessicalizzata in modo completamente diverso da una lingua all’altra.

Per verificarlo, si confronta la complessità polisemica di **20 lemmi** (8 sostantivi, 6 verbi, 6 aggettivi) tradotti in **tre lingue** – inglese, italiano e spagnolo – usando l’Open Multilingual WordNet (OMW) tramite NLTK. Per ciascuna lingua si misura il numero di sensi (synset) e si calcola l’entropia di Shannon della loro distribuzione, per poi confrontare i risultati e individuare i lemmi con **asimmetria cross-linguistica** più marcata.

2 Background Teorico

2.1 Le tre dimensioni della polisemia

Seguendo l’impostazione delle dispense, la complessità polisemica di una parola non si riduce al solo conteggio dei sensi, ma si articola su tre dimensioni:

- **Numero di sensi** $N(w) = |\{s_1, \dots, s_n\}|$: la misura più intuitiva, ma insufficiente da sola.
- **Distribuzione dei sensi**, misurata tramite l’**entropia di Shannon**:

$$H(w) = - \sum_i p(s_i | w) \log_2 p(s_i | w)$$

Entropia bassa indica un senso dominante; entropia alta indica sensi più equamente distribuiti (maggiore complessità percepita).

- **Separabilità semantica**: quanto i sensi sono concettualmente distanti tra loro (non misurata in questo laboratorio, che si concentra sulle prime due dimensioni a livello cross-linguistico).

2.2 Il limite del dataset multilingue: distribuzione uniforme

A differenza dell’inglese, dove WordNet fornisce statistiche d’uso (frequenze SemCor) che permettono di stimare $p(s_i | w)$ in modo realistico, l’Open Multilingual WordNet **non fornisce frequenze d’uso** per le lingue non inglesi: fornisce solo l’insieme dei synset collegati a un lemma, senza indicazione di quale sia più comune. Si assume quindi, per tutte le lingue, una **distribuzione uniforme** sui sensi disponibili:

$$p(s_i | w) = \frac{1}{n} \quad \forall i, \quad H(w) = - \sum_{i=1}^n \frac{1}{n} \log_2 \frac{1}{n} = \log_2 n$$

Questo significa che, in questo esperimento, l’entropia è una funzione monotona del numero di sensi ($H = \log_2 n$): non aggiunge informazione indipendente dal conteggio, ma

fornisce una scala più interpretabile (in bit) per confrontare lemmi con numero di sensi molto diverso. È un limite esplicito da tenere presente nell’interpretazione dei risultati: con dati di frequenza reali (es. annotazioni SemCor anche per IT/ES), l’entropia potrebbe discostarsi dal semplice $\log_2 n$ rivelando differenze di *distribuzione* a parità di numero di sensi.

2.3 Open Multilingual WordNet (OMW)

L’OMW (Bond & Foster, 2013) collega i synset di Princeton WordNet (inglese) a risorse lessicali multilingue, permettendo di interrogare `wordnet.synsets(lemma, lang='ita')` per ottenere i synset associati a un lemma italiano o spagnolo. È la stessa risorsa citata nelle dispense per gli “aspetti correlati alla ricerca onomasiologica” e per gli studi cross-linguistici sulla polisemia.

3 Metodologia

3.1 Selezione dei lemmi

Sono stati selezionati 20 lemmi inglesi con traduzione italiana e spagnola, scelti per includere casi di polisemia notoriamente elevata in inglese (*bank, run, break, head, line*) insieme a casi più contenuti, bilanciando tre categorie grammaticali:

Tabella 1: Categorie grammaticali dei 20 lemmi

Categoria	N. lemmi	Esempi
Sostantivo	8	bank, hand, head, line, key, table, mouth, foot
Verbo	6	run, give, take, see, break, turn
Aggettivo	6	light, hard, free, right, open, deep

3.2 Calcolo delle metriche

Estrazione dei synset e calcolo di entropia

```
1 def calcola_metriche(synsets: list) -> dict:
2     """Distribuzione uniforme (OMW non fornisce frequenze per IT/ES)."""
3     n = len(synsets)
4     if n <= 1:
5         return {'n_sensi': n, 'entropia': 0.0, 'top1_share': 1.0}
6     dist = np.ones(n) / n
7     h = scipy_entropy(dist, base=2)
8     return {'n_sensi': n, 'entropia': round(h, 4),
9             'top1_share': round(1 / n, 4)}
10
11 def costruisci_dataframe() -> pd.DataFrame:
12     righe = []
13     for lemma_en, lemma_it, lemma_es, categoria in LEMMI:
14         for lang_code, lemma in [('eng', lemma_en),
15                                   ('ita', lemma_it), ('spa', lemma_es)]:
16             synsets = wn.synsets(lemma, lang=lang_code)
17             metriche = calcola_metriche(synsets)
18             righe.append({'lemma_en': lemma_en, 'lemma': lemma,
19                           'lingua_code': lang_code,
20                           'categoria': categoria, **metriche})
21     return pd.DataFrame(righe)
```

Per ogni lemma e lingua si recuperano i synset con `wn.synsets(lemma, lang=...)`, si conta n , e si calcola l'entropia assumendo distribuzione uniforme. Il `top1_share` ($= 1/n$ in questo caso) rappresenta la quota del senso più frequente sotto l'ipotesi di uniformità.

3.3 Misura dell'asimmetria cross-linguistica

Per ogni lemma si definisce l'**asimmetria** come la differenza tra il numero massimo e minimo di sensi tra le tre lingue:

$$\text{asimmetria}(w) = \max(N_{\text{en}}, N_{\text{it}}, N_{\text{es}}) - \min(N_{\text{en}}, N_{\text{it}}, N_{\text{es}})$$

insieme ai rapporti $N_{\text{en}}/N_{\text{it}}$ e $N_{\text{en}}/N_{\text{es}}$, che quantificano di quante volte l'inglese sia più (o meno) polisemico delle lingue romanze per lo stesso lemma.

4 Risultati

4.1 Statistiche descrittive per lingua

Tabella 2: Statistiche aggregate sui 20 lemmi, per lingua

Lingua	Media sensi	Mediana	Max	Media entropia	Monosemici
Inglese	31.70	30.5	75	4.79 bit	0
Italiano	7.95	6.5	23	2.71 bit	0
Spagnolo	13.15	12.5	32	3.45 bit	0

Il dato più evidente è la **netta gerarchia** Inglese $\gg$ Spagnolo $>$ Italiano: in media, per lo stesso lemma, WordNet inglese registra circa **4 volte più sensi** dell'italiano e oltre

il doppio dello spagnolo. Nessun lemma risulta monosemico in nessuna lingua (sempre $n \geq 2$), confermando che i lemmi scelti sono genuinamente polisemici.

4.2 Heatmap: numero di sensi per lemma e lingua




Figura 1: Numero di sensi per ciascuno dei 20 lemmi, nelle tre lingue. I lemmi sono ordinati per numero di sensi in inglese (decrescente).

La Figura 1 rende immediatamente visibile il pattern: la colonna “Inglese” è sistematicamente la più scura (valori più alti) per quasi tutti i lemmi, con *break* (75 sensi) e *run* (57) come casi estremi. Le colonne italiana e spagnola sono molto più chiare, ma con alcune eccezioni interessanti discusse in Sez. 5.

4.3 Entropia polisemica per lemma e lingua




Figura 2: Entropia di Shannon (bit) per ciascun lemma, confrontata tra le tre lingue.

Essendo l'entropia calcolata come $\log_2 n$ sotto l'ipotesi di uniformità (Sez. 2.2), il grafico in Figura 2 ha lo stesso andamento relativo dell'heatmap, ma in scala logaritmica: questo comprime visivamente le differenze per lemmi molto polisemici (es. la distanza tra 75 e 57 sensi, pari a 18 sensi assoluti, corrisponde a soli 0.40 bit di differenza) ed è quindi più indicato per confrontare la *complessità percepita* piuttosto che il conteggio grezzo.

4.4 Asimmetria EN vs. lingue romanze




Figura 3: Numero di sensi in inglese contro italiano (sinistra) e spagnolo (destra). La linea diagonale tratteggiata indica parità; i punti colorati per categoria grammaticale.

Tutti i punti in Figura 3 si trovano **sistematicamente sotto la diagonale di parità**, in entrambi i pannelli: per nessuno dei 20 lemmi l'italiano o lo spagnolo risultano più polisemici dell'inglese. La dispersione è maggiore nel pannello EN-ES che in quello EN-IT, coerentemente con la media più alta dello spagnolo (13.15 vs 7.95) osservata in Sez. 4.1.

Tabella 3: Top 5 lemmi per asimmetria cross-linguistica (max–min sensi)

Lemma (EN)	Inglese	Italiano	Spagnolo	Asimmetria
break	75	6	23	69
run	57	5	7	52
light	47	5	17	42
head	42	9	11	33
open	36	4	24	32

Tabella 4: Lemmi con minore asimmetria (comportamento più simile tra lingue)

Lemma (EN)	Inglese	Italiano	Spagnolo	Asimmetria
mouth	11	7	6	5
table	8	2	6	6
foot	14	6	8	8
hand	16	5	6	11
see	25	14	14	11

4.5 Distribuzione per lingua e categoria grammaticale




Figura 4: Sinistra: distribuzione del numero di sensi per lingua. Destra: distribuzione per categoria grammaticale, confrontata tra lingue.

Il pannello sinistro di Figura 4 conferma visivamente la gerarchia $EN \gg ES > IT$ con box ben separati e poca sovrapposizione. Il pannello destro mostra che la gerarchia si mantiene **all'interno di ogni categoria grammaticale** (sostantivi, verbi, aggettivi), suggerendo che il fenomeno non è un artefatto della scelta di una particolare classe di parole, ma una caratteristica strutturale della differenza tra le risorse lessicali delle tre lingue in OMW.

4.6 Rapporti di polisemia




Figura 5: Sinistra: rapporto EN/IT ed EN/ES per ciascun lemma. Destra: confronto diretto del numero di sensi per i 8 lemmi più asimmetrici.

Il pannello sinistro di Figura 5 mostra che per il lemma *run* il rapporto EN/ES raggiunge 8.14 (57 sensi inglesi contro 7 spagnoli): un fattore di oltre 8×. Il rapporto EN/IT più alto si osserva per *break* (12.5×). Questi valori estremi confermano quantitativamente l’intuizione qualitativa delle dispense: “la stessa area semantica può essere lessicalizzata in modi diversi” – in questo caso, l’inglese concentra un numero molto maggiore di accezioni sotto un’unica forma lessicale.

5 Discussione

5.1 La gerarchia $EN \gg ES > IT$ non è (solo) linguistica

Il risultato più robusto – la media di 31.7 sensi in inglese contro 13.2 in spagnolo e 7.95 in italiano – deve essere interpretato con cautela. Princeton WordNet (la base della parte inglese di OMW) è una risorsa costruita e raffinata per oltre 30 anni da linguisti computazionali, con una granularità dei sensi spesso molto fine (lo stesso problema della granularità discusso nelle dispense, Cap. 1: WordNet distingue sensi che un parlante non percepirebbe come distinti). Le estensioni multilingue di OMW per italiano e spagnolo sono invece mappature più recenti e meno esaustive. Una parte della differenza osservata è quindi plausibilmente dovuta a **differenze nella copertura e nella granularità delle risorse**, non solo a una reale differenza di polisemia tra le lingue – una limitazione importante da segnalare, in linea con l’invito delle dispense a non considerare il numero di sensi nel dizionario come misura definitiva (Cap. 4: “una parola può avere molti sensi nel dizionario, ma usarne abitualmente solo pochi”).

5.2 Il caso *bank*: asimmetria semantica, non solo quantitativa

Il lemma *bank* (18 sensi EN, 2 IT, 8 ES) è istruttivo non solo per il numero ma per la **struttura** dei sensi. In italiano, “banca” (2 sensi) copre quasi esclusivamente l’istituto

finanziario: il senso “riva del fiume” è lessicalizzato in una parola completamente diversa (*riva*), non tracciata in questo studio per il lemma *bank*. In spagnolo, invece, “banco” (8 sensi) è semanticamente più carico: copre l’istituto finanziario, ma anche il mobile (panca/banco di scuola) e il banco di sabbia/pesci – un comportamento più vicino a quello inglese, dove *bank* include già il significato geografico oltre a quello finanziario. Questo è un esempio concreto di **asimmetria cross-linguistica nella lessicalizzazione**: la stessa area concettuale viene divisa diversamente tra le tre lingue, esattamente il fenomeno teorizzato nelle dispense con l’esempio italiano “tempo” (atmosferico + cronologico) vs. l’inglese (*weather/time* separati).

5.3 *run* e *break*: i casi di massima asimmetria

I due lemmi con asimmetria più estrema sono entrambi verbi: *run* (52) e *break* (69). Questo è in linea con l’osservazione delle dispense secondo cui i verbi tendono a presentare “polisemia molto elevata” in inglese (lo stesso esempio di *run* è citato esplicitamente nel Cap. 4 delle dispense). Il verbo inglese *run* si estende infatti a domini semantici molto eterogenei – corsa fisica, gestione (*run a business*), funzionamento di macchine (*the engine runs*), candidatura politica (*run for office*), liquidi che scorrono – ciascuno dei quali in italiano e spagnolo è tipicamente lessicalizzato con un verbo distinto (*correre, gestire, funzionare, candidarsi, scorrere*), motivando direttamente il basso numero di sensi rilevato per “correre”/“correr” (5 e 7 rispettivamente), che in OMW intercetta solo l’accezione di movimento fisico.

5.4 I lemmi più stabili cross-linguisticamente

All’estremo opposto, *mouth* (asimmetria 5) e *table* (asimmetria 6) mostrano comportamento più omogeneo tra le lingue. Si tratta di due sostantivi concreti con un referente fisico ben definito (la bocca, il tavolo): coerentemente con quanto discusso a proposito dei concetti **Concrete Generic/Specific** nei laboratori 1-2, il vincolo del referente fisico limita anche la variabilità del numero di estensioni di significato disponibili, in tutte e tre le lingue.

5.5 Implicazioni per il NLP multilingue

I risultati confermano in modo quantitativo le implicazioni discusse nelle dispense (Cap. 4.5.3): un sistema di **machine translation** o di **cross-lingual transfer** che assuma una corrispondenza 1:1 tra i sensi di un lemma inglese e quelli del corrispettivo italiano o spagnolo commetterebbe un errore sistematico, specialmente per verbi ad alta polisemia come *run* o *break*: un modello addestrato sulla granularità fine di WordNet inglese, se applicato senza adattamento a un dominio italiano o spagnolo, tenderà a generare ambiguità spurie o a fallire nel mappare correttamente le accezioni.

6 Conclusioni

Il laboratorio ha verificato empiricamente, su 20 lemmi e tre lingue, la tesi delle dispense secondo cui **non esiste una polisemia universale**: il numero di sensi disponibili per lo stesso lemma varia sistematicamente tra inglese, italiano e spagnolo (rispettivamente

31.7, 7.95 e 13.15 sensi medi), con asimmetrie individuali fino a $12.5\times$ (*break*, EN/IT) e $8.14\times$ (*run*, EN/ES).

I risultati principali sono:

1. **Gerarchia sistematica EN $\gg$ ES $>$ IT**, confermata sia nell’aggregato sia all’interno di ogni categoria grammaticale (sostantivi, verbi, aggettivi) – ma da interpretare cum grano salis, essendo in parte attribuibile a differenze di copertura/granularità tra le risorse lessicali, non solo a una reale differenza di polisemia.
2. **I verbi mostrano l’asimmetria più marcata** (*break*, *run*), coerentemente con la tendenza dei verbi inglesi a un’estensione semantica molto ampia rispetto alle lingue romanze.
3. **I sostantivi concreti con referente fisico stabile** (*mouth*, *table*, *foot*) mostrano la minore asimmetria cross-linguistica, suggerendo che il vincolo referenziale limiti la variabilità anche a livello multilingue.
4. **L’asimmetria non è solo quantitativa ma strutturale**: il caso *bank/banca/banco* mostra come la stessa area concettuale possa essere ripartita in modo diverso tra parole distinte (italiano) o concentrata in un’unica forma più carica semanticamente (spagnolo, più vicino all’inglese).

Il limite principale dello studio è l’assunzione di **distribuzione uniforme dei sensi** per tutte le lingue, dovuta all’assenza di dati di frequenza d’uso in OMW per italiano e spagnolo (a differenza dell’inglese, dove tali dati esistono via SemCor). Un’estensione naturale del lavoro sarebbe integrare stime di frequenza per le lingue romanze (es. da corpora annotati o da conteggi su corpora di testo generici), permettendo di calcolare un’entropia realistica e non semplicemente $\log_2 n$, e di distinguere lemmi con *molti sensi ma fortemente dominati da un uso comune* da lemmi con sensi realmente equiprobabili – la distinzione esplicitamente evidenziata come cruciale nelle dispense (Cap. 4.7, “distribuzione sbilanciata della complessità”).