

UNIVERSITÀ DEGLI STUDI DI TORINO

Dipartimento di Informatica

Corso di Laurea Magistrale in Informatica

LAB-4

Topic Modeling con BERTopic

Tecnologie del Linguaggio Naturale — A.A. 2025/2026

Prof. Luigi Di Caro

Studente: Alessandro Olivero

Corso: Tecnologie del Linguaggio Naturale

Anno: 2025/2026

Torino, 14 maggio 2026

Indice

1	Obiettivo	2
2	Dataset	2
3	Architettura della Pipeline	2
4	Configurazioni Testate	3
4.1	Config 1 — Baseline	3
4.2	Config 2 — MiniLM, clustering fine	3
4.3	Config 3 — MiniLM, clustering grossolano	3
5	Risultati	4
5.1	Metriche quantitative	4
5.2	Top-10 topic — Config 1 (Baseline)	4
5.3	Top-10 topic — Config 2 (MiniLM fine)	4
5.4	Top-10 topic — Config 3 (MiniLM coarse)	4
6	Analisi e Valutazione Qualitativa	4
6.1	Config 1 vs Config 2: granularità e qualità	4
6.2	Config 3: un failure mode istruttivo	6
6.3	Riepilogo dei trade-off osservati	6
6.4	Configurazione consigliata	6
7	Conclusioni	6

1. Obiettivo

L'obiettivo del laboratorio è costruire una **pipeline completa di Topic Modeling** sul dataset `MaartenGr/arxiv_nlp`, composto da 44.949 abstract di articoli scientifici nel dominio NLP. La pipeline combina quattro componenti: embedding testuale, riduzione dimensionale con UMAP, clustering density-based con HDBSCAN, e infine estrazione di topic interpretabili tramite BERTopic.

Il laboratorio richiede di testare **almeno tre configurazioni** diverse, variando modello di embedding, parametri UMAP e parametri HDBSCAN, documentando metriche quantitative e producendo una valutazione qualitativa comparativa che spieghi i trade-off osservati.

2. Dataset

Il dataset utilizzato è `MaartenGr/arxiv_nlp`, disponibile su HuggingFace. Contiene **44.949 abstract** di paper NLP provenienti da ArXiv, senza etichette tematiche predefinite.

```
1 from datasets import load_dataset
2
3 dataset = load_dataset("MaartenGr/arxiv_nlp", split="train")
4 abstracts = dataset["Abstracts"]
5 # len(abstracts) == 44949
```

Listing 1: Caricamento del dataset

3. Architettura della Pipeline

La pipeline è composta da quattro fasi eseguite in sequenza:

1. **Embedding** — ogni abstract viene convertito in un vettore denso tramite un modello `SentenceTransformer`.
2. **UMAP** — gli embedding ad alta dimensionalità vengono proiettati in uno spazio a dimensione ridotta preservando la struttura semantica locale e globale.
3. **HDBSCAN** — algoritmo di clustering density-based che identifica cluster di forma arbitraria e assegna etichetta `-1` agli outlier.
4. **BERTopic** — estrae rappresentazioni testuali interpretabili per ciascun cluster tramite TF-IDF contestualizzato (c-TF-IDF).

```
1 from sentence_transformers import SentenceTransformer
2 from umap import UMAP
3 from hdbscan import HDBSCAN
4 from bertopic import BERTopic
5
6 emb_model = SentenceTransformer("thenlper/gte-small")
7 umap_model = UMAP(n_components=5, n_neighbors=15,
8                   min_dist=0.0, metric="cosine", random_state=42)
9 hdbscan_model = HDBSCAN(min_cluster_size=50, metric="euclidean",
```

```

10         cluster_selection_method="eom")
11
12 topic_model = BERTopic(embedding_model=emb_model,
13                        umap_model=umap_model,
14                        hdbscan_model=hdbscan_model)
15
16 embeddings    = emb_model.encode(abstracts, show_progress_bar=
17     True)
18 topics, probs  = topic_model.fit_transform(abstracts, embeddings
19     )

```

Listing 2: Struttura generale della pipeline BERTopic

4. Configurazioni Testate

4.1 Config 1 — Baseline

Configurazione di riferimento, corrispondente a quella proposta nelle slide del corso. Utilizza il modello `gte-small` con parametri UMAP e HDBSCAN standard.

Componente	Impostazione
Embedding model	thenlper/gte-small (384 dim.)
UMAP	n_components=5, n_neighbors=15, min_dist=0.0
HDBSCAN	min_cluster_size=50, metric=euclidean

4.2 Config 2 — MiniLM, clustering fine

Modello più leggero, dimensionalità UMAP aumentata e cluster più piccoli per favorire topic più granulari e separazione di sottoargomenti affini.

Componente	Impostazione
Embedding model	all-MiniLM-L6-v2 (384 dim., più compatto)
UMAP	n_components=10, n_neighbors=10, min_dist=0.0
HDBSCAN	min_cluster_size=30, metric=euclidean

4.3 Config 3 — MiniLM, clustering grossolano

Stesso modello della Config 2, ma con parametri che forzano cluster molto più ampi. Questa configurazione è progettata per esplorare il comportamento della pipeline al limite opposto rispetto alla Config 2.

Componente	Impostazione
Embedding model	all-MiniLM-L6-v2
UMAP	n_components=5, n_neighbors=30, min_dist=0.0
HDBSCAN	min_cluster_size=150, metric=euclidean

5. Risultati

5.1 Metriche quantitative

Configurazione	#Topic	Outlier	Outlier%	Tempo totale
Config 1 — Baseline	151	14.357	31,9%	$\approx$ 3h 47m
Config 2 — MiniLM fine	171	12.747	28,4%	$\approx$ 17m 30s
Config 3 — MiniLM coarse	49	14.899	33,1%	$\approx$ 11m

Tabella 1: Confronto quantitativo tra le tre configurazioni

5.2 Top-10 topic — Config 1 (Baseline)

ID	Count	Top-5 parole
0	2235	speech, asr, recognition, end, acoustic
1	2166	question, qa, questions, answer, answering
2	1603	medical, clinical, biomedical, patient, health
3	886	summarization, summaries, summary, abstractive, document
4	862	translation, nmt, machine, bleu, neural
5	670	relation, extraction, re, relations, entity
6	657	gender, bias, biases, debiasing, fairness
7	581	ner, entity, named, recognition, entities
8	375	parsing, dependency, parser, parsers, treebank
9	352	law, frequency, zipf, words, word

Tabella 2: Config 1 — Top-10 topic per numero di documenti

5.3 Top-10 topic — Config 2 (MiniLM fine)

5.4 Top-10 topic — Config 3 (MiniLM coarse)

6. Analisi e Valutazione Qualitativa

6.1 Config 1 vs Config 2: granularità e qualità

Entrambe le configurazioni producono topic semanticamente coerenti e privi di stop words, segno che sia `gte-small` sia `all-MiniLM-L6-v2` codificano adeguatamente il contenuto semantico degli abstract.

ID	Count	Top-5 parole
0	2722	dialogue, dialog, response, conversational, conversation
1	2432	speech, asr, recognition, end, acoustic
2	1844	question, qa, answer, questions, answering
3	1141	medical, clinical, biomedical, patient, notes
4	1009	summarization, summaries, summary, abstractive, document
5	986	hate, offensive, detection, speech, social
6	716	emotion, emotions, emotional, multimodal, empathetic
7	663	gender, bias, biases, fairness, debiasing
8	524	relation, extraction, re, relations, entity
9	519	parsing, dependency, parser, amr, parsers

Tabella 3: Config 2 — Top-10 topic per numero di documenti

ID	Count	Top-5 parole
0	2701	dialogue, the , dialog, to , and
1	2424	speech, asr, recognition, the , to
2	2245	translation, machine, nmt, the , to
3	1746	medical, clinical, and , the , of
4	1637	question, answer, questions, qa, answering
5	1424	word, embeddings, similarity, semantic, embedding
6	1327	transformer, attention, the , models, of
7	1167	summarization, summaries, summary, abstractive, document
8	966	image, visual, multimodal, images, the
9	859	adversarial, attacks, attack, privacy, to

Tabella 4: Config 3 — Top-10 topic. Le stop words in grassetto evidenziano la degradazione della qualità rappresentativa.

La Config 2 produce **20 topic in più** (171 vs 151) e registra una percentuale di outlier inferiore (28,4% vs 31,9%). Questo è attribuibile a due fattori: il valore `min_cluster_size=30` consente la formazione di cluster più piccoli e numerosi, mentre `n_components=10` preserva più struttura semantica locale, facilitando la separazione di sottoargomenti affini.

Un esempio emblematico: nella Config 1 il topic 0 è *speech/ASR*, mentre nella Config 2 emerge un topic distinto dedicato ai *sistemi dialogici* (*dialogue*, *conversational*, *response*), separato da ASR. La Config 2 è quindi più capace di distinguere sfumature tematiche all'interno dello stesso macro-dominio.

Sul piano computazionale la differenza è netta: la Config 1 richiede circa **3 ore e 47 minuti** a causa del costo di `gte-small` su CPU (13.484 secondi solo per gli embedding), mentre la Config 2 completa in meno di 18 minuti. Poiché la qualità risultante è comparabile o superiore, `all-MiniLM-L6-v2` rappresenta la scelta più efficiente per dataset di questa dimensione in ambienti senza GPU dedicata.

6.2 Config 3: un failure mode istruttivo

La Config 3 è il caso più interessante, in quanto espone un **failure mode reale e prevedibile** della pipeline BERTopic.

Con `min_cluster_size=150` e `n_neighbors=30`, HDBSCAN forma solo 49 cluster, ciascuno contenente un elevato numero di documenti eterogenei. BERTopic estrae le parole rappresentative tramite c-TF-IDF calcolato sui documenti di ciascun cluster: se il cluster è troppo grande e tematicamente misto, le parole discriminanti vengono *diluite* da termini ad alta frequenza globale, tra cui le stop words.

Questo si manifesta chiaramente nelle top-5 parole (evidenziate in grassetto nella Tabella 4):

- Topic 0: `dialogue`, `the`, `dialog`, `to`, `and`
- Topic 1: `speech`, `asr`, `recognition`, `the`, `to`
- Topic 6: `transformer`, `attention`, `the`, `models`, `of`

La presenza di articoli e preposizioni nelle prime cinque posizioni indica che il segnale semantico specifico del cluster è insufficiente rispetto al rumore introdotto dalla dimensione eccessiva. Il topic diventa *non interpretabile*: si tratta di un aggregato di sottoargomenti che avrebbero dovuto restare separati. Paradossalmente, anche la percentuale di outlier aumenta leggermente (33,1%), poiché cluster molto grandi in HDBSCAN tendono ad assorbire meno punti periferici.

6.3 Riepilogo dei trade-off osservati

6.4 Configurazione consigliata

La **Config 2** risulta complessivamente la migliore: produce il maggior numero di topic (171), la minor percentuale di outlier (28,4%), parole rappresentative pulite e semanticamente coerenti, e un tempo di esecuzione praticabile in assenza di GPU (≈ 17 minuti su CPU).

7. Conclusioni

Il laboratorio ha mostrato come la qualità del topic modeling con BERTopic dipenda criticamente dalla combinazione di tre fattori: la capacità del modello di embedding di catturare la semantica del dominio, la granularità della proiezione UMAP e la soglia di densità imposta da HDBSCAN.

Parametro	Valore basso	Valore alto
<code>min_cluster_size</code>	Più topic granulari; possibili micro-cluster rumorosi	Meno topic generali; rischio stop words nelle top parole
<code>n_neighbors</code> (UMAP)	Struttura locale preservata; cluster più separati	Struttura globale preservata; cluster meno distinti
<code>n_components</code> (UMAP)	Più veloce; possibile perdita semantica	Più ricco semanticamente; più lento
Dimensione modello embedding	Modelli compatti (MiniLM): veloci, qualità comparabile	Modelli grandi (gte-small): lenti su CPU, non sempre superiori

Tabella 5: Sintesi dei trade-off osservati nelle tre configurazioni

La Config 3 illustra concretamente la lezione teorica del corso: anche tecniche moderne come BERTopic non sono esenti da failure modes prevedibili e analizzabili. Conoscere il funzionamento interno della pipeline è indispensabile per interpretarne correttamente l'output e scegliere i parametri appropriati — coerentemente con l'obiettivo del laboratorio di *capire le scelte, non solo ottenere un output*.