

Progetto Esteso – TLN Parte III

RAG Ibrido con Valutazione Quantitativa

Riassunto per lo studio

Tecnologie del Linguaggio Naturale – Prof. Di Caro – A.A. 2025/2026

Indice

1 Cos'è RAG — la base del progetto

RAG (**Retrieval-Augmented Generation**) è un sistema che risponde a domande combinando due componenti:

1. Un **motore di ricerca** che recupera i documenti più rilevanti per la domanda;
2. Un **LLM** (Large Language Model) che legge quei documenti e genera la risposta.

Il vantaggio è che il modello non deve “ricordare” tutto: accede a conoscenza esterna al momento del bisogno. Il flusso è:

Query utente $\xrightarrow{\text{retrieval}}$ Documenti rilevanti $\xrightarrow{\text{generazione}}$ Risposta

1.1 Cosa abbiamo costruito nel LAB-5

Nel quinto laboratorio abbiamo implementato un sistema RAG completo sul dataset `MaartenGr/arxiv_nlp` di Hugging Face, contenente circa 45.000 abstract di paper scientifici NLP. Il sistema:

- genera **embeddings semantici** degli abstract con `all-MiniLM-L6-v2`;
- indicizza i vettori con **FAISS** (Fast Approximate Nearest Neighbor);
- recupera i k documenti più simili alla query;
- genera la risposta con un LLM locale (es. `Qwen2.5-0.5B`).

2 Il problema del RAG base: perché non basta

Il retrieval basato solo su embeddings ragiona per **concetti**, non per **parole esatte**. Questo crea problemi in due casi tipici:

- Query con **termini tecnici specifici** (nomi di algoritmi, acronimi);
- Query **molto brevi** dove il contesto semantico è insufficiente.

Esempio. Se cerchi “BERT pre-training”, il sistema semantico potrebbe restituire documenti che parlano di transformer in generale, anche se non contengono letteralmente quelle parole.

3 Il progetto esteso: Hybrid Search

3.1 BM25 — il retrieval lessicale

BM25 (*Best Match 25*) è un algoritmo di ranking classico che misura la rilevanza di un documento rispetto a una query basandosi sulla **frequenza delle parole** nel documento e nella collezione. A differenza degli embeddings, BM25 lavora sulle parole esatte.

La formula di scoring è:

$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

dove $f(q_i, D)$ è la frequenza del termine nel documento, $|D|$ è la lunghezza del documento, avgdl è la lunghezza media, e $k_1 = 1.5$, $b = 0.75$ sono parametri tipici.

3.2 Confronto tra i due approcci

	Embeddings semantici	BM25 lessicale
Punto di forza	Capisce sinonimi e concetti	Preciso su termini esatti
Punto debole	Impreciso su termini specifici	Non capisce il significato
Buono per	Query concettuali e lunghe	Query con termini tecnici

3.3 Hybrid Search: la combinazione

Combiniamo i due metodi con **Reciprocal Rank Fusion (RRF)**:

$$\text{RRF}(d) = \sum_{r \in R} \frac{1}{k + r(d)}$$

dove $r(d)$ è il rank del documento d nella lista r e $k = 60$ è una costante tipica. In pratica:

1. BM25 produce una lista ordinata di documenti;
2. Gli embeddings producono un'altra lista ordinata;
3. RRF fonde le due liste dando peso ai documenti che appaiono in cima a entrambe.

4 La valutazione quantitativa

Non ci limitiamo a dire “funziona bene”: **misuriamo** quanto funziona bene.

4.1 Metriche di retrieval

Precision@k – dei primi k documenti restituiti, quanti sono rilevanti?

$$P@k = \frac{|\text{documenti rilevanti tra i primi } k|}{k}$$

Recall@k – di tutti i documenti rilevanti esistenti, quanti ne ho recuperati?

$$R@k = \frac{|\text{documenti rilevanti tra i primi } k|}{|\text{tutti i documenti rilevanti}|}$$

4.2 Faithfulness

La risposta generata è fedele ai documenti recuperati, o il modello “inventa” informazioni non presenti nel contesto?

4.3 Disegno sperimentale

Configurazione	Retrieval	Atteso migliore su
RAG base	Solo embeddings	Query concettuali
RAG ibrido	BM25 + embeddings (RRF)	Query con termini precisi

4.4 Log di esecuzione: generazione delle risposte

Durante la fase di valutazione qualitativa (Answer Relevance e Faithfulness), per ogni query del gold standard il sistema genera una risposta con l’LLM al k migliore individuato:

Generazione risposte per valutazione qualitativa (k=3)...

```
[transformers] Both 'max_new_tokens' (=300) and 'max_length' (=20) seem to have been set. 'max_new_tokens' will take precedence. Please refer to the documentation for more information.
```

(ripetuto una volta per ciascuna query del gold standard)

Descrizione. Il warning è emesso dalla pipeline `text-generation` di Hugging Face a ogni chiamata di `generate()`. Il `GenerationConfig` caricato di default insieme al modello porta `max_length=20`, mentre la pipeline è configurata con `max_new_tokens=300`; i due limiti convivono nella config finché non si disattiva esplicitamente `max_length`, e `transformers` segnala che userà `max_new_tokens` ignorando il valore residuo. È un avviso innocuo, non un errore: ogni risposta viene comunque generata con il budget di 300 token nuovi previsto. Compare una volta per ogni query del gold standard valutata.

5 Stack tecnologico

- `rank_bm25` – implementazione Python di BM25
- `sentence-transformers` – generazione embeddings
- `faiss-cpu` – vector store per nearest neighbor search

- **datasets** (HuggingFace) – caricamento dataset arXiv NLP
- **transformers + torch** – LLM locale per la generazione
- **RAGAS** (opzionale) – framework per valutazione automatica RAG

6 Cosa dire domani al professore

“Abbiamo completato tutti e cinque i laboratori. Come progetto esteso vorremmo partire dal LAB-5 e estenderlo in due direzioni.

La prima è implementare un hybrid search: invece di usare solo gli embeddings semantici, combiniamo BM25 con gli embeddings tramite Reciprocal Rank Fusion, e confrontiamo i risultati su query di tipo diverso.

La seconda è aggiungere una valutazione quantitativa con Precision@k, Recall@k e, se riusciamo, la faithfulness.

L’obiettivo non è solo far funzionare il sistema, ma confrontare almeno due configurazioni e analizzare i trade-off.”

7 Perché non è banale

- Non basta collegare due API: bisogna scegliere il parametro k della fusion e gestire score su scale diverse (BM25 illimitato vs. cosine in $[-1, 1]$).
- La valutazione richiede un gold standard costruito a mano, non solo l’osservazione soggettiva delle risposte.
- Bisogna analizzare i trade-off (precisione lessicale vs. recall semantico) invece di limitarsi a far funzionare il sistema.

8 Connessione con il corso

- **Cap. 6 – Pre-LLM NLP:** BM25 è citato esplicitamente come baseline robusta per il retrieval lessicale.
- **Cap. 7 – RAG:** il progetto è un’estensione diretta del LAB-5, citata nella sezione 7.14.8 della dispensa.
- **Cap. 9 – Valutazione:** le metriche Precision@k e faithfulness sono al centro della griglia di valutazione del prof.