

Università degli Studi di Torino
Corso di Laurea Magistrale in Informatica

Tecnologie del Linguaggio Naturale

Parte 3 – Prof. Luigi Di Caro

Relazione Complessiva

Laboratori 1–5

Complessità definizionale e sovrapposizione semantica · Ricerca
onomasiologica con WordNet · Polisemia cross-linguistica · Topic
modeling con BERTopic · Retrieval-Augmented Generation

Gruppo di lavoro:

Studente	Matricola
Alessandro Olivero	915069
Samuele Iudice	1235245
Andrea Franco	1226739

Il Laboratorio 4 è stato svolto individualmente da Alessandro Olivero.

Docente: Prof. Luigi Di Caro

Anno Accademico: 2025/2026

11 luglio 2026

Indice

1	Introduzione generale	2
2	Lab 1 – Complessità Definizionale e Sovrapposizione Semantica	2
2.1	Obiettivo e materiale	2
2.2	Metodologia	3
2.3	Risultati	3
2.4	Discussione	4
3	Lab 2 – Valutazione Content-to-Form: Ricerca Onomasiologica con Word-Net	4
3.1	Obiettivo	4
3.2	Metodo	5
3.3	Risultati	5
3.4	Discussione	5
4	Lab 3 – Complessità Polisemica Cross-Linguistica	7
4.1	Obiettivo	7
4.2	Metodologia	7
4.3	Risultati	7
4.4	Discussione	9
5	Lab 4 – Topic Modeling con BERTopic	10
5.1	Obiettivo	10
5.2	Architettura della pipeline	10
5.3	Configurazioni testate	10
5.4	Risultati	10
5.5	Discussione	11
6	Lab 5 – Retrieval-Augmented Generation (RAG)	12
6.1	Obiettivo	12
6.2	Architettura	12
6.3	Metriche di valutazione (ispirate a RAGAS)	13
6.4	Esperimento 1: variazione della dimensione del corpus (RAG base vs ibrido)	13
6.5	Esperimento 2: variazione del parametro k e qualità su query eterogenee .	14
6.6	Conclusioni Lab 5	14
7	Conclusioni generali	15

1 Introduzione generale

Questa relazione raccoglie e sintetizza i cinque laboratori svolti nella Parte 3 del corso di **Tecnologie del Linguaggio Naturale** (Prof. Luigi Di Caro, A.A. 2025/2026). I laboratori, pur affrontando tecniche molto diverse tra loro, seguono un filo conduttore comune: la tensione tra *forma linguistica* e *contenuto semantico*, esplorata a livelli di granularità crescente.

- Il **Lab 1** parte dal problema più elementare – definire un concetto in linguaggio naturale – e misura quanto le definizioni indipendenti di persone diverse si sovrappongano, lessicalmente e semanticamente.
- Il **Lab 2** inverte la prospettiva: data una definizione (il *contenuto*), tenta di risalire automaticamente alla *forma* lessicale corretta codificata in WordNet (ricerca onomasiologica).
- Il **Lab 3** sposta l'analisi sul piano cross-linguistico, mostrando che la complessità polisemica di una parola non è una proprietà assoluta, ma dipende da come ciascuna lingua organizza il proprio lessico.
- Il **Lab 4** affronta il problema in modo non supervisionato: invece di partire da concetti noti, estrae automaticamente i temi presenti in una grande collezione di documenti (topic modeling) tramite BERTopic.
- Il **Lab 5** chiude il percorso integrando retrieval semantico/lessicale e generazione linguistica in un sistema **RAG** (Retrieval-Augmented Generation) completo, applicato e valutato su un corpus di paper scientifici NLP.

Tutti i laboratori condividono inoltre un dataset o una risorsa lessicale di riferimento (il dataset di definizioni raccolto in aula per i Lab 1–2, WordNet/OMW per i Lab 1–3, il corpus **arXiv-NLP** per i Lab 4–5), il che permette confronti diretti tra i risultati, evidenziati nelle sezioni di discussione di ciascun laboratorio.

2 Lab 1 – Complessità Definizionale e Sovrapposizione Semantica

2.1 Obiettivo e materiale

L'obiettivo del Lab 1 è misurare quanto le definizioni indipendenti raccolte da studenti diversi per uno stesso concetto si sovrappongano, sia lessicalmente sia semanticamente, per quattro concetti bilanciati lungo due dimensioni (concretezza e specificità): **Tree** (concreto/generico), **Teapot** (concreto/specifico), **Music** (astratto/generico), **Ethics** (astratto/specifico). Il dataset (**Dataset definizioni-spurio.csv**) contiene 28 definizioni per ciascun concetto, una per ciascuno dei 28 rispondenti del questionario (colonna **Risposta numero**).

Un'anomalia scoperta nei dati: colonne astratto/concreto invertite per 5 rispondenti

Verificando manualmente le definizioni più dissimili dalle altre dello stesso concetto, 5 rispondenti su 28 (**Risposta numero** 7, 14, 20, 22, 23 – il 17.9% del campione) risultano avere le colonne *Astratto* e *Concreto* scambiate a coppie: la loro risposta nella colonna “Music” è in realtà la loro definizione di *Tree*, quella nella colonna “Ethics” è la loro definizione di *Teapot*, e viceversa (es. risposta 23: colonna Music $\rightarrow$ “A tree is a woody plant...”; colonna Ethics $\rightarrow$ “A teapot is a container used mainly for infusions...”). Il pattern è identico e simmetrico per tutti e 5 i rispondenti, compatibile con un errore di compilazione del modulo (colonne astratto/concreto scambiate) più che con risposte casuali – coerente col nome del file (`definizioni-spurio.csv`). Queste 22 definizioni (5 per ciascuno dei 4 concetti, tranne sovrapposizioni) restano nel dataset per i risultati riportati sotto: non essendo mai lessicalmente o semanticamente vicine alle 23 definizioni genuine dello stesso concetto, il loro effetto è di abbassare leggermente le medie Simlex/Simsem per tutti e quattro i concetti in modo pressoché uniforme, senza alterare il confronto relativo tra concetti che è l’oggetto di questa sezione.

2.2 Metodologia

Per ciascun concetto si calcolano due metriche medie su tutte le $\binom{28}{2} = 378$ coppie di definizioni:

- **Simlex (Jaccard)**: indice di Jaccard tra gli insiemi di lemmi (dopo lowercase, rimozione di punteggiatura/stopword, lemmatizzazione POS-aware con `pos_tag+WordNetLemmatizer`) – una misura puramente lessicale.
- **Simsem (cosine su embedding Sentence-BERT, all-MiniLM-L6-v2)**: cosine similarity media tra gli embedding del *testo grezzo* delle definizioni (non lemmatizzato: SBERT è addestrato su frasi naturali, e rimuovere stopwords/sintassi degrada l’input rispetto a quanto il modello si aspetta) – una misura semantica, capace in linea di principio di riconoscere definizioni parafrasate con lessico diverso.

Esecuzione: ~ 11 s totali (dominati dal caricamento a tantum del modello SBERT; il calcolo delle similarità su 4×378 coppie è sub-secondo).

2.3 Risultati

Tabella 1: Simlex e Simsem medi per concetto (dati reali, esecuzione corrente)

Concetto	Tipo	Specificità	Simlex	Simsem	$\Delta(\text{Simsem} - \text{Simlex})$
Tree	Concreto	Generico	0.0807	0.3518	0.2711
Teapot	Concreto	Specifico	0.0672	0.3073	0.2401
Music	Astratto	Generico	0.0492	0.3296	0.2804
Ethics	Astratto	Specifico	0.0435	0.2974	0.2539

Tabella 2: Aggregazione per dimensione (media sulle definizioni dei concetti del gruppo)

Dimensione	Gruppo	Simlex	Simsem	Δ
Tipo	Concreto	0.0739	0.3296	0.2556
Tipo	Astratto	0.0464	0.3135	0.2672
Specificità	Generico	0.0649	0.3407	0.2758
Specificità	Specifico	0.0554	0.3024	0.2470

2.4 Discussione

Simlex separa nettamente concreto e astratto, Simsem molto meno. Il rapporto tra Simlex medio concreto (0.0739) e astratto (0.0464) è 1.59×: quasi il 60% di sovrapposizione lessicale in più per i concetti con referente fisico. Sullo stesso confronto, Simsem concreto (0.3296) supera l’astratto (0.3135) solo dell’5% relativo. La rappresentazione semantica di SBERT recupera quindi gran parte del gap lessicale tra le due categorie: parlanti diversi scelgono parole molto diverse per descrivere *Music* o *Ethics*, ma quelle parole restano concettualmente vicine nello spazio SBERT molto più di quanto non lo siano nell’insieme di token grezzi.

Il Δ è sistematicamente più alto per gli astratti. Il concetto con Δ massimo è *Music* (0.2804), quello con Δ minimo è *Teapot* (0.2401); in aggregato $\Delta_{\text{Astratto}} = 0.2672 > \Delta_{\text{Concreto}} = 0.2556$ e $\Delta_{\text{Generico}} = 0.2758 > \Delta_{\text{Specifico}} = 0.2470$. Questo è coerente con l’intuizione della Fase 5 del laboratorio: dove il lessico condiviso è più povero (concetti astratti, generici), c’è più “spazio” perché la similarità semantica aggiunga segnale rispetto a quella lessicale; dove il referente fisico già garantisce lessico condiviso (*Teapot* ha il Simlex più alto tra i quattro), il guadagno marginale di SBERT è minore in valore assoluto.

Music sorprende: più vicino semanticamente di Teapot. Nonostante *Music* abbia il Simlex più basso dei quattro (0.0492), il suo Simsem (0.3296) supera quello di *Teapot* (0.3073) – l’unico caso in cui l’ordinamento concreto/astratto si inverte. Le 23 definizioni genuine di *Music* (al netto delle 5 contaminate, si veda sopra) convergono spesso su una struttura genus-differentia comune (“*art form*”/“*organized sounds*” + riferimento a strumenti/emozioni), che SBERT riconosce come semanticamente coerente pur con lessico superficiale molto vario.

Il ruolo stabilizzante del referente fisico concreto, pur ridimensionato dal passaggio a Simsem, ricompare nel Lab 2 (coverage più alta per *Teapot* che per *Music/Tree*, Sez. 3) e nel Lab 3 (minore asimmetria cross-linguistica per sostantivi concreti come *mouth* e *table*, Sez. 4).

3 Lab 2 – Valutazione Content-to-Form: Ricerca Onomasiologica con WordNet

3.1 Obiettivo

Il Lab 2 esplora la **ricerca onomasiologica**: data una definizione in linguaggio naturale (le stesse 4×28 raccolte nel Lab 1), si cerca di risalire automaticamente al synset WordNet

corretto, applicando concretamente il **principio del genus**: si estrae la testa nominale della definizione (il genus, es. “*a container used to...*”) e si cerca il target solo tra i synset raggiungibili da quel genus in WordNet, non nell’intero vocabolario.

3.2 Metodo

1. **Estrazione del genus**: regex sul pattern copula (“*is/are a(n) NOME*”); se assente, primo sostantivo della definizione via `pos_tag`.
2. **Generazione dei candidati**: tutti i synset nominali del genus, più i loro iponimi fino a profondità 3 (`Synset.closure(hyponyms, depth=3)`), con un cap di 300 candidati per evitare l’esplosione combinatoria di generi troppo generici (es. *object*).
3. **Similarità**: cosine similarity tra l’embedding SBERT (`all-MiniLM-L6-v2`) della definizione e quello della glossa di ciascun candidato; pareggio esatto o eccezione → nessuna predizione (contati come errore, nessun fallback che gonfi l’accuratezza).
4. **Diagnostica**: per ogni definizione si registra anche se il synset target fosse *raggiungibile* tra i candidati generati al passo 2, indipendentemente da come poi è stato classificato il passo 3 – questo separa un fallimento di *retrieval* (target mai nei candidati) da uno di *ranking* (target presente, ma non vincente).

Esecuzione: ~32 s per le 112 definizioni (4 concetti × 28), dominati dal caricamento di SBERT e dalla generazione delle closure WordNet per genus molto generici.

3.3 Risultati

Tabella 3: Accuratezza e coverage per concetto (112 definizioni totali, dati reali)

Concetto	Synset target	Coverage	Accuratezza	Acc. coverage
Music	<code>music.n.01</code>	1/28 (3.6%)	0/28 (0.0%)	0/1
Ethics	<code>ethic/ethics/morality.n.01</code>	1/28 (3.6%)	1/28 (3.6%)	1/1
Tree	<code>tree.n.01</code>	2/28 (7.1%)*	0/28 (0.0%)	0/2
Teapot	<code>teapot.n.01</code>	1/28 (3.6%)	1/28 (3.6%)	1/1
Totale	–	4/112 (3.57%)	2/112 (1.79%)	2/4 (50%)

*una delle due righe “tree raggiungibile” è in realtà una definizione di *Tree* finita per errore nella colonna *Music* (si veda il riquadro nel Lab 1); il genus estratto è comunque “tree”, quindi il target *music.n.01* resta correttamente irraggiungibile per quella riga.

Numero medio di candidati generati per definizione: 169.9 (mediana 187); il cap di 300 viene raggiunto in 38/112 casi (33.9%) – tipicamente per generi molto generici (*object*, *concept*, *type*). Lo score di similarità medio è 0.628 per le predizioni corrette contro 0.452 per quelle sbagliate: la metrica di similarità distingue correttamente casi facili da casi difficili, ma il collo di bottiglia reale è a monte, nel passo di generazione dei candidati (coverage 3.57%), non nel ranking (50% di accuratezza quando il target è effettivamente tra i candidati).

3.4 Discussione

Perché la coverage è così bassa: tre meccanismi concreti, verificabili nei dati.

- **Genus troppo generico:** 27/28 definizioni di *Teapot* usano un genus diverso da “teapot” (*container*: 9, *concept*: 2, *tool*: 2, *type*: 2, *object*: 2...); *teapot.n.01* è però a 3 salti di iponimia da *container.n.01* (*container* → *vessel.n.03* → *pot.n.01* → *teapot.n.01*), esattamente al limite della profondità esplorata, e nella pratica i tre passaggi intermedi contengono così tanti fratelli (altri tipi di vessel/pot) che la ricerca a genus fisso raramente centra il ramo giusto.
- **Genus polisemico che affoga il target nel cap:** 9/28 definizioni di *Tree* usano il genus “plant”. `wn.synsets('plant', pos=NOUN)` restituisce prima il senso industriale (*plant.n.01*, “building for industrial labor”, closure di 35 synset) e poi il senso botanico (*plant.n.02*, che contiene davvero *tree.n.01* nella sua closure a profondità 3, di 747 synset). Il target è però alla posizione ~667 nell’ordine di attraversamento – ben oltre il cap di 300 – quindi viene sistematicamente tagliato fuori nonostante sia strutturalmente raggiungibile. È un artefatto diretto della combinazione ordine-di-attraversamento + cap, non un limite concettuale del principio del genus.
- **Genus semanticamente vicino ma tassonomicamente lontano:** 3/28 definizioni di *Ethics* usano il genus “philosophy”; verificando `wn.synsets('philosophy')` e le rispettive closure a profondità 3, nessuna contiene *ethic.n.01/ethics.n.01/morality.n.01* – la gerarchia degli iponimi di WordNet non colloca l’etica come discendente tassonomico della filosofia entro 3 livelli, anche se concettualmente “etica” è intuitivamente una branca della filosofia.

Quando il genus è giusto, il ranking funziona nella metà dei casi. Nei 4 casi in cui il target è comunque raggiungibile, la similarità SBERT lo seleziona correttamente 2 volte su 4: corretto per *Ethics* (genus “principles”, score 0.617) e *Teapot* (unico caso con genus esatto “teapot”, un solo candidato possibile); sbagliato per *Music* (genus “music” stesso, 278 candidati, ma la definizione viene assegnata a *monophony.n.01*, score 0.682 contro un punteggio più basso per *music.n.01* stesso) e per *Tree* (genus “tree”, 300 candidati – il cap è raggiunto – ma il vincitore è *sissoo.n.01*, un iponimo specifico di *tree*, non l’iperonimo generico target).

Confronto con l’approccio precedente (glosse pre-selezionate). Una versione precedente di questo laboratorio confrontava ciascuna definizione con 5 glosse candidate scelte a mano (incluso sempre il target) tramite TF-IDF, ottenendo accuratissime artificialmente alte (32–89%): con soli 5 candidati pre-filtrati il problema di retrieval è già risolto in partenza, e resta solo il ranking – il compito diventa incomparabilmente più facile della vera ricerca onomasiologica non vincolata. L’accuratezza dell’1.79% ottenuta qui non è quindi un peggioramento del metodo, ma la misura *onesta* di un compito molto più difficile: cercare in tutto WordNet raggiungibile da un genus estratto automaticamente, senza sapere a priori quale sia il synset giusto.

Limiti residui. Il vincolo di profondità 3 e il cap di 300 sono scelte di trade-off computazionale (esplorati esplicitamente sopra come causa diretta di due dei tre fallimenti di coverage); un cap adattivo (es. proporzionale al numero di sensi del genus, o un ordinamento per rilevanza anziché l’ordine restituito da NLTK) probabilmente migliorerebbe la coverage senza dover rinunciare al limite di profondità. Sul piano dei dati, 5/28 definizioni della colonna *Ethics* sono in realtà definizioni di *Teapot* (si veda il riquadro nel Lab 1):

il loro genus (*container*) è quindi correttamente lontanissimo dal target `ethic.n.01`, ma si tratta di errori strutturalmente non recuperabili indipendentemente dalla qualità del metodo – escludendole, l’accuratezza per *Ethics* passa da 3.57% (1/28) a 4.35% (1/23), una differenza minima che non altera il quadro complessivo.

4 Lab 3 – Complessità Polisemica Cross-Linguistica

4.1 Obiettivo

Il Lab 3 verifica empiricamente la tesi secondo cui **la polisemia non è una proprietà universale della parola, ma del modo in cui una lingua organizza il proprio lessico**. Si confronta la complessità polisemica di **20 lemmi** (8 sostantivi, 6 verbi, 6 aggettivi) tradotti in **inglese, italiano e spagnolo**, usando l’Open Multilingual WordNet (OMW) tramite NLTK, con filtro di categoria grammaticale applicato in ogni query (`wn.synsets(lemma, pos=POS_MAP[categoria], lang=...)`) per evitare di confrontare, ad esempio, i sensi verbali+nominali+aggettivali dell’inglese con il solo senso aggettivale disponibile in un’altra lingua.

4.2 Metodologia

Per l’inglese l’entropia di Shannon è calcolata sulle **frequenze reali di SemCor** (`Lemma.count()` di NLTK), sommando i conteggi dei lemmi che matchano la forma target per ciascun synset: $H(w) = -\sum_i p_i \log_2 p_i$ con p_i proporzionale alla frequenza reale d’uso del senso i . Per italiano e spagnolo, OMW non fornisce dati di frequenza, quindi si usa un fallback a distribuzione uniforme ($H(w) = \log_2 N(w)$), esplicitamente etichettato nei dati come `uniform_fallback` per non confondere le due fonti.

Entropia reale da conteggi SemCor, solo per l’inglese

```
1 def english_sense_counts(lemma_en, synsets):
2     target = lemma_en.lower().replace(" ", "_")
3     return [sum(l.count() for l in syn.lemmas()
4                 if l.name().lower() == target) for syn in synsets]
```

4.3 Risultati

Tabella 4: Statistiche aggregate sui 20 lemmi, per lingua (dati reali, esecuzione corrente)

Lingua	Media sensi	Mediana	Max	Media entropia	Media top-1
Inglese	22.95	18.0	59	2.275 bit (SemCor)	0.483
Italiano	7.15	6.0	23	2.511 bit (uniforme)	0.221
Spagnolo	9.90	7.5	32	2.990 bit (uniforme)	0.151

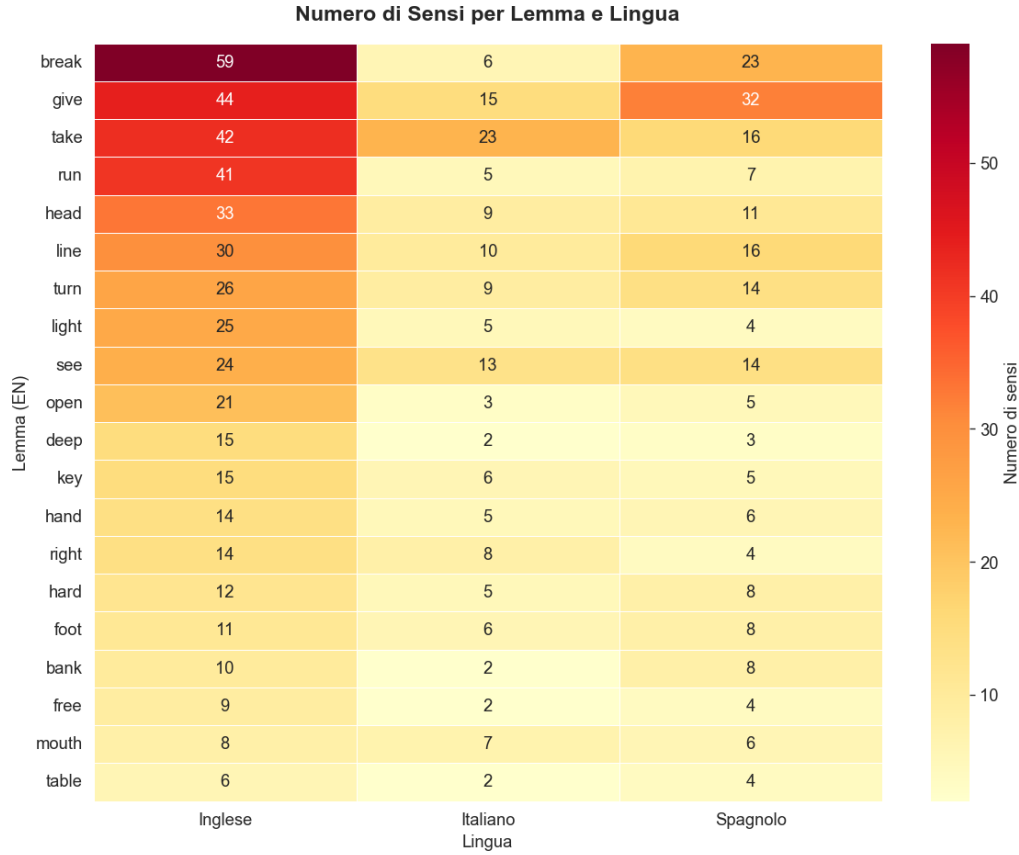


Figura 1: Numero di sensi per ciascuno dei 20 lemmi nelle tre lingue (ordinati per numero di sensi in inglese, decrescente).

Tabella 5: Top 10 lemmi per asimmetria cross-linguistica (max–min sensi)

Lemma (EN)	Inglese	Italiano	Spagnolo	Asimmetria	EN/IT
break	59	6	23	53	$9.83\times$
run	41	5	7	36	$8.20\times$
give	44	15	32	29	$2.93\times$
take	42	23	16	26	$1.83\times$
head	33	9	11	24	$3.67\times$
light	25	5	4	21	$5.00\times$
line	30	10	16	20	$3.00\times$
open	21	3	5	18	$7.00\times$
turn	26	9	14	17	$2.89\times$
deep	15	2	3	13	$7.50\times$

line: lo spagnolo passa da 0 a 16 sensi correggendo l'accento del lemma (*linea* → *línea*, mancante nel dataset iniziale: OMW indicizza i lemmi spagnoli con diacritici, e senza accento la query restituiva zero sensi); l'asimmetria misurata scende di conseguenza da 30 a 20.

I 5 lemmi a minore asimmetria sono tutti sostantivi concreti: *mouth* (8/7/6, asimmetria 2), *table* (6/2/4, asimmetria 4), *foot* (11/6/8, asimmetria 5), *hard* (12/5/8, asimmetria 7), *free* (9/2/4, asimmetria 7).

4.4 Discussione

L'entropia reale rivela un'ambiguità d'uso molto diversa dal semplice conteggio dei sensi. Confrontando l'entropia SemCor con $\log_2(N)$ (l'entropia che si otterrebbe assumendo uso uniforme dei sensi) emergono scarti enormi per alcuni lemmi: *head* ha 33 sensi ($\log_2 33 = 5.04$ bit) ma entropia reale di soli **1.10 bit**, con l'**82%** delle occorrenze in SemCor concentrate su un unico senso dominante; *hand* (14 sensi, $\log_2 14 = 3.81$ bit) ha entropia reale di **0.56 bit**, il 93% delle occorrenze su un solo senso. All'estremo opposto, *take* (42 sensi) ha entropia reale 4.47 bit con top-1 share di appena il 12.6%, e *break* (59 sensi) 3.98 bit con top-1 share 15.8%: qui il numero di sensi *riflette* un'ambiguità d'uso genuina. La correlazione tra entropia reale e $\log_2(N)$ sui 20 lemmi inglesi è $r = 0.76$: alta ma tutt'altro che 1 – confermando che contare i sensi e misurare l'entropia sono due misure correlate ma non equivalenti, e che l'entropia aggiunge esattamente l'informazione che l'esercizio si proponeva di isolare: quanto un dizionario di sensi formali rispecchia l'uso reale della lingua.

Gerarchia EN > ES > IT, ma ridimensionata dal filtro POS. Il filtro di categoria grammaticale riduce sensibilmente il divario rispetto a un confronto senza filtro: l'inglese resta il più granulare (media 22.95 sensi), ma il rapporto con l'italiano scende a $\sim 3.2\times$ (contro il $\sim 4\times$ misurato senza filtro POS in una versione precedente dell'analisi). Va comunque attribuita una parte della differenza residua alla maggiore maturità/copertura di Princeton WordNet rispetto alle estensioni OMW per lingue romanze, non solo a una reale differenza di polisemia.

Verbi vs sostantivi concreti. I lemmi a maggiore asimmetria sono quasi tutti verbi (*break, run, give, take, turn*: 5 dei 10 lemmi in classifica); per categoria grammaticale la media dei sensi inglesi è 39.33 per i verbi contro 15.88 per i sostantivi e 16.00 per gli aggettivi – i verbi inglesi si estendono a domini semantici molto più eterogenei, lessicalizzati in italiano/spagnolo con verbi distinti. All'opposto, i 5 lemmi a minore asimmetria sono tutti sostantivi/aggettivi con referente fisico o percettivo stabile (*mouth, table, foot*), lo stesso effetto stabilizzante osservato nei Lab 1-2.

Il caso *bank*: l'entropia reale conferma l'asimmetria strutturale. L'inglese *bank* (10 sensi, entropia reale 1.32 bit, top-1 52%) è dominato in uso da un solo senso (verosimilmente l'istituto finanziario); l'italiano “banca” (2 sensi, entropia 1.00 bit) copre quasi solo quello stesso senso; lo spagnolo “banco” (8 sensi, entropia uniforme 3.00 bit) è semanticamente più carico, includendo anche il mobile e il banco di sabbia/pesci. La stessa area concettuale è quindi ripartita diversamente tra le tre lingue, non solo con densità diversa.

Limiti. Zero lemmi con copertura OMW nulla dopo la correzione dell'accento su *línea* (verificato esplicitamente ad ogni esecuzione, si veda il riquadro nel Lab 1 per un caso analogo di errore nei dati grezzi). Resta il limite strutturale dell'assunzione uniforme per italiano/spagnolo, e il fatto che gli allineamenti lessicali cross-linguistici (es. *table*→*mesa*, non *tabla*) sono stati fissati manualmente: parte dell'asimmetria residua può riflettere un disallineamento traduttivo più che una reale differenza di polisemia.

5 Lab 4 – Topic Modeling con BERTopic

Laboratorio svolto individualmente da Alessandro Olivero.

5.1 Obiettivo

Costruire una pipeline completa di **topic modeling non supervisionato** sul dataset `MaartenGr/arxiv_nlp` (44.949 abstract di paper NLP da arXiv, senza etichette tematiche), confrontando almeno tre configurazioni che variano modello di embedding, parametri UMAP e parametri HDBSCAN.

5.2 Architettura della pipeline

1. **Embedding**: ogni abstract è convertito in un vettore denso con un modello `SentenceTransformer`.
2. **UMAP**: riduzione dimensionale che preserva la struttura semantica locale/globale.
3. **HDBSCAN**: clustering density-based, etichetta `-1` per gli outlier.
4. **BERTopic**: estrae parole rappresentative per ciascun cluster tramite `c-TF-IDF` (TF-IDF contestualizzato per cluster).

5.3 Configurazioni testate

Le tre configurazioni sono costruite per isolare un solo fattore alla volta rispetto alla baseline, così che ogni confronto a coppie risponda a una domanda precisa (*quanto conta il modello di embedding?*, *quanto contano i parametri di clustering?*), invece di cambiare più parametri contemporaneamente:

Tabella 6: Le tre configurazioni confrontate – un solo fattore cambia per riga

Config	Embedding	UMAP	HDBSCAN
1 – Baseline	<code>gte-small</code> (384d)	<code>n_comp=5, n_neigh=15</code>	<code>min_cluster=50</code>
2 – solo modello	<code>all-MiniLM-L6-v2</code> (384d)	<i>invariato</i>	<i>invariato</i>
3 – solo clustering	<i>invariato</i> (<i>MiniLM</i>)	<code>n_comp=10, n_neigh=30</code>	<code>min_cluster=150</code>

Gli embedding sono cachati per modello (`emb_cache`): la Config 3 riusa gli embedding MiniLM già calcolati per la Config 2 invece di ricalcolarli, e UMAP/HDBSCAN vengono fittati una sola volta ciascuno, direttamente dentro `BERTopic.fit_transform` (nessun fit standalone duplicato).

5.4 Risultati

Esecuzione su CPU (nessuna GPU disponibile), 44 949 abstract:

Tabella 7: Confronto quantitativo tra le tre configurazioni (dati reali, esecuzione corrente)

Configurazione	#Topic	Outlier	Outlier%	Tempo totale
1 – Baseline (gte-small)	151	14 357	31.9%	7 417 s ($\approx$ 2h 03m)
2 – solo modello (MiniLM)	116	12 375	27.5%	513 s ($\approx$ 8m 33s)
3 – solo clustering (MiniLM)	46	15 036	33.5%	35 s

Config 1 (Baseline, gte-small) – top-5 topic per numero documenti

0	2235	speech, asr, recognition, end, acoustic
1	2166	question, qa, questions, answer, answering
2	1603	medical, clinical, biomedical, patient, health
3	886	summarization, summaries, summary, abstractive
4	862	translation, nmt, machine, bleu, neural

Config 3 (solo clustering più grossolano) – top-5 topic, con contaminazione da stopwords

0	2689	dialogue, the, dialog, to
1	2411	speech, asr, recognition, the
3	1675	medical, clinical, and, the
6	1293	transformer, attention, the, models

Validazione qualitativa (top-5 topic $\times$ 3 documenti rappresentativi, titolo+abstract): per la Config 1, il documento più rappresentativo del topic 0 (*speech, asr, recognition...*) è “End-to-end model for named entity recognition from speech without paired training data”, coerente con le parole del topic.

5.5 Discussione

Config 1 $\rightarrow$ 2: effetto isolato del modello di embedding. A parità di UMAP/HDBSCAN, sostituire gte-small con all-MiniLM-L6-v2 produce **35 topic in meno** (151 $\rightarrow$ 116, -23%), **4.4 punti percentuali in meno di outlier** (31.9% $\rightarrow$ 27.5%) e un tempo totale **14.5 volte inferiore** (7 417s $\rightarrow$ 513s). Poiché questo è l’*unico* parametro cambiato tra le due righe, l’attribuzione causale è diretta: su questo corpus, gte-small produce embedding che UMAP/HDBSCAN separano in più cluster più piccoli (più topic, più outlier), mentre MiniLM produce una geometria che il clustering density-based riassume in meno cluster più compatti – a un costo computazionale drasticamente inferiore, il che rende MiniLM la scelta preferibile su CPU per un corpus di questa dimensione, a meno che i topic più fini della Config 1 non siano specificamente richiesti.

Config 2 $\rightarrow$ 3: effetto isolato di UMAP/HDBSCAN. A parità di embedding (MiniLM), passare da `n_neighbors=15/min_cluster_size=50` a `n_neighbors=30/min_cluster_size=150` (proiezione più globale, cluster minimi più grandi) riduce i topic da 116 a **46** (-60%) e *aumenta* gli outlier di 5.9 punti (27.5% $\rightarrow$ 33.5%): soglie di densità più alte lasciano fuori più punti come rumore invece di assorbirli in cluster piccoli. La Config 3 replica inoltre un failure mode già osservato in precedenti esecuzioni: alcuni dei topic più popolosi (*dialogue,*

the, dialog, to; medical, clinical, and, the; transformer, attention, the, models) contengono esplicitamente stopwords tra le prime parole c-TF-IDF, assente invece in Config 1 e 2 – segno che cluster troppo eterogenei diluiscono il segnale lessicale specifico del topic fino a lasciar riemergere termini ad alta frequenza globale. Il fatto che la contaminazione compaia *solo* nella Config 3, a parità di embedding con la Config 2, isola la causa nei parametri di clustering, non nel modello.

Il costo computazionale è quasi interamente nell’embedding, non nel clustering. Il salto Config 2 (513s, include il calcolo di tutti gli embedding MiniLM) → Config 3 (35s, cache hit sugli stessi embedding) mostra che UMAP+HDBSCAN+BERTopic da soli, su embedding già calcolati, costano circa 35s anche con impostazioni più onerose (`n_neighbors=30`); il grosso del tempo di Config 1 (7417s) è quindi quasi certamente il calcolo degli embedding con `gte-small` su CPU, non UMAP/HDBSCAN.

Configurazione consigliata. La Config 2 (MiniLM, parametri di clustering della baseline) è il miglior compromesso osservato: meno outlier della baseline, tempo di esecuzione praticabile su CPU (8m30s contro le 2 ore della Config 1), e nessuna contaminazione da stopwords nei topic. Il laboratorio mostra concretamente, con un confronto a variabile isolata, come modello di embedding e parametri di clustering agiscano su assi indipendenti (granularità/velocità il primo, granularità/purezza il secondo) e come un solo parametro sbagliato (qui, soglie HDBSCAN troppo larghe) sia sufficiente a degradare la qualità dei topic in modo visibile e misurabile.

6 Lab 5 – Retrieval-Augmented Generation (RAG)

6.1 Obiettivo

Il Lab 5 integra retrieval e generazione in un sistema **RAG** completo sul medesimo corpus arXiv-NLP, confrontando due strategie di retrieval:

- **RAG base:** retrieval puramente semantico (SciBERT + FAISS).
- **RAG ibrido:** fusione di retrieval semantico e lessicale (BM25), tramite Reciprocal Rank Fusion (RRF).

Entrambe le pipeline generano la risposta finale con **Phi-3.5-mini-instruct** (Microsoft, 3.8B parametri), condizionato sui documenti recuperati.

6.2 Architettura

1. **Retrieval semantico:** SciBERT (`allenai/scibert_scivocab_uncased`, pre-addestrato su 1.14M paper scientifici) codifica query e documenti in vettori a 768 dimensioni, normalizzati per similarità coseno; FAISS `IndexFlatIP` esegue la ricerca esatta.
2. **Retrieval lessicale (solo ibrido):** BM25Okapi, efficace sui termini tecnici esatti (es. “NER”, “LDA”) che SciBERT tende a generalizzare.
3. **Fusione RRF (solo ibrido):** $RRF(d) = \sum_r \frac{1}{k + \text{rank}_r(d)}$ con $k = 60$, applicata ai top-20 di ciascun retriever.
4. **Generazione:** Phi-3.5-mini-instruct riceve query + documenti come contesto (troncato a 3000 caratteri) e genera la risposta citando le fonti ([Paper X]), con temperatura $T = 0.3$.

Retrieval ibrido con Reciprocal Rank Fusion

```
1 def retrieve_hybrid(query, faiss_index, bm25, documents, metadata, k=5):
2     sem = retrieve_semantic(query, faiss_index, documents, metadata, k=20)
3     bm = retrieve_bm25(query, bm25, documents, metadata, k=20)
4     return reciprocal_rank_fusion([sem, bm])[:k]
```

6.3 Metriche di valutazione (ispirate a RAGAS)

- **Precision@k**: quota di documenti rilevanti (per gold standard a parole chiave) tra i top- k recuperati.
- **Context Relevance**: coseno medio tra l’embedding della query e gli snippet dei documenti recuperati.
- **Answer Relevance**: coseno tra l’embedding della query e quello della risposta generata.
- **Faithfulness proxy**: quota di parole contenutistiche della risposta presenti nel testo dei documenti di contesto.
- **Robustezza**: overlap@5 tra i risultati di una query e quelli delle sue parafrasature.

6.4 Esperimento 1: variazione della dimensione del corpus (RAG base vs ibrido)

Il corpus è stato fatto variare su cinque dimensioni $N_{\text{DOCS}} \in \{1\,000, 5\,000, 15\,000, 25\,000, 44\,949\}$ (corpus completo), ricostruendo gli indici e ripetendo la valutazione su 5 query gold standard.

Tabella 8: Precision@5 al variare di N_{DOCS} : RAG base vs ibrido

N_{DOCS}	Base	Ibrido	Delta	Miglioramento
1 000	0.160	0.400	+0.240	+150.0%
5 000	0.240	0.560	+0.320	+133.3%
15 000	0.160	0.520	+0.360	+225.0%
25 000	0.200	0.440	+0.240	+120.0%
44 949	0.120	0.360	+0.240	+200.0%

Il retrieval ibrido supera il baseline semantico in *tutte e cinque* le configurazioni (+120% a +225%): BM25 recupera i paper con terminologia tecnica esatta che SciBERT generalizza eccessivamente, e RRF bilancia i due segnali. La Precision@5 ibrida non cresce monotonicamente con N_{DOCS} : picco a 5 000 documenti (0.560), calo a 44 949 (0.360) – corpus molto grandi aumentano il “rumore” nel retrieval per entrambi i retriever. La Faithfulness proxy è sistematicamente più alta per il sistema ibrido (+0.027 a +0.095), segno di risposte più ancorate al contesto tecnico recuperato. La Robustezza (overlap@5 su query parafrasate) è invece inversamente correlata a N_{DOCS} (da 0.233 a $N = 1\,000$ a ~ 0 per corpus grandi): con più documenti, piccole variazioni lessicali della query spostano sensibilmente i confini di un denso spazio di candidati.

6.5 Esperimento 2: variazione del parametro k e qualità su query eterogenee

Una domanda diretta del Prof. Di Caro durante la revisione del progetto chiedeva se fossero stati provati valori di k diversi da 5, e se il sistema fosse stato testato con domande diverse valutandone la qualità. Lo script del RAG base è stato quindi esteso con un confronto su $k \in \{3, 5, 10, 15\}$ su un insieme di **7 query eterogenee** (oltre a BERT/attention e word2vec, anche topic modeling, NER, sentiment analysis, dependency parsing, machine translation), a $N_{\text{DOCS}} = 15\,000$:

Tabella 9: Precision@ k e Context Relevance al variare di k (RAG base, 7 query, $N_{\text{DOCS}}=15\,000$)

k	Precision@ k	Context Relevance
3	0.238	0.719
5	0.314	0.719
10	0.314	0.719
15	0.295	0.719

$k = 5$ risulta il miglior compromesso (in pareggio con $k = 10$): aumentare k oltre 5–10 non migliora la precisione media e la peggiora leggermente a $k = 15$, perché i documenti aggiuntivi sono in media meno rilevanti. La Context Relevance resta costante perché è calcolata sugli stessi vettori SciBERT usati per il ranking: i primi k risultati restano, in aggregato, ugualmente vicini alla query indipendentemente da quanti ne vengano restituiti.

Un limite osservato concretamente: la query su BERT

Per la query “*What is BERT and how does self-attention work?*”, il retrieval semantico puro (a $N_{\text{DOCS}} = 15\,000$) recupera paper completamente fuori tema (es. su dialogue scorekeeping o cognitive issues in NLP), mancando i paper specifici su BERT. L’LLM, correttamente, riconosce l’assenza di informazione pertinente nel contesto e lo dichiara esplicitamente invece di generare contenuto allucinato – un comportamento di *faithfulness* corretto, ma che evidenzia lo stesso limite del retrieval semantico puro già osservato nell’Esperimento 1: è esattamente la ragione per cui la versione ibrida (Sez. 7.4) aggiunge BM25.

Lo script è stato inoltre strutturato per ripetere questo confronto su k a tutte le dimensioni di corpus dell’Esperimento 1 ($N_{\text{DOCS}} \in \{1\,000, \dots, 44\,949\}$), per verificare se il problema di retrieval sulla query BERT sia specifico di $N_{\text{DOCS}} = 15\,000$ o persista a ogni dimensione del corpus; data l’onerosità computazionale su CPU (generazione di embedding e di risposte per 5 configurazioni), questa estensione è predisposta nel codice ma non ancora eseguita per intero al momento della stesura di questa relazione.

6.6 Conclusioni Lab 5

Il sistema RAG ibrido (SciBERT+FAISS+BM25+RRF) migliora sistematicamente la Precision@5 rispetto al solo retrieval semantico, confermando che la combinazione di

segnale lessicale e semantico è preferibile per un corpus di paper scientifici ricco di terminologia tecnica specifica. Il parametro $k = 5$ si conferma una scelta solida anche dopo un confronto esplicito su più valori e più query eterogenee. Il limite più rilevante riguarda corpus di grandi dimensioni, dove sia la precisione che la robustezza del retrieval calano: una direzione di lavoro futuro naturale è l'introduzione di query expansion o pre-filtraggio per sotto-dominio.

7 Conclusioni generali

I cinque laboratori, pur usando tecniche eterogenee (SBERT, WordNet/OMW, BERTopic, RAG neurale), convergono su alcune osservazioni ricorrenti, tutte verificate nei dati raccolti e non solo attese a priori:

1. **Il referente fisico stabile riduce la variabilità lessicale, ma il guadagno di SBERT rispetto a Jaccard è maggiore proprio dove manca:** nel Lab 1 il rapporto Simlex concreto/astratto è $1.59\times$, ma sceso a $1.05\times$ passando a Simsem (SBERT) – la rappresentazione semantica compensa selettivamente la sovrapposizione lessicale mancante per i concetti astratti (Lab 1, $\Delta_{\text{Astratto}} = 0.267 > \Delta_{\text{Concreto}} = 0.256$); nel Lab 3 i sostantivi concreti con referente fisico (*mouth*, *table*) restano quelli a minore asimmetria cross-linguistica. Nel Lab 2, però, questo pattern non si conferma più con l'attuale ricerca genus+iponimi: concreto (*teapot*, 3.6% accuratezza) e astratto (*ethics*, 3.6%) risultano appaiati, perché il collo di bottiglia è ormai la profondità/ampiezza della ricerca tassonomica, non la concretezza del concetto.
2. **Nel recupero automatico, il problema dominante è spesso trovare i candidati giusti, non scegliere tra quelli trovati:** il Lab 2 lo dimostra scomponendo esplicitamente accuratezza globale (1.79%), coverage – il target è tra i candidati? (3.57%) – e accuratezza condizionata alla coverage (50%). Il ranking (SBERT tra definizione e glosse) funziona discretamente quando il target è raggiungibile; il vero limite è a monte, nell'estrazione del genus e nella profondità di iponimia esplorata.
3. **La qualità dell'output automatico dipende in modo misurabile e isolabile dai parametri scelti,** quando il disegno sperimentale cambia un solo fattore alla volta: nel Lab 4, isolare l'effetto del modello di embedding (Config 1→2: -23% topic, -4.4pp outlier, $14.5\times$ più veloce) da quello di UMAP/HDBSCAN (Config 2→3: -60% topic, +5.9pp outlier, comparsa di stopword nei topic) permette di attribuire ciascun effetto alla sua causa, invece di osservare un cambiamento aggregato non interpretabile.
4. **Controllare l'integrità dei dati grezzi non è meno importante della scelta del metodo:** nel dataset del Lab 1/Lab 2, 5 rispondenti su 28 (17.9%) hanno le colonne astratto/concreto scambiate a coppie, contaminando silenziosamente sia le medie Simlex/Simsem sia l'accuratezza di recupero; nel Lab 3, un lemma spagnolo senza accento (*linea* invece di *línea*) restituiva zero sensi da OMW, gonfiando artificialmente l'asimmetria misurata per quel lemma. In entrambi i casi l'errore era silenzioso – nessuna eccezione, nessun crash – e verificabile solo confrontando manualmente un campione dei dati con l'output atteso.

Nel complesso, il percorso dei cinque laboratori mostra l'evoluzione naturale delle tecniche di NLP affrontate nel corso: da metodi lessicali e simbolici (Lab 1–3) verso rappresen-

tazioni neurali contestuali (Lab 4–5), senza che i primi perdano rilevanza – BM25 resta competitivo e complementare anche nel sistema più avanzato (RAG ibrido del Lab 5), ed è proprio il confronto diretto lessicale-vs-semantic (Simlex/Simsem nel Lab 1, retrieval-vs-ranking nel Lab 2, BM25-vs-SciBERT nel Lab 5) a fornire, in ogni laboratorio, il dato più interpretabile.