

Università degli Studi di Torino
Corso di Laurea Magistrale in Informatica

Tecnologie del Linguaggio Naturale

Parte 3 – Prof. Luigi Di Caro

Relazione Complessiva

Laboratori 1–5

Complessità definizionale e sovrapposizione semantica · Ricerca
onomasiologica con WordNet · Polisemia cross-linguistica · Topic
modeling con BERTopic · Retrieval-Augmented Generation

Gruppo di lavoro:

Studente	Matricola
Alessandro Olivero	915069
Samuele Iudice	1235245
Andrea Franco	1226739

Il Laboratorio 4 è stato svolto individualmente da Alessandro Olivero.

Docente: Prof. Luigi Di Caro

Anno Accademico: 2025/2026

28 giugno 2026

Indice

1	Introduzione generale	2
2	Lab 1 – Complessità Definizionale e Sovrapposizione Semantica	2
2.1	Obiettivo e materiale	2
2.2	Analisi qualitativa	3
2.3	Metodologia quantitativa	3
2.4	Risultati	3
2.5	Discussione	4
3	Lab 2 – Valutazione Content-to-Form: Ricerca Onomasiologica con Word-Net	4
3.1	Obiettivo	4
3.2	Metodo	4
3.3	Risultati	5
3.4	Discussione	5
4	Lab 3 – Complessità Polisemica Cross-Linguistica	5
4.1	Obiettivo	5
4.2	Metodologia	6
4.3	Risultati	6
4.4	Discussione	8
5	Lab 4 – Topic Modeling con BERTopic	8
5.1	Obiettivo	9
5.2	Architettura della pipeline	9
5.3	Configurazioni testate	9
5.4	Risultati	9
5.5	Discussione	10
6	Lab 5 – Retrieval-Augmented Generation (RAG)	10
6.1	Obiettivo	10
6.2	Architettura	10
6.3	Metriche di valutazione (ispirate a RAGAS)	11
6.4	Esperimento 1: variazione della dimensione del corpus (RAG base vs ibrido)	11
6.5	Esperimento 2: variazione del parametro k e qualità su query eterogenee	12
6.6	Conclusioni Lab 5	13
7	Conclusioni generali	13

1 Introduzione generale

Questa relazione raccoglie e sintetizza i cinque laboratori svolti nella Parte 3 del corso di **Tecnologie del Linguaggio Naturale** (Prof. Luigi Di Caro, A.A. 2025/2026). I laboratori, pur affrontando tecniche molto diverse tra loro, seguono un filo conduttore comune: la tensione tra *forma linguistica* e *contenuto semantico*, esplorata a livelli di granularità crescente.

- Il **Lab 1** parte dal problema più elementare – definire un concetto in linguaggio naturale – e misura quanto le definizioni indipendenti di persone diverse si sovrappongano, lessicalmente e semanticamente.
- Il **Lab 2** inverte la prospettiva: data una definizione (il *contenuto*), tenta di risalire automaticamente alla *forma* lessicale corretta codificata in WordNet (ricerca onomasiologica).
- Il **Lab 3** sposta l’analisi sul piano cross-linguistico, mostrando che la complessità polisemica di una parola non è una proprietà assoluta, ma dipende da come ciascuna lingua organizza il proprio lessico.
- Il **Lab 4** affronta il problema in modo non supervisionato: invece di partire da concetti noti, estrae automaticamente i temi presenti in una grande collezione di documenti (topic modeling) tramite BERTopic.
- Il **Lab 5** chiude il percorso integrando retrieval semantico/lessicale e generazione linguistica in un sistema **RAG** (Retrieval-Augmented Generation) completo, applicato e valutato su un corpus di paper scientifici NLP.

Tutti i laboratori condividono inoltre un dataset o una risorsa lessicale di riferimento (il dataset di definizioni raccolto in aula per i Lab 1–2, WordNet/OMW per i Lab 1–3, il corpus **arXiv-NLP** per i Lab 4–5), il che permette confronti diretti tra i risultati, evidenziati nelle sezioni di discussione di ciascun laboratorio.

2 Lab 1 – Complessità Definizione e Sovrapposizione Semantica

2.1 Obiettivo e materiale

L’obiettivo del Lab 1 è esplorare la complessità insita nella formulazione di definizioni in linguaggio naturale, per quattro concetti bilanciati lungo due dimensioni (concretezza e specificità):

- **Tree** (Albero): concreto, generico.
- **Teapot** (Teiera): concreto, specifico.
- **Music** (Musica): astratto, generico.
- **Ethics** (Etica): astratto, specifico.

È stato utilizzato un dataset (**Dataset definizioni-spurio.csv**) contenente le definizioni in linguaggio naturale raccolte in aula da studenti diversi per ciascuno dei quattro concetti, con il vincolo che ogni definizione fosse comprensibile a un lettore generico.

2.2 Analisi qualitativa

Dall'analisi delle definizioni raccolte emergono tre dinamiche linguistiche rilevanti:

1. **Scelte lessicali e specificità:** per i concetti concreti il lessico si concentra su componenti fisiche e funzionali (*roots, metal container*); per i concetti astratti il vocabolario si sposta sulla sfera cognitiva e sensoriale (*sentiment, behavior, melodious sounds*).
2. **Difficoltà concettuale:** i concetti astratti generano definizioni più eterogenee e dipendenti dal contesto socio-culturale, mentre per i concetti concreti il referente fisico guida in modo più uniforme la descrizione.
3. **Strategie definitorie:** lo schema aristotelico *genus-differentia* è adottato spontaneamente per i concetti concreti (*Tree = kind of plant [genus] + composed by a trunk [differentia]*), mentre per i concetti astratti prevalgono parafrasi operative basate sull'effetto prodotto.

2.3 Metodologia quantitativa

Per quantificare la sovrapposizione tra le definizioni di uno stesso concetto sono state applicate due metriche, calcolate a coppie su tutte le definizioni disponibili per ciascun concetto:

- **Simlex (Jaccard):** il testo viene normalizzato (minuscolo, rimozione di punteggiatura e stopwords, lemmatizzazione) e si calcola l'indice di Jaccard tra gli insiemi di parole di ogni coppia di definizioni.
- **Simsem (Cosine su TF-IDF):** le definizioni vengono vettorizzate con TF-IDF e si calcola la cosine similarity media tra tutte le coppie, per catturare la vicinanza concettuale anche in assenza di sovrapposizione lessicale esatta.

Indice di Jaccard tra definizioni normalizzate

```
1 def jaccard_similarity(set1, set2):
2     if not set1 or not set2:
3         return 0.0
4     intersection = len(set1.intersection(set2))
5     union = len(set1.union(set2))
6     return intersection / union
```

2.4 Risultati

Tabella 1: Sovrapposizione lessicale (Simlex) e semantica (Simsem) media, per concetto

Concetto	Tipo	Specificità	Simlex (Jaccard)	Simsem (Cosine)
Tree	Concreto	Generico	0.084	0.077
Teapot	Concreto	Specifico	0.057	0.062
Ethics	Astratto	Specifico	0.034	0.041
Music	Astratto	Generico	0.034	0.036

2.5 Discussione

- **Variabilità lessicale altissima:** i valori di Jaccard sono estremamente bassi per tutti i concetti (massimo 8.4% per *Tree*), a dimostrazione che parlanti diversi scelgono vocaboli molto diversi anche descrivendo lo stesso referente.
- **Il coseno TF-IDF compensa parzialmente la variabilità lessicale:** per i concetti astratti (*Ethics*, *Music*) la similarità semantica supera quella lessicale, perché il TF-IDF allinea parzialmente sinonimi e termini affini che il solo confronto insiemistico non cattura.
- **Concretezza vs astrazione:** emerge un pattern netto – i concetti concreti ottengono punteggi di similarità sistematicamente superiori. Il referente fisico vincola il lessico condiviso dai parlanti, mentre l’astrazione concettuale amplifica le divergenze interpretative.

Questo ultimo punto – il ruolo stabilizzante del referente fisico concreto – ricorrerà anche nel Lab 2 (accuratezza di recupero più alta per concetti concreti) e nel Lab 3 (minore asimmetria cross-linguistica per sostantivi concreti come *mouth* e *table*).

3 Lab 2 – Valutazione Content-to-Form: Ricerca Onomasiologica con WordNet

3.1 Obiettivo

Il Lab 2 esplora la **ricerca onomasiologica**: dato un contenuto (una definizione in linguaggio naturale, le stesse raccolte nel Lab 1), si cerca di risalire alla forma lessicale codificata in WordNet, ovvero al synset corretto. Si inverte così la direzione tipica di un dizionario (forma $\rightarrow$ contenuto), chiedendosi: *quanto deve essere “buona” una definizione perché permetta il recupero automatico del concetto giusto?*

3.2 Metodo

Per ciascuno dei quattro concetti (*Music*, *Ethics*, *Tree*, *Teapot*) sono stati selezionati da WordNet 3.1 i 5 synset candidati più plausibili (incluso il synset target corretto, sensi alternativi e iperonimi). Per ciascuna delle 28 definizioni del dataset si applica la procedura:

1. Pulizia del testo: minuscolo, rimozione di punteggiatura e stopwords.
2. Vettorizzazione TF-IDF della definizione e delle 5 glosse candidate.
3. Selezione del synset con cosine similarity più alta rispetto alla definizione.
4. Confronto con il synset target per determinare se il recupero è corretto.

Selezione del synset per cosine similarity TF-IDF

```
1 corpus = [defn_clean] + glosses_clean
2 tfidf = TfidfVectorizer()
3 mat = tfidf.fit_transform(corpus)
4 sims = cosine_similarity(mat[0:1], mat[1:])[0]
5 best_synset = syn_names[int(np.argmax(sims))]
6 correct = (best_synset == target_syn)
```

3.3 Risultati

Tabella 2: Accuratezza e score di similarità per concetto (28 definizioni totali)

Concetto	Tipo	Specificità	Sintet target	Corretto	Score medio
Music	Astratto	Generico	<code>music.n.01</code>	9/28 (32.1%)	0.130
Ethics	Astratto	Specifico	<code>ethics.n.01</code>	12/28 (42.9%)	0.152
Tree	Concreto	Generico	<code>tree.n.01</code>	25/28 (89.3%)	0.103
Teapot	Concreto	Specifico	<code>teapot.n.01</code>	20/28 (71.4%)	0.127

Tabella 3: Aggregazione per tipo e specificità

Dimensione	Gruppo	Score medio	Accuratezza
Tipo	Astratto	0.141	37.5%
Tipo	Concreto	0.115	80.4%
Specificità	Generico	0.116	60.7%
Specificità	Specifico	0.140	57.1%

3.4 Discussione

Concreto vs astratto. Il risultato più significativo è la netta differenza di accuratezza tra concetti concreti (80.4%) e astratti (37.5%). I concetti concreti hanno proprietà fisiche ben definite che si traducono in un vocabolario condiviso e prevedibile tra gli studenti, facilitando il matching con le glosse WordNet; i concetti astratti ammettono invece angolature molto diverse (emotiva, filosofica, strutturale), per cui il TF-IDF non riesce a catturare la somiglianza concettuale quando le parole usate divergono.

L’efficacia dello schema genus-differentia. Le definizioni che seguono esplicitamente lo schema *genus-differentia* ottengono sistematicamente score più alti: ad esempio la definizione di *Ethics* con score 0.63 (“*branch of philosophy [genus] that studies human behavior by trying to define what is right and what is wrong [differentia]*”) si allinea quasi letteralmente con la glossa di `ethics.n.01`.

Limiti del TF-IDF. Il metodo presenta tre limiti rilevanti: *opacità semantica* (sinonimi come *container* e *vessel* non vengono riconosciuti come simili), *sensibilità alla lunghezza* (definizioni brevi producono vettori sparsi) e *assenza di struttura sintattica* (bag-of-words, mentre lo schema genus-differentia ha una struttura semanticamente significativa). Un approccio con embedding contestuali (es. Sentence-BERT) supererebbe il limite della dipendenza lessicale esatta – esattamente l’approccio poi adottato nei Lab 4 e 5.

4 Lab 3 – Complessità Polisemica Cross-Linguistica

4.1 Obiettivo

Il Lab 3 verifica empiricamente la tesi secondo cui **la polisemia non è una proprietà universale della parola, ma del modo in cui una lingua organizza il proprio**

lessico: la stessa area concettuale può essere lessicalizzata in modo completamente diverso da una lingua all'altra. Si confronta la complessità polisemica di **20 lemmi** (8 sostantivi, 6 verbi, 6 aggettivi) tradotti in **inglese, italiano e spagnolo**, usando l'Open Multilingual WordNet (OMW) tramite NLTK.

4.2 Metodologia

Per ogni lemma e lingua si recuperano i synset con `wn.synsets(lemma, lang=...)` e si conta il numero di sensi $N(w)$. Poiché OMW non fornisce frequenze d'uso per le lingue non inglesi (a differenza dell'inglese, dove esistono dati SemCor), si assume una **distribuzione uniforme** sui sensi disponibili, per cui l'entropia di Shannon si riduce a $H(w) = \log_2 N(w)$: una scala più interpretabile del conteggio grezzo, ma non una misura indipendente da esso – un limite esplicito del dataset multilingue, discusso criticamente nella relazione originale.

L'**asimmetria** cross-linguistica di un lemma è definita come

$$\text{asimmetria}(w) = \max(N_{en}, N_{it}, N_{es}) - \min(N_{en}, N_{it}, N_{es}).$$

4.3 Risultati

Tabella 4: Statistiche aggregate sui 20 lemmi, per lingua

Lingua	Media sensi	Mediana	Max	Media entropia
Inglese	31.70	30.5	75	4.79 bit
Italiano	7.95	6.5	23	2.71 bit
Spagnolo	13.15	12.5	32	3.45 bit




Figura 1: Numero di sensi per ciascuno dei 20 lemmi nelle tre lingue (ordinati per numero di sensi in inglese, decrescente).

Tabella 5: Top 5 lemmi per asimmetria cross-linguistica (max–min sensi)

Lemma (EN)	Inglese	Italiano	Spagnolo	Asimmetria
break	75	6	23	69
run	57	5	7	52
light	47	5	17	42
head	42	9	11	33
open	36	4	24	32




Figura 2: Sinistra: distribuzione del numero di sensi per lingua. Destra: distribuzione per categoria grammaticale.

4.4 Discussione

Gerarchia EN $\gg$ ES > IT. In media l'inglese registra circa 4 volte più sensi dell'italiano e oltre il doppio dello spagnolo, per lo stesso lemma. Il pattern si mantiene all'interno di ogni categoria grammaticale, ma va interpretato con cautela: Princeton WordNet è una risorsa raffinata da oltre 30 anni con granularità dei sensi molto fine, mentre le estensioni OMW per italiano e spagnolo sono mappature più recenti e meno esaustive. Parte della differenza è quindi attribuibile a copertura/granularità delle risorse, non solo a una reale differenza di polisemia.

Il caso *bank*: asimmetria strutturale, non solo quantitativa. In italiano “banca” (2 sensi) copre quasi solo l'istituto finanziario (il senso “riva del fiume” è lessicalizzato come *riva*); in spagnolo “banco” (8 sensi) è più carico semanticamente, includendo anche il mobile e il banco di sabbia/pesci – più vicino al comportamento inglese. La stessa area concettuale viene quindi ripartita diversamente tra le tre lingue.

Verbi vs sostantivi concreti. I lemmi con asimmetria massima sono entrambi verbi (*run*, *break*), che in inglese si estendono a domini semantici eterogenei lessicalizzati in italiano/spagnolo con verbi distinti. All'opposto, sostantivi concreti con referente fisico stabile (*mouth*, *table*) mostrano la minore asimmetria – lo stesso effetto stabilizzante del referente concreto osservato nei Lab 1–2.

Implicazioni per l'NLP multilingue. Un sistema di machine translation o cross-lingual transfer che assuma una corrispondenza 1:1 tra i sensi di un lemma inglese e del suo corrispettivo italiano/spagnolo commetterebbe un errore sistematico, specialmente per verbi ad alta polisemia.

Il limite principale è l'assunzione di distribuzione uniforme dei sensi, dovuta all'assenza di dati di frequenza d'uso in OMW per le lingue romanze.

5 Lab 4 – Topic Modeling con BERTopic

Laboratorio svolto individualmente da Alessandro Olivero.

5.1 Obiettivo

Costruire una pipeline completa di **topic modeling non supervisionato** sul dataset `MaartenGr/arxiv_nlp` (44.949 abstract di paper NLP da arXiv, senza etichette tematiche), confrontando almeno tre configurazioni che variano modello di embedding, parametri UMAP e parametri HDBSCAN.

5.2 Architettura della pipeline

1. **Embedding**: ogni abstract è convertito in un vettore denso con un modello `SentenceTransformer`.
2. **UMAP**: riduzione dimensionale che preserva la struttura semantica locale/globale.
3. **HDBSCAN**: clustering density-based, etichetta `-1` per gli outlier.
4. **BERTopic**: estrae parole rappresentative per ciascun cluster tramite `c-TF-IDF` (TF-IDF contestualizzato per cluster).

5.3 Configurazioni testate

Tabella 6: Le tre configurazioni confrontate

Config	Embedding	UMAP	HDBSCAN
1 – Baseline	<code>gte-small</code> (384d)	<code>n_comp=5, n_neigh=15</code>	<code>min_cluster=50</code>
2 – MiniLM fine	<code>all-MiniLM-L6-v2</code>	<code>n_comp=10, n_neigh=10</code>	<code>min_cluster=30</code>
3 – MiniLM coarse	<code>all-MiniLM-L6-v2</code>	<code>n_comp=5, n_neigh=30</code>	<code>min_cluster=150</code>

5.4 Risultati

Tabella 7: Confronto quantitativo tra le tre configurazioni

Configurazione	#Topic	Outlier	Outlier%	Tempo totale
1 – Baseline	151	14.357	31.9%	$\approx$ 3h 47m
2 – MiniLM fine	171	12.747	28.4%	$\approx$ 17m 30s
3 – MiniLM coarse	49	14.899	33.1%	$\approx$ 11m

Esempio – Config 1 (Baseline), top-5 topic per numero documenti

0	2235	<code>speech, asr, recognition, end, acoustic</code>
1	2166	<code>question, qa, questions, answer, answering</code>
2	1603	<code>medical, clinical, biomedical, patient, health</code>
3	886	<code>summarization, summaries, summary, abstractive</code>
4	862	<code>translation, nmt, machine, bleu, neural</code>

5.5 Discussione

Config 1 vs Config 2: granularità e qualità. Entrambe producono topic semanticamente coerenti e privi di stopword. La Config 2 produce 20 topic in più (171 vs 151) e meno outlier (28.4% vs 31.9%): `min_cluster_size=30` più basso consente cluster più piccoli e numerosi, mentre `n_components=10` preserva più struttura semantica locale. Computazionalmente la differenza è enorme: la Config 1 richiede $\approx 3h47m$ (13.484s solo per gli embedding con `gte-small` su CPU), la Config 2 meno di 18 minuti – a parità (o superiorità) di qualità, `all-MiniLM-L6-v2` è la scelta più efficiente per dataset di questa dimensione senza GPU.

Config 3: un failure mode istruttivo. Con `min_cluster_size=150` e `n_neighbors=30`, HDBSCAN forma solo 49 cluster molto più grandi e tematicamente misti. Il c-TF-IDF, calcolato su cluster troppo eterogenei, diluisce le parole discriminanti con termini ad alta frequenza globale – incluse le stopword: i topic risultanti contengono esplicitamente *the*, *to*, *and*, *of* tra le prime cinque parole (es. topic “transformer, attention, **the**, models, **of**”), segno che il segnale semantico specifico del cluster è insufficiente rispetto al rumore introdotto dalla dimensione eccessiva.

Configurazione consigliata. La Config 2 risulta complessivamente la migliore: più topic, meno outlier, parole rappresentative pulite, tempo di esecuzione praticabile su CPU. Il laboratorio mostra come la qualità del topic modeling dipenda criticamente dalla combinazione di tre fattori – capacità dell’embedding di catturare la semantica del dominio, granularità della proiezione UMAP, soglia di densità di HDBSCAN – e come anche tecniche moderne come BERTopic non siano esenti da failure mode prevedibili e analizzabili.

6 Lab 5 – Retrieval-Augmented Generation (RAG)

6.1 Obiettivo

Il Lab 5 integra retrieval e generazione in un sistema **RAG** completo sul medesimo corpus arXiv-NLP, confrontando due strategie di retrieval:

- **RAG base:** retrieval puramente semantico (SciBERT + FAISS).
- **RAG ibrido:** fusione di retrieval semantico e lessicale (BM25), tramite Reciprocal Rank Fusion (RRF).

Entrambe le pipeline generano la risposta finale con **Phi-3.5-mini-instruct** (Microsoft, 3.8B parametri), condizionato sui documenti recuperati.

6.2 Architettura

1. **Retrieval semantico:** SciBERT (`allenai/scibert_scivocab_uncased`, pre-addestrato su 1.14M paper scientifici) codifica query e documenti in vettori a 768 dimensioni, normalizzati per similarità coseno; FAISS `IndexFlatIP` esegue la ricerca esatta.
2. **Retrieval lessicale (solo ibrido):** BM25Okapi, efficace sui termini tecnici esatti (es. “NER”, “LDA”) che SciBERT tende a generalizzare.

3. **Fusione RRF (solo ibrido):** $RRF(d) = \sum_r \frac{1}{k + \text{rank}_r(d)}$ con $k = 60$, applicata ai top-20 di ciascun retriever.
4. **Generazione:** Phi-3.5-mini-instruct riceve query + documenti come contesto (troncato a 3000 caratteri) e genera la risposta citando le fonti ([Paper X]), con temperatura $T = 0.3$.

Retrieval ibrido con Reciprocal Rank Fusion

```

1 def retrieve_hybrid(query, faiss_index, bm25, documents, metadata, k=5):
2     sem = retrieve_semantic(query, faiss_index, documents, metadata, k=20)
3     bm = retrieve_bm25(query, bm25, documents, metadata, k=20)
4     return reciprocal_rank_fusion([sem, bm])[:k]

```

6.3 Metriche di valutazione (ispirate a RAGAS)

- **Precision@k:** quota di documenti rilevanti (per gold standard a parole chiave) tra i top- k recuperati.
- **Context Relevance:** coseno medio tra l’embedding della query e gli snippet dei documenti recuperati.
- **Answer Relevance:** coseno tra l’embedding della query e quello della risposta generata.
- **Faithfulness proxy:** quota di parole contenutistiche della risposta presenti nel testo dei documenti di contesto.
- **Robustezza:** overlap@5 tra i risultati di una query e quelli delle sue parafrasature.

6.4 Esperimento 1: variazione della dimensione del corpus (RAG base vs ibrido)

Il corpus è stato fatto variare su cinque dimensioni $N_{\text{DOCS}} \in \{1\,000, 5\,000, 15\,000, 25\,000, 44\,949\}$ (corpus completo), ricostruendo gli indici e ripetendo la valutazione su 5 query gold standard.

Tabella 8: Precision@5 al variare di N_{DOCS} : RAG base vs ibrido

N_{DOCS}	Base	Ibrido	Delta	Miglioramento
1 000	0.160	0.400	+0.240	+150.0%
5 000	0.240	0.560	+0.320	+133.3%
15 000	0.160	0.520	+0.360	+225.0%
25 000	0.200	0.440	+0.240	+120.0%
44 949	0.120	0.360	+0.240	+200.0%

Il retrieval ibrido supera il baseline semantico in *tutte e cinque* le configurazioni (+120% a +225%): BM25 recupera i paper con terminologia tecnica esatta che SciBERT generalizza eccessivamente, e RRF bilancia i due segnali. La Precision@5 ibrida non cresce monotonicamente con N_{DOCS} : picco a 5 000 documenti (0.560), calo a 44 949 (0.360) – corpus molto grandi aumentano il “rumore” nel retrieval per entrambi i retriever. La Faithfulness proxy è sistematicamente più alta per il sistema ibrido (+0.027 a +0.095), segno di risposte più ancorate al contesto tecnico recuperato. La Robustezza (overlap@5 su query parafrasate)

è invece inversamente correlata a N_{DOCS} (da 0.233 a $N = 1\,000$ a ~ 0 per corpus grandi): con più documenti, piccole variazioni lessicali della query spostano sensibilmente i confini di un denso spazio di candidati.

6.5 Esperimento 2: variazione del parametro k e qualità su query eterogenee

Una domanda diretta del Prof. Di Caro durante la revisione del progetto chiedeva se fossero stati provati valori di k diversi da 5, e se il sistema fosse stato testato con domande diverse valutandone la qualità. Lo script del RAG base è stato quindi esteso con un confronto su $k \in \{3, 5, 10, 15\}$ su un insieme di **7 query eterogenee** (oltre a BERT/attention e word2vec, anche topic modeling, NER, sentiment analysis, dependency parsing, machine translation), a $N_{\text{DOCS}} = 15\,000$:

Tabella 9: Precision@ k e Context Relevance al variare di k (RAG base, 7 query, $N_{\text{DOCS}}=15\,000$)

k	Precision@ k	Context Relevance
3	0.238	0.719
5	0.314	0.719
10	0.314	0.719
15	0.295	0.719

$k = 5$ risulta il miglior compromesso (in pareggio con $k = 10$): aumentare k oltre 5–10 non migliora la precisione media e la peggiora leggermente a $k = 15$, perché i documenti aggiuntivi sono in media meno rilevanti. La Context Relevance resta costante perché è calcolata sugli stessi vettori SciBERT usati per il ranking: i primi k risultati restano, in aggregato, ugualmente vicini alla query indipendentemente da quanti ne vengano restituiti.

Un limite osservato concretamente: la query su BERT

Per la query “*What is BERT and how does self-attention work?*”, il retrieval semantico puro (a $N_{\text{DOCS}} = 15\,000$) recupera paper completamente fuori tema (es. su dialogue scorekeeping o cognitive issues in NLP), mancando i paper specifici su BERT. L’LLM, correttamente, riconosce l’assenza di informazione pertinente nel contesto e lo dichiara esplicitamente invece di generare contenuto allucinato – un comportamento di *faithfulness* corretto, ma che evidenzia lo stesso limite del retrieval semantico puro già osservato nell’Esperimento 1: è esattamente la ragione per cui la versione ibrida (Sez. 7.4) aggiunge BM25.

Lo script è stato inoltre strutturato per ripetere questo confronto su k a tutte le dimensioni di corpus dell’Esperimento 1 ($N_{\text{DOCS}} \in \{1\,000, \dots, 44\,949\}$), per verificare se il problema di retrieval sulla query BERT sia specifico di $N_{\text{DOCS}} = 15\,000$ o persista a ogni dimensione del corpus; data l’onerosità computazionale su CPU (generazione di embedding e di risposte per 5 configurazioni), questa estensione è predisposta nel codice ma non ancora eseguita per intero al momento della stesura di questa relazione.

6.6 Conclusioni Lab 5

Il sistema RAG ibrido (SciBERT+FAISS+BM25+RRF) migliora sistematicamente la Precision@5 rispetto al solo retrieval semantico, confermando che la combinazione di segnale lessicale e semantico è preferibile per un corpus di paper scientifici ricco di terminologia tecnica specifica. Il parametro $k = 5$ si conferma una scelta solida anche dopo un confronto esplicito su più valori e più query eterogenee. Il limite più rilevante riguarda corpus di grandi dimensioni, dove sia la precisione che la robustezza del retrieval calano: una direzione di lavoro futuro naturale è l'introduzione di query expansion o pre-filtraggio per sotto-dominio.

7 Conclusioni generali

I cinque laboratori, pur usando tecniche eterogenee (TF-IDF, WordNet/OMW, BERTopic, RAG neurale), convergono su alcune osservazioni ricorrenti:

1. **I concetti concreti con referente fisico stabile sono sistematicamente più trattabili computazionalmente** dei concetti astratti: maggiore sovrapposizione lessicale tra definizioni indipendenti (Lab 1), maggiore accuratezza di recupero onomasiologico (Lab 2), minore asimmetria cross-linguistica (Lab 3).
2. **I metodi lessicali puri (TF-IDF, BM25) sono baseline solide ma limitate** quando la variabilità lessicale è alta: insufficienti per concetti astratti nel Lab 2, ma complementari – non sostituibili – al retrieval semantico nel Lab 5, dove la combinazione ibrida supera sistematicamente entrambi i metodi presi singolarmente.
3. **La qualità dell'output automatico dipende criticamente dai parametri scelti**, e questa dipendenza è stata verificata esplicitamente in più laboratori: la combinazione di modello di embedding, granularità UMAP e soglia HDBSCAN nel Lab 4 (con un vero e proprio failure mode osservato nella Config 3), e il valore di k nel retrieval del Lab 5.
4. **La valutazione quantitativa rivela limiti che l'ispezione qualitativa da sola non mostrerebbe**: lo score pari a zero per sinonimi non riconosciuti nel Lab 2, le stopword infiltrate nei topic del Lab 4, la query su BERT non risolta correttamente nel Lab 5 nonostante un sistema altrimenti funzionante.

Nel complesso, il percorso dei cinque laboratori mostra l'evoluzione naturale delle tecniche di NLP affrontate nel corso: da metodi lessicali e simbolici (Lab 1–3) verso rappresentazioni neurali contestuali (Lab 4–5), senza che i primi perdano rilevanza – BM25 resta competitivo e complementare anche nel sistema più avanzato (RAG ibrido del Lab 5).