

Università degli Studi di Torino
Corso di Laurea Magistrale in Informatica

Tecnologie del Linguaggio Naturale

Parte 3 – Prof. Luigi Di Caro

Lab 1

Complessità Definizionale e Sovrapposizione Semantica

Confronto lessicale (Jaccard) e semantico (Sentence-BERT) fra definizioni
indipendenti

Gruppo di lavoro:

Studente	Matricola
Alessandro Olivero	915069
Samuele Iudice	1235245
Andrea Franco	1226739

Docente: Prof. Luigi Di Caro

Anno Accademico: 2025/2026

Indice

1	Introduzione	2
2	Dataset e Analisi Qualitativa Preliminare	2
2.1	Esempi dal dataset	2
2.2	Un'anomalia nei dati, scoperta ispezionando le coppie a similarità minima .	2
3	Metodologia	4
3.1	Pipeline di preprocessing (condivisa fra le due metriche, con un'eccezione voluta)	4
3.2	Simlex: indice di Jaccard	4
3.3	Simsem: cosine similarity su embedding Sentence-BERT	4
4	Risultati	5
4.1	Risultati aggregati per concetto	5
4.2	Statistiche estese: dispersione e coppie estreme	5
4.3	Impatto quantitativo della contaminazione	6
5	Discussione	7
6	Conclusioni	7

1 Introduzione

L'obiettivo del Lab 1 è misurare quanto le definizioni indipendenti, raccolte da studenti diversi per uno stesso concetto, si sovrappongano – sia lessicalmente sia semanticamente – per quattro concetti bilanciati lungo due dimensioni (concretezza e specificità):

- **Tree** (Albero): concreto, generico.
- **Teapot** (Teiera): concreto, specifico.
- **Music** (Musica): astratto, generico.
- **Ethics** (Etica): astratto, specifico.

Il dataset (`Dataset definizioni-spurio.csv`) contiene 28 definizioni per ciascun concetto, una per ciascuno dei 28 rispondenti del questionario. Si applicano due metriche indipendenti – **Simlex**, puramente lessicale, e **Simsem**, semantica – a tutte le $\binom{28}{2} = 378$ coppie di definizioni per concetto (1 512 coppie totali), per rispondere alla domanda centrale della Fase 5 della consegna: *la sovrapposizione semantica riflette meglio l'intuizione umana di quella lessicale?*

2 Dataset e Analisi Qualitativa Preliminare

2.1 Esempi dal dataset

- **Tree (CG)**: “A plant with roots, trunk, branches and foliage used to obtain timber and produce paper.”
- **Ethics (AS)**: “Philosophical thought aimed at explaining ideal human behavior, attempting to demonstrate what is right and what is wrong.”

Per i concetti concreti (*Tree*, *Teapot*) il lessico converge su componenti fisiche e funzionali (*roots*, *trunk*, *container*); per i concetti astratti (*Music*, *Ethics*) il vocabolario si sposta sulla sfera cognitiva e valoriale (*behavior*, *sentiment*, *right/wrong*). Lo schema aristotelico *genus-differentia* è adottato spontaneamente per i concetti concreti (*Tree* = *plant* [genus] + *trunk/branches* [differentia]); per i concetti astratti prevalgono parafrasi operative basate sull'effetto prodotto (*Music* = *sequence of sounds that triggers emotions*).

2.2 Un'anomalia nei dati, scoperta ispezionando le coppie a similarità minima

Calcolando, per ciascun concetto, la coppia di definizioni con **Simsem minima** (Sez. 4.2), emerge un pattern sistematico e non casuale:

Tabella 1: Coppie a similarità semantica minima per concetto – tutte spiegate dalla stessa anomalia

Concetto	Definizione A	Definizione B	Simsem
Music	“A tree is a woody plant capable of growing in height...”	“Insieme di suoni” (IT)	−0.035
Ethics	“Etica: insieme di regole morali che una persona segue” (IT)	“A teapot is a container used mainly for infusions...”	−0.135
Tree	“Organism covered in bark, leaves that cover the branches...”	“Art that has no visual or tactile representation but seeks to express concepts through harmonies...”	−0.034
Teapot	“Container useful for holding and pouring tee”	“Ethics includes moral principles that must be respected when making choices.”	−0.151

In **ogni** concetto, la coppia meno simile in assoluto contiene una definizione “intrusa” che appartiene concettualmente a un *altro* concetto del dataset: una definizione di *Tree* compare come outlier nella colonna *Music*, una definizione di *Teapot* nella colonna *Ethics*, una definizione di *Music* nella colonna *Tree*, una definizione di *Ethics* nella colonna *Teapot*. Verificando manualmente l’intero dataset (colonna per colonna, confrontando ogni definizione col proprio concetto dichiarato), risulta che **5 rispondenti su 28** (Risposta numero 7, 14, 20, 22, 23 – il 17.9% del campione) hanno le colonne *Astratto* e *Concreto* scambiate a coppie: la loro risposta nella colonna “Music” (AG, astratto-generico) è in realtà la loro definizione di *Tree* (CG, concreto-generico), e quella nella colonna “Ethics” (AS, astratto-specifico) è la loro definizione di *Teapot* (CS, concreto-specifico) – e viceversa. Il pattern è identico e simmetrico per tutti e 5 i rispondenti (esempio, risposta 23: colonna Music → “A tree is a woody plant...”; colonna Ethics → “A teapot is a container used mainly for infusions...”), compatibile con un errore sistematico di compilazione del modulo (colonne astratto/concreto invertite) più che con risposte casuali – coerentemente col nome del file (**definizioni-spurio.csv**). Si segnalano inoltre, isolatamente, due definizioni compilate in italiano invece che in inglese (*Music*, risposta 27: “Insieme di suoni”; *Ethics*, risposta 9: “Etica: insieme di regole morali...”), un secondo tipo di rumore indipendente dalla contaminazione a colonne invertite.

Queste 22 definizioni “intruse” (5 per ciascuno dei 4 concetti, escludendo sovrapposizioni) **restano nel dataset** per tutti i risultati aggregati riportati sotto – coerentemente con l’indicazione della consegna di lavorare sul dataset così come raccolto in aula – ma il loro effetto è quantificabile: non essendo mai lessicalmente o semanticamente vicine alle 23 definizioni genuine dello stesso concetto, abbassano leggermente le medie Simlex/Simsem per tutti e quattro i concetti in modo pressoché uniforme (Sez. 4.3), senza alterare il confronto *relativo* fra concetti che è l’oggetto principale di questa relazione.

3 Metodologia

3.1 Pipeline di preprocessing (condivisa fra le due metriche, con un'eccezione voluta)

Il testo viene normalizzato con una pipeline unica: lowercase, rimozione di punteggiatura, filtraggio delle stopwords (parole di lunghezza < 3 o presenti nella stopwords-list NLTK), e lemmatizzazione POS-aware (`pos_tag + WordNetLemmatizer`, con mappatura Treebank $\rightarrow$ WordNet per il tag di ciascun token).

Pipeline di normalizzazione e lemmatizzazione POS-aware

```
1 def preprocess_definition(text):
2     text = text.lower()
3     text = re.sub(f"[{re.escape(string.punctuation)}]", " ", text)
4     tokens = [t for t in text.split()
5               if t.isalpha() and t not in STOP_WORDS and len(t) > 2]
6     tagged = pos_tag(tokens)
7     lemmas = [LEMMATIZER.lemmatize(tok, _wordnet_pos(pos))
8               for tok, pos in tagged]
9     return " ".join(lemmas), set(lemmas)
```

Un punto metodologico rilevante: i token *lemmatizzati* vengono usati per Simlex (Jaccard), ma **non** per Simsem. SBERT è addestrato su frasi naturali; rimuovere stopwords e sintassi (necessario per un confronto insiemistico come Jaccard) degraderebbe l'input rispetto a quanto il modello si aspetta. Simsem viene quindi calcolata sul testo *grezzo* della definizione, allineato per indice alle stesse definizioni usate per Simlex (una definizione viene scartata da entrambe le metriche solo se il preprocessing la svuota completamente, cioè se non contiene nessun token alfabetico non-stopword).

3.2 Simlex: indice di Jaccard

$$\text{Simlex}(d_1, d_2) = J(T_1, T_2) = \frac{|T_1 \cap T_2|}{|T_1 \cup T_2|}$$

dove T_1, T_2 sono gli insiemi di lemmi delle due definizioni. Simlex = 0 se gli insiemi sono disgiunti o vuoti, = 1 se identici.

3.3 Simsem: cosine similarity su embedding Sentence-BERT

$$\text{Simsem}(d_1, d_2) = \cos(\vec{e}_1, \vec{e}_2) = \frac{\vec{e}_1 \cdot \vec{e}_2}{\|\vec{e}_1\| \|\vec{e}_2\|}$$

dove $\vec{e}_1, \vec{e}_2 \in \mathbb{R}^{384}$ sono gli embedding delle definizioni grezze prodotti da all-MiniLM-L6-v2. A differenza di Jaccard, Simsem può essere (leggermente) negativa: due embedding possono avere angolo > 90 .

Calcolo di Simlex e Simsem per un concetto

```
1 processed = [preprocess_definition(d) for d in raw_definitions]
2 valid = [(raw, toks) for raw, (cleaned, toks)
3           in zip(raw_definitions, processed) if cleaned]
4 raw_for_sbirt = [r for r, _ in valid]
5 token_sets = [t for _, t in valid]
6
7 simlex_scores = [jaccard_similarity(token_sets[i], token_sets[j])
8                  for i, j in itertools.combinations(range(len(token_sets)), 2)]
9 avg_simlex = np.mean(simlex_scores)
10
11 embs = SBERT_MODEL.encode(raw_for_sbirt, show_progress_bar=False)
12 cos_sim_matrix = cosine_similarity(embs)
13 upper_tri = cos_sim_matrix[np.triu_indices(cos_sim_matrix.shape[0], k=1)]
14 avg_simsem = np.mean(upper_tri)
```

Tempo di esecuzione totale: ~ 11 secondi per i 4 concetti (dominati dal caricamento una tantum del modello SBERT; il calcolo delle similarità sulle $4 \times 378 = 1512$ coppie è sub-secondo).

4 Risultati

4.1 Risultati aggregati per concetto

Tabella 2: Simlex e Simsem medi per concetto (dati reali, esecuzione corrente, $n = 378$ coppie/concetto)

Concetto	Tipo	Specificità	Simlex	Simsem	$\Delta(\text{Simsem} - \text{Simlex})$
Tree	Concreto	Generico	0.0807	0.3518	0.2711
Teapot	Concreto	Specifico	0.0672	0.3073	0.2401
Music	Astratto	Generico	0.0492	0.3296	0.2804
Ethics	Astratto	Specifico	0.0435	0.2974	0.2539

Tabella 3: Aggregazione per dimensione (Tipo, Specificità)

Dimensione	Gruppo	Simlex	Simsem	Δ
Tipo	Concreto	0.0739	0.3296	0.2556
Tipo	Astratto	0.0464	0.3135	0.2672
Specificità	Generico	0.0649	0.3407	0.2758
Specificità	Specifico	0.0554	0.3024	0.2470

4.2 Statistiche estese: dispersione e coppie estreme

Le medie da sole nascondono la forma della distribuzione delle 378 coppie per concetto: la deviazione standard e i valori estremi mostrano quanto siano eterogenee.

Tabella 4: Statistiche estese sulle 378 coppie per concetto (media, deviazione standard, minimo, massimo)

Concetto	Simlex				Simsem			
	media	std	min	max	media	std	min	max
Music	0.0492	0.0671	0.000	0.333	0.3296	0.2307	-0.035	0.890
Ethics	0.0435	0.0795	0.000	0.467	0.2974	0.2554	-0.135	0.893
Tree	0.0807	0.1147	0.000	0.714	0.3518	0.2193	-0.034	0.817
Teapot	0.0672	0.0957	0.000	0.500	0.3073	0.2831	-0.151	0.860

Tre osservazioni tecniche da questa tabella:

- **La deviazione standard di Simsem è sempre 3–6 volte quella di Simlex** in valore assoluto, ma va letta in proporzione alla scala: il *coefficiente di variazione* (std/media) di Simlex è sistematicamente più alto (es. Ethics: $0.0795/0.0435 = 1.83$) di quello di Simsem (Ethics: $0.2554/0.2974 = 0.86$) – Jaccard non è solo più basso in media, è anche relativamente più instabile, coerente con la sua natura di conteggio su insiemi piccoli (poche decine di lemmi per definizione) dove una singola parola in comune o mancante sposta il punteggio in modo sproporzionato.
- **Teapot ha la Simsem con maggiore dispersione** (std= 0.2831, la più alta fra i quattro concetti) nonostante il Simlex relativamente contenuto: le definizioni di teiera oscillano fra parafrasi molto simili al genus-differentia canonico (“container for tea”, Simsem fino a 0.860) e definizioni idiosincratiche (dettagli su forma, materiale, uso) che se ne allontanano semanticamente pur restando corrette.
- **Il minimo di Simsem è negativo in tutti i concetti tranne Music** (per un margine minimo, -0.035): conferma che SBERT non è vincolato in $[0, 1]$ come Jaccard, e che le coppie contaminate (Sez. 2.2) producono coerentemente gli angoli più ampi nello spazio degli embedding.

4.3 Impatto quantitativo della contaminazione

Per verificare che la contaminazione (Sez. 2.2) non alteri le conclusioni relative fra concetti, si ricalcolano Simlex/Simsem **escludendo** le 5 risposte contaminate per concetto (23 definizioni invece di 28, $\binom{23}{2} = 253$ coppie):

Tabella 5: Simsem con e senza le risposte contaminate

Concetto	Simsem (28 def.)	Simsem (23 def., pulito)	Variazione
Music	0.3296	0.3499	+0.0203
Ethics	0.2974	0.3183	+0.0209
Tree	0.3518	0.3712	+0.0194
Teapot	0.3073	0.3277	+0.0204

La rimozione delle definizioni contaminate alza Simsem di ≈ 0.02 in **tutti e quattro** i concetti, in modo pressoché uniforme (deviazione fra le quattro variazioni: 0.0006):

la contaminazione agisce come un abbassamento sistematico e costante, non selettivo per concetto, e l'ordinamento relativo fra i quattro concetti ($Tree > Music > Teapot > Ethics$) è identico prima e dopo la pulizia. Questo giustifica quantitativamente, e non solo per argomentazione qualitativa, la scelta di riportare i risultati sul dataset completo: le conclusioni sul contrasto concreto/astratto non dipendono dalla presenza delle 22 definizioni intrusive.

5 Discussione

Simlex separa nettamente concreto e astratto, Simsem molto meno. Il rapporto fra Simlex medio concreto (0.0739) e astratto (0.0464) è $1.59\times$: quasi il 60% di sovrapposizione lessicale in più per i concetti con referente fisico. Sullo stesso confronto, Simsem concreto (0.3296) supera l'astratto (0.3135) solo del 5% relativo. La rappresentazione semantica di SBERT recupera quindi gran parte del gap lessicale fra le due categorie: parlanti diversi scelgono parole molto diverse per descrivere *Music* o *Ethics*, ma quelle parole restano concettualmente vicine nello spazio SBERT molto più di quanto non lo siano nell'insieme di token grezzi – è questa la risposta quantitativa alla domanda della Fase 5: sì, la sovrapposizione semantica riflette meglio l'intuizione umana, e lo si può misurare esattamente come il rapporto fra i due effect size ($1.59\times$ contro $1.05\times$).

Il Δ è sistematicamente più alto per gli astratti. Il concetto con Δ massimo è *Music* (0.2804), quello con Δ minimo è *Teapot* (0.2401); in aggregato $\Delta_{\text{Astratto}} = 0.2672 > \Delta_{\text{Concreto}} = 0.2556$ e $\Delta_{\text{Generico}} = 0.2758 > \Delta_{\text{Specifico}} = 0.2470$. Dove il lessico condiviso è più povero (concetti astratti, generici), c'è più “spazio” perché la similarità semantica aggiunga segnale rispetto a quella lessicale; dove il referente fisico già garantisce lessico condiviso (*Teapot* ha il Simlex più alto dei quattro), il guadagno marginale di SBERT è minore in valore assoluto.

Music sorprende: più vicino semanticamente di Teapot. Nonostante *Music* abbia il Simlex più basso dei quattro (0.0492), il suo Simsem (0.3296) supera quello di *Teapot* (0.3073) – l'unico caso in cui l'ordinamento concreto/astratto si inverte. Le definizioni genuine di *Music* convergono spesso su una struttura comune (“sequenza di suoni che suscita emozioni”), che SBERT riconosce come semanticamente coerente pur con lessico superficiale molto vario: la coppia a Simsem massima del dataset intero (0.890, Tabella 6) è proprio una coppia *Music*, fra due parafrasi quasi sinonime (“triggering emotions” / “arousing emotions... in the listener”).

Il ruolo stabilizzante del referente fisico. È ridimensionato, ma non annullato, dal passaggio a Simsem: ricompare nel Lab 2 (coverage più alta per *Teapot* che per *Music/Tree*) e nel Lab 3 (minore asimmetria cross-linguistica per sostantivi concreti come *mouth* e *table*).

6 Conclusioni

Il laboratorio mostra, con dati quantitativi su 1 512 coppie di definizioni, che (1) la sovrapposizione puramente lessicale (Simlex) è sempre molto bassa (4–8%) e fortemente polarizzata fra concreto e astratto ($1.59\times$); (2) la sovrapposizione semantica (Simsem) resta

sostanzialmente più alta in valore assoluto (30–35%) e quasi indipendente dal contrasto concreto/astratto ($1.05\times$), confermando che SBERT cattura una nozione di similarità molto più vicina all'intuizione umana di quanto non faccia il solo conteggio insiemistico; (3) un difetto nei dati grezzi (5/28 risposte con colonne astratto/concreto scambiate) è stato identificato sistematicamente ispezionando le coppie a similarità minima – non un'osservazione aneddotica, ma il prodotto diretto dell'analisi quantitativa – e il suo impatto sui risultati è stato misurato ($\approx +0.02$ di Simsem se rimosso, uniformemente sui quattro concetti) e giudicato non rilevante per le conclusioni relative.