

Università degli Studi di Torino
Corso di Laurea Magistrale in Informatica

Tecnologie del Linguaggio Naturale

Parte 3 – Prof. Luigi Di Caro

Lab 2

Valutazione Content-to-Form: Ricerca
Onomasiologica con WordNet

Genus extraction + iponimi WordNet + similarità Sentence-BERT

Gruppo di lavoro:

Studente	Matricola
Alessandro Olivero	915069
Samuele Iudice	1235245
Andrea Franco	1226739

Docente: Prof. Luigi Di Caro

Anno Accademico: 2025/2026

Indice

1	Introduzione	2
2	Metodo	2
3	Risultati	3
3.1	Risultati aggregati: la scomposizione retrieval/ranking	3
3.2	Statistiche sui candidati	3
3.3	Perché la coverage è così bassa: tre meccanismi concreti, verificabili nei dati	4
3.4	I 4 casi con target raggiungibile, in dettaglio	4
3.5	Verifica di robustezza rispetto alla contaminazione del dataset	5
4	Discussione	5
5	Conclusioni	6

1 Introduzione

Il Lab 2 affronta la **ricerca onomasiologica**: data una definizione in linguaggio naturale (le stesse 4×28 del Lab 1), risalire automaticamente al synset WordNet corretto, applicando concretamente il **principio del genus**: si estrae la testa nominale della definizione (il genus, es. “a container used to...”) e si cerca il target solo fra i synset raggiungibili da quel genus in WordNet, non nell’intero vocabolario. Si inverte così la direzione tipica di un dizionario (forma→contenuto), ponendo la domanda: *quanto deve essere “buona” una definizione perché permetta il recupero automatico del concetto giusto?*

2 Metodo

1. **Estrazione del genus**: regex sul pattern copula (“is/are a(n) NOME”); se assente, primo sostantivo della definizione via `pos_tag`.
2. **Generazione dei candidati**: tutti i synset nominali del genus, più i loro iponimi fino a profondità 3 (`Synset.closure(hyponyms, depth=3)`), con un cap di 300 candidati (uscita anticipata) per evitare l’esplosione combinatoria di generi troppo generici.
3. **Similarità**: cosine similarity fra l’embedding SBERT (`all-MiniLM-L6-v2`) della definizione e quello della glossa di ciascun candidato; pareggio esatto o eccezione → nessuna predizione (contati come errore, nessun fallback che gonfi l’accuratezza).
4. **Diagnostica**: per ogni definizione si registra se il synset target fosse *raggiungibile* fra i candidati generati al passo 2, indipendentemente da come poi è stato classificato il passo 3 – questo separa un fallimento di *retrieval* (target mai nei candidati) da uno di *ranking* (target presente ma non vincente).

Generazione dei candidati dal genus (con cap e uscita anticipata)

```
1 def get_candidates_from_genus(genus, depth=GENUS_DEPTH, max_candidates=
    MAX_CANDIDATES):
2     genus_synsets = wn.synsets(genus, pos=wn.NOUN)
3     seen, unique = set(), []
4     def add(syn):
5         if syn.name() not in seen:
6             seen.add(syn.name()); unique.append(syn)
7     for syn in genus_synsets:
8         add(syn)
9         if len(unique) >= max_candidates: break
10    for hypo in syn.closure(lambda s: s.hyponyms(), depth=depth):
11        add(hypo)
12        if len(unique) >= max_candidates: break
13        if len(unique) >= max_candidates: break
14    return unique
```

Esecuzione: ~32 secondi per le 112 definizioni ($4 \text{ concetti} \times 28$), dominati dal caricamento di SBERT e dalla generazione delle closure WordNet per generi molto generici.

3 Risultati

3.1 Risultati aggregati: la scomposizione retrieval/ranking

Tabella 1: Accuratezza, coverage e accuratezza condizionata, per concetto (112 definizioni totali, dati reali)

Concetto	Synset target	Coverage	Accuratezza	Acc. coverage
Music	music.n.01	1/28 (3.6%)	0/28 (0.0%)	0/1
Ethics	ethic/ethics/morality.n.01	1/28 (3.6%)	1/28 (3.6%)	1/1
Tree	tree.n.01	2/28 (7.1%)*	0/28 (0.0%)	0/2
Teapot	teapot.n.01	1/28 (3.6%)	1/28 (3.6%)	1/1
Totale	–	4/112 (3.57%)	2/112 (1.79%)	2/4 (50%)

*una delle due righe “tree raggiungibile” è in realtà la definizione di *Tree* finita per errore nella colonna *Music* (contaminazione, Sez. 3.5); il genus estratto è comunque “tree”, quindi il target *music.n.01* resta correttamente irraggiungibile.

La scomposizione è il risultato più informativo del laboratorio: l'**accuratezza globale** (1.79%) confonde due fallimenti concettualmente distinti. La **coverage** (3.57%) misura quante volte il target è anche solo presente fra i candidati generati dal genus – il vero collo di bottiglia. Condizionando sui soli 4 casi in cui il target è raggiungibile, l'**accuratezza sale al 50%**: la similarità SBERT, quando ha la possibilità di scegliere il synset giusto, lo fa in metà dei casi – una performance ben diversa (e più interpretabile) del 1.79% aggregato.

3.2 Statistiche sui candidati

Numero medio di candidati generati per definizione: **169.9** (mediana 187); il cap di 300 viene raggiunto in **38/112 casi (33.9%)** – tipicamente per generi molto generici (*object*, *concept*, *type*). Lo score di similarità medio è **0.628** per le predizioni corrette contro **0.452** per quelle sbagliate: la metrica di similarità distingue correttamente casi facili da casi difficili una volta che il target è in gioco, confermando che il ranking (fase 3) funziona ragionevolmente bene; il problema reale è a monte, nella fase 2 (generazione dei candidati).

Tabella 2: Distribuzione dello status di scoring

Status	Conteggio
ok (predizione prodotta)	110
no_candidates (genus non estratto / vuoto)	2

I 2 casi **no_candidates** corrispondono alle due definizioni compilate in italiano invece che in inglese, già identificate nel Lab 1 (*Music*, risposta 27: “Insieme di suoni”; *Ethics*, risposta 9: “Etica: insieme di regole morali...”): né la regex sul pattern copula né il PoS tagger inglese trovano un genus valido su testo italiano, e la pipeline fallisce in modo esplicito (**status=no_candidates**) invece di produrre un risultato spurio.

3.3 Perché la coverage è così bassa: tre meccanismi concreti, verificabili nei dati

- **Genus troppo generico:** 27/28 definizioni di *Teapot* usano un genus diverso da “teapot” (*container*: 9, *concept*: 2, *tool*: 2, *type*: 2, *object*: 2...); *teapot.n.01* è però a 3 salti di iponimia da *container.n.01* (*container* → *vessel.n.03* → *pot.n.01* → *teapot.n.01*), esattamente al limite della profondità esplorata, e nella pratica i tre passaggi intermedi contengono così tanti fratelli (altri tipi di vessel/pot) che la ricerca a genus fisso raramente centra il ramo giusto.
- **Genus polisemico che affoga il target nel cap:** 9/28 definizioni di *Tree* usano il genus “plant”. `wn.synsets('plant', pos=NOUN)` restituisce prima il senso industriale (*plant.n.01*, “building for industrial labor”, closure di 35 synset) e poi il senso botanico (*plant.n.02*, che contiene davvero *tree.n.01* nella sua closure a profondità 3, di 747 synset). Il target è però alla posizione ~667 nell’ordine di attraversamento – ben oltre il cap di 300 – quindi viene sistematicamente tagliato fuori nonostante sia strutturalmente raggiungibile. È un artefatto diretto della combinazione ordine-di-atteversamento + cap, non un limite concettuale del principio del genus.
- **Genus semanticamente vicino ma tassonomicamente lontano:** 3/28 definizioni di *Ethics* usano il genus “philosophy”; verificando `wn.synsets('philosophy')` e le rispettive closure a profondità 3, nessuna contiene *ethic.n.01/ethics.n.01/morality.n.01* – la gerarchia degli iponimi di WordNet non colloca l’etica come discendente tassonomico della filosofia entro 3 livelli, anche se concettualmente “etica” è intuitivamente una branca della filosofia.

3.4 I 4 casi con target raggiungibile, in dettaglio

Tabella 3: I 4 casi in cui il target è raggiungibile: genus, numero candidati, sintesi predetto

Concetto	Genus	N. candidati	Sintesi predetto	Score
music	music	278	<i>monophony.n.01</i> (errato)	0.682
ethics	principles	65	<i>ethic.n.01</i> (corretto)	0.617
tree	tree	300 (cap)	<i>sissoo.n.01</i> (errato)	0.557
teapot	teapot	1	<i>teapot.n.01</i> (corretto)	0.638

Il caso *teapot* è degenerare ma istruttivo: quando il genus estratto coincide esattamente con la testa lessicale del target, il numero di candidati collassa a 1 (lo stesso *teapot.n.01*), e la predizione è ovviamente corretta – non per merito del ranking, ma perché il retrieval ha già risolto il problema. Il caso *tree* mostra invece un fallimento di *ranking* genuino: con genus “tree” e 300 candidati (il cap viene raggiunto anche qui, segno che pure “tree” come genus produce un ventaglio molto ampio di iponimi), SBERT preferisce *sissoo.n.01* (un iponimo specifico di *tree*, un tipo di albero indiano) al target generico *tree.n.01* – probabilmente perché la definizione dello studente conteneva dettagli specifici (dimensioni, forma) che si allineano lessicalmente meglio con la gloss di una specie particolare che con quella, più astratta, del genere.

3.5 Verifica di robustezza rispetto alla contaminazione del dataset

Come nel Lab 1, 5/28 risposte per concetto hanno le colonne astratto/concreto scambiate (Sez. 2.2 della Relazione Lab 1). Ricalcolando l'accuratezza escludendo queste 22 righe contaminate (23 definizioni invece di 28 per concetto):

Tabella 4: Accuratezza con e senza le risposte contaminate

Concetto	Acc. (28 def.)	Acc. (23 def., pulito)	Variazione
Ethics	1/28 (3.57%)	1/23 (4.35%)	+0.78 p.p.
Music	0/28 (0.00%)	0/23 (0.00%)	0
Tree	0/28 (0.00%)	0/23 (0.00%)	0
Teapot	1/28 (3.57%)	1/23 (4.35%)	+0.78 p.p.

Nessuna delle 22 righe contaminate è mai stata classificata correttamente (verificato esplicitamente incrociando gli ID delle risposte contaminate con `is_correct`): la variazione dell'accuratezza rimuovendole è minima (al più +0.78 punti percentuali) e non altera il quadro complessivo. Questo è atteso: una definizione di *Teapot* inserita per errore nella colonna *Ethics* ha un genus (*container*) strutturalmente lontanissimo dal target `ethic.n.01`, quindi la sua classificazione come “errata” è corretta indipendentemente dalla qualità del metodo – non un artefatto della contaminazione, ma un caso strutturalmente non recuperabile.

4 Discussione

Confronto con l'approccio precedente (glosse pre-selezionate). Una versione precedente di questo laboratorio confrontava ciascuna definizione con 5 glosse candidate scelte a mano (incluso sempre il target) tramite TF-IDF, ottenendo accuratezze artificialmente alte (32–89%): con soli 5 candidati pre-filtrati il problema di retrieval è già risolto in partenza, e resta solo il ranking – il compito diventa incomparabilmente più facile della vera ricerca onomasiologica non vincolata. L'accuratezza dell'1.79% ottenuta qui non è quindi un peggioramento del metodo, ma la misura *onesta* di un compito molto più difficile: cercare in tutto WordNet raggiungibile da un genus estratto automaticamente, senza sapere a priori quale sia il synset giusto. La coverage al 3.57% è il numero che rende esplicito quanto più difficile: un sistema “fortunato” che indovinasse sempre nei 4 casi raggiungibili otterrebbe comunque solo il 3.57% di accuratezza massima teorica con questa configurazione di genus-extraction e profondità.

Il ranking non è il problema. Il fatto che l'accuratezza condizionata alla raggiungibilità sia del 50% (2/4), e che lo score medio separi nettamente corretti (0.628) da errati (0.452), mostra che SBERT applicato alle glosse funziona ragionevolmente: il collo di bottiglia è strutturalmente a monte, nell'estrazione del genus e nella profondità/ampiezza della ricerca tassonomica che ne deriva, non nella qualità della misura di similarità semantica.

Limiti residui e possibili estensioni. Il vincolo di profondità 3 e il cap di 300 sono scelte di trade-off computazionale, esplorate esplicitamente sopra come causa diretta di due dei tre fallimenti di coverage (teapot, tree). Un cap adattivo (es. proporzionale al numero di sensi del genus) o un ordinamento per rilevanza semantica anziché l'ordine restituito da NLTK (che sembra riflettere un ordinamento interno del database WordNet, non una priorità semantica) probabilmente migliorerebbero la coverage senza dover rinunciare al limite di profondità. Un'estensione naturale sarebbe estrarre *più di un* candidato genus per definizione (es. sia la testa nominale immediatamente dopo la copula sia il primo sostantivo della frase, quando diversi) e unire i rispettivi insiemi di candidati.

5 Conclusioni

Il Lab 2 mostra empiricamente che la ricerca onomasiologica automatica basata su genus-extraction + iponimi WordNet, applicata senza vincoli artificiali sul numero di candidati (a differenza di una selezione manuale di poche glosse), è un compito genuinamente difficile: accuratezza globale 1.79%, ma soprattutto **coverage** 3.57% – il target è presente fra i candidati generati automaticamente solo in 4 casi su 112. La scomposizione in coverage e accuratezza condizionata (50% quando il target è raggiungibile) è il contributo metodologico principale: isola il problema di *retrieval* (trovare i candidati giusti) da quello di *ranking* (scegliere fra i candidati trovati), mostrando che il secondo – la similarità SBERT fra definizione e glosse – funziona meglio di quanto l'accuratezza aggregata suggerisca. I tre meccanismi concreti identificati (genus troppo generico per *teapot*, genus polisemico che affoga il target nel cap per *tree*, genus tassonomicamente distante per *ethics*) spiegano interamente i fallimenti di coverage osservati, e sono verificabili direttamente interrogando WordNet – non ipotesi qualitative ma fatti computabili.