

**Università degli Studi di Torino**  
Corso di Laurea Magistrale in Informatica

---

## **Tecnologie del Linguaggio Naturale**

Parte 3 – Prof. Luigi Di Caro

---

### **Lab 3**

#### **Complessità Polisemica Cross-Linguistica**

Confronto della polisemia tra Inglese, Italiano e Spagnolo tramite Open Multilingual WordNet

#### **Gruppo di lavoro:**

| <b>Studente</b>    | <b>Matricola</b> |
|--------------------|------------------|
| Alessandro Olivero | 915069           |
| Samuele Iudice     | 1235245          |
| Andrea Franco      | 1226739          |

**Docente:** Prof. Luigi Di Caro

**Anno Accademico:** 2025/2026

# Indice

|          |                                                                                                     |           |
|----------|-----------------------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduzione</b>                                                                                 | <b>2</b>  |
| <b>2</b> | <b>Background Teorico</b>                                                                           | <b>2</b>  |
| 2.1      | Le tre dimensioni della polisemia . . . . .                                                         | 2         |
| 2.2      | Entropia reale (SemCor) per l'inglese, distribuzione uniforme per IT/ES . .                         | 2         |
| 2.3      | Open Multilingual WordNet (OMW) . . . . .                                                           | 3         |
| <b>3</b> | <b>Metodologia</b>                                                                                  | <b>3</b>  |
| 3.1      | Selezione dei lemmi . . . . .                                                                       | 3         |
| 3.2      | Calcolo delle metriche . . . . .                                                                    | 4         |
| 3.3      | Misura dell'asimmetria cross-linguistica . . . . .                                                  | 5         |
| <b>4</b> | <b>Risultati</b>                                                                                    | <b>5</b>  |
| 4.1      | Statistiche descrittive per lingua . . . . .                                                        | 5         |
| 4.2      | Heatmap: numero di sensi per lemma e lingua . . . . .                                               | 6         |
| 4.3      | Entropia polisemica per lemma e lingua . . . . .                                                    | 7         |
| 4.4      | Asimmetria EN vs. lingue romanze . . . . .                                                          | 7         |
| 4.5      | Distribuzione per lingua e categoria grammaticale . . . . .                                         | 8         |
| 4.6      | Rapporti di polisemia . . . . .                                                                     | 9         |
| <b>5</b> | <b>Discussione</b>                                                                                  | <b>9</b>  |
| 5.1      | L'entropia reale rivela ambiguità d'uso che il conteggio dei sensi nasconde .                       | 9         |
| 5.2      | La gerarchia EN $\gg$ ES > IT non è (solo) linguistica . . . . .                                    | 10        |
| 5.3      | Il caso <i>bank</i> : asimmetria semantica, non solo quantitativa . . . . .                         | 10        |
| 5.4      | Verbi vs sostantivi concreti: la categoria grammaticale spiega parte dell'a-<br>simmetria . . . . . | 11        |
| 5.5      | I lemmi più stabili cross-linguisticamente . . . . .                                                | 11        |
| 5.6      | Implicazioni per il NLP multilingue . . . . .                                                       | 12        |
| <b>6</b> | <b>Conclusioni</b>                                                                                  | <b>12</b> |

# 1 Introduzione

Questo laboratorio affronta il **Progetto 3: Confronto cross-linguistico** proposto nelle dispense del corso (Capitolo 4, “Polisemia: complessità, struttura e variazioni multilingue”). L’obiettivo è verificare empiricamente una delle tesi centrali del capitolo: *la polisemia non è una proprietà universale della parola, ma del modo in cui una lingua organizza il proprio lessico*. Non esiste cioè una “polisemia assoluta” indipendente dalla lingua – la stessa area concettuale può essere lessicalizzata in modo completamente diverso da una lingua all’altra.

Per verificarlo, si confronta la complessità polisemica di **20 lemmi** (8 sostantivi, 6 verbi, 6 aggettivi) tradotti in **tre lingue** – inglese, italiano e spagnolo – usando l’Open Multilingual WordNet (OMW) tramite NLTK. Per ciascuna lingua si misura il numero di sensi (synset) e si calcola l’entropia di Shannon della loro distribuzione, per poi confrontare i risultati e individuare i lemmi con **asimmetria cross-linguistica** più marcata.

## 2 Background Teorico

### 2.1 Le tre dimensioni della polisemia

Seguendo l’impostazione delle dispense, la complessità polisemica di una parola non si riduce al solo conteggio dei sensi, ma si articola su tre dimensioni:

- **Numero di sensi**  $N(w) = |\{s_1, \dots, s_n\}|$ : la misura più intuitiva, ma insufficiente da sola.
- **Distribuzione dei sensi**, misurata tramite l’**entropia di Shannon**:

$$H(w) = - \sum_i p(s_i | w) \log_2 p(s_i | w)$$

Entropia bassa indica un senso dominante; entropia alta indica sensi più equamente distribuiti (maggiore complessità percepita).

- **Separabilità semantica**: quanto i sensi sono concettualmente distanti tra loro (non misurata in questo laboratorio, che si concentra sulle prime due dimensioni a livello cross-linguistico).

### 2.2 Entropia reale (SemCor) per l’inglese, distribuzione uniforme per IT/ES

Per l’inglese, WordNet fornisce statistiche d’uso reali attraverso **SemCor**, un corpus (352 testi del Brown Corpus) annotato manualmente col synset corretto per ogni occorrenza: il campo `Lemma.count()` di NLTK restituisce, per ciascun lemma appartenente a un synset, il numero di occorrenze osservate in SemCor con quel senso. Sommando i conteggi dei lemmi che matchano la forma target per ciascun synset candidato si ottiene una stima diretta di  $p(s_i | w)$ :

$$p(s_i | w) = \frac{\text{count}(s_i, w)}{\sum_j \text{count}(s_j, w)}, \quad H(w) = - \sum_{i=1}^n p(s_i | w) \log_2 p(s_i | w)$$

Questa è un’entropia *genuina*, che riflette quanto l’uso reale della parola sia concentrato su pochi sensi dominanti o distribuito su molti sensi in modo comparabile – un’informazione non deducibile dal solo conteggio  $n$  dei sensi disponibili.

L’Open Multilingual WordNet, al contrario, **non fornisce frequenze d’uso** per italiano e spagnolo: restituisce solo l’insieme dei synset collegati a un lemma, senza indicazione di quale sia più comune. Per queste due lingue si ricade quindi, per necessità, su una **distribuzione uniforme** sui sensi disponibili:

$$p(s_i | w) = \frac{1}{n} \quad \forall i, \quad H_{\text{unif}}(w) = - \sum_{i=1}^n \frac{1}{n} \log_2 \frac{1}{n} = \log_2 n.$$

Per IT/ES, dunque, l’entropia resta una funzione puramente monotona di  $n$  e non aggiunge informazione indipendente dal conteggio dei sensi; per l’inglese, invece, l’entropia reale può discostarsi anche molto da  $\log_2 n$ , ed è proprio questo scarto – misurato esplicitamente in Sezione 5.1 – a rivelare se un lemma è genuinamente ambiguo in uso o soltanto ricco di sensi sulla carta. Nei dati esportati, il metodo effettivamente usato per ciascuna riga è tracciato nella colonna `metodo_entropia` (`real_semcor` per l’inglese, `uniform_fallback` per IT/ES), così da non confondere le due fonti quando si confrontano i valori fra lingue.

## 2.3 Open Multilingual WordNet (OMW)

L’OMW (Bond & Foster, 2013) collega i synset di Princeton WordNet (inglese) a risorse lessicali multilingue, permettendo di interrogare `wordnet.synsets(lemma, lang='ita')` per ottenere i synset associati a un lemma italiano o spagnolo. È la stessa risorsa citata nelle dispense per gli “aspetti correlati alla ricerca onomasiologica” e per gli studi cross-linguistici sulla polisemia.

# 3 Metodologia

## 3.1 Selezione dei lemmi

Sono stati selezionati 20 lemmi inglesi con traduzione italiana e spagnola, scelti per includere casi di polisemia notoriamente elevata in inglese (*bank, run, break, head, line*) insieme a casi più contenuti, bilanciando tre categorie grammaticali. La categoria grammaticale non è solo un’etichetta descrittiva: viene passata come filtro esplicito (`pos=` in `wn.synsets`) a ogni query, per evitare di confrontare, per uno stesso lemma, i sensi di categorie grammaticali diverse fra una lingua e l’altra (senza il filtro, per esempio, i sensi nome+verbo+aggettivo dell’inglese *light* verrebbero confrontati con il solo senso aggettivale disponibile per l’italiano *leggero* in OMW, gonfiando artificialmente l’asimmetria misurata).

Tabella 1: Categorie grammaticali dei 20 lemmi

| Categoria  | N. lemmi | Esempi                                          |
|------------|----------|-------------------------------------------------|
| Sostantivo | 8        | bank, hand, head, line, key, table, mouth, foot |
| Verbo      | 6        | run, give, take, see, break, turn               |
| Aggettivo  | 6        | light, hard, free, right, open, deep            |

## 3.2 Calcolo delle metriche

*Estrazione dei synset (con filtro POS) e calcolo di entropia*

```
1 POS_MAP = {'sostantivo': wn.NOUN, 'verbo': wn.VERB, 'aggettivo': wn.ADJ}
2
3 def english_sense_counts(lemma_en, synsets):
4     """Conteggi SemCor per ciascun synset, sommando i lemmi che matchano."""
5     target = lemma_en.lower().replace(" ", "_")
6     return [sum(l.count() for l in syn.lemmas()
7               if l.name().lower() == target) for syn in synsets]
8
9 def calcola_metriche(synsets, lemma, lang_code):
10     n = len(synsets)
11     if n == 0:
12         # buco di copertura OMW
13         return {'n_sensi': 0, 'entropia': np.nan, 'top1_share': np.nan,
14               'metodo_entropia': 'no_senses'}
15     if n == 1:
16         return {'n_sensi': 1, 'entropia': 0.0, 'top1_share': 1.0,
17               'metodo_entropia': 'monosemous'}
18     if lang_code == 'eng':
19         # entropia reale da SemCor
20         counts = np.array(english_sense_counts(lemma, synsets), dtype=float)
21         if counts.sum() > 0:
22             dist = counts / counts.sum()
23             return {'n_sensi': n, 'entropia': round(float(scipy_entropy(dist,
24             base=2)), 4),
25                   'top1_share': round(float(dist.max()), 4),
26                   'metodo_entropia': 'real_semcor'}
27     dist = np.ones(n) / n
28     # fallback uniforme (IT/ES)
29     return {'n_sensi': n, 'entropia': round(float(scipy_entropy(dist, base=2)),
30     4),
31           'top1_share': round(1 / n, 4), 'metodo_entropia': 'uniform_fallback'}
32
33 def costruisci_dataframe() -> pd.DataFrame:
34     righe = []
35     for lemma_en, lemma_it, lemma_es, categoria in LEMMI:
36         wn_pos = POS_MAP[categoria]
37         for lang_code, lemma in [('eng', lemma_en),
38                                   ('ita', lemma_it), ('spa', lemma_es)]:
39             synsets = wn.synsets(lemma, pos=wn_pos, lang=lang_code)
40             metriche = calcola_metriche(synsets, lemma, lang_code)
41             righe.append({'lemma_en': lemma_en, 'lemma': lemma,
42                           'lingua_code': lang_code,
43                           'categoria': categoria, **metriche})
44     return pd.DataFrame(righe)
```

Per ogni lemma e lingua si recuperano i synset con `wn.synsets(lemma, pos=..., lang=...)` (filtro di categoria grammaticale applicato in ogni query, si veda Sez. 3.1), si conta  $n$ , e si calcola l'entropia: reale da SemCor per l'inglese quando i conteggi sono disponibili, uniforme altrimenti (Sez. 2.2). Il caso  $n = 0$  (nessun senso trovato per quella lingua/categoria) è trattato separatamente e non produce un `top1_share` fittizio di 1.0, per non confondere un buco di copertura di OMW con un caso di reale monosemia ( $n = 1$ ).

### 3.3 Misura dell'asimmetria cross-linguistica

Per ogni lemma si definisce l'**asimmetria** come la differenza tra il numero massimo e minimo di sensi tra le tre lingue:

$$\text{asimmetria}(w) = \max(N_{\text{en}}, N_{\text{it}}, N_{\text{es}}) - \min(N_{\text{en}}, N_{\text{it}}, N_{\text{es}})$$

insieme ai rapporti  $N_{\text{en}}/N_{\text{it}}$  e  $N_{\text{en}}/N_{\text{es}}$ , che quantificano di quante volte l'inglese sia più (o meno) polisemico delle lingue romanze per lo stesso lemma.

## 4 Risultati

### 4.1 Statistiche descrittive per lingua

Tabella 2: Statistiche aggregate sui 20 lemmi, per lingua (dati reali, con filtro POS ed entropia SemCor per l'inglese)

| Lingua   | Media sensi | Mediana | Max | Media entropia | Metodo entropia     |
|----------|-------------|---------|-----|----------------|---------------------|
| Inglese  | 22.95       | 18.0    | 59  | 2.275 bit      | SemCor (reale)      |
| Italiano | 7.15        | 6.0     | 23  | 2.511 bit      | uniforme (fallback) |
| Spagnolo | 9.90        | 7.5     | 32  | 2.990 bit      | uniforme (fallback) |

Il dato più evidente è la **netta gerarchia** Inglese  $\gg$  Spagnolo  $>$  Italiano: in media, per lo stesso lemma, WordNet inglese registra  $3.21\times$  più sensi dell'italiano e  $2.32\times$  più sensi dello spagnolo. Nessun lemma risulta monosemico o privo di sensi in nessuna lingua ( $n \geq 2$  per tutte le 60 combinazioni lemma $\times$ lingua), confermando che i lemmi scelti sono genuinamente polisemici anche dopo il filtro di categoria grammaticale.

Un'osservazione che il solo conteggio dei sensi non potrebbe rivelare: la **media entropia inglese (2.275 bit) è più bassa** di quella italiana (2.511) e spagnola (2.990), pur avendo l'inglese quasi il triplo dei sensi medi. Questo è possibile solo perché l'entropia inglese è calcolata su frequenze reali (SemCor) mentre quella di IT/ES è per costruzione  $\log_2 n$ : l'uso reale dell'inglese è, in media, più concentrato su un senso dominante di quanto la sola numerosità dei sensi WordNet lascerebbe supporre (si veda l'analisi quantitativa in Sez. 5.1).

## 4.2 Heatmap: numero di sensi per lemma e lingua




Figura 1: Numero di sensi per ciascuno dei 20 lemmi, nelle tre lingue. I lemmi sono ordinati per numero di sensi in inglese (decrescente).

La Figura 1 rende immediatamente visibile il pattern: la colonna “Inglese” è sistematicamente la più scura (valori più alti) per quasi tutti i lemmi, con *break* (59 sensi) e *run* (41) come casi estremi. Le colonne italiana e spagnola sono molto più chiare, ma con alcune eccezioni interessanti discusse in Sez. 5.

### 4.3 Entropia polisemica per lemma e lingua




Figura 2: Entropia di Shannon (bit) per ciascun lemma, confrontata tra le tre lingue (SemCor per l'inglese, uniforme per IT/ES).

Per italiano e spagnolo, essendo l'entropia calcolata come  $\log_2 n$  sotto l'ipotesi di uniformità, il loro andamento nella Figura 2 ricalca esattamente quello dell'heatmap ma in scala logaritmica – utile per confrontare la *complessità percepita* piuttosto che il conteggio grezzo, ma senza aggiungere informazione indipendente da  $n$ . Per l'inglese, invece, le barre *non* sono una trasformazione monotona del numero di sensi: un lemma con molti sensi può avere entropia reale bassa se l'uso è concentrato (es. *head*, Sez. 5.1), rendendo il barplot inglese l'unico dei tre a portare informazione genuinamente distinta da quella della Figura 1.

### 4.4 Asimmetria EN vs. lingue romanze




Figura 3: Numero di sensi in inglese contro italiano (sinistra) e spagnolo (destra). La linea diagonale tratteggiata indica parità; i punti colorati per categoria grammaticale.



Tutti i punti in Figura 3 si trovano **sistematicamente sotto la diagonale di parità**, in entrambi i pannelli: per nessuno dei 20 lemmi l’italiano o lo spagnolo risultano più polisemici dell’inglese. La dispersione è maggiore nel pannello EN-ES che in quello EN-IT, coerentemente con la media più alta dello spagnolo (9.90 vs 7.15) osservata in Sez. 4.1.

Tabella 3: Top 5 lemmi per asimmetria cross-linguistica (max–min sensi, dati reali)

| Lemma (EN) | Inglese | Italiano | Spagnolo | Asimmetria | EN/IT |
|------------|---------|----------|----------|------------|-------|
| break      | 59      | 6        | 23       | 53         | 9.83× |
| run        | 41      | 5        | 7        | 36         | 8.20× |
| give       | 44      | 15       | 32       | 29         | 2.93× |
| take       | 42      | 23       | 16       | 26         | 1.83× |
| head       | 33      | 9        | 11       | 24         | 3.67× |

Tabella 4: Lemmi con minore asimmetria (comportamento più simile tra lingue, dati reali)

| Lemma (EN) | Inglese | Italiano | Spagnolo | Asimmetria |
|------------|---------|----------|----------|------------|
| mouth      | 8       | 7        | 6        | 2          |
| table      | 6       | 2        | 4        | 4          |
| foot       | 11      | 6        | 8        | 5          |
| hard       | 12      | 5        | 8        | 7          |
| free       | 9       | 2        | 4        | 7          |

## 4.5 Distribuzione per lingua e categoria grammaticale




Figura 4: Sinistra: distribuzione del numero di sensi per lingua. Destra: distribuzione per categoria grammaticale, confrontata tra lingue.

Il pannello sinistro di Figura 4 conferma visivamente la gerarchia  $EN \gg ES > IT$  con box ben separati e poca sovrapposizione. Il pannello destro mostra che la gerarchia si mantiene **all’interno di ogni categoria grammaticale** (sostantivi, verbi, aggettivi), suggerendo che il fenomeno non è un artefatto della scelta di una particolare classe di

parole, ma una caratteristica strutturale della differenza tra le risorse lessicali delle tre lingue in OMW.

## 4.6 Rapporti di polisemia




Figura 5: Sinistra: rapporto EN/IT ed EN/ES per ciascun lemma. Destra: confronto diretto del numero di sensi per i 8 lemmi più asimmetrici.

Il pannello sinistro di Figura 5 mostra che per il lemma *break* il rapporto EN/IT raggiunge 9.83 (59 sensi inglesi contro 6 italiani), il più alto fra i 20 lemmi; per *run* il rapporto EN/ES è 5.86 (41 contro 7). Questi valori estremi confermano quantitativamente l'intuizione qualitativa delle dispense: “la stessa area semantica può essere lessicalizzata in modi diversi” – in questo caso, l'inglese concentra un numero molto maggiore di accezioni sotto un'unica forma lessicale.

## 5 Discussione

### 5.1 L'entropia reale rivela ambiguità d'uso che il conteggio dei sensi nasconde

La disponibilità di un'entropia *reale* (da SemCor) solo per l'inglese permette un confronto diretto, sui 20 lemmi inglesi, fra l'entropia osservata e quella che si otterrebbe assumendo (come per IT/ES) una distribuzione uniforme,  $\log_2 n$ . La correlazione fra le due misure è  $r = 0.76$ : alta, ma tutt'altro che 1 – il numero di sensi e l'ambiguità d'uso reale sono quantità correlate ma distinte. Gli scarti più ampi sono istruttivi:

Tabella 5: Lemmi inglesi con maggiore scarto fra entropia reale ed entropia uniforme  $\log_2 n$

| Lemma | $n$ sensi | Entropia reale | $\log_2 n$ | Scarto   | Quota senso dominante |
|-------|-----------|----------------|------------|----------|-----------------------|
| head  | 33        | 1.10 bit       | 5.04 bit   | 3.94 bit | 82%                   |
| hand  | 14        | 0.56 bit       | 3.81 bit   | 3.24 bit | 93%                   |
| turn  | 26        | 1.63 bit       | 4.70 bit   | 3.07 bit | 74%                   |
| key   | 15        | 1.38 bit       | 3.91 bit   | 2.53 bit | 67%                   |

*Head* ha 33 sensi catalogati in WordNet, ma l’82% delle occorrenze reali in SemCor usa un unico senso dominante (verosimilmente “parte del corpo”): l’entropia reale (1.10 bit) è quasi cinque volte più bassa di quella che il solo conteggio dei sensi (5.04 bit) suggerirebbe. *Hand* è ancora più estremo: 14 sensi ma il 93% dell’uso concentrato su un solo senso. All’estremo opposto, lemmi come *take* (42 sensi, entropia reale 4.47 bit, quota del senso dominante appena 12.6%) o *break* (59 sensi, 3.98 bit, 15.8%) mostrano un’ambiguità d’uso che *corrisponde* effettivamente all’alto numero di sensi catalogati. In altre parole: un numero di sensi elevato è condizione necessaria ma non sufficiente per un’ambiguità d’uso elevata, e solo l’entropia calcolata su dati di frequenza reali può distinguere i due casi – esattamente il limite già segnalato in Sez. 2.2 a proposito di IT/ES, per cui questa distinzione resta strutturalmente invisibile.

## 5.2 La gerarchia $EN \gg ES > IT$ non è (solo) linguistica

Il risultato più robusto – la media di 22.95 sensi in inglese contro 9.90 in spagnolo e 7.15 in italiano – deve essere interpretato con cautela. Princeton WordNet (la base della parte inglese di OMW) è una risorsa costruita e raffinata per oltre 30 anni da linguisti computazionali, con una granularità dei sensi spesso molto fine (lo stesso problema della granularità discusso nelle dispense, Cap. 1: WordNet distingue sensi che un parlante non percepirebbe come distinti). Le estensioni multilingue di OMW per italiano e spagnolo sono invece mappature più recenti e meno esaustive. Una parte della differenza osservata è quindi plausibilmente dovuta a **differenze nella copertura e nella granularità delle risorse**, non solo a una reale differenza di polisemia tra le lingue – una limitazione importante da segnalare, in linea con l’invito delle dispense a non considerare il numero di sensi nel dizionario come misura definitiva (Cap. 4: “una parola può avere molti sensi nel dizionario, ma usarne abitualmente solo pochi”), un invito che l’analisi di Sez. 5.1 rende ora operativo (almeno per l’inglese) invece che puramente qualitativo.

## 5.3 Il caso *bank*: asimmetria semantica, non solo quantitativa

Il lemma *bank* (10 sensi nominali EN, entropia reale 1.32 bit, quota del senso dominante 52%; 2 IT, entropia 1.00 bit; 8 ES, entropia uniforme 3.00 bit) è istruttivo non solo per il numero ma per la **struttura** dei sensi. L’entropia reale conferma che, anche in inglese, l’uso di *bank* è dominato da un solo senso (verosimilmente l’istituto finanziario) nonostante 10 sensi catalogati. In italiano, “banca” (2 sensi) copre quasi esclusivamente lo stesso istituto finanziario: il senso “riva del fiume” è lessicalizzato in una parola completamente diversa (*riva*), non tracciata in questo studio per il lemma *bank*. In spagnolo, invece, “banco” (8 sensi) è semanticamente più carico: copre l’istituto finanziario, ma anche il mobile

(panca/banco di scuola) e il banco di sabbia/pesci – un comportamento più vicino a quello inglese, dove *bank* include già il significato geografico oltre a quello finanziario. Questo è un esempio concreto di **asimmetria cross-linguistica nella lessicalizzazione**: la stessa area concettuale viene divisa diversamente tra le tre lingue, esattamente il fenomeno teorizzato nelle dispense con l’esempio italiano “tempo” (atmosferico + cronologico) vs. l’inglese (*weather/time* separati).

## 5.4 Verbi vs sostantivi concreti: la categoria grammaticale spiega parte dell’asimmetria

Aggregando per categoria grammaticale (Tabella 6) emerge un pattern netto: i verbi inglesi hanno in media **39.33 sensi**, contro 15.88 dei sostantivi e 16.00 degli aggettivi – più del doppio. La stessa gerarchia (verbi > aggettivi  $\approx$  sostantivi) si mantiene in italiano (11.83 vs 5.88 vs 4.17) e spagnolo (17.67 vs 8.00 vs 4.67), ma con un divario assoluto molto più ampio in inglese: la differenza fra verbi e sostantivi è di 23.45 sensi in inglese, contro 5.95 in italiano e 9.67 in spagnolo.

Tabella 6: Numero medio di sensi per categoria grammaticale e lingua

| Categoria  | Inglese | Italiano | Spagnolo |
|------------|---------|----------|----------|
| Verbo      | 39.33   | 11.83    | 17.67    |
| Aggettivo  | 16.00   | 4.17     | 4.67     |
| Sostantivo | 15.88   | 5.88     | 8.00     |

I due lemmi con asimmetria più estrema sono infatti entrambi verbi: *break* (53) e *run* (36). Questo è in linea con l’osservazione delle dispense secondo cui i verbi tendono a presentare “polisemia molto elevata” in inglese (lo stesso esempio di *run* è citato esplicitamente nel Cap. 4 delle dispense). Il verbo inglese *run* si estende infatti a domini semantici molto eterogenei – corsa fisica, gestione (*run a business*), funzionamento di macchine (*the engine runs*), candidatura politica (*run for office*), liquidi che scorrono – ciascuno dei quali in italiano e spagnolo è tipicamente lessicalizzato con un verbo distinto (*correre, gestire, funzionare, candidarsi, scorrere*), motivando direttamente il basso numero di sensi rilevato per “correre”/“correr” (5 e 7 rispettivamente), che in OMW intercetta solo l’accezione di movimento fisico. Sui 5 lemmi a maggiore asimmetria (Tabella 3), 4 su 5 sono verbi (*break, run, give, take*; l’unica eccezione è il sostantivo *head*), confermando quantitativamente che la categoria grammaticale non è un dettaglio metodologico ma un fattore esplicativo di primo ordine dell’asimmetria osservata.

## 5.5 I lemmi più stabili cross-linguisticamente

All’estremo opposto, *mouth* (asimmetria 2) e *table* (asimmetria 4) mostrano il comportamento più omogeneo tra le lingue. Si tratta di due sostantivi concreti con un referente fisico ben definito (la bocca, il tavolo): coerentemente con quanto discusso a proposito dei concetti **Concrete Generic/Specific** nei laboratori 1-2, il vincolo del referente fisico limita anche la variabilità del numero di estensioni di significato disponibili, in tutte e tre le lingue. Da notare che tutti e 5 i lemmi a minore asimmetria (Tabella 4) sono sostan-

tivi o aggettivi – mai verbi – un’ulteriore conferma, in negativo, del pattern discusso in Sez. 4.5.

## 5.6 Implicazioni per il NLP multilingue

I risultati confermano in modo quantitativo le implicazioni discusse nelle dispense (Cap. 4.5.3): un sistema di **machine translation** o di **cross-lingual transfer** che assuma una corrispondenza 1:1 tra i sensi di un lemma inglese e quelli del corrispettivo italiano o spagnolo commetterebbe un errore sistematico, specialmente per verbi ad alta polisemia come *run* o *break*: un modello addestrato sulla granularità fine di WordNet inglese, se applicato senza adattamento a un dominio italiano o spagnolo, tenderà a generare ambiguità spurie o a fallire nel mappare correttamente le accezioni. L’analisi di Sez. 5.1 aggiunge una sfumatura pratica: per lemmi come *head* o *hand*, il rischio reale non è la genuina ambiguità (che l’entropia mostra essere bassa), ma l’illusione di ambiguità indotta dal solo conteggio dei sensi WordNet – un sistema che trattasse ogni senso catalogato come ugualmente probabile sovrastimerebbe sistematicamente la difficoltà di disambiguazione per questi lemmi.

## 6 Conclusioni

Il laboratorio ha verificato empiricamente, su 20 lemmi e tre lingue, la tesi delle dispense secondo cui **non esiste una polisemia universale**: il numero di sensi disponibili per lo stesso lemma varia sistematicamente tra inglese, italiano e spagnolo (rispettivamente 22.95, 7.15 e 9.90 sensi medi, con filtro di categoria grammaticale applicato in ogni query), con asimmetrie individuali fino a  $9.83\times$  (*break*, EN/IT) e  $5.86\times$  (*run*, EN/ES).

I risultati principali sono:

1. **Gerarchia sistematica EN  $\gg$  ES > IT**, confermata sia nell’aggregato sia all’interno di ogni categoria grammaticale (sostantivi, verbi, aggettivi) – ma da interpretare cum grano salis, essendo in parte attribuibile a differenze di copertura/granularità tra le risorse lessicali, non solo a una reale differenza di polisemia.
2. **L’entropia reale (SemCor) rivela ambiguità d’uso non deducibile dal conteggio dei sensi**: la correlazione fra entropia reale e  $\log_2 n$  sui 20 lemmi inglesi è  $r = 0.76$ , non 1. Lemmi come *head* (33 sensi, ma 82% di uso concentrato su un solo senso) sono formalmente polisemici ma praticamente quasi monosemici in uso; lemmi come *take* o *break* sono invece genuinamente ambigui, con l’uso distribuito su molti sensi.
3. **I verbi mostrano l’asimmetria più marcata** (media 39.33 sensi EN contro 11.83 IT e 17.67 ES), coerentemente con la tendenza dei verbi inglesi a un’estensione semantica molto ampia rispetto alle lingue romanze; 4 dei 5 lemmi più asimmetrici sono verbi.
4. **I sostantivi concreti con referente fisico stabile** (*mouth*, *table*, *foot*) mostrano la minore asimmetria cross-linguistica, suggerendo che il vincolo referenziale limiti la variabilità anche a livello multilingue.
5. **L’asimmetria non è solo quantitativa ma strutturale**: il caso *bank/banca/banco* mostra come la stessa area concettuale possa essere ripartita in modo diverso tra

parole distinte (italiano) o concentrata in un'unica forma più carica semanticamente (spagnolo, più vicino all'inglese) – e l'entropia reale conferma che, comunque la si ripartisca, l'uso resta dominato da un unico senso in tutte e tre le lingue.

Il limite principale dello studio resta l'assunzione di **distribuzione uniforme dei sensi** per italiano e spagnolo, dovuta all'assenza di dati di frequenza d'uso in OMW per queste due lingue (a differenza dell'inglese, dove tali dati esistono via SemCor e sono stati effettivamente usati in questa versione dello studio). Un'estensione naturale del lavoro sarebbe integrare stime di frequenza anche per le lingue romanze (es. da corpora annotati o da conteggi su corpora di testo generici), permettendo di verificare se il pattern osservato per l'inglese in Sez. 5.1 – sensi numerosi ma uso concentrato per alcuni lemmi – si replichi anche in italiano e spagnolo, e di distinguere lemmi con *molti sensi ma fortemente dominati da un uso comune* da lemmi con sensi realmente equiprobabili in tutte e tre le lingue, non solo in inglese.