

Università degli Studi di Torino
Corso di Laurea Magistrale in Informatica

Tecnologie del Linguaggio Naturale

Parte 3 – Prof. Luigi Di Caro

Lab 4

Topic Modeling con BERTopic

Confronto a variabile isolata: modello di embedding vs. parametri di clustering

Studente:

Alessandro Olivero – 915069

Docente: Prof. Luigi Di Caro

Anno Accademico: 2025/2026

Indice

1	Obiettivo	2
2	Architettura della Pipeline	2
3	Configurazioni Testate	2
4	Risultati Quantitativi	3
4.1	Top-10 topic per configurazione	3
5	Analisi e Discussione	4
5.1	Config 1 $\rightarrow$ 2: effetto isolato del modello di embedding	4
5.2	Config 2 $\rightarrow$ 3: effetto isolato di UMAP/HDBSCAN	5
5.3	Il costo computazionale è quasi interamente nell'embedding, non nel clustering	5
5.4	Confronto con un design non isolato (nota metodologica)	5
6	Configurazione Consigliata	5
7	Conclusioni	6

1 Obiettivo

Costruire una pipeline completa di **topic modeling non supervisionato** sul dataset `MaartenGr/arxiv_nlp` (44949 abstract di paper NLP da arXiv, senza etichette tematiche), confrontando almeno tre configurazioni che variano modello di embedding, parametri UMAP e parametri HDBSCAN. Il vincolo metodologico esplicito della consegna è di **non cambiare più parametri contemporaneamente**: ogni confronto a coppie deve isolare un solo fattore, così che l'effetto osservato sia attribuibile senza ambiguità alla sua causa.

2 Architettura della Pipeline

1. **Embedding**: ogni abstract è convertito in un vettore denso con un modello SentenceTransformer.
2. **UMAP**: riduzione dimensionale che preserva la struttura semantica locale/globale.
3. **HDBSCAN**: clustering density-based, etichetta `-1` per gli outlier.
4. **BERTopic**: estrae parole rappresentative per ciascun cluster tramite c-TF-IDF (TF-IDF contestualizzato per cluster).

3 Configurazioni Testate

Le tre configurazioni sono costruite per isolare un solo fattore alla volta rispetto alla baseline:

Tabella 1: Le tre configurazioni confrontate – un solo fattore cambia per riga

Config	Embedding	UMAP	HDBSCAN
1 – Baseline	gte-small (384d)	n_comp=5, n_neigh=15	min_cluster=50
2 – solo modello	all-MiniLM-L6-v2 (384d)	<i>invariato</i>	<i>invariato</i>
3 – solo clustering	<i>invariato</i> (MiniLM)	n_comp=10, n_neigh=30	min_cluster=150

Le tre configurazioni: un solo campo cambia fra righe consecutive

```
1 configurations = [  
2     {"nome": "Config_1_baseline", "embedding_model": "thenlper/gte-small",  
3       "umap_params": {"n_components": 5, "n_neighbors": 15, "min_dist": 0.0,  
4         "metric": "cosine", "random_state": 42},  
5       "hdbscan_params": {"min_cluster_size": 50, "metric": "euclidean",  
6         "cluster_selection_method": "eom"}},  
7     { # Cambia SOLO il modello embedding rispetto alla baseline  
8       "nome": "Config_2_model_only", "embedding_model": "all-MiniLM-L6-v2",  
9       "umap_params": {...}, # identico a Config_1  
10      "hdbscan_params": {...}, # identico a Config_1  
11     { # Stesso embedding di Config_2, cambia SOLO UMAP/HDBSCAN  
12       "nome": "Config_3_cluster_only", "embedding_model": "all-MiniLM-L6-v2",  
13       "umap_params": {"n_components": 10, "n_neighbors": 30, ...},  
14       "hdbscan_params": {"min_cluster_size": 150, ...}},  
15 ]
```

Gli embedding sono cachati per modello (`emb_cache`): la Config 3 riusa gli embedding MiniLM già calcolati per la Config 2 invece di ricalcolarli, e UMAP/HDBSCAN vengono fittati una sola volta ciascuno, direttamente dentro `BERTopic.fit_transform` (nessun fit standalone duplicato che raddoppierebbe inutilmente il tempo di calcolo).

4 Risultati Quantitativi

Esecuzione su CPU (nessuna GPU disponibile), 44 949 abstract:

Tabella 2: Confronto quantitativo tra le tre configurazioni (dati reali, esecuzione corrente)

Configurazione	#Topic	Outlier	Outlier%	Tempo totale
1 – Baseline (gte-small)	151	14 357	31.9%	7 417 s ($\approx$ 2h 03m)
2 – solo modello (MiniLM)	116	12 375	27.5%	513 s ($\approx$ 8m 33s)
3 – solo clustering (MiniLM)	46	15 036	33.5%	35 s

4.1 Top-10 topic per configurazione

Tabella 3: Config 1 (Baseline, gte-small) – top-10 topic per numero di documenti

ID	Count	Top parole
0	2235	speech, asr, recognition, end, acoustic
1	2166	question, qa, questions, answer
2	1603	medical, clinical, biomedical, patient
3	886	summarization, summaries, summary, abstractive
4	862	translation, nmt, machine, bleu
5	670	relation, extraction, re, relations
6	657	gender, bias, biases, debiasing
7	581	ner, entity, named, recognition
8	375	parsing, dependency, parser, parsers
9	352	law, frequency, zipf, words

Tabella 4: Config 2 (solo modello, MiniLM) – top-10 topic per numero di documenti

ID	Count	Top parole
0	2675	dialogue, dialog, response, conversational
1	2446	speech, asr, recognition, end
2	2379	translation, nmt, machine, mt
3	1803	question, answer, qa, questions
4	1614	medical, clinical, biomedical, patient
5	958	summarization, summaries, summary, abstractive
6	911	hate, offensive, speech, detection
7	838	image, visual, multimodal, images
8	719	lingual, cross, languages, multilingual
9	713	emotion, emotions, emotional, multimodal

Tabella 5: Config 3 (solo clustering più grossolano) – top-10 topic, stopwords in **grassetto**

ID	Count	Top parole
0	2689	dialogue, the , dialog, to
1	2411	speech, asr, recognition, the
2	2163	translation, machine, nmt, the
3	1746	medical, clinical, and , the
4	1637	question, answer, questions, qa
5	1426	word, embeddings, similarity, semantic
6	1327	transformer, attention, the , models
7	1165	summarization, summaries, summary, abstractive
8	966	image, visual, multimodal, images
9	859	adversarial, attacks, attack, privacy

Validazione qualitativa (Config 1, topic 0, documento più rappresentativo)

Titolo: “End-to-end model for named entity recognition from speech without paired training data”

Abstract (estratto): “Recent works showed that end-to-end neural approaches tend to become very popular for spoken language understanding (SLU). . .”

Coerente con le parole del topic (*speech, asr, recognition, end, acoustic*): il documento più rappresentativo tratta esplicitamente di riconoscimento vocale e NER, confermando che il cluster è semanticamente compatto e non un artefatto del clustering.

5 Analisi e Discussione

5.1 Config 1 → 2: effetto isolato del modello di embedding

A parità di UMAP/HDBSCAN, sostituire **gte-small** con **all-MiniLM-L6-v2** produce **35 topic in meno** (151→116, −23%), **4.4 punti percentuali in meno di outlier** (31.9%→27.5%) e un tempo totale **14.5 volte inferiore** (7 417s→513s). Poiché questo è l’*unico* parametro cambiato tra le due righe, l’attribuzione causale è diretta: su questo corpus, **gte-small** produce embedding che UMAP/HDBSCAN separano in più cluster più piccoli (più topic, più outlier), mentre MiniLM produce una geometria che il clustering density-based riassume in meno cluster più compatti – a un costo computazionale drasticamente inferiore.

Un esempio qualitativo del cambiamento di granularità: nella Config 1 il topic 0 è speech/ASR generico (2 235 documenti); nella Config 2 emerge un topic *distinto* dedicato ai sistemi dialogici (*dialogue, dialog, response, conversational*, 2 675 documenti), separato dal topic ASR (2 446 documenti). La Config 2 non è quindi solo “più veloce”: separa sfumature tematiche che la Config 1, con lo stesso numero di cluster totali ma un embedding diverso, tende a fondere.

5.2 Config 2 → 3: effetto isolato di UMAP/HDBSCAN

A parità di embedding (MiniLM), passare da `n_neighbors=15/min_cluster_size=50` a `n_neighbors=30/min_cluster_size=150` (proiezione più globale, cluster minimi più grandi) riduce i topic da 116 a **46** (−60%) e *aumenta* gli outlier di 5.9 punti (27.5%→33.5%): soglie di densità più alte lasciano fuori più punti come rumore invece di assorbirli in cluster piccoli.

La Config 3 mostra inoltre un **failure mode** riproducibile: alcuni dei topic più popolosi (*dialogue*, **the**, *dialog*, **to**; *medical*, *clinical*, **and**, **the**; *transformer*, *attention*, **the**, *models*) contengono esplicitamente stopwords tra le prime parole c-TF-IDF, assente invece in Config 1 e Config 2. Cluster troppo eterogenei diluiscono il segnale lessicale specifico del topic fino a lasciar riemergere termini ad alta frequenza globale. Il fatto che la contaminazione compaia *solo* nella Config 3, a parità di embedding con la Config 2, isola inequivocabilmente la causa nei parametri di clustering, non nel modello – questo è esattamente il valore del design a variabile isolata: senza di esso, non si potrebbe distinguere se la degradazione derivi dal modello o dal clustering.

5.3 Il costo computazionale è quasi interamente nell’embedding, non nel clustering

Il salto Config 2 (513s, include il calcolo di tutti gli embedding MiniLM per 44 949 documenti) → Config 3 (35s, cache hit sugli stessi embedding) mostra che UMAP+HDBSCAN+BERTopic da soli, su embedding già calcolati, costano circa 35 secondi anche con impostazioni più onerose (`n_neighbors=30`, cluster più grandi da esplorare); il grosso del tempo di Config 1 (7417s ≈ 2 ore) è quindi quasi certamente il calcolo degli embedding con `gte-small` su CPU, non UMAP/HDBSCAN. Questo ha un’implicazione pratica diretta: se si vogliono esplorare molte combinazioni di parametri UMAP/HDBSCAN, conviene fissare presto il modello di embedding più economico compatibile con la qualità richiesta e sfruttare la cache, piuttosto che ricalcolare embedding costosi a ogni esperimento.

5.4 Confronto con un design non isolato (nota metodologica)

Una prima versione di questo esperimento cambiava simultaneamente modello, `n_components`, `n_neighbors` e `min_cluster_size` fra Config 1 e Config 2: un miglioramento osservato (più topic, meno outlier) non era quindi attribuibile né al modello né al clustering singolarmente. Nel design corrente, isolare i due fattori rivela che producono effetti *opposti* sul numero di topic quando applicati in sequenza (il modello da solo li aumenta leggermente rispetto a un ipotetico MiniLM+HDBSCAN più fine; il clustering più grossolano da solo li riduce drasticamente): un risultato che il design confuso avrebbe potuto mascherare o invertire a seconda di quale effetto dominasse numericamente.

6 Configurazione Consigliata

La **Config 2** (MiniLM, parametri di clustering della baseline) è il miglior compromesso osservato: meno outlier della baseline (27.5% vs 31.9%), tempo di esecuzione praticabile su CPU (8m33s contro le 2 ore della Config 1), e nessuna contaminazione da stopwords nei topic. Se la priorità fosse invece un numero minore di topic più ampi (per un’esplorazione

di alto livello del corpus), la Config 3 resterebbe utilizzabile solo dopo un post-processing che rimuova le stopwords residue dalle rappresentazioni c-TF-IDF.

7 Conclusioni

Il laboratorio mostra, con un confronto a variabile isolata, come modello di embedding e parametri di clustering agiscano su assi indipendenti: il primo governa principalmente granularità e velocità (Config 1→2: -23% topic, 14.5× più veloce), il secondo governa principalmente granularità e purezza semantica dei topic (Config 2→3: -60% topic, comparsa di stopwords). Un solo parametro impostato in modo troppo aggressivo (qui, soglie HDBSCAN troppo larghe) è sufficiente a degradare la qualità dei topic in modo visibile e misurabile, anche mantenendo lo stesso modello di embedding di una configurazione che funziona bene – una conferma diretta, con numeri, del principio metodologico (variare un solo fattore alla volta) richiesto dalla consegna.