

Glossario – TLN Parte 3 (Prof. Luigi Di Caro)

Termini, nomi e definizioni chiave per ripasso rapido – Università di Torino, A.A. 2025/2026

1. Semantica Computazionale

Relazioni semantiche lessicali

- **Sinonimia** – significato uguale o molto simile. Es.: *comprare* / *acquistare*; *grande* / *enorme*.
- **Antonimia** – significato opposto. Es.: *caldo* / *freddo*; *vivo* / *morto*; *salire* / *scendere*.
- **Iponimia** – relazione “è un tipo di” (categoria più specifica → più generale). Es.: *cane* è iponimo di *animale*; *rosa* è iponimo di *fiore*.
- **Iperonimia** – l’inverso dell’iponimia (categoria più generale). Es.: *animale* è iperonimo di *cane*; *mobile* è iperonimo di *sedia*.
- **Meronimia** – relazione “è parte di”. Es.: *zampa* è meronimo di *cane*; *ruota* è meronimo di *auto*; *pagina* è meronimo di *libro*.
- **Olonimia** – l’inverso della meronimia (il tutto rispetto alla parte). Es.: *cane* è olonimo di *zampa*; *auto* è olonimo di *ruota*.
- **Polisemia** – una parola con più sensi *correlati* tra loro. Es.: *libro* = oggetto fisico oppure contenuto testuale; *testa* = parte del corpo oppure “capo/leader”.
- **Omonimia** – stessa forma (grafica/fonetica), sensi *non* correlati. Es.: *riso* (cereale) / *riso* (atto del ridere); *banco* (mobile) / *banco* (banco di pesci); ingl. *bank* (istituto finanziario) / *bank* (riva del fiume).
- **Semantica lessicale** – il significato come rete di queste relazioni tra parole, organizzate in risorse come WordNet.
- **Semantica formale** – il significato come condizioni di verità, espresso in logica (Montague).
- **Semantica distribuzionale** – il significato come distribuzione dei contesti d’uso in un corpus.
- **Ipotesi Distribuzionale** (Firth, 1957) – “you shall know a word by the company it keeps”.
- **WordNet** (Miller, 1995) – rete lessicale organizzata in *synset* (insiemi di sinonimi).
- **BabelNet** – WordNet multilingue, integrato con Wikipedia.
- **FrameNet** – organizza il lessico in *frame semantici* (es. COMMERCIAL_TRANSACTION).
- **ConceptNet** – knowledge graph di senso comune, crowd-sourced.
- **Similarità coseno** – $\text{sim}(a, b) = \cos \theta = \frac{a \cdot b}{|a||b|}$.
- **WSD** (Word Sense Disambiguation) – sceglie il senso corretto tra un inventario predefinito (es. WordNet).
- **WSI** (Word Sense Induction) – scopre i sensi automaticamente via clustering, senza inventario.
- **Granularità dei sensi** (Kilgariff, 1997) – il problema di decidere se due usi sono sensi diversi.

Spiegazione – WSD vs WSI. La differenza non è cosa fanno (entrambi assegnano un senso a una parola in contesto) ma da dove parte il sistema: la WSD presuppone

sensi già noti e catalogati (es. i 4 sensi di *bank* in WordNet) e sceglie quello giusto; la WSI non ha un elenco di partenza e scopre i sensi raggruppando i contesti simili (clustering). Il problema della granularità nasce perché non esiste un confine oggettivo tra “stesso senso, sfumatura diversa” e “senso diverso”: è una scelta lessicografica, non un fatto della lingua.

2. Definizioni, Semasiologia, Onomasiologia

- **Approccio semasiologico** – dalla forma al contenuto (dizionari tradizionali).
- **Approccio onomasiologico** – dal contenuto alla forma (dizionari analogici).
- **Genus-differentia** – definizione aristotelica: categoria generale (genus) + proprietà distintive (differentia).
- **Circularità definitoria** – ogni definizione usa altri concetti, senza un punto di arresto naturale.
- **Primitive semantiche** (Wierzbicka) – ipotetico livello ultimo, non ulteriormente definibile.
- **Valutazione intrinseca** – qualità della definizione isolata (coerenza, similarità col termine).
- **Valutazione estrinseca** – qualità misurata sul contributo a un task reale (WSD, QA, IR).
- **SimLex** – similarità lessicale (overlap/Jaccard tra parole di due definizioni).
- **SimSem** – similarità semantica (coseno tra embedding delle definizioni).

Spiegazione – perché la circolarità è inevitabile.

Ogni definizione spiega una parola con altre parole (cane → mammifero → animale → essere vivente → ...): prima o poi il percorso deve riusare parole già incontrate, altrimenti proseguirebbe all’infinito. Il problema quindi non è “come evitarla” (non si può), ma “dove fermarsi in modo utile”. Per questo si distingue valutazione intrinseca (la definizione è coerente in sé?) da estrinseca (funziona in un compito reale, es. ritrovare il synset corretto in WordNet, come nel Lab 2): la seconda è più costosa ma più informativa sulla reale utilità della definizione.

3. Privacy, Dati, Misinformation

- **User empowerment** – rendere l’utente più informato e in controllo, non sostituirne il giudizio.
- **Rilascio controllato** – generalizzare/oscurare parzialmente un contenuto per ridurre il rischio mantenendo utilità.
- **Misinformation** – contenuto non verificato o fuorviante; distinto dalla rilevanza (un documento può essere rilevante e falso).
- **Explainability** – capacità di un sistema di rendere comprensibili le proprie decisioni; condizione per la fiducia.

- **Hallucination** – generazione da parte di un LLM di contenuti plausibili ma falsi.
- **Annotazione PRE / POST** – giudizio dato prima e dopo aver visto l’output di un sistema RAG.
- **KURAMi** – progetto PRIN (UniTo/Bicocca/Statale MI) su privacy release e misinformation: conoscenza + user empowerment.

Spiegazione – perché la privacy è un problema semantico. Non basta controllare se un testo contiene un dato esplicitamente sensibile (nome, telefono): il rischio nasce anche da ciò che si può *inferire* combinando informazioni apparentemente innocue con la conoscenza del contesto (orari di lavoro, abitudini, relazioni familiari). È lo stesso principio dietro l’annotazione PRE/POST: in fase PRE l’annotatore giudica “a occhio” sul solo testo; in fase POST il sistema RAG rende esplicite inferenze che il testo permette ma che non erano state notate, spesso cambiando il giudizio finale (es. P8 nel capitolo: da “nessuna violazione” a “violazione sì”).

4. Polisemia

- **Polisemia** – una parola con più sensi correlati (es. *libro* = oggetto/contenuto).
- **Omonimia** – una parola con sensi non correlati (es. *banco* = pesce/mobile).
- **Entropia dei sensi** – $H(w) = -\sum_i p(s_i|w) \log p(s_i|w)$; bassa = un senso dominante, alta = sensi bilanciati.
- **Distanza inter-senso** – $d(s_i, s_j) = 1 - \cos(s_i, s_j)$; misura quanto due sensi sono separati nello spazio.
- **Embeddings statici** – un solo vettore per parola, indipendente dal contesto (Word2Vec, GloVe).
- **Embeddings contestuali** – un vettore diverso per ogni occorrenza (BERT, ELMo); rivelano cluster di senso.
- **Regular polysemy** (Apresjan) – estensioni di senso regolari via metafora/metonimia, non arbitrarie.

Spiegazione – l’entropia dei sensi. L’entropia $H(w)$ non misura *quanti* sensi ha una parola, ma *quanto sono bilanciati*: una parola con due sensi distribuiti 95%/5% ha entropia bassa (quasi sempre lo stesso senso, facile da indovinare anche senza contesto); una parola con due sensi 50%/50% ha entropia massima (il contesto è indispensabile). Questo spiega perché il “numero di sensi” da solo è una misura insufficiente della difficoltà di disambiguazione: contano anche la distribuzione (entropia) e la separabilità geometrica nello spazio degli embeddings, cioè quanto i cluster di senso sono lontani tra loro.

5. Basic Level

- **Basic Level** – livello di categorizzazione cognitivamente privilegiato: né troppo generico né troppo specifico (es. *cane*).
- **Roger Brown** (1958) – “How shall a thing be called?”: i parlanti convergono naturalmente sul livello base.
- **Eleanor Rosch** – Basic Level Categories: massimizzano distintività percettiva tra categorie e similarità intra-categoria.
- **Criteri di Brown** – brevità, concretezza, facilità di pronuncia, alta frequenza.

- **Basic English** (Ogden, 1930) – vocabolario ridotto a 850 parole fondamentali.
- **Age of Acquisition (AoA)** – età media in cui una parola viene appresa.
- **Concreteness** – grado di tangibilità/percepibilità sensoriale di un concetto.
- **Torrielli, Rapp, Di Caro (2023)** – studio sulla soggettività della classificazione basic/advanced.

Spiegazione – il paradosso del Basic Level. Il livello base è allo stesso tempo oggettivo (correla con misurare quantificabili come frequenza ed età di acquisizione) e soggettivo (dipende da chi giudica: un medico considera “basic” un termine tecnico come “ECG”, un non esperto no). Per questo Torrielli, Rapp e Di Caro (2023) trovano solo un accordo moderato tra annotatori (κ 0.4–0.6): non esiste un confine netto tra basic e advanced, ma un continuum influenzato da contesto, età ed expertise – da qui la proposta di modellare la basicness come punteggio continuo [0, 1] invece che come dicotomia.

6. Pre-LLM NLP

- **Text Mining** – applicazione di tecniche di data mining al testo non strutturato.
- **TF-IDF** – peso di un termine in base a frequenza nel documento e rarità nella collezione.
- **BM25** – evoluzione di TF-IDF con saturazione della frequenza; standard de facto per l’IR.
- **Naive Bayes / SVM** – classificatori statistici classici (assumono indipendenza / trovano iperpiani ottimali).
- **LDA** (Latent Dirichlet Allocation) – modello probabilistico di topic modeling su bag-of-words.
- **BERTopic** – topic modeling neurale: embeddings + UMAP + HDBSCAN + c-TF-IDF.
- **TextRank** – summarization estrattiva basata su PageRank tra frasi.
- **Stratificazione (non sostituzione)** – tecniche vecchie e nuove coesistono, ciascuna nella propria nicchia.

Spiegazione – perché “stratificazione” e non “sostituzione”. Ogni nuova epoca del NLP (simbolica → statistica → neurale → Transformer) non ha cancellato la precedente, ma le ha aggiunto un nuovo strato di capacità: Google Search usa ancora BM25 (tecnica anni ’90) come primo stadio di retrieval prima dei reranker neurali, perché è velocissimo, deterministico e poco costoso. La lezione è che ogni tecnica resta la scelta migliore nella propria “nicchia ecologica” (costo, latenza, interpretabilità) anche quando ne esistono di più potenti ma più costose e opache.

7. RAG

- **RAG** (Retrieval-Augmented Generation) – combina retrieval di documenti esterni e generazione LLM.
- **Memoria parametrica** – conoscenza implicita, compressa nei pesi del modello.
- **Memoria non-parametrica** – conoscenza esplicita in documenti esterni, aggiornabile.
- **Chunking** – suddivisione dei documenti in porzioni più piccole per il retrieval

(fisso/strutturale/semantico).

- **Dense retrieval** – retrieval basato su embeddings semantici (SBERT, DPR, ColBERT).
- **Hybrid search** – combinazione di retrieval lessicale (BM25) e semantico (embeddings).
- **Vector database / ANN** – indice per ricerca approssimata del vicino più prossimo (FAISS, HNSW).
- **Faithfulness** – quanto la risposta generata è supportata dai documenti recuperati (metrica RAGAS).

Spiegazione – perché il chunking è difficile. Non esiste una dimensione “giusta” per un chunk: se troppo piccolo (una singola frase), si perde il contesto necessario per interpretarlo correttamente; se troppo grande (una pagina intera), si introduce rumore che confonde il retrieval e può superare la finestra di contesto del LLM. Il chunking semantico prova a risolvere il problema spostando il confine solo dove il significato cambia davvero (misurando la distanza coseno tra segmenti di testo vicini), invece di tagliare a un numero fisso di token.

8. LLM, Prompting, Human-AI Interaction

- **Base model** – addestrato solo a predire il token successivo; non segue istruzioni.
- **Instruction-tuned model** – addestrato con SFT e RLHF/DPO per seguire istruzioni.
- **Chain-of-Thought (CoT)** – prompting che induce il modello a ragionare passo-passo.
- **Few-shot learning** – fornire esempi nel prompt per guidare il comportamento del modello.
- **Self-Consistency** – generare più risposte e scegliere quella più frequente.
- **Temperatura** – parametro che controlla la casualità/creatività dell’output.
- **Allucinazione** – generazione di contenuti plausibili ma falsi da parte di un LLM.
- **Goal-oriented interaction** – l’utente esprime obiettivi in linguaggio naturale, non comandi predefiniti.
- **Over-trust / under-trust** – fidarsi troppo o troppo poco degli output di un LLM.

Spiegazione – perché un LLM allucina (e perché il CoT aiuta). Un LLM non ha un meccanismo per distinguere “vero” da “falso”: genera sempre la continuazione statisticamente più probabile data la sequenza di testo

vista finora, indipendentemente dal fatto che corrisponda alla realtà. Le allucinazioni non sono quindi un bug occasionale ma una conseguenza diretta del funzionamento del modello. Per lo stesso motivo il Chain-of-Thought migliora il ragionamento: obbligando il modello a scrivere i passaggi intermedi invece di “saltare” alla risposta, riduce la probabilità che si fermi su una conclusione plausibile ma sbagliata.

9. Valutazione dell’Esame

- **Linguaggio tecnico preciso** – criterio di valutazione della parte teorica.
- **Pensiero comparativo** – capacità di confrontare approcci e valutarne i trade-off.
- **Ownership del codice** – saper spiegare e modificare al volo il proprio codice di laboratorio.

Spiegazione – cosa distingue davvero un voto alto. Non basta definire correttamente un termine (“cos’è Word2Vec”): serve saperlo confrontare con altri approcci (“quando basta Word2Vec e quando serve BERT contestuale, e perché”). Allo stesso modo in laboratorio non basta dire “ho ottenuto 15 topic”: bisogna saper argomentare quali sono coerenti, quali rumore, e cosa cambierebbe con un altro parametro. È il pensiero comparativo – non la memorizzazione – il criterio che pesa di più.

10. Conclusioni

- **Groundedness** – ancoraggio del linguaggio al mondo fisico/sociale, assente negli LLM addestrati solo su testo.
- **Alignment** – allineamento di un modello ai valori umani (tipicamente via RLHF).
- **Neuro-symbolic AI** – integrazione tra rappresentazioni simboliche esplicite e reti neurali.
- **“Il futuro è conversazione”** – l’interfaccia uomo-macchina si sposta dal codice al dialogo.

Spiegazione – perché le tensioni non si “risolvono”, si integrano. Il filo conduttore del capitolo finale è che ogni tensione (simbolico/subsimbolico, conoscenza implicita/esplicita) non si chiude scegliendo un polo, ma trovando dove ciascuno funziona meglio. La RAG è l’esempio più chiaro di integrazione neuro-simbolica: combina retrieval esplicito e verificabile con generazione neurale fluida, invece di far vincere l’uno sull’altro – lo stesso principio che spiega perché tecniche “vecchie” come BM25 (Cap. 6) convivono ancora oggi con i Transformer.