

Riassunto Veloce – TLN Parte 3 (Prof. Luigi Di Caro)

Le cose fondamentali del corso, spiegate capitolo per capitolo – Università di Torino, A.A. 2025/2026

Le idee fondamentali del corso

Il filo conduttore della Parte 3 è una domanda unica: *come si rappresenta, recupera e genera il significato?* Alcune idee tornano in quasi ogni capitolo e vale la pena tenerle a mente prima di entrare nei dettagli:

- **L'ipotesi distribuzionale** (Firth, 1957: “you shall know a word by the company it keeps”) è la base sia del vecchio TF-IDF sia dei moderni embeddings: il significato si deduce dal contesto d'uso.
- **Stratificazione, non sostituzione**: ogni nuova tecnica (statistica, neurale, Transformer) si aggiunge alle precedenti invece di cancellarle – BM25 e SVM restano in produzione per scelta, non per ignoranza.
- **Conoscenza implicita vs esplicita**: i pesi di un LLM sono impliciti, potenti ma non verificabili; una knowledge base (WordNet, un database) è esplicita, verificabile ma statica e costosa da mantenere.
- **Quasi nulla è binario**: i sensi di una parola, la basicness di un termine, la qualità di una definizione sono fenomeni *graduali*, misurati con metriche quantitative (entropia, similarità coseno) più che con categorie nette.
- **Le tensioni si integrano, non si risolvono**: simbolico/subsimbolico, retrieval/generazione, precisione/accessibilità – il caso più chiaro è la RAG, che combina retrieval esplicito e generazione neurale invece di far vincere l'uno sull'altro.

Capitolo per capitolo

1. Semantica Computazionale

Il significato di una parola si può descrivere in tre modi complementari: come **rete di relazioni** con altre parole (semantica lessicale: sinonimia, iponimia, meronimia, organizzate in risorse come WordNet); come **condizioni di verità** espresse in logica (semantica formale, adatta a frasi ma non a concetti vaghi o gradualità); o come **distribuzione dei contesti d'uso** in un corpus (semantica distribuzionale, alla base di Word2Vec e BERT). Da qui nascono due compiti pratici: la **disambiguazione** (WSD: scegliere un senso tra un inventario già noto, es. i 4 sensi di *bank* in WordNet) e l'**induzione dei sensi** (WSI: scoprirli da zero via clustering, senza inventario). Un problema che attraversa tutto il capitolo è la **granularità**: dove finisce una sfumatura di significato e comincia un senso davvero diverso? Non c'è una risposta oggettiva, solo convenzioni lessicografiche più o meno utili a seconda del task.

2. Definizioni, Semasiologia, Onomasiologia

Ogni definizione sceglie una prospettiva sul concetto: per **genere e differenza specifica** (Aristotele: “cane = mammifero della famiglia dei canidi”), per esempio, per rinvio ad altri concetti noti, o per parafrasi. Le definizioni si muovono in due direzioni: **semasiologica** (dalla parola al significato, come un dizionario classico) e **onomasiologica** (dal significato alla parola, utile per il fenomeno “ce l'ho sulla punta della lingua” e per il retrieval semantico). Un limite strutturale è la **circolarità definitoria**: ogni definizione usa altre parole, quindi non esiste un punto di arresto assoluto, solo scelte più o meno utili su dove fermarsi. Per questo si valutano le definizioni in due modi: **intrinsecamente** (è chiara e coerente in sé?) ed **estrinsecamente** (funziona in un compito concreto, come ritrovare il synset giusto in WordNet, cfr. Lab 2?).

3. Privacy, Rilascio dei Dati e Misinformation

Privacy e disinformazione sono due facce dello stesso problema informativo: cosa un utente *esponde* e a cosa è *esposto*. La privacy non riguarda solo i dati esplicitamente sensibili, ma anche ciò che si può **inferire** combinandoli con il contesto – per questo è un problema semantico, non solo tecnico. La misinformation ricorda che **rilevanza e verità sono dimensioni distinte**: un documento può rispondere bene a una query ed essere comunque falso. Il collante fra i due problemi è l'**explainability**: un sistema che segnala un rischio deve spiegare perché, altrimenti l'utente non può fidarsi né contestare la decisione (*user empowerment*). Il progetto **KURAMi** applica queste idee: nell'esperimento di annotazione PRE/RAG/POST, l'output di un sistema RAG spesso non conferma ma *amplia* il giudizio iniziale, rendendo visibili inferenze implicite nel testo che l'annotatore non aveva notato.

4. Polisemia

Una parola polisemica non è semplicemente “quella con più sensi”: la vera complessità dipende da come questi sensi si **distribuiscono** nell'uso reale (misurata con l'**entropia**: bassa se un senso domina, alta se sono bilanciati) e da quanto sono **separabili** nello spazio degli embeddings contestuali (BERT produce un vettore diverso per ogni occorrenza, rendendo visibili i cluster di senso; Word2Vec ne produce uno solo, comprimendo tutti i sensi insieme). Questa complessità **non è universale tra lingue** (l'inglese *bank* unisce due concetti che l'italiano separa in *banca/riva*), e non va vista come rumore da eliminare: le estensioni di senso seguono spesso pattern regolari come metafora e metonimia (*head* = testa/capo/cima).

5. Il Basic Level

Esiste un livello di categorizzazione che i parlanti preferiscono spontaneamente: né troppo generico (*animale*) né troppo specifico (*barboncino*), ma quello intermedio (*cane*) – più breve, concreto, frequente e cognitivamente più facile da riconoscere (Brown, 1958; Rosch, anni '70). Questo livello però **non è fisso**: dipende dal dominio (per un armiere “cane” è un termine tecnico), dall'età, dall'expertise e dalla cultura – motivo per cui gli studi sperimentali (incluso quello di Torrielli, Rapp e Di Caro, 2023) trovano solo un **accordo moderato** tra annotatori umani. È utile in molte applicazioni pratiche (semplificazione testuale, apprendimento L2, traduzione automatica) proprio perché fa da ponte naturale tra precisione tecnica e comprensibilità.

6. Pre-LLM NLP: dal Text Mining in poi

Prima degli attuali modelli linguistici il NLP è passato per quattro fasi: **simbolica** (regole scritte a mano, come ELIZA – elegante ma fragile), **statistica** (TF-IDF, BM25, Naive Bayes, SVM – impara dai dati ma resta superficiale, ignora l'ordine delle parole), **neurale pre-Transformer** (Word2Vec: il significato diventa una posizione in uno spazio geometrico) e **Transformer** (attention, BERT, GPT – unifica i task ma diventa opaco). Il punto centrale è che questa storia **non è una sequenza di sostituzioni ma una stratificazione**: Google usa ancora BM25 come primo filtro prima dei modelli neurali, non per pigrizia ma perché è veloce, deterministico ed economico – ogni tecnica resta la scelta migliore nel proprio contesto d'uso.

7. Retrieval-Augmented Generation (RAG)

Un LLM tradizionale ha solo **memoria parametrica**: tutto ciò che sa è compresso nei suoi pesi, non aggiornabile né verificabile, e quando non sa qualcosa non si ferma – genera comunque una risposta plausibile (**allucinazione**). La RAG aggiunge una **memoria non parametrica** esterna: prima recupera i documenti più rilevanti (BM25 lessicale, embedding semantici, o *hybrid search* che combina i due), poi genera la risposta basandosi su quei documenti. Un problema pratico cruciale è il **chunking**: dividere i documenti in porzioni né troppo piccole (perdono contesto) né troppo grandi (introducono rumore e superano la finestra del modello). La RAG riduce le allucinazioni ma non le elimina, e non risolve la comprensione: il modello *usa* i documenti, non li *capisce* davvero.

8. LLM, Prompting e Human-AI Interaction

Un modello **base** predice solo il token successivo; diventa capace di seguire istruzioni tramite fine-tuning supervisionato e RLHF (o DPO) – diventa cioè **instruction-tuned**. Poiché con un LLM l'interfaccia è il linguaggio stesso, il modo in cui si formula un prompt cambia molto il risultato: chiarezza, esempi (*few-shot*) e soprattutto il **Chain-of-Thought** (far scrivere i passaggi intermedi di ragionamento) migliorano l'affidabilità, perché il modello non ha nessun meccanismo per distinguere il vero dal plausibile – genera sempre la continuazione statisticamente più probabile, che è esattamente il motivo per cui allucina. Questo cambia anche il modo di interagire con un sistema: da interfacce a comandi fissi (*task-oriented*) a un dialogo aperto su obiettivi (*goal-oriented*), con benefici (accessibilità) ma anche rischi di fiducia mal calibrata (*over-trust/under-trust*) e di opacità decisionale.

9. Valutazione dell'Esame

L'esame valuta due cose in parallelo. Nella **parte teorica** non basta definire correttamente un termine: bisogna saperlo confrontare con altri approcci e collocarlo nel suo contesto storico e metodologico (perché Word2Vec fu rivoluzionario, quando basta e quando invece serve BERT contestuale). Nella **parte di laboratorio** non conta il codice recitato a memoria ma l'*ownership*: saperlo spiegare, modificarlo al volo, e soprattutto saper analizzare criticamente i risultati ottenuti, inclusi quelli inaspettati.

10. Conclusioni

Il corso si chiude mostrando che tutti i temi affrontati condividono le stesse tensioni di fondo: rappresentazione **simbolica** (esplicita, rigida) contro **subsimbolica** (potente, opaca); conoscenza **implicita** (nei pesi di un modello) contro **esplicita** (in una knowledge base, verificabile ma statica); un modello per ogni task contro un solo modello universale. Nessuna di queste tensioni si “risolve” scegliendo un polo: **si integrano**, come fa la RAG combinando retrieval simbolico e generazione neurale. Il messaggio finale è che gli LLM hanno spostato l'interfaccia uomo-macchina **dal codice alla conversazione** – un cambiamento che apre un'accessibilità senza precedenti, ma porta con sé nuove responsabilità su verità, competenza e fiducia.