

Le idee fondamentali del corso

Il filo conduttore della Parte 3 è una domanda unica: *come si rappresenta, recupera e genera il significato?* Alcune idee tornano in quasi ogni capitolo:

- **Ipotesi distribuzionale** (Firth, 1957: “you shall know a word by the company it keeps”): il significato si deduce dal contesto d’uso – base sia del vecchio TF-IDF sia dei moderni embeddings.
- **Stratificazione, non sostituzione**: ogni nuova tecnica (statistica, neurale, Transformer) si aggiunge alle precedenti invece di cancellarle – BM25 e SVM restano in produzione per scelta, non per ignoranza.
- **Conoscenza implicita vs esplicita**: i pesi di un LLM sono impliciti, potenti ma non verificabili; una knowledge base (WordNet, un database) è esplicita, verificabile ma statica e costosa da mantenere.
- **Quasi nulla è binario**: sensi di una parola, basicness, qualità di una definizione sono fenomeni *graduali*, misurati con metriche quantitative (entropia, similarità coseno) più che con categorie nette.
- **Le tensioni si integrano, non si risolvono**: simbolico/subsimbolico, retrieval/generazione – il caso più chiaro è la RAG, che combina i due invece di far vincere l’uno sull’altro.

Capitolo 1 – Semantica Computazionale

In breve. Il significato di una parola può essere descritto secondo **tre prospettive complementari** (non alternative, perché rispondono a domande diverse).

La **semantica lessicale** tratta il significato come un *inventario*: le parole sono nodi in una rete di relazioni (sinonimia, iponimia, meronimia, antonimia, polisemia – vedi il box di esempi qui sotto). La risorsa di riferimento è **WordNet** (Miller, 1995), che raggruppa le parole in *synset* (insiemi di sinonimi) collegati da relazioni semantiche, oltre 117.000 synset per l’inglese; **BabelNet** la estende a più di 500 lingue integrando Wikipedia; **VerbNet** si concentra sui ruoli tematici dei verbi; **FrameNet** organizza il lessico in *frame* (es. COMMERCIAL_TRANSACTION con ruoli buyer/seller/goods/money); **ConceptNet** raccoglie conoscenza di senso comune crowd-sourced (es. *coffee-UsedFor-staying awake*). Il problema aperto è la **granularità** (Kilgariff, 1997): WordNet distingue 10 sensi per il verbo *run*, ma la distinzione è in parte arbitraria e dipende dalle scelte dei lessicografi – non esiste un confine oggettivo tra “stesso senso, sfumatura diversa” e “senso diverso”.

La **semantica formale** tratta il significato come *condizioni di verità*, usando la logica come metalinguaggio: “Tutti i gatti sono mammiferi” diventa $\forall x(\text{Gatto}(x) \rightarrow \text{Mammifero}(x))$. Approcci principali: la semantica *model-theoretic* di Montague (1970), la *Discourse Representation Theory* di Kamp (1981, gestisce anafora e quantificazione), il lambda calculus di Church (1940). Il suo limite fondamentale è non saper rappresentare vaghezza e gradualità (“Maria è piuttosto alta”), che richiedono estensioni come la fuzzy logic.

La **semantica distribuzionale** rompe con le prime due: parte non da regole ma dai dati osservabili. Analizzando grandi corpora si costruiscono *embeddings*: **Word2Vec** (Mikolov, 2013, CBOW/Skip-gram) predice parole dai contesti; **GloVe** fattorizza matrici di co-occorrenza; **BERT/ELMo** producono *embeddings contestuali* che cambiano a seconda del contesto, risolvendo in parte il problema della polisemia. L'esempio più citato è l'analogia $\vec{king} - \vec{man} + \vec{woman} \approx \vec{queen}$: le relazioni semantiche diventano direzioni geometriche. La **similarità coseno** è la misura standard: $\text{sim}(a, b) = \cos \theta = \frac{a \cdot b}{|a||b|}$ (vicino a 1 = alta similarità, vicino a 0 = non correlate, vicino a -1 = opposizione). Il limite è l'**interpretabilità**: il significato non è più esplicito ma distribuito su centinaia di dimensioni opache.

Da qui nascono due compiti pratici distinti. La **Word Sense Disambiguation (WSD)** assume un inventario di sensi già noto (tipicamente WordNet) e cerca il senso $s^* = \arg \max_s P(s \mid w, C)$ più probabile dato il contesto C (approcci: Lesk 1986, knowledge-based; supervised con feature contestuali; neurale con embeddings contestuali). La **Word Sense Induction (WSI)** scopre i sensi da zero raggruppando i contesti in cluster (context clustering, graph-based, topic modeling/LDA, neural clustering), senza inventario predefinito – utile per domini specialistici ma più difficile da valutare (si usa il metodo delle *pseudo-word*: fondere artificialmente due parole non correlate e verificare se il sistema le riseparano correttamente).

Un filo secondario del capitolo è il **Question Answering**: non tutte le domande sono uguali (fattuali, definitorie, causali, ipotetiche – tassonomia di Li & Roth, 2002: ABBR/ENTY/DESC/HUM/LOC/NUM). I sistemi storici a pipeline modulare (Watson di IBM, oltre 100 componenti) sono stati superati dai LLM generativi, che però introducono nuove criticità – allucinazioni, assenza di grounding, bias – a cui la RAG (Cap. 7) tenta di rispondere.

Relazioni semantiche lessicali (con esempi).

- **Sinonimia** – significato uguale o molto simile. Es.: *comprare* / *acquistare*; *grande* / *enorme*.
- **Antonimia** – significato opposto. Es.: *caldo* / *freddo*; *vivo* / *morto*.
- **Iponimia** – “è un tipo di” (dal più specifico al più generale). Es.: *cane* è iponimo di *animale*.
- **Iperonimia** – l'inverso: la categoria più generale. Es.: *animale* è iperonimo di *cane*.
- **Meronimia** – “è parte di”. Es.: *zampa* è meronimo di *cane*; *ruota* di *auto*.
- **Olonimia** – l'inverso: il tutto rispetto alla parte. Es.: *cane* è olonimo di *zampa*.
- **Polisemia** – una parola con più sensi *correlati*. Es.: *libro* = oggetto fisico / contenuto testuale.
- **Omonimia** – stessa forma, sensi *non* correlati. Es.: *riso* (cereale) / *riso* (il ridere); ingl. *bank* (banca) / *bank* (riva).

Termini chiave.

- **WordNet** / **BabelNet** / **FrameNet** / **ConceptNet** – risorse lessico-semantiche (synset, frame, senso comune) di potere espressivo e scalabilità diverse.
- **Similarità coseno** – $\cos \theta = a \cdot b / (|a||b|)$, misura standard di vicinanza tra vettori.
- **WSD** – sceglie il senso corretto tra un inventario predefinito. **WSI** – scopre i sensi via clustering, senza inventario.
- **Granularità dei sensi** (Kilgariff, 1997) – il confine tra sensi è una convenzione lessicografica, non un fatto oggettivo.
- **Tassonomia di Li & Roth** – classifica le domande in ABBR, ENTY, DESC, HUM, LOC, NUM.

Capitolo 2 – Definizioni, Semasiologia, Onomasiologia

In breve. Ogni volta che definiamo una parola scegliamo alcune proprietà ed escludiamo altre: la definizione *non è mai neutra*, ma una forma di modellizzazione del significato. Esistono diverse strategie: **genus-differentia** (Aristotele: categoria generale + proprietà distintive, es. “triangolo = poligono con tre lati” – si presta bene alla formalizzazione ma non sempre basta per concetti astratti); **per esempio** (più accessibile, meno rigorosa); **per riferimento/rinvio** ad altri concetti già noti (rischia di amplificare la circolarità); **per parafrasi** o descrizione operativa (frequente in contesti educativi).

Le definizioni si muovono in due direzioni opposte. L’approccio **semasiologico** parte dalla forma per arrivare al contenuto (i dizionari tradizionali: data la parola *penna*, elenca i significati possibili). L’approccio **onomasiologico** parte dal contenuto per risalire alla forma (i dizionari analogici: data la descrizione “strumento per scrivere con inchiostro”, risale a *penna*) – rilevante per il fenomeno del *tip-of-the-tongue* e per il retrieval semantico moderno.

Un problema strutturale è la **circolarità definitoria**: ogni definizione descrive un concetto tramite altri concetti (cane → mammifero → animale → essere vivente → ...), quindi prima o poi il percorso deve riusare termini già incontrati. Non esiste una soluzione, solo la domanda se esistano “primitive semantiche” (Wierzbicka, 1996) su cui fermarsi.

La qualità di una definizione si giudica su sei criteri: chiarezza, accuratezza, specificità, completezza, adeguatezza al pubblico, disambiguazione. Si valuta in due modi: **intrinsecamente** (proprietà interne – similarità semantica, overlap lessicale, coerenza – veloce ma poco legata all’uso reale) ed **estrinsecamente** (il contributo a un task applicativo come WSD, QA o IR – più costosa ma più informativa). Nel **Lab 1** del corso, l’overlap lessicale (*SimLex*, Jaccard su parole) e semantico (*SimSem*, coseno TF-IDF) tra definizioni diverse dello stesso concetto risultano più alti e vicini tra loro per i concetti *concreti* (il referente fisico vincola il vocabolario) che per quelli *astratti*; nel **Lab 2**, risalire al synset WordNet corretto da una definizione riesce fino a 2,1 volte meglio per i concetti concreti (accuratezza 89,3% per “albero” contro 32,1% per “musica”), perché TF-IDF non cattura la sinonimia pura tipica dei concetti astratti.

Termini chiave.

- **Genus-differentia** – definizione per categoria generale + proprietà distintive.
- **Semasiologico** (forma→contenuto) vs **onomasiologico** (contenuto→forma).
- **Circolarità definitoria** – ogni definizione usa altri concetti; nessun punto di arresto oggettivo.
- **Valutazione intrinseca** (proprietà interne) vs **estrinseca** (utilità su un task reale).
- **SimLex** (Jaccard, overlap lessicale) vs **SimSem** (coseno, overlap semantico).

Capitolo 3 – Privacy, Rilascio dei Dati e Misinformation

In breve. Privacy e disinformazione sono trattate come due facce dello stesso problema: cosa un utente *espone* e a cosa è *esposto*. Il rilascio dei dati non è solo una questione tecnica (presenza/assenza di attributi identificativi): il rischio nasce anche da ciò che si può **inferire** combinando un contenuto apparentemente innocuo con il contesto e conoscenza esterna – per questo la privacy è un problema *semantico*. Le strategie di *rilascio controllato* (generalizzare, oscurare parzialmente) sostituiscono i modelli binari visibile/nascosto.

Sul fronte della misinformation, il punto chiave è che **rilevanza e veridicità sono dimensioni distinte**: un documento può rispondere bene a una query e restare comunque falso o fuorviante – servono modelli che integrino coerenza con fonti affidabili ed evidenze.

Il collante fra i due problemi è l'**explainability**: quando un sistema segnala un rischio o una falsità, l'utente deve poter capire perché, altrimenti la decisione appare arbitraria o viene accettata acriticamente – questa è la logica dello **user empowerment**: non sostituire il giudizio umano, ma renderlo più informato. Gli LLM, con le loro *hallucinations*, hanno reso il problema più urgente; la **RAG** (Cap. 7) ancora la generazione a fonti verificabili.

Il progetto **KURAMi** (PRIN, UniTo/Bicocca/Statale Milano) applica queste idee su due pilastri: rappresentazione della conoscenza (fonti, gradi di certezza) e user empowerment. Nell'esperimento di annotazione a tre fasi – **PRE** (giudizio non assistito), visione dell'output **RAG**, e **POST** (revisione) – emerge che il sistema non si limita a confermare giudizi già presi: in alcuni casi *rafforza* la confidenza (violazioni già evidenti), in altri porta a una *revisione* del giudizio, rendendo visibili inferenze implicite (relazioni familiari, routine) che l'annotatore non aveva notato in prima battuta.

Termini chiave.

- **Privacy come problema semantico** – il rischio dipende da contenuto + contesto + conoscenza esterna, non solo dal dato esplicito.
- **Misinformation** – rilevanza $\neq$ veridicità.
- **Explainability** – condizione per la fiducia, non un accessorio.
- **Hallucination** – generazione LLM di contenuti plausibili ma falsi.
- **KURAMi** – progetto su privacy release e misinformation: conoscenza + user empowerment.

Capitolo 4 – Polisemia

In breve. Il capitolo sposta l'attenzione dalla domanda “quale senso è corretto?” (WSD, Cap. 1) a una più profonda: *quanto è complesso* il sistema dei sensi di una parola? Il **numero di sensi** da solo è insufficiente: due parole con lo stesso numero di sensi possono avere complessità molto diversa a seconda di come i sensi si **distribuiscono**. Si misura con l'**entropia dei sensi** $H(w) = -\sum_i p(s_i|w) \log p(s_i|w)$: bassa se un senso domina (es. *school* = “istituzione educativa” quasi sempre), alta se i sensi sono bilanciati (es. *bank*, dove “istituto finanziario” e “riva” possono essere entrambi plausibili) – più è alta, più serve il contesto per disambiguare.

Una seconda dimensione è la **separabilità semantica**: alcuni sensi sono lontanissimi (*bass* pesce/strumento), altri formano una catena di estensioni collegate (*paper* materiale/documento/articolo). Con gli embeddings **contestuali** (BERT) ogni occorrenza genera un vettore diverso, e i sensi diventano osservabili come **cluster** nello spazio vettoriale: la **distanza inter-senso** $d(s_i, s_j) = 1 - \cos(s_i, s_j)$ quantifica quanto due cluster sono separati. Gli embeddings **statici** (Word2Vec, GloVe), al contrario, comprimono tutti i sensi in un solo vettore.

La polisemia **non è universale** tra lingue: l'inglese *bank* unisce in un'unica forma due concetti che l'italiano separa in *banca/riva* – con conseguenze dirette su machine translation e allineamento di embeddings multilingui. Infine, la polisemia **non è rumore**: le estensioni di senso seguono spesso pattern regolari (Apresjan, *regular polysemy*) come metafora e metonimia (*head* = testa/capo/cima). I corpora usati per il training spesso sotto-rappresentano le parole ad alta entropia, facendo apparire i sistemi di WSD più accurati di quanto siano davvero su casi realmente difficili.

Termini chiave.

- **Entropia dei sensi** – $H(w) = -\sum_i p(s_i|w) \log p(s_i|w)$; bassa = senso dominante, alta = sensi bilanciati.
- **Distanza inter-senso** – $d(s_i, s_j) = 1 - \cos(s_i, s_j)$; misura la separabilità geometrica dei sensi.
- **Embeddings statici** (un vettore/parola) vs **contestuali** (un vettore/occorrenza).
- **Regular polysemy** (Apresjan) – estensioni di senso regolari via metafora/metonimia.

Capitolo 5 – Il Basic Level

In breve. **Roger Brown** (1958, “How Shall a Thing be Called?”) osserva che, di fronte a un’entità del mondo reale, i parlanti convergono spontaneamente su un livello intermedio: non l’iperonimo più vago (*animale*) né l’iponimo più specifico (*barboncino*), ma il **livello base** (*cane*). I suoi criteri: brevità, concretezza, facilità di pronuncia, alta frequenza. **Eleanor Rosch** estende il lavoro dal punto di vista cognitivo: il basic level è il livello che massimizza la distintività percettiva tra categorie e la similarità intra-categoria, minimizzando lo sforzo cognitivo di categorizzazione – confermato sperimentalmente da tempi di riconoscimento più rapidi.

Il livello base si colloca a metà di una gerarchia tassonomica (da cui il nome alternativo *middle level*): Essere vivente → Animale → Mammifero → **Cane** → Bassotto → Bassotto a pelo lungo. I bambini lo acquisiscono per primo (12–24 mesi), poi espandono verso gli iperonimi (24–36 mesi) e infine differenziano i subordinati (3–5 anni); l’*over-extension* verso il basso (chiamare “cane” ogni cane) è comune, quella verso l’alto è rara.

Il basic level **non è però universale né oggettivo**: è *domain-dependent* (“cane” è basic in zoologia ma tecnico in armeria), varia con l’età, l’expertise e la cultura (lacune lessicali: il russo distingue due basic level per il blu, alcune lingue amazzoniche ne hanno uno solo per blu+verde). Lo studio di **Torrielli, Rapp e Di Caro (2023)** conferma questa soggettività: l’accordo tra annotatori umani è solo moderato (κ 0.4–0.6). Si misura con sei approcci (frequenza, *Age of Acquisition*, *concreteness*, lunghezza della parola, densità del vicinato semantico, punteggio composito) e si applica a text simplification, apprendimento L2 (livelli CEFR), machine translation (preservare il registro), WSD (i sensi basic sono più frequenti) e summarization.

Termini chiave.

- **Basic Level** – livello di categorizzazione cognitivamente privilegiato (Brown 1958, Rosch anni ’70).
- **Age of Acquisition (AoA)** – età media in cui una parola viene appresa.
- **Concreteness** – grado di tangibilità/percepibilità sensoriale di un concetto.
- **Basic English** (Ogden, 1930) – vocabolario ridotto a 850 parole fondamentali.

Capitolo 6 – Pre-LLM NLP: dal Text Mining in poi

In breve. Il capitolo racconta il NLP in **quattro atti**. *Atto I – Simbolico* (1950s–80s): se il linguaggio è governato da regole (Chomsky), si possono codificare a mano – **ELIZA** (Weizenbaum, 1966) simula uno psicoterapeuta con pattern matching, **SHRDLU** (Winograd, 1970) manipola blocchi virtuali; funzionano in domini ristretti ma sono fragili fuori da essi. *Atto II – Statistico* (1990s–2010s): con più dati e potenza di calcolo, si lascia che i modelli imparino le regole – **Hidden Markov Models** per il PoS tagging, **Naive Bayes** e **SVM** per la classificazione, **TF-IDF** e le matrici di co-occorrenza per catturare distintività e similarità; nasce il concetto di benchmark (precision/recall/F1). Il limite resta la superficialità: le bag-of-words ignorano l'ordine delle parole. *Atto III – Neurale pre-Transformer* (2010–2017): il significato diventa **geometria** – **Word2Vec** (Mikolov, 2013) mostra che semplici task di predizione contestuale fanno emergere relazioni semantiche (king–man+woman $\approx$ queen); arrivano LSTM e i primi meccanismi di attention, ma i task restano separati. *Atto IV – Transformer* (2017–oggi): “Attention is All You Need” (Vaswani, 2017) elimina la ricorrenza; BERT (2018) introduce il masked language modeling; GPT-3 (2020) mostra il *few-shot learning*; arrivano ChatGPT e GPT-4.

Il **Text Mining** applica tecniche di data mining al testo non strutturato, con cinque task ricorrenti: **clustering** (K-means, senza etichette – il problema è che non esiste un modo puramente algoritmico di dire se un clustering è “semanticamente buono”); **classificazione** (Naive Bayes, SVM – interpretabili, ancora usati dove serve accountability); **summarization** (estrattiva con TextRank/PageRank tra frasi, poi astrattiva con seq2seq/BART/T5 – più fluida ma meno fedele); **information retrieval** (da Boolean search a TF-IDF/BM25 fino al dense retrieval); **topic modeling** (**LDA**, Blei et al. 2003, bag-of-words probabilistico, richiede k fissato a priori; **BERTopic**, pipeline neurale con embeddings + UMAP + HDBSCAN + c-TF-IDF, topic più coerenti ma meno interpretabili probabilisticamente).

Il messaggio chiave è che il progresso è **stratificazione, non sostituzione**: Google Search usa ancora BM25 come primo stadio prima dei reranker neurali; molte pipeline di produzione usano SVM o TF-IDF per motivi di interpretabilità, costo e latenza, non per ignoranza. Quattro lezioni per il futuro: le assunzioni esplicite (TF-IDF, Naive Bayes) sono più trasparenti di quelle implicite (LLM); la semplicità ha un valore duraturo (TF-IDF, 1972, ancora in produzione); ogni epoca ha avuto il suo “modello universale” che poi ha mostrato limiti; il costo dei dati e del calcolo cresce a ogni generazione.

Termini chiave.

- **TF-IDF** – peso di un termine per frequenza nel documento e rarità nella collezione.
- **BM25** – evoluzione di TF-IDF con saturazione della frequenza; standard per l'IR.
- **LDA** vs **BERTopic** – topic modeling probabilistico su bag-of-words vs. pipeline neurale su embeddings.
- **Stratificazione** – tecniche vecchie e nuove coesistono, ciascuna nella propria nicchia.

Capitolo 7 – Retrieval-Augmented Generation (RAG)

In breve. Un LLM ha solo **memoria parametrica**: conoscenza implicita, compressa nei pesi, non aggiornabile né verificabile – quando non sa qualcosa non si ferma, genera comunque una risposta plausibile (**allucinazione**). La RAG introduce una **memoria non-parametrica**: documenti esterni, espliciti e aggiornabili. Il principio è: *un modello non deve sapere tutto, deve sapere come trovare ciò che non sa*.

L'**Information Retrieval** classico (**TF-IDF**, **BM25**) soffre di *vocabulary mismatch*: una query su “auto” può non trovare documenti su “automobile”. Il **dense retrieval** risolve il problema proiettando query e documenti nello stesso spazio vettoriale (**Sentence-BERT**, **DPR**, **ColBERT**, **Contriever**), con similarità coseno o dot product; la **hybrid search** combina i due: $\text{score} = \alpha \cdot \text{BM25} + (1 - \alpha) \cdot \text{sim}$.

L'architettura RAG ha cinque componenti: *document store*, *indexing* (creazione embeddings), *query processing*, *retrieval*, *generation*. Un problema pratico centrale è il **chunking**: dividere i documenti in porzioni gestibili – troppo piccole perdono contesto, troppo grandi introducono rumore e superano la finestra del modello. Si va dal *chunking fisso* (N token con overlap) a quello *strutturale* (paragrafi/sezioni) fino al *semantico* (un confine si inserisce solo dove la distanza coseno tra segmenti vicini supera una soglia). Per scalare su milioni di documenti si usano **vector database** con indici *Approximate Nearest Neighbors* (FAISS, HNSW), che riducono la ricerca da $O(n)$ a $O(\log n)$.

La valutazione distingue metriche di retrieval (**Precision@k**, **MRR**, **NDCG**) da metriche di generazione (**Faithfulness**: la risposta è supportata dai documenti? **Answer/Context Relevance**: framework come **RAGAS**). I limiti restano reali: la RAG dipende criticamente dalla qualità del retrieval (“garbage in, garbage out”), fatica nel *reasoning multi-hop* e nel gestire fonti contraddittorie – *il modello non capisce i documenti, li utilizza*.

Termini chiave.

- **Memoria parametrica** (nei pesi, implicita) vs **non-parametrica** (documenti esterni, esplicita).
- **Dense retrieval** – retrieval basato su embeddings semantici invece che su keyword esatte.
- **Chunking** – suddivisione dei documenti; problema di granularità (fisso/strutturale/semantico).
- **Faithfulness** – quanto la risposta generata è supportata dai documenti recuperati.

Capitolo 8 – LLM, Prompting e Human-AI Interaction

In breve. Un modello **base** predice solo il token successivo e non segue istruzioni; diventa **instruction-tuned** tramite *Supervised Fine-Tuning* (esempi annotati di interazioni) e *Reinforcement Learning from Human Feedback* (RLHF – o la più recente *Direct Preference Optimization*, DPO). Poiché con un LLM l'interfaccia è il linguaggio stesso, il **prompting** diventa un'abilità: chiarezza e specificità, delimitatori per separare testo e istruzioni, formato di output esplicito, e iterazione (raramente il primo tentativo è ottimale).

Le strategie avanzate sfruttano il fatto che il modello non ha un meccanismo per distinguere il vero dal plausibile – genera sempre la continuazione statisticamente più probabile. Il **Chain-of-Thought** (“ragiona passo-passo”) riduce gli errori nei task di ragionamento obbligando il modello a esplicitare i passaggi intermedi invece di saltare alla conclusione. Il **few-shot learning** fornisce esempi diretti nel prompt invece di una descrizione verbale del task. La **self-consistency** genera più risposte indipendenti e sceglie quella più frequente. Il **role prompting** (“sei un esperto di...”) migliora tono e competenza apparente. La **temperatura** controlla la casualità: bassa (0.0–0.3) per output deterministici e fattuali, alta (0.8–1.0+) per scrittura creativa.

I limiti restano strutturali: **allucinazioni** (non un bug occasionale, ma conseguenza diretta di come il modello genera testo), conoscenza *statica* al training cutoff, **bias** riflessi dai dati di training, ragionamento superficiale (pattern matching più che causalità profonda), finestra di contesto limitata (“lost in the middle”), costi computazionali ed energetici.

Sul piano dell’interazione, gli LLM spostano le interfacce da **task-oriented** (menu, comandi predefiniti: l’utente si adatta al sistema) a **goal-oriented** (obiettivi in linguaggio naturale, raffinati via dialogo: il sistema si adatta all’utente) – con nuovi pattern (co-creazione, debugging conversazionale, delega progressiva) ma anche nuove sfide: la **calibrazione della fiducia** (*over-trust*: accettare output senza verifica; *under-trust*: ignorare suggerimenti validi – gli LLM non comunicano bene la propria incertezza), l’**accountability** (chi è responsabile di un output problematico?), l’**opacità** (sistemi black-box) e il rischio di *deskilling*.

Termini chiave.

- **Base model** (completa testo) vs **instruction-tuned** (SFT + RLHF/DPO).
- **Chain-of-Thought** – ragionamento esplicito passo-passo nel prompt.
- **Temperatura** – controlla la casualità/creatività dell’output.
- **Task-oriented** (comandi fissi) vs **goal-oriented** (obiettivi in linguaggio naturale).

Capitolo 9 – Valutazione dell’Esame

In breve. Nelle parole del Prof. Di Caro: “l’obiettivo non è superare l’esame, ma diventare qualcuno che sa fare NLP”. La **parte teorica** (circa metà del voto) valuta tre criteri in ordine di importanza crescente: linguaggio tecnico preciso (“embedding” non è sinonimo generico di “rappresentazione”), chiarezza concettuale e contestuale (sapere *perché* Word2Vec fu rivoluzionario, non solo cosa sia), e **pensiero comparativo** (saper confrontare approcci e valutarne i trade-off – il criterio che distingue un esperto da un novizio). La **parte di laboratorio** (l’altra metà) richiede **ownership** del codice: saperlo navigare, spiegare, modificare al volo (“cosa succederebbe con `n_components=15` invece di 5?”), e soprattutto saper condurre un’analisi critica dei risultati, inclusi quelli inaspettati o i fallimenti – non basta dire “ho ottenuto 15 topic”, bisogna saper argomentare quali sono coerenti e perché.

Termini chiave.

- **Pensiero comparativo** – confrontare approcci diversi e valutarne i trade-off.
- **Ownership del codice** – saper spiegare e modificare al volo il proprio codice di laboratorio.

Capitolo 10 – Conclusioni: Semantica, Conoscenza e Futuro del NLP

In breve. Il capitolo finale rilegge il corso come un percorso su come rappresentare, recuperare e generare significato, individuando **temi trasversali** che attraversano tutti i capitoli precedenti sotto forma di tensioni: **simbolico** (rappresentazioni esplicite, interpretabili, rigide) contro **subsimbolico** (distribuito, potente, opaco); conoscenza **implicita** (nei pesi di un LLM) contro **esplicita** (in una knowledge base, verificabile ma statica); un modello **per ogni task** (pre-LLM) contro un solo modello **general-purpose** (LLM con prompting multiplo); nessuna metrica di valutazione perfetta (BLEU/ROUGE correlano male con la qualità percepita).

Nessuna di queste tensioni si “risolve” scegliendo un polo: **si integrano**. La RAG è l’esempio più chiaro di integrazione neuro-simbolica (retrieval esplicito + generazione neurale); allo stesso modo tecniche “vecchie” come BM25 convivono ancora oggi con i Transformer (Cap. 6). Restano sfide aperte: la **comprensione** vs il pattern matching (gli errori di un modello che non comprende sono sistematici e imprevedibili), la **groundedness** (il linguaggio umano è ancorato al mondo fisico, gli LLM sono addestrati solo su testo), la **composizionalità** (i Transformer processano sequenze, non alberi sintattici), l’assenza di memoria episodica a lungo termine, la robustezza (prompt injection, jailbreak) e l’**alignment** (RLHF allinea a quali valori, definiti da chi?).

Il messaggio finale: *“abbiamo spostato l’interfaccia human-computer dal codice alla conversazione”*. Prima degli LLM l’utente doveva tradurre le proprie intenzioni in linguaggio formale; ora è la macchina ad adattarsi, tramite dialogo – un cambiamento che abbassa le barriere d’accesso ma introduce nuove responsabilità su verità, competenza e fiducia.

Termini chiave.

- **Groundedness** – ancoraggio del linguaggio al mondo fisico/sociale, assente negli LLM addestrati solo su testo.
- **Alignment** – allineamento di un modello ai valori umani (tipicamente via RLHF).
- **Neuro-symbolic AI** – integrazione tra rappresentazioni simboliche esplicite e reti neurali.