

Riassunto – Parte 4 TIPA

NLP applicato alla sanità: dataset, modelli, bias e assistenti
conversazionali

Materiale: Barbara Di Eugenio et al. (UIC)

12 giugno 2026

Indice

1	Biomedical / Healthcare NER & Relation Extraction	4
1.1	Strumenti per l'estrazione di entità	4
1.2	UMLS – Unified Medical Language System	4
1.3	Task comuni di Relation Extraction biomedica	4
1.4	Approcci alla Relation Extraction	4
1.5	Relazioni Temporali in testo clinico	5
1.5.1	Tipi di evento (EVENT)	5
1.5.2	Espressioni temporali (TIMEX)	5
1.5.3	Tipi di relazione temporale (TLINK)	5
2	I Dati Clinici e i Loro Problemi	5
2.1	Tipi di dati biomedici	5
2.2	Task principali su testo biomedico	5
2.3	Sfide nel testo biomedico	6
2.4	Electronic Medical Records (EMR): note cliniche	6
2.5	De-identificazione: 18 identificatori HIPAA	6
2.6	Social media	6
2.7	Sfide di annotazione	7
2.8	Intercoder Agreement – Cohen's Kappa	7
2.9	Shared Tasks di riferimento	7
3	Assistenti Conversazionali in Sanità: Heart Failure	7
3.1	Panoramica	7
3.2	Motivazione e obiettivi	8
3.3	Dataset: 20 interazioni paziente-educatore	8
3.4	Tre prototipi sul contenuto di sale	8
3.5	Studio utente (within-subject): HFFood-NS vs HFFood-GPT	8
4	Intro agli Assistenti Virtuali per la Salute	8
4.1	Panoramica	9
4.2	Virtual Health Coach (NSF 1838770, 2018–2025)	9
4.3	Approcci NLU: estrazione dell'obiettivo	9
4.3.1	Approccio classico (Goal Extraction)	9

4.3.2	Neural NLU v1	9
4.3.3	Neural NLU v2 – Approccio Neuro-Simbolico [Zhou et al. LREC-COLING 24]	9
4.4	NLG: generazione della risposta	9
4.4.1	Risposte empatiche [Zhou et al. COLING 22]	9
4.4.2	Text-Unit-Text generation [Zhou et al. LREC-COLING 24]	10
4.5	Confronto con LLM	10
4.6	Valutazione con nursing students	10
4.7	Take-aways del Virtual Coach	10
5	LLM, Bias e Fairness in Sanità	10
5.1	Definizioni	10
5.2	Domande di ricerca	10
5.3	6 Benchmark su 4 Dataset	11
5.4	Tre approcci, tre LLM	11
5.5	Risultati di accuratezza	11
5.6	Metriche di Fairness	11
5.7	Risultati di Fairness	11
5.8	Conclusioni	12
6	NLP e Visualizzazione: EDA Collaborativa	12
6.1	Panoramica	12
6.2	Studio 1: impatto del CA sulla EDA collaborativa	12
6.3	Clarification Requests (CR)	12
6.4	Parte 3 – CA Clarification-Aware (Studio 2)	13
6.4.1	Pipeline CA clarification-aware	13
6.4.2	Studio 2: 38 partecipanti, 19 gruppi	13
6.5	Conclusioni	13
7	Temporal Reasoning in Clinical Narratives: T2D	13
7.1	Problema	14
7.2	Dataset: UI Health	14
7.3	Parte 1 – Predizione T2D con cue temporali a livello di visita	14
7.4	Parte 2 – Temporal Relation Extraction (TREx) da testo clinico (ACL 2025)	14
7.4.1	Definizione del task	14
7.4.2	GraphTREx – Graph-based Temporal Relation Extraction	15
7.4.3	Dataset	15
7.4.4	Risultati	15
7.4.5	Trasferimento a UI Health	15
7.5	Parte 3 – Disease Risk Prediction con Temporal Graphs	15
7.5.1	HiT-GNN (Hierarchical Temporal GNN)	15
7.5.2	ReVeAL – Reasoning with Verifier Aided Labeling	16
7.5.3	Risultati su UI Health e MIMIC-IV	16
7.6	Conclusioni e contributi chiave	16
8	Veracity Bias negli LLM	16
8.1	Panoramica	16
8.2	Due nuove forme di bias	16
8.3	Setup sperimentale	17

8.4	Risultati: Attribution Bias (razza)	17
8.5	Risultati: Attribution Bias (genere)	17
8.6	Risultati: Evaluation Bias	17
8.7	Studio aggiuntivo	17
8.8	Conclusioni	18

Biomedical / Healthcare NER & Relation Extraction

File: *biomedical_IR (1).pdf* – 30 slide

Strumenti per l'estrazione di entità

- **MetaMap (2001)**: mappa testo biomedico al Metathesaurus UMLS.
- **Apache cTAKES (2010)**: pipeline completa (sentence boundary detector, tokenizer, normalizer, POS tagger, shallow parser, NER annotator con stato e negazione). Estrae concetti clinici e li mappa a CUI (Concept Unique Identifier) in UMLS.
- **MedSpacy**: toolkit Python moderno per testo clinico.
- **LLM**: versioni varie per estrazione generica.

UMLS – Unified Medical Language System

Release 2026: 18M nomi, 3.5M concetti, 9.3M codici, 31 lingue, 195 vocabolari. Tre componenti:

- **Metathesaurus**: raggruppa sinonimi sotto un unico CUI con termine preferito. Es.: “Addison’s disease”, “Bronzed disease”, “Primary Adrenal Insufficiency” → C0001403.
- **Semantic Network**: 135 tipi semantici (es. *Disease or Syndrome*) e 54 relazioni gerarchiche e non (es. *treats*, *causes*, *isa*).
- **SPECIALIST Lexicon & Tools**: risorse lessicali per NLP clinico.

Task comuni di Relation Extraction biomedica

1. Protein–protein interaction
2. Chemical–protein interaction (dataset CHEMPROT)
3. Gene–disease relations
4. Chemical–disease relations
5. Medical problem – treatment (migliora / peggiora / causa / somministrata per / controindicata per)
6. Medical problem – test e medical problem – medical problem

Approcci alla Relation Extraction

- **Rule-based**: regole su pattern sintattici (path nel parse tree, sequenze tra entità); scarsa generalizzabilità su relazioni a lunga distanza.
- **Supervised (SVM, Naive Bayes, CRF)**: richiedono feature engineering (path nel dependency parse, tipo entità, distanza); buona generalizzabilità.
- **Deep learning (LSTM, RNN, GRU)**: migliore generalizzabilità; richiedono grandi quantità di dati annotati.

- **Distant supervision:** ricava etichette da una Knowledge Base esistente (es. entità correlate in KB → esempio positivo). Limiti: non tutte le frasi con entità correlate sono esempi positivi; richiede una KB di partenza.

Relazioni Temporali in testo clinico

Il testo clinico contiene informazioni temporali implicite ed esplicite. Le entità principali sono:

Tipi di evento (EVENT)

- **PROBLEM:** malattia, infezione (es. “knee pain”)
- **TREATMENT:** farmaco, procedura terapeutica
- **TEST:** esame diagnostico, esame di laboratorio
- **CLINICAL_DEPT:** trasferimento a reparto
- **EVIDENTIAL:** report, evidenza (es. “shows”, “reports”)
- **OCCURRENCE:** tutti gli altri eventi

Espressioni temporali (TIMEX)

DATE, TIME, DURATION, FREQUENCY.

Tipi di relazione temporale (TLINK)

BEFORE, AFTER, SIMULTANEOUS, OVERLAP, BEGUN_BY, ENDED_BY, DURING, BEFORE_OVERLAP.

Esempio: “Knee pain has increased over the last two or three weeks prior to the admission”
→ EVENT (knee pain) – TIMEX (two or three weeks) – EVENT (admission), TLINK: BEFORE.

I Dati Clinici e i Loro Problemi

File: *data-resources.pdf* – 41 slide

Tipi di dati biomedici

1. **Letteratura biomedica:** MEDLINE/PubMed (33M record), PMC.
2. **Electronic Medical Records (EMR/EHR).**
3. **Social media:** X/Twitter, forum medici, blog.

Task principali su testo biomedico

- **Gene Mention Identification:** identificare nomi di geni/proteine nel testo.
- **Gene Normalization:** collegare menzioni di geni a identificatori standard (es. FlyBase → NCBI Entrez Gene ID).

- **Chemical Disease Recognition:** identificare e normalizzare entità chimiche e malattie (da abstract PubMed).

Sfide nel testo biomedico

- **Ambiguità:** stessa sigla, significati diversi (NACT = Neoadjuvant chemotherapy / N-acetyltransferase / Na⁺-coupled citrate transporter).
- **NE molto lunghe:** “human hematopoietic progenitor cells”.
- **Costruzioni complesse:** due NE condividono lo stesso head noun (“91 and 84 kDa proteins”).
- **Inconsistenza di denominazione:** NF- κ B, NFKappaB, NF-kappa B.
- **Nested NE:** <Protein><DNA>Kappa 3</DNA> binding factor</Protein>.
- **Abbreviazioni:** TCED, IFN, TPA.
- **Ambiguità contestuale:** IL-2 può essere proteina o DNA.

Electronic Medical Records (EMR): note cliniche

Le note cliniche contengono linguaggio informale, abbreviazioni mediche, date pseudonimizzate, strutture senza frasi complete. Ulteriori sfide:

- Formattazione variabile (altezza/peso/pressione su una riga).
- Punteggiatura mancante.
- Gergo medico e abbreviazioni ad hoc: “*septic picture likely aspiration pneumonia secondary to dobhoff placement*”.
- Acronimi: “*recent tension PTX at OSH*”.
- Errori ortografici: “*definate*” (sic), “*abcess*” (sic).

Il progetto **i2b2/n2c2** ha prodotto dataset annotati per concetti, asserzioni e relazioni cliniche. Caso clinico italiano annotato per: malattia, sintomo, procedura, sito anatomico, farmaco (corpus E3C).

De-identificazione: 18 identificatori HIPAA

I record medici devono essere de-identificati (es. nomi, date, ospedali sostituiti con <XXX_Patient>, <XXX_DATE>, ecc.) prima di poter essere condivisi per la ricerca.

Social media

Sfide aggiuntive rispetto al testo clinico:

- **Contesto multiplo:** stessa parola con effetti opposti in tweet diversi (Advil cura il dolore / provoca upset stomach).
- **Forme abbreviate:** “CIT” per Citopram, slang (“*seroquel knocked me out*”), senso implicito (“*hard time getting some Zs*”).
- **Linguaggio figurato:** “*My skin is paper, razor is the pen*”.

- Conversazioni paziente-provider: dinamiche di turno, overlap, particelle, linguaggio implicito.

Sfide di annotazione

- Il supervised learning richiede corpus di grandi dimensioni.
- **Annotation bottleneck**: annotazione manuale da esperti non scalabile; crowd-sourcing manca di competenza di dominio.
- **Annotazione con LLM**: approccio emergente per ridurre il collo di bottiglia.

Intercoder Agreement – Cohen’s Kappa

Misura la concordanza tra annotatori al netto del caso.

$$\kappa = \frac{P(A) - P(E)}{1 - P(E)}$$

dove $P(A)$ = accordo osservato, $P(E)$ = accordo atteso per caso.

Esempio: 2 annotatori classificano 150 occorrenze di “Sì” in Accept / Ack.

- $P(A) = 125/150 = 83.3\%$
- $P(E) = (95/150)(70/150) + (55/150)(80/150) = 0.491$
- $\kappa = (0.833 - 0.491)/(1 - 0.491) = 0.67$

Interpretazione (Landis & Koch 1977 / Krippendorff 1980):

κ	Giudizio (L&K)	κ	Giudizio (K)
< 0.20	Poor	< 0.67	Bad
0.20–0.40	Fair	0.67–0.80	Tentative
0.40–0.60	Moderate	≥ 0.80	Definite
0.60–0.80	Substantial		
> 0.80	Almost perfect		

Shared Tasks di riferimento

BioCreative, National NLP Clinical Challenges (n2c2), BioNLP Workshop, ClinicalNLP Workshop, Text Retrieval Conference (TREC).

Assistenti Conversazionali in Sanità: Heart Failure

File: heart-failure-ca.pdf – 24 slide

Panoramica

Barbara Di Eugenio (University of Illinois Chicago). Progetto **HFChat** (NSF 2232307, 2022–2025): agente conversazionale per l’educazione di pazienti afroamericani con insufficienza cardiaca (HF).

Motivazione e obiettivi

Ipotesi: pazienti AA con accesso a informazioni culturalmente competenti faranno scelte di self-care più consapevoli. Obiettivi: scoprire preoccupazioni dei pazienti, esplorare approcci neuro-simbolici, valutare LLM. Sfida: nessun metodo formalizzato per modellare la competenza culturale.

Dataset: 20 interazioni paziente–educatore

Contenuto HF standard: definizione HF, farmaci (diuretici, “water pill”), dieta a basso sodio, attività fisica, sintomi, follow-up.

	Turni	Frase	Parole
Paziente (48%)	108	131	850
Educatore (52%)	117	205	2280

Tre prototipi sul contenuto di sale

1. **HFChat** (Google DialogFlow): solo 32% delle domande risposto correttamente. Pilota con 9 pazienti.
2. **HFFood-NS** (neuro-simbolico, PPTOD/T5): dataset sintetico da 87.425 dialoghi, 525.392 turni. Slot: food, cook, type, part, food weight, metric (da USDA). Regole simboliche per recupero e calcolo del valore di sodio.
3. **HFFood-GPT** (GPT-4, “Sodium Scout”): prompt con limite di 40 parole; usa file JSON con dati USDA.

Studio utente (within-subject): HFFood-NS vs HFFood-GPT

20 pazienti AA ospedalizzati; sistemi identificati come “Lion” (NS) e “Shark” (GPT). Stessa speech recognition (OpenAI Whisper-1).

Metrica	HFFood-NS	HFFood-GPT
Task completion	84%	62%
Salt value accuracy	37%	24%
Slot accuracy	56%	89%
SMOG [grado] ↓	7.05	10.58
FKGL [grado] ↓	2.71	7.10
FKRE [facilità] ↑	91.21	71.79

Il target sanitario è il 6° grado (scuola media inferiore). **NS vince** su completamento, accuratezza sodio e leggibilità. GPT vince su slot accuracy ma risponde in media 51 parole (prompt: max 40), ed è pedante su unità di misura errate. Nessuna preferenza utente significativa al questionario.

Intro agli Assistenti Virtuali per la Salute

File: *intro-virtual-coach.pdf* – 39 slide

Panoramica

Due sistemi: **Virtual Health Coach** (SMART goals via SMS) e **HFChat** (educazione HF). Sfide generali: dati scarsi/non condivisibili, modelli devono essere esplicabili, equi, non biased; LLM con allucinazioni, opacità; valutazione senza SOTA da battere.

Virtual Health Coach (NSF 1838770, 2018–2025)

Obiettivo: motivare a uno stile di vita attivo tramite obiettivi **SMART** (Specific, Measurable, Attainable, Realistic, Time-bound) via SMS. Es.: “*I will walk on my lunch break for 20 mins Wed and Thurs this week.*”

Dataset:

	Dataset 1	Dataset 2
Health coaches	1	3
Pazienti	30	28
Durata	4 settimane	8 settimane
Messaggi totali	2853	4134

Fasi del dialogo: **Goal Identification** → **Goal Refining** → **Anticipate Barrier**. Annotazione a tre livelli; 10 attributi SMART da estrarre (attività, luogo, giorni, orario, ...).

Approcci NLU: estrazione dell’obiettivo

Approccio classico (Goal Extraction)

Joint Goal Accuracy (tutti e 10 gli attributi corretti): **20%** [Gupta et al. SigDIAL 20–21]. Nessuna generazione di risposta.

Neural NLU v1

Architettura neurale per riassumere l’obiettivo e generare risposta [Zhou et al. COLING 22].

Joint Goal Accuracy: **21.7%**.

Neural NLU v2 – Approccio Neuro-Simbolico [Zhou et al. LREC-COLING 24]

Workflow end-to-end:

1. **Neurale**: genera un’istruzione eseguibile (es. **Copy{Days}**) ed estrae un obiettivo parziale (es. “Walk 2,500 steps”).
2. **Simbolico**: edita l’obiettivo parziale sulla base dell’obiettivo precedente e dell’istruzione.

Joint Goal Accuracy: **52.8%** – miglioramento netto rispetto ai precedenti.

NLG: generazione della risposta

Risposte empatiche [Zhou et al. COLING 22]

Basate su tre meccanismi di comunicazione (Sharma et al. 2020):

- **EMOR** (Emotional Reactions): “*I would be very worried*”
- **INTER** (Interpretations): “*I know anxiety is scary*”
- **EXPL** (Explorations): “*What happened? How come?*”

Classificatore BERT per rilevamento emozione nel turno del paziente; GPT-2 fine-tunato per generare risposte empatiche con token di meccanismo [EMOR].

Text-Unit-Text generation [Zhou et al. LREC-COLING 24]

Generazione di risposta attraverso una rappresentazione intermedia strutturata.

Confronto con LLM

GPT-3.5-turbo (two-shot ICL): qualitativamente le risposte risultano incomplete o incoerenti rispetto all’approccio neuro-simbolico.

Valutazione con nursing students

45 studenti di infermieristica valutano 900 item totali (~20/studente): risposta *senza modifiche* / *con modifiche minori* / *con modifiche maggiori e irrilevante* / *dannosa* / *incoerente*. Risultato: nessuna risposta dannosa o incoerente.

Take-aways del Virtual Coach

- Dataset raccolto e parzialmente condivisibile.
- Approccio neuro-simbolico con le prestazioni più alte.
- LLM (GPT-3.5) qualitativamente inferiori.
- Valutazione con studio utente su studenti infermieristica.

LLM, Bias e Fairness in Sanità

File: llm-fairness-healthcare_coling25.pdf – 23 slide (COLING 2025)

Definizioni

- **Bias**: inclinazione o pregiudizio verso o contro una persona/gruppo in modo considerato ingiusto (Oxford Languages).
- **Fairness**: trattamento imparziale e giusto senza favoritismi o discriminazioni.

Domande di ricerca

Gli LLM saranno efficaci in sanità come in altri domini? Aiuteranno a ridurre le disparità sanitarie?

6 Benchmark su 4 Dataset

1. Medical QA (MedQA – US Medical Licensing Exam)
2. Predizione raggiungimento obiettivi (Health Coaching)
3. Predizione mortalità a 1 anno (MIMIC-IV)
4. Predizione riammissione a 90 giorni (MIMIC-IV)
5. Predizione Schizofrenia/Bipolare/Sano – “Meeting New Neighbor”
6. Predizione Schizofrenia/Bipolare/Sano – “Complaining to a Landlord”

Tre approcci, tre LLM

- **ICL con Chain-of-Thought:** GPT-4, Claude-3 Sonnet, LLaMA-3 8b.
- **PEFT (LoRA):** LLaMA-3 8b.
- **LLM as Agents (ReAct + Reflexion + conoscenza esterna):** GPT-4.

Risultati di accuratezza

Prestazioni eterogenee: alcuni modelli superano di poco il random. L’approccio agente funziona per MedQA (86.9% GPT-4) ma fallisce sui casi reali. Il framework migliore varia per task. Close-source > open-source in generale.

Metriche di Fairness

- **DPD (Demographic Parity Difference):** $DPD = P(\hat{Y} = 1|Z = z) - P(\hat{Y} = 1|Z \neq z)$. Non considera la ground truth.
- **EOD (Equal Opportunity Difference):** $EOD = P(\hat{Y} = 1|Y = 1, Z = z) - P(\hat{Y} = 1|Y = 1, Z \neq z)$. Considera la ground truth.

Risultati di Fairness

- Disparità presenti in tutti i task; più marcate per razza che per genere.
- I pazienti **afroamericani ricevono sistematicamente previsioni meno favorevoli.**
- Fine-tuning: migliora fairness su riammissione, peggiora su mortalità e health coaching.
- GPT-4 rifiuta di predire la razza (14–28%); Claude-3 rifiuta su razza e genere; LLaMA-3 predice con stereotipi espliciti nell’appendice del paper.
- Accuracy nella predizione della razza da dialogo: GPT-4 75.3%, LLaMA-3 ~60%, Claude-3 rifiuta.

Conclusioni

LLM non performanti su task sanitari reali; disparità demografiche sostanziali. Serve: più dati sanitari con informazioni demografiche. Domanda aperta: come mitigare il bias e migliorare la fairness?

NLP e Visualizzazione: EDA Collaborativa

File: `nlp-visualization.pdf` – 58 slide (tesi Abari Bhattacharya, difesa apr. 2026)

Panoramica

Studio sull'impatto di un assistente conversazionale (CA) nell'analisi esplorativa dei dati (EDA) collaborativa. Dati COVID-19 per contee USA. Gap nei sistemi esistenti: mancanza di conversazionalità, valutazione con utenti reali, supporto alla collaborazione.

Studio 1: impatto del CA sulla EDA collaborativa

15 gruppi di 2 partecipanti, 2 task da 25 min. Due sistemi a confronto:

- **PE (Property Extractor)**: proattivo, genera grafici spontaneamente.
- **DM (Dialogue Manager)**: più lento, più spazio alla riflessione.

RQ1: PE → più utterance processate e grafici generati (soprattutto line chart COVID); DM → esplorazione più ampia di proprietà del DB.

RQ2: PE → conclusioni su casi COVID; DM → fattori come diabete e malattie cardiovascolari. L'architettura del sistema influenza le inferenze degli utenti.

RQ3: 72% trova i grafici utili; 40% facile da usare; apprendimento on-the-fly aumenta carico cognitivo in task collaborativo.

Clarification Requests (CR)

Le CR sono fondamentali nella comunicazione per negoziare il significato. **Grounded Clarification**: legata a specifico contesto/modalità percettiva.

Tre modalità di grounding:

- **Visiva** (49%): difficoltà a interpretare la visualizzazione generata.
- **Uditiva** (28%): difficoltà a recuperare informazione parlata.
- **Cinestesica** (23%): incertezza sulle capacità/procedura del sistema.

Dataset ClarVis: 29 trascritti, ~6.9K turni totali, 445 CR (6.4% dei turni); 73.5% delle CR riferita al turno precedente. $\kappa = 0.89$ per CR identification.

Baseline: DistilBERT+Prev1 per CR-ID (F1=0.66); TF-IDF+LR per modalità visiva (F1=0.73); pattern: Visivo > Cinestesico > Uditivo.

Parte 3 – CA Clarification-Aware (Studio 2)

Pipeline CA clarification-aware

Architettura a pipeline modulare (più controllabile e interpretabile):

1. Intent detection (CR / VIS / None)
2. Reference resolution
3. Visualization construction and generation
4. Clarification response generation

Backend – Intent Classification: DistilBERT + focal loss + Prev3 (addestrato su Clar-Vis). Performance: CR (75.0/73.1/74.0 P/R/F1), VIS (79.2/81.0/80.1), None (92.5/92.1/92.3). Lexicon appreso di 394 frasi CR-V.

Backend – Generazione risposte CR: GPT-4o-mini con prompt strutturato (tipo CR: spiegazione / significato elemento chart / confronto); output ancorato a dati e chart.

Studio 2: 38 partecipanti, 19 gruppi

Task: EDA collaborativa su COVID-19 (warm-up 5 min + 3 task da 15 min). Istruzioni: fare domande come domande sui dati, usare grafici come evidenza, parlare apertamente.

RQ4 – Interaction flow e task progress:

- Le CR svolgono un ruolo secondario e di supporto (VIS = uso primario).
- Pattern tipico: CR → VIS (62% dei casi dopo una CR).
- Le CR emergono a momenti di incertezza/interpretazione, non uniformemente.
- I partecipanti raggiungono conclusioni più solide nelle task principali rispetto al warm-up.

RQ5 – Perceived usefulness:

- Usefulness: da Neutro (13/38) a Positivo (18/38).
- Risposte percepite come ancorate ai dati/chart.
- Alcune difficoltà interpretative (unclear/unexpected responses): soprattutto resting (12/19 gruppi).
- Strategie utenti: task decomposition + visual feedback iterativo; preferenza per heatmap e bar chart.

Conclusioni

CA clarification-aware supporta l'EDA collaborativa combinando accessibilità + visualizzazione + supporto alle CR. L'EDA con CA è un ciclo: risposte CR → generazione chart → interazione → interpretazione → nuove domande.

Temporal Reasoning in Clinical Narratives: T2D

File: temporal-rels-t2D.pdf – 60 slide (tesi Rochana Chaturvedi)

Problema

Type 2 Diabetes (T2D): 500M malati nel mondo; diagnosi precoce fondamentale; 50% dei pazienti di pronto soccorso UIC non diagnosticati. Serve uno **screening opportunistico** automatico, specialmente per popolazioni svantaggiate.

Limiti attuali: EHR strutturato rumoroso e decontestualizzato (HbA1c mancante nel 56.8% delle osservazioni); note cliniche non analizzate automaticamente in modo da catturare il contesto temporale.

Dataset: UI Health

EHR longitudinale (gen. 2010 – lug. 2021). Dopo filtraggio: ~ 1 M note, 1717 pazienti T2D, 106K pazienti NoD. LLM usato per raffinare la data di prima diagnosi (intersezione di due prompt per ridurre falsi positivi).

Parte 1 – Predizione T2D con cue temporali a livello di visita

Architettura del modello:

- **BoCUI encoder (CNN):** bag-of-CUI per ogni visita (embedding cui2vec).
- **Visit Sequence Encoder (LSTM):** modella la sequenza temporale delle visite.
- **HbA1c time-series (GRU + Attention):** modella i valori HbA1c nel tempo.
- **Sensitive Attributes (SA):** genere, razza, etnia, fascia d'età.
- **Decoder (DNN):** classificazione T2D vs. NoD.

Risultati:

- HbA1c time-series = migliore tra i modelli strutturati.
- Concetti clinici da note migliorano le prestazioni.
- **Temporal modeling** dei concetti da le prestazioni migliori.
- Combinare strutturato + non strutturato riduce il recall sulla classe T2D.
- **Bias:** prestazioni più basse per le donne; modelli ibridi con HbA1c favoriscono solo il gruppo White.
- Interpretabilità (LRP): chronic kidney disease e disoccupazione contribuiscono positivamente alla predizione T2D.

Parte 2 – Temporal Relation Extraction (TReX) da testo clinico (ACL 2025)

Definizione del task

Estrarre entità (eventi e TIMEX) e le loro relazioni temporali (TLINK: BEFORE, AFTER, OVERLAP, ecc.) da note cliniche. Sfide: jargon, abbreviazioni, sinonimi/omonimi, dipendenze temporali implicite ($A < B, B < C \Rightarrow A < C$), documenti lunghi ($O(n^2)$ coppie).

GraphTReX – Graph-based Temporal Relation Extraction

Combina:

- **LPLM (BioMedBERT)**: rappresentazioni contestualizzate locali.
- **GNN (Heterogeneous Graph Transformer – HGT)**: ragionamento relazionale globale su dipendenze a lunga distanza.
- **Sliding windows**: gestione di documenti lunghi.
- **Landmark nodes**: Context nodes (catturano contesto tra due entità) e Window nodes (collegano entità distanti).

SpanTReX: versione senza GNN (baseline neurale).

Dataset

- **I2B2 2012**: 310 dimissioni, ~35K entità, ~61K relazioni.
- **E3C**: 84 case report clinici (italiano), ~5K entità, ~4K relazioni.

Risultati

Modello	I2B2 F1	E3C F1
Rules + ML Hybrid	63.4	–
SPERT	61.1	13.6
SpanTReX	66.6	22.6
GraphTReX	68.8	23.5

Nuovo stato dell’arte su I2B2 2012 (>5% di miglioramento end-to-end). I landmark nodes migliorano le relazioni a lunga distanza: +8.9% su coppie molto distanti ($d > 1$).

Trasferimento a UI Health

Annotazione di 9 note cliniche reali (2 pazienti): de-identificazione, estrazione entità con SpanTReX + Metamap, coreference, TLINK. GraphTReX ottiene F1=52.0% sulle TLINK (vs 38.0% di SpanTReX), con +14% di miglioramento.

Parte 3 – Disease Risk Prediction con Temporal Graphs

HiT-GNN (Hierarchical Temporal GNN)

Pipeline completa:

1. BiLSTM per codifica delle note per visita.
2. TReX (GraphTReX) per costruire grafi temporali.
3. Aggregazione dei grafi + GNN per embedding del documento.
4. FC + Sigmoid per classificazione T2D/NoD.

Framework di inference-time scaling per predizione esplicabile con LLM:

- **Large Reasoner (Llama-3.1 8B)**: genera predizione con spiegazione, 5 reasoning paths per training, 10 per test.
- **Small Verifier (Llama-3.2 1B, fine-tunato con LoRA)**: valida il ragionamento del modello grande (assegna confidence score).
- Training: hard cases (reasoner sbaglia su almeno un path); inferenza: majority vote top-k (3).

Risultati su UI Health e MIMIC-IV

Dataset	Modello	AUC	F1
UI Health	HiT-GNN	72.2% (+4% vs CLSTM)	–
UI Health	Llama-1b-ft	65.1%	–
UI Health	ReVeAL	–	65.2%
MIMIC-IV	HiT-GNN	–	T2D recall 63.3%
MIMIC-IV	Llama-1b-ft	64.4%	–

Nota: Llama-1b senza fine-tuning è il modello più debole; il fine-tuning sacrifica l’esplicabilità. ReVeAL fornisce il migliore trade-off tra performance ed esplicabilità.

Conclusioni e contributi chiave

- **SpanTREx / GraphTREx**: nuovo SOTA per TREx end-to-end su testo clinico.
- **HiT-GNN**: prima applicazione di TREx per risk detection temporale.
- **ReVeAL**: LLM scaling scalabile ed esplicabile per basse risorse.
- Nuovo corpus annotato di note cliniche reali per validare la portabilità dei modelli.
- Framework privacy-aware con bilanciamento demografico per valutazione trasparente.

Veracity Bias negli LLM

File: *veracity-bias-slides-acl25.pdf* – 16 slide (ACL 2025)

Panoramica

Yue Zhou e Barbara Di Eugenio (UIC). Due nuove forme di bias negli LLM legate alla *veridicità* delle soluzioni, senza provocazioni sociali esplicite nel prompt.

Due nuove forme di bias

1. **Attribution Bias**: il modello attribuisce soluzioni a gruppi demografici in base alla veridicità inferita – soluzioni corrette → gruppo “positivo”; errate → gruppo “negativo”.

2. **Evaluation Bias:** il modello valuta la veridicità di soluzioni *identiche* in modo diverso a seconda del gruppo demografico percepito dell'autore.

Setup sperimentale

Dataset: Math (GSM8K, MATH500), Coding (HumanEval), Commonsense (CommonsenseQA, ARC-easy), Essay (ASAP-AES, rubrica 1–6).

LLM testati: GPT-3.5-turbo, GPT-4o, Claude-3 Sonnet, Gemini-Pro-1.5, LLaMA-3-8b.

Metriche:

- **Correctness Attribution Bias** (AB^{cor}): quanto più spesso un gruppo è associato a soluzioni corrette.
- **Incorrectness Attribution Bias** (AB^{inc}): quanto più spesso a soluzioni errate.
- **Evaluation Preference** (EP): quante volte il modello favorisce un gruppo rispetto a un altro nella valutazione.

Risultati: Attribution Bias (razza)

Il gruppo **Black** è sistematicamente il meno associato a soluzioni corrette in tutti i task e modelli. Es. [Math, GPT-4o]: Asiatici associati a soluzioni corrette 14% più di errate; Neri associati a soluzioni errate 21% più di corrette.

Refusal rates: GPT-4o rifiuta su razza (14–28%); Claude-3 rifiuta su razza e genere (2% commonsense); con nomi indiretti **nessun modello rifiuta**.

Risultati: Attribution Bias (genere)

Risultati misti. GPT-4o, GPT-3.5, Gemini favoriscono il femminile; Claude-3 e LLaMA-3 il maschile.

Risultati: Evaluation Bias

Meno severo dell'attribution bias. Il gruppo **Asian** riceve mediamente i punteggi più bassi per lo stesso elaborato.

Modello	EP razziale	EP genere
GPT-4o	13.3% (Hispanic > Asian)	3.3% (F > M)
Claude-3	6.7% (Hispanic > Asian)	6.7% (F > M)
Gemini-1.5-Pro	6.7% (White > Asian)	10% (F > M)
LLaMA-3-8b	13.3% (Hispanic > Asian)	3.3% (M > F)

Studio aggiuntivo

Gli LLM assegnano colori stereotipici ai gruppi razziali nel codice Matplotlib generato, rivelando bias nascosti anche nel codice.

Conclusioni

- Nuova prospettiva sul bias: ragionamento sulla veridicità senza prompt sociali.
- Rilevanza della fairness nei task di ragionamento (educazione, valutazione).
- Necessità di ampliare il discorso sul bias oltre i test tradizionali.